



Razpoznavna prstnih sledi s pomočjo globokega učenja

Lara Anžur

Univerzitetni študijski program Računalništvo in informatika

Fakulteta za računalništvo in informatiko

Mentor: prof. dr. Peter Peer
Somentor: asist. Tim Oblak

Copyright: To delo je ponujeno pod licenco CC-BY-4.0.

Prstni odtisi so izjemno zanesljiv način identifikacije posameznikov v forenziki, saj so edinstveni in trajni. Klasične metode prepoznavne prstnih odtisov, ki uporabljajo strojno učenje, se pogosto soočajo z izzivi pri obdelavi nizkokakovostnih primerov, kar zahteva asistenco forenzikov. Vedno bolj priljubljena postaja uporaba globokega učenja, ki odpravlja nekatere od omejitev klasičnih metod, vendar je na tem področju še vedno razvitih premalo rešitev. V tej diplomski nalogi smo razvili model, ki temelji na siamskih nevronske mreže (SNN) v kombinaciji z arhitekturo ResNet34, kar nam je omogočilo učinkovito primerjavo prstnih sledi v latentnem prostoru. Osnovni model smo dodatno izboljšali z integracijo prostorskih transformatorskih mrež (STN), ki zagotavljajo rotacijsko invariantnost, ter z vključitvijo domenskega znanja o minucijah, s čimer smo v proces dodali dodatne relevantne informacije. Metode smo ovrednotili na več javno dostopnih podatkovnih zbirkah, pri čemer je naš model dosegel višjo stopnjo natančnosti v primerjavi z nekaterimi klasičnimi metodami, kar potrjuje tudi perspektivnost globokega učenja na področju identifikacije prstnih sledi.

iskanje ujemanj prstnih sledi | identifikacija | globoko učenje | siamske nevronske mreže | prostorske transformatorske mreže | trojna izguba

Prstni odtisi so izjemno zanesljiv način identifikacije posameznikov, saj so edinstveni in trajni [1, 2]. V sklopu forenzične preiskave ločimo med referenčnimi prstnimi odtisi (pridobljeni v nadzorovanem okolju) in prstnimi sledmi oz. latentnimi prstnimi odtisi (najdeni na kraju zločina). Prstne sledi so pogosto slabe kakovosti, delne, zamegljene in deformirane, kar močno oteži njihovo identifikacijo.

Kljub razvoju avtomatiziranih sistemov (AFIS) proces analize in identifikacije forenzičnih sledi pogosto zahteva ročno obravnavo preiskovalcev po metodologiji ACE-V (Analysis, Comparison, Evaluation and Verification) zaradi kompleksnosti problemov, kot so prisotnost šuma, različnih ozadij in nejasnih značilk, kot so minucije (konci in razcepi grebenov). Klasični pristopi, ki temeljijo na ročno določenih značilkah, se pogosto srečujejo s težavami pri slikah nizke kakovosti in pri velikih znotraj-razrednih variacijah. Zato uporaba naprednejših metod na podlagi strojnega učenja postaja nujna za izboljšanje uspešnosti AFIS sistemov na področju forenzične identifikacije prstnih sledi.

A. Motivacija. V zadnjem času so algoritmi globokega učenja postali vse bolj priljubljeni na področju prepoznavne prstnih odtisov. Za razliko od klasičnih pristopov, kjer se značilke izluščijo z uporabo vnaprej določenih metod, uporaba globokega učenja omogoča samodejno luščenje značilk iz podatkov z minimalno predobdelavo. Posledično se takšni algoritmi bolje prilagajajo biometričnim vzorcem, ki prihajajo iz nenadzorovanega okolja.

Kljub metodološkim napredkom pa na področju še vedno primanjkuje metod, ki bi neposredno naslovile razpoznavo prstnih sledi v forenziki. V ta namen so na letošnji konferenci IJCB (International Joint Conference on Biometrics) [3] organizatorji priredili tekmovanje z naslovom Latent in the Wild Fingerprint Recognition Competition [4]. Ta se je osredotočal predvsem na razpoznavo prstnih sledi, avtorji tekmovanja pa so objavili tudi novo podatkovno zbirko prstnih sledi LFIW.

Z namenom, da prispevamo k razvoju področja, smo se odločili, da se v sklopu te diplomske naloge udeležimo tekmovanja in skušamo razviti svojo metodo za razpoznavo prstnih sledi. Tekmovanja se je udeležilo šest ekip s celotnega sveta, od teh pa so le tri oddale rešitve, ki so dosegale merila tekmovanja. Naša ekipa je na tekmovanju zasedla tretje mesto, pred nami pa sta bili še dve ekipi, ki sta zastopali dva znana komercialna ponudnika programske opreme za razpoznavo prstnih sledi. Poleg metode, ki smo jo razvili za tekmovanje, ta diplomska naloga opisuje tudi kasnejše izboljšave našega pristopa. Članek s povzetkom in ugotovitvami tekmovanja [5] bo predvidoma objavljen septembra 2024.

B. Prispevek. V okviru diplomske naloge smo razvili algoritem za razpoznavo prstnih sledi, pri čemer smo za podlago uporabili globoko učenje. Naš cilj je bil pravilno identificirati prstno sled s kraja zločina glede na zbirko že znanih prstnih odtisov ter prstnih sledi. Za neko prstno sled smo v podatkovni zbirki poiskali referenčni prstni odtis, ki se je s prstno sledjo najbolj ujemal, in na podlagi tega določili identiteto posameznika.

Glavni prispevki naloge so naslednji:

- Osnovni model, s katerim smo sodelovali na tekmovanju LFIW Recognition Competition konference IJCB. Ta temelji na metodah globokega učenja, pri čemer smo

Fingerprint Recognition Using Deep Learning

Fingerprints are an extremely reliable method of identifying individuals in forensic science, as they are unique and permanent. Classical fingerprint recognition methods that use machine learning often face challenges when processing low-quality samples, which requires forensic experts' assistance. The use of deep learning, which overcomes some of the limitations of classical methods, is becoming increasingly popular, but there are still too few developed solutions in this field. In this thesis, we developed a model based on Siamese neural networks (SNN) combined with the ResNet34 architecture, enabling us to efficiently compare fingerprints in latent space. We further enhanced the basic model by integrating spatial transformer networks (STN), which ensure rotational invariance, and incorporating domain knowledge about minutiae, adding additional relevant information to the process. We evaluated the methods on several publicly available datasets, where our model achieved a higher level of accuracy compared to some classical methods, confirming the potential of deep learning in the field of fingerprint identification.

Fingerprint Matching | Identification | Deep Learning | Siamese Neural Networks | Spatial Transformer Network | Triplet Loss

navdih iskali na področju prepoznavne obrazov, kjer so algoritmi že precej bolj razviti kot na našem področju. Tako smo tudi prišli na idejo, da bi za podlago uporabili siamske nevronske mreže v kombinaciji s trojno izgubo.

2. Vse nadgradnje osnovnega modela, ki v obzir vzamejo značilnosti slik prstnih sledi. Tukaj se nanašamo predvsem na težave CNN z rotacijsko invariantno ter hkrati dodatno uporabo domenskega znanja, ki smo ga na različne načine dodatno pridobili iz vhodnih slik. Na ta način smo se bolj prilagodili obravnavanim podatkom.
3. Rezultate našega dela smo ovrednotili na javnih podatkovnih zbirkah z metrikami uspešnosti, ki so smiselne za vrednotenje problema identifikacije.

1. Pregled sorodnih del

Med obstoječimi rešitvami se za identifikacijo posameznika z uporabo prstnih sledi nekatere nagibajo v bolj klasično smer (luščenje značilk, uporaba strojnega učenja in iskalnikov ujemanja), spet druge, bolj moderne, pa se zatekajo k uporabi globokega učenja.

Med klasične rešitve štejemo programski paket NBIS [6], ki vključuje algoritem MIN-DTCT [7] za luščenje minucij ter BOZORTH3 [8] za ujemanje odtisov. Pomembna inovacija je bil pristop MCC (*angl.* Minutiae Cylinder-Code) [9], ki poleg globalne postavitev minucij upošteva lokalno strukturo (npr. bližnje grebene), kar poveča robustnost na translacijo in rotacijo. Kljub temu njihova uporaba na forenzičnih prstnih sledih ostaja omejena zaradi kompleksnosti podatkov in velike količine šuma.

Na področju prstnih sledi je bila predlagana rešitev MSU Latent AFIS [10, 11], ki samodejno izlušči regijo interesa in uporablja več komplementarnih postopkov za luščenje značilk (minucij in texture). V novejših raziskavah [12] so avtorji predlagali hibridni pristop, ki vključuje domensko znanje in globoko učenje. Mreža uporablja prostorsko transformatorsko mrežo (*angl.* spatial transformer network, STN) za odpravo težav rotacijske invariantnosti, nato pa v dveh vzporednih vejah zajame tako značilnosti texture kot fiksno dolžino reprezentacije minucij.

V praksi poleg odprtoko

2. Uporaba globokega učenja za razpoznavo prstnih sledi

Za razliko od klasičnih metod, globoko učenje omogoča neposredno učenje reprezentacij iz slik, kar poveča robustnost na popačenja, šum in kompleksna ozadja. V naši nalogi problem identifikacije obravnavamo v odprti množici (*angl.* open-set identification), kar pomeni, da iskana identiteta morda ni prisotna v podatkovni zbirki. Zato klasifikacija z metodo prečne entropije ni ustrezna. Namesto tega uporabljamo siamske nevronske mreže (SNN) [13–15].

Cilj SNN je učenje preslikave vhodnih slik v latentni prostor, kjer so primeri iste identitete blizu skupaj, primeri različnih identitet pa narazen. Za optimizacijo siamskih mrež se pogosto uporablja funkcija trojne izgube (*angl.* triplet loss) [16]:

$$L(a, p, n) = \max(\|f(a) - f(p)\|^2 - \|f(a) - f(n)\|^2 + m, 0), \quad (1)$$


kjer je a sidro, p pozitiven primer iste identitete, n negativen primer druge identitete, $f(x)$ označuje izhod mreže, m pa rob, ki določa minimalno razdaljo med paroma. Ključen dejavnik pri učenju s trojno izgubo je primerna izbira trojčkov; učenje je najbolj učinkovito, ko izbiramo t. i. težke trojčke, kjer mreža še vedno naredi napako.

Konvolucijske nevronske mreže (CNN) načeloma niso rotacijsko invariantne. Ta problem lahko rešimo z integracijo modula prostorsko transformatorske mreže (STN) [17]. STN mreži omogoča, da se aktivno in brez nadzora nauči prostorskih transformacij vhodne slike (npr. affine transformacije), kar pomaga pri poravnavi prstnih sledi pred nadaljnjim luščenjem značilk in izboljša identifikacijo rotiranih prstnih sledi. Gradient po x_i^s izračunamo kot:

$$\frac{\partial V_i^c}{\partial x_i^s} = \sum_{n=1}^H \sum_{m=1}^W \max(0, 1 - |y_i^s - n|) \cdot \begin{cases} 0 & \text{if } |m - x_i^s| \geq 1 \\ 1 & \text{if } m \geq x_i^s \\ -1 & \text{if } m < x_i^s \end{cases} \quad (2)$$

in analogno za y_i^s .

2.0.1. Razširitev za več kanalov. V prejšnjih podpoglavjih smo za lažjo predstavljivost delovanje razložili na vhodih z enim kanalom ($c = 1$). Postopek seveda deluje tudi za vhode z več kanali, in sicer je treba transformirati vsak kanal posebej, saj želimo ohraniti prostorsko konsistenco med kanali.



Slika 1. Struktura našega osnovnega globokega modela, ki uporablja SNN in trojno izgubo.

3. Metode

3.1. Arhitektura ResNet34. Za osnovno arhitekturo globokega modela smo uporabili ResNet34 [18], ki se je v literaturi [19] pokazal kot dober kompromis med hitrostjo in kompleksnostjo pri razpoznavi prstnih sledi. ResNet uvaja preskočne povezave (*angl.* skip connections), s katerimi se uspešno rešuje problem izginjajočih gradientov in se omogoča učenje precej globljih arhitektur. V našem primeru smo izhod ResNet34 spremenili tako, da zadnja polno povezana plast vrne iskani značilni vektor namesto verjetnosti razredov.

3.2. Implementacija osnovnega modela z uporabo ResNet34 in SNN. Čeprav je v forenzičnih podatkovnih zbirkah različnih identitet zelo veliko, se vseeno lahko zgodi, da zbirka za nekatere primerke še nima shranjene identitete. V kontekstu umetne inteligence to pomeni, da klasifikacija v posamične razrede v tem primeru ni najbolj smiselna rešitev, saj za novo najdeno identiteto še ne obstaja razred, model pa bi bilo treba ponovno natrenirati. Kot smo že omenili, se problemi take narave rešujejo z uporabo siamskih nevronske mreže, saj te delujejo glede na podobnost med vhodi in uporabljajo tudi temu primerne funkcije izgube.

Da bi razumeli strukturo našega modela, moramo najprej določiti funkcijo izgube. V našem primeru smo se odločili za uporabo trojne izgube, saj prejšnje ugotovitve [20] kažejo, da je kontrastna izguba bolj nagnjena k pretiranemu prilaganju (*angl.* overfitting) na vhodne podatke kot trojna, kar seveda ni optimalno za končno rešitev. Ker smo torej izbrali funkcijo trojne izgube, naš model na vходу prejme trojček slik, kjer ena od njih predstavlja sidro, drugi dve pa pozitiven in negativen primer.

V poglavju o siamskih nevronske mreže smo omenili tudi pomembnost selekcije trojčkov, saj si želimo sestaviti zahtevnejše trojčke, ki bodo prispevali k učinkovitejšemu učenju mreže. Naš pristop je bil naslednji: izmed vseh razpoložljivih identitet v množici smo naključno izbrali dve različni (sidro in pozitiven primer pripadata eni identiteti, negativen primer pa drugi). Za sidro in negativen primer smo izbrali naključna vzorca znotraj identitete, neodvisno od tega, ali ta predstavlja sled, odtis ali umetno generiran prstni odtis. Na drugi strani pri pozitivnih primerih v izbor nismo vključili referenčnih prstnih odtisov, saj bi to potencialno lahko vodilo k izbiri lahkega trojčka - če bi za sidro in pozitiven primer bili izbrani dve različni instanci pravega prstnega odtisa, bi si primera bila med seboj skoraj zagotovo bolj podobna kot pa negativnemu primeru, zaradi česar bi bil trojček preprost, to pa bi poslabšalo rezultate.

Struktura mreže je predstavljena na sliki 1. Za osnovni globoki model smo uporabili ResNet34, in sicer z že naučenimi utežmi. Naložen model je bil učen na barvnih slikah, mi pa smo uporabljali sivinske, zato smo morali število kanalov na prvi konvolucijski plasti zmanjšati iz 3 na 1, kar smo dosegli s povprečenjem uteži. Poleg tega smo modificirali tudi zadnjo, polno povezano plast, saj ta načeloma vrne razred, v katerega je model primer klasificiral, mi pa potrebujemo značilni vektor.

Ker so bili izhodni vektorji normirani na obod enotske hipersfere, je bila največja možna razdalja med njimi enaka dve, najmanjša pa 0. Razdaljo smo ne metriko podobnosti pretvorili z enačbo (3):

$$s = 1 - \frac{d}{2}. \quad (3)$$

kjer s predstavlja podobnost med vložitvama, d pa razdaljo med njima. Funkcija se nam je zdela ustrezna, saj je na ta način odvisnost med podobnostjo in razdaljo linearna.

3.3. Izboljšava s STN. Po pregledu celotne podatkovne zbirke smo spoznali, da rotacije nekaterih prstnih sledi ne ustrezajo rotacijam njihovih referenčnih prstnih odtisov, kar je

pripeljalo do razlik v napovedih. Iz tega razloga smo se odločili za integracijo modula STN v obstoječo arhitekturo mreže.

Implementirali smo ga z ločenim razredom, katerega objekt smo vključili na začetek mreže. Prvi del STN, torej njegovo lokalizacijsko mrežo, bi lahko strukturno definirali kot polno povezano ali pa konvolucijsko, mi pa smo se na podlagi rezultatov relevantnega članka [17] odločili, da je konvolucijska struktura ustrežnejša. Parameter θ smo inicializirali kot identitetno matriko velikosti 2×3 . Ob prehodu naprej (*angl.* forward pass) po mreži smo ob izhodu iz lokalizacijske mreže shranili vrednosti v θ , za tem pa izvedli še inverzno transformacijo, s čimer smo dobili vzorčno mrežo, ter nazadnje še vzorčili vrednosti slikovnih točk.


3.4. Upoštevanje domenskega znanja. V zadnjem delu smo obstoječi model poskušali še dodatno nadgraditi z vpeljavo domenske komponente. Zgradili smo konvolucijski model, ki na podlagi vhodne slike generira matriko verjetnosti za lokacije minucij. Modela znotraj implementacije nismo trenirali, temveč smo naučenega uporabljali za napovedi lokacij minucij na naših vhodih, s čimer smo želeli obogatiti vektorsko predstavitev posameznega vhoda in dodati relevantne informacije, ki bi morda izboljšale rezultat.

V nadaljevanju bomo najprej predstavili zgradbo modela za napoved minucij, zatem pa še dve različici implementacije z drugačnim načinom integracije prednaučenega modela v mrežo.

3.4.1. Model za iskanje minucij. Za izluščevanje domenskega znanja o minucijah smo uporabili prednaučeno nevronske mreže, ki temelji na arhitekturi U-Net [21]. Mreža s pomočjo sigmoidne funkcije na izhodu zgenerira matriko $p_m \in [0, 1]$, ki podaja verjetnost prisotnosti minucije na vsaki slikovni točki vhodne slike. Model za iskanje minucij smo predhodno naučili in njegove uteži v nadaljnjih eksperimentih zamrznili, kar pomeni, da je v našem cevovodu deloval le kot fiksni prediktor za ekstrakcijo značilk.

3.4.2. Zaporedna implementacija. V prvem poskusu smo implementacijo izvedli na nekoliko bolj zapleten način, in sicer smo novi model integrirali neposredno v glavno vejo naše mreže. Vhodno sliko smo najprej obdelali s STN, nato pa jo poslali skozi U-Net, ki je vrnil verjetnostno matriko za minucije na sliki.

Prejeti izhod smo združili s transformirano sliko tako, da je po novem vhod bil sestavljen iz dveh kanalov, tega pa smo poslali skozi izvorni globok model (ResNet34). Pri tem smo morali v kodi prilagoditi dimenzijo kanalov, saj je imel samo prvi kanal (kanal s sliko) prednaučeno utež. Na zaključnem izhodu smo tako dobili značilne vektorje za sidro, pozitiven in negativen primer. Med temi smo na enak način kot v predhodnih implementacijah izračunali razdalje ter izgubo. Struktura mreže je vidna na sliki 2.



Slika 2. Primerjava zaporedne (na levi) in vzporedne (na desni) implementacije.

3.4.3. Vzporedna implementacija. Po zgledu članka [12] smo se odločili za implementacijo, ki razdeli glavno vejo na dve vzporedni, kar poveča računsko učinkovitost. Enako kot pri zgornji implementaciji smo najprej izvedli transformacijo slike s STN, zatem pa smo mrežo razcepili na dve vzporedni veji.

V prvi veji smo uporabili našo strukturo U-Net za iskanje minucij, pri čemer smo tukaj izpustili del z dekodirnikom. Razlog je bil v tem, da smo kot izhod potrebovali značilni vektor, ne pa rekonstruirane slike. Po končni plasti kodirnika smo njegov izhod povprečili na eno vrednost, novemu izhodu pa odstranili odvečne dimenzije.

V sklopu druge veje smo sledili postopku, opisanemu v poglavju 3.2. Dobljena vektorja smo sprva normalizirali, ju nato združili v daljši vektor in ju nazadnje še enkrat normalizirali, s čimer smo pridobili izhod iz mreže. Računanje razdalj in funkcije izgube je potekalo na enak način kot v prejšnjih implementacijah. Strukturo mreže si lahko ogledamo na sliki 2.

4. Eksperimenti in rezultati

V prejšnjih poglavjih smo spoznali metode, ki jih bomo sedaj uporabili v eksperimentalnem delu diplomske naloge. Najprej bomo predstavili okolje, zatem podatkovne zbirke ter

obdelavo podatkov, nato pa bomo opisali še, na kakšen način smo algoritem implementirali in ga izboljševali.

4.1. Eksperimentalno okolje. Celotna implementacija diplomske naloge je bila napisana v programskem jeziku Python, ki s svojimi številnimi knjižnicami olajšuje delo na področju umetne inteligence. Modele smo razvijali v okolju PyTorch (2.3.0). Za potrebe učenja, evalvacije in testiranja smo uporabili grafično kartico NVIDIA GeForce RTX 3080 CUDA (12.1).

4.2. Podatkovne zbirke. Podatki, ki smo jih uporabili, so skupek naslednjih podatkovnih zbirk:

- NIST SD 302 (ter pripadajoča sintetično generirana zbirka),
- NIST SD 27,
- podatkovna zbirka tekmovanja LFIW.

Skupaj smo tako zbrali 4640 različnih identitet z več predstavitvami, med katerimi je bilo 48430 parov prstnih odtisov s pripadajočimi prstnimi sledmi.

Vsaka izmed podatkovnih zbirk je za posamezne primere imela svoj zapis, te pa smo za lažjo uporabo med seboj poenotili. Za shranjevanje poti do posameznih datotek smo uporabili slovar z naslednjo strukturo:

```
data = {
    "0000abbb_cd": {
        "latents": [ ... ],
        "references": [ ... ],
        "synthetic": [ ... ]
    },
    ...
}
```

kjer a predstavlja podatkovno zbirko (0 - LFIW, 1 - SD27, 2 - SD302, obe izvorna in sintetično generirana), bbb identifikacijsko številko osebe, cd pa identifikacijsko številko prsta, pri čemer $c = 0$ pomeni desna roka in $c = 5$ leva, d pa označuje prst s številom med 1 in 5 ($d = 1$ je palec itd.). To je torej ena identiteta v naši združeni podatkovni zbirki, ki je sestavljena iz identifikacijske številke osebe ter podrobnosti o pripadajočem prstu. Vsaka identiteta ima lahko tri tipe prstnih odtisov:

1. prstne sledi, označene kot "latents" : tukaj se nahajajo poti do prstnih sledi, ki ustrezajo identiteti v ključu,
2. referenčni prstni odtisi, označeni kot "references" : v seznamu so poti do prstnih odtisov s to identiteto,
3. ter sintetično generirani prstni odtisi, označeni kot "synthetic" , za katere imamo prav tako shranjene poti do zelenih datotek.

Ustvarjeni slovar smo shranili v datoteko tipa *.pkl*, ki smo jo v času učenja in evalvacije za pridobivanje podatkov uporabili v glavni programski kodi.

4.3. Razdelitev podatkov in predobdelava slik. Najprej smo identitete iz slovarja naključno razdelili v tri množice, in sicer učno, validacijsko in testno, pri čemer smo v testno vključili 10 % identitet, ki so vsebovale vsaj eno prstno sled in vsaj en referenčni prstni odtis, sintetično generiranih prstnih odtisov pa nismo vzeli v obzir. Kadar je bilo za identiteto mogoče izbrati več različnih parov, smo za referenčni prstni odtis vzeli prvo pojavitev iz seznama, med prstnimi sledmi pa izbrali sliko z najvišjo kakovostjo z uporabo ocenjevalca kakovosti. S tem smo dobili 209 parov, na podlagi katerih smo testirali učinkovitost modela. V nadaljevanju smo za vsak par (pravi ali nepravi) prstnega odtisa in prstne sledi izračunali evklidsko razdaljo med njunima vložitvama v latentnem prostoru. Izračunane vrednosti smo shranili v matriko velikosti 209×209 .

Izmed preostalih identitet smo jih 90 % namenili učenju, 10 % pa sprotni evalvaciji modela. Z uvedbo množice za evalvacijo smo zagotovili, da se naš model ni pretirano prilegal učnim podatkom.

V času učenja smo torej uporabljali le slovarja, ki sta vsebovala identitete učne ter evalvacijske množice. Identitetam pripadajoče podatke iz omenjenih množic smo shranili v dve podatkovni zbirki v obliki objekta *RecognitionDataset*, ki prejme naslednje parametre: pot do imenika s slikami, celotni slovar, izbrane identitete in logično vrednost, če želimo na podatkih izvesti transformacije ali ne. Za vsako izmed podatkovnih množic smo inicializirali generator iz knjižnice *torch.utils.data*, s katerim smo določili velikost paketa (*angl.* batch size), omogočili naključno urejanje identitet po vsaki epohi in nastavili parameter za paralelizacijo tako, da je ta omogočala šest hkratnih procesov.

Posamične slike smo znotraj *RecognitionDataset* objekta še nekoliko obdelali. Najprej smo sliko prebrali kot sivinsko, potem pa glede na vrednosti slikovnih točk na njej našli najmanjši možen očitni okvir (*angl.* bounding box) s pripadajočima ogliščema (zgornje levo in spodnje desno) ter dimenzijama za višino in širino pravokotnika. Sliko smo glede na pridobljeni okvir obrezali, da je ostal le relevanten del. Če slika ni imela kvadratne oblike, smo jo do pravilne dimenzije dopolnili z belimi slikovnimi točkami in ji spremenili velikost na 512×512 .

Med učenjem smo slike v učni množici dodatno obdelali z različnimi afinimi transformacijami, kot sta translacija in rotacija, hkrati pa tudi z barvnimi transformacijami, kjer smo spreminjali svetlost, kontrast ter nasičenost. Na ta način smo obogatili našo obstoječo zbirko podatkov z umetno ustvarjenimi primerki.

4.4. Metrike. Pri forenzičnih preiskavah je zelo pomembno, da za vhodno prstno sled najdemo v prvih nekaj prstnih odtisih z največjim ujemanjem. V našem primeru smo se odločili, da rezultat prikažemo za prvih 25 najbolj podobnih primerov, in sicer s krivuljo CMC (*angl.* cumulative matching characteristic). Uspešnost modelov smo poleg tega preverili še z grafom porazdelitev pravih in lažnih parov (*angl.* genuine-impostor distribution), kjer so lažni pari vsi možni pari referenčnega prstnega odtisa in prstne sledi z različnimi identitetama. Rezultate smo ocenili tudi glede na krivulji FNMR (*angl.* false non-match rate) in FMR (*angl.* false match rate), kjer prva predstavlja razmerje napačno klasificiranih pravih parov in druga razmerje napačno klasificiranih lažnih parov, oboje v odvisnosti od praga $t \in [0,1]$. Presečišče med omenjenima krivuljama je točka EER (*angl.* equal error rate), ki smo jo prav tako uporabili kot metriko za evalvacijo modelov. Nazadnje smo modele ovrednotili še z izrisom ROC krivulje in površine pod njo (*angl.* area under curve, AUC).

4.5. Rezultati. Med delom na diplomski nalogi smo preizkusili več različnih načinov za doseganje optimalnih rezultatov za ujemanje prstnih odtisov. V tem poglavju bomo predstavili rezultate nekaterih modelov in jih med seboj primerjali. Imena izbranih modelov s kratkim opisom so predstavljena v tabeli 1.

Ime modela	Opis modela
IJCB	začetni model, ki vključuje samo SNN in je bil uporabljen na tekmovanju
STN_conv	nadgradnja IJCB modela z vpeljavo prostorsko transformatorske mreže s konvolucijsko lokalizacijsko mrežo
Domain_1	dodatno domensko znanje v obliki verjetnostne mape minucij, implementirano v eni veji
Domain_2	dodatno domensko znanje v obliki verjetnostne mape minucij, implementirano v dveh vejah
Triplet_selection	nadgradnja z vzorčenjem srednje-težkih in težkih trojčkov

Tabela 1: Izbrani modeli, predstavljeni z imenom in opisom.


4.5.1. Model z implementacijo ResNet34 in SNN. Sprva smo implementirali osnovni model (v nadaljevanju model IJCB), predstavljen v poglavju 3.2. Model je z metriko CMC pri rangi 25 dosegel 22 % delež pravih identifikacij, kar pomeni, da je med prvimi 25 primeri odkril pravilno identiteto v 22 %.

Razlogov, zakaj model IJCB ne prispeva dobrih rezultatov, je lahko veliko. V prejšnjih poglavjih smo omenili, da CNN niso rotacijsko invariantni. Poleg tega poskušamo klasificirati na podlagi prstnih sledi in ne referenčnih prstnih odtisov, zaradi česar je veliko možnosti, da na rezultate vpliva slaba kakovost prstnih sledi. Oba razloga lahko vplivata na to, da model iz slike pridobi premalo informacij, da bi bila vektorska predstavitev reprezentativna za vhodno sliko. Omenjene težave smo poskušali nasloviti v nadaljnjih implementacijah.


4.5.2. Model z dodatkom STN. Najprej smo model IJCB poskušali izboljšati z dodatkom modula STN, ki naslovi problem rotacijske invariantnosti mreže (model poimenujmo STN_conv). Rezultati so pokazali, da se je vrednost CMC pri rangi 25 izboljšala iz 22 % na 32 %. Čeprav smo napredovali, bi si še vedno želeli višjo vrednost omenjene metrike. Vrednost AUC se je prav tako izboljšala iz 0.63 na 0.71.

Na sliki 3 je predstavljena porazdelitev pravih in nepravih parov. V primerjavi z modelom IJCB trenutni model občutno bolje ločuje med pravimi in lažnimi pari. Pravi pari so večinoma med vrednostma podobnosti 0.8 in 1, kar nam pove, da model zelo dobro klasificira pravilne pare. Tudi klasifikacija lažnih parov se je od začetnega modela precej izboljšala, saj na sredini osi x ni več velikega števila nepravih parov. Težava pa se pojavi v rdečih parih na skrajni desni strani grafa, kar nam pove, da model še vedno ne zna najbolje klasificirati lažnih parov.

Razlog je še vedno lahko slaba reprezentacija slike, povzročena s strani nizke kakovosti. Možnost sicer obstaja tudi v tem, da se model uči na premajhnem številu težkih trojčkov, zaradi česar se uteži ne posodablajo ustrezno.



Slika 3. Prikaz porazdelitev pravih in lažnih parov za model STN_conv.



(a) Prikaz porazdelitev pravih in lažnih parov za model Domain_1.

(b) Prikaz porazdelitev pravih in lažnih parov za model Domain_2.

Slika 4. Prikaz porazdelitev za model Domain_1 in Domain_2.

4.5.3. Model z dodatkom domenskega znanja - zaporedna in vzporedna implementacija. Ker smo menili, da model iz same slike dobi premalo informacij, smo se odločili, da dodamo še informacije o minucijah. To smo si zamislili na dva načina:


1. z zaporedno implementacijo: ResNet34 bo poleg slike, transformirane s STN, na vходу prejel še verjetnostno matriko minucij,
2. z vzporedno implementacijo: mrežo bomo razdelili na dve veji, kjer bomo iz ene dobili predstavni vektor iz ResNet-a, iz druge pa vektor s predstavitvijo minucij, ta pa bomo med seboj združili.

Pri tem smo obdržali modul STN, saj je ta predhodno vseeno pripomogel k izboljšanju rezultata.

Obe implementaciji (imenujmo prvo Domain_1 in drugo Domain_2) sta bili na podlagi rezultatov boljši od predhodnih dveh modelov. Domain_1 je za CMC pri rangi 25 dosegla vrednost 0.34, Domain_2 pa 0.37. Pri krivulji ROC in AUC pa je bil boljši model Domain_1 z vrednostjo 0.80, medtem ko je model Domain_2 dosegel vrednost 0.76.

Na slikah 4a in 4b si lahko ogledamo porazdelitve pravih in lažnih parov. V primeru Domain_1 glede na frekvenco lahko vidimo, da se je število lažnih parov v desnem delu grafa precej zmanjšalo od prejšnjega najboljšega modela. V levem delu se je distribucija nepravilnih parov razdelila na dva vrhova, kar ni idealno, bi pa lahko pomenilo, da najbolj levi vrh rdeče predstavlja enostavne trojčke, srednji srednje-težke trojčke in desni, ki še vedno ostaja na desnem delu grafa, težke trojčke. Pri Domain_2 sicer na levi strani ne vidimo dveh vrhov, je pa po drugi strani opazno, da se morda model ni učil dovolj epoh, saj se vse vrednosti podobnosti nahajajo med približno 0.3 in 0.9.

Po tem koraku so vsi zaključki kazali na to, da bo potrebna implementacija, ki bo bolj strogo izbirala trojčke za učenje in evalvacijo.



Slika 5. Prikaz porazdelitev pravih in lažnih parov za model Triplet_selection.

4.5.4. Izbor težkih trojčkov. V sklopu modela Triplet_selection smo kot nadgradnjo uvedli strožjo selekcijo trojčkov, kjer smo za podlago vzeli vzporedno implementacijo iz prejšnjega poglavja, saj se nam je ta zdela bolj perspektivna. Izbor smo implementirali na ravni paketa, kjer smo znotraj njega najprej izračunali pare pozitivnih razdalj, tj. pare razdalj med pozitivnimi primeri in sidri. Zatem smo za vsakega izmed negativnih primerov v paketu izračunali razdalje do sider (negativne razdalje). Glede na izračunane pozitivne in negativne razdalje smo ugotovili, kateri negativni primeri v kombinaciji z danim pozitivnim primerom in sidrom sestavijo težak trojček in kateri srednje-težkega. V času učenja smo tako naključno izbirali med uporabo težkih in srednje-težkih trojčkov. Kadar v paketu ni bilo na voljo nobenega izmed navedenih tipov trojčkov, smo uporabili naključnega.

Rezultati predstavljenega pristopa so na sliki 5 prikazani s porazdelitvijo pravih in lažnih parov. Tukaj je distribucija parov precej podobna tisti iz Domain_1, le da so oboji primeri na desni strani bolj strnjeni.

Malo slabši je bil rezultat krivulje CMC, in sicer z vrednostjo 0.33. Površina pod krivuljo ROC znaša 0.79, kar je ponovno podobno kot domenski model z zaporedno implementacijo. Glede na vse preizkušene metrike sta si modela med seboj zelo podobna, Domain_1 je malenkost boljši. V nadaljnjih eksperimentih bi lahko preizkusili tudi, kako se obnaša kombinacija primerjanih modelov.


Ker je enak del parov kljub uvedbi težji trojčkov še vedno ostal na desni strani grafa, lahko sklepamo, da je težava nekje drugje. Eno od pojasnil bi recimo lahko bilo, da se model uči na nekem deležu podatkov s slabo kakovostjo, ki kvari splošen rezultat modela.

4.5.5. Medsebojna primerjava modelov. Modele bomo sedaj ovrednotili še vzporedno. Začeli bomo z metrikama, katerih vrednosti smo komentirali že znotraj predstavitve rezultatov posameznih modelov, to sta CMC in ROC s pripadajočimi AUC.


Krivulja CMC na sliki 6a prikazuje delež pravih identifikacij v odvisnosti od ranga. Trendi vseh krivulj so si med seboj precej podobni, le strmina modela IJCB je bolj položna od drugih. Pri rangu 25 je torej najboljši model Domain_2, sledijo mu Domain_1, Triplet_selection in STN_conv, nazadnje pa še model IJCB. Delež pravih identifikacij pri prvem rangu je za vse modele zelo majhen, kar nam pove, da se pravilna identiteta le redko pojavi na prvem mestu po podobnosti z vhodnim prstnim odtisom. Za uporabnost forenzikom bi morala biti vrednost deleža pri našem zadnjem rangu precej višja.

Nadaljujmo s krivuljo ROC ter površino pod njo (rezultati so prikazani na sliki 6b).

Rezultate lahko ovrednotimo na podlagi oblike krivulje ROC. Po literaturi je najbolj zaželeno, da se krivulja ukrivi proti točki (0,1), saj s tem posledično doseže tudi največjo površino pod krivuljo. V našem primeru lahko vidimo, da se nobena od krivulj ne ukrivi najbolj v levi zgornji kot. Ponovno od preostalih odstopa krivulja IJCB, ki je vsaj v desnem delu grafa spuščena precej nižje od preostalih krivulj, kar nakazuje na slabšo klasifikacijo. Tudi vrednost AUC je precej nižja od preostalih modelov. Modeli STN_conv, Domain_1, Domain_2 in Triplet_selection imajo krivulje podobnih oblik,




(a) Prikaz krivulj CMC za vse modele.



(b) Prikaz krivulj ROC s pripadajočimi AUC za vse modele.

Slika 6. Prikaz krivulj CMC in ROC za vse modele.



Slika 7. Prikaz izrisa krivulj FNMR in FMR za delež primeru v odvisnosti od praga. Krivulji se sekata v presečišču EER.

najnižja ima hkrati tudi najmanjšo vrednost AUC, najvišja pa največjo. Kljub temu pa vsi modeli vsebujejo veliko lažno pozitivnih parov, zaradi česar pride do pomanjkanja zelene krivine v levem zgornjem kotu.


Naslednje bomo rezultate ocenili z metriko, ki je do zdaj še nismo uporabili - to bo vrednost EER, za katero želimo, da je čim bližja 0. Kot rečeno gre za presečišče med krivuljama FNMR in FMR, kjer prva predstavlja delež pravih parov, ki so bili klasificirani kot napačni (ekvivaletno pomeni FN, *angl.* false negative), druga pa predstavlja lažne pare, ki so bili klasificirani kot pravilni (ekvivaletno metriki FP, *angl.* false positive).

Glede na rezultate lahko potrdimo, da model IJCB z vrednostjo 0.44 najslabše klasificira prstne sledi. Sledi mu STN_conv s 0.37, temu pa Domain_2 z 0.32 ter Triplet_selection z 0.31 in nazadnje Domain_1 z 0.30, kar je tudi najboljši rezultat.


Sodeč po predhodnih ugotovitvah lahko sklepamo, da je za takšno vrednost EER odgovorna krivulja FMR, ki slabo klasificira lažne pare (spomnimo se rdečih vrhov v distribuciji pravih in lažnih parov na desni strani grafov modelov). Za ilustracijo bomo za model z najnižjo vrednostjo EER prikazali na sliki 7. Naša domneva se izkaže za pravilno, saj je oblika krivulje FNMR podobna kot v literaturi in je tudi zaželeno v dobrih modelih. Na drugi strani pa oblika modre krivulje, ki je na sredini vodoravna, namesto da bi se po osi y spuščala proti 0, pove, da ima model še možnosti izboljšav na področju napačno pozitivnih primerov.

Na podlagi vseh dosedanjih rezultatov, kot npr. vrednosti CMC, AUC, porazdelitve lažnih in pravih parov, lahko zaključimo, da je naš najboljši model Domain_1, saj ta zelo dobro klasificira prave pare, neprave pa tudi najboljše od vseh preostalih. Rezultatsko mu je zelo blizu tudi model Triplet_selection.

4.5.6. Zaključni eksperimenti. V zadnjem delu eksperimentov smo poskušali še nekatere druge lastnosti naših modelov. Naša prva ideja je bila, da je lahko za nastali rezultat večinsko odgovorna le ena izmed podatkovnih zbirk. Na sliki 8 lahko vidimo prispevke



Slika 8. Prikaz prispevkov posameznih podatkovnih baz h končnemu rezultatu v obliki porazdelitev pravih in nepravih parov.



Slika 9. Na slikah so po vrsticah predstavljeni pari referenčnih prstnih odtisov in prstnih sledi iz različnih podatkovnih zbirk (LFIW, SD27, SD302; v tem vrstnem redu). Na levi strani so predstavljeni pari, kjer sta si primera v paru glede na podobnost najbližja, kar pomeni rang 1 na krivulji CMC. Na desni strani pa prikazujemo pare, kjer referenčni prstni odtis ni najden med prvimi 20 najbolj podobnimi primeri iz zbirke, čeprav gre za pravi par.

posameznih podatkovnih zbirk h končnemu rezultatu. Opazimo, da največji delež napačno klasificiranih nepravih parov prispeva baza SD302. Ta je že sicer znana po tem, da vsebuje veliko nizko kakovostnih prstnih sledi, kar je morda prispevalo k slabšemu rezultatu. Možnost je tudi v tem, da sintetično generirani prstni odtisi zaradi neuravnoteženosti razredov slabo vplivajo na končni rezultat, za kar pa nismo naredili eksperimentov.

Izbrani model bomo ovrednotili še na kvalitativen način, in sicer s prikazom slik (gl. sliko 9). Najprej sta po vrsticah predstavljena po dva para podatkovnih zbirk LFIW, SD27 in SD302 (v tem vrstnem redu). Na levi strani so pari, ki so bili na krivulji CMC rangirani z rangom 1, na desni pa pari, za katere je bil rang večji od 20.

Če si malo ogledamo slike, opazimo, da so levi pari precej kakovostnejši od desnih - vsaj v pomenu prstnih sledi. Njihove slike so kvadratne oblike ali pa vsebujejo celotno prstno sled. V primerjavi z njimi so prstne sledi na desni strani ne najbolj kakovostne (neizostrene), na njih je težavno najti regijo interesa, zadnji primer pa je precej nenavadne oblike in ni zajet v celoti. Tudi iz kvalitativnih rezultatov tako lahko vidimo, da je najverjetneje težava v kakovosti prstnih sledi, kot smo že prej ugotovili, je tukaj najbolj problematična baza SD302.

Nazadnje bomo naredili še primerjavo rezultatov najboljšega modela z rezultati modelov iz tekmovanja. Tukaj omenimo, da so bili podatki na tekmovanju testirani s skrito množico podatkovne zbirke LFIW, mi pa smo svoje modele ovrednotili s kombinacijo podatkovnih zbirk, na katerih smo modele tudi trenirali (seveda smo pri tem uporabili ločene identitete). V naši testni množici je bilo namreč premalo primerov podatkovne

zbirke LFIW, da bi bili rezultati zanesljivi.

V tabeli 2 so prikazani rezultati modelov iz tekmovanja, kjer prve tri vrstice predstavljajo neke že znane metode, s katerimi so bili modeli na tekmovanju primerjani (od teh smo v poglavju 1 omenili MCC in Latent AFIS, tretjo pa razvija komercialni ponudnik). V naslednji treh vrsticah so predstavljeni rezultati treh najboljših modelov na tekmovanju, med katerimi je bil tudi naš, v zadnji vrstici pa so za primerjavo dodani rezultati našega končnega najboljšega modela. Vrednostim metrik iz tekmovanja smo za večjo preglednost poenotili število decimalnih mest.

	AUC	EER	FTER [%]
MSU-AFIS	0.57	0.48	7.7
MCC	0.75	0.32	36.7
VeriFinger_12.3	0.81	0.27	40.8
VeriFinger_13.1	0.85	0.23	6.2
LatentMinuComp_v0	0.79	0.29	2.2
IJCB	0.55	0.48	0.0
Končni model	0.80	0.30	0.0

Tabela 2: Primerjava metrik iz tekmovanja.

V prvem stolpcu so predstavljene vrednosti AUC. Naš začetni model je od vseh dosegel najnižjo vrednost, ki znaša 0.55, končni pa bi se z vrednostjo 0.80 uvrstil na tretje mesto, takoj za rešitvijo VeriFinger_12.3. Naš model je na tekmovanju za EER dosegel vrednost 0.48, kar je enak rezultat kot MSU-AFIS. Z uporabo različnih izboljšav smo EER zmanjšali na 0.30, kar bi nas med tekmovalce še vedno uvrstilo kot tretje, bi se pa drugemu mestu zelo približali. Na tekmovanju so sicer testirali še eno metriko, in sicer FTER (*angl.* failure to enroll rate), ki nam pove, koliko primerov je bilo iz različnih razlogov (navadno je to nizka kakovost) zavrnjenih že na vhodu. Od tega sta naša modela bila edina, ki sta v učenje vključila vse vzorce, kar ju je naredilo robustna na vse vhode. Po drugi strani pa so lahko vključeni latentni prstni odtisi z nizko kakovostjo slabo vplivali na končni rezultat naših modelov.

Po rezultatih sodeč nam je z dodatnimi izboljšavami uspelo precej izboljšati osnovni model in hkrati doseči boljše rezultate od standardnih metod. Ponovno pa moramo poudariti, da rezultati niso bili pridobljeni na enakih množicah, in bi za neposredno primerjavo potrebovali temeljitejšo evalvacijo.

5. Zaključek

V sklopu diplomske naloge smo razvili nov pristop za identifikacijo prstnih sledi, ki v ozadju uporablja globoko učenje. Naš začetni model smo implementirali kot siamsko nevronske mreže, ki v svoji arhitekturi uporablja ResNet34. Z začetnim modelom smo se udeležili tudi tekmovanja v identifikaciji prstnih sledi na mednarodni biometrični konferenci IJCB. Kljub temu da je rešitev predstavljala le začetno idejo, smo na koncu dosegli tretje mesto. Osnovno rešitev smo nato nadgradili še z dodatkom prostorske transformatorske mreže, domenskega znanja in nekaterih drugih "nearhitekturnih" izboljšav.

Naš najboljši model za rang 25 na krivulji CMC dosegel rezultat 0.34, kar pomeni, da je model v 34 % našel pravo identiteto za vhodno prstno sled med 25 najbolj podobnimi primeri iz referenčne podatkovne zbirke. V sklopu ROC krivulje je dosegel vrednost AUC 0.80, za EER pa 0.30. V vseh naštetih metrikah je precej napredoval od osnovnega modela. Čeprav je bil rezultat modela boljši od tistih, ki za ujemanje uporabljajo klasične metode, je težava še vedno ostala pri številu lažno pozitivnih primerov, zaradi česar menimo, da so v potencialnem nadaljnjem razvoju rešitve mogoče izboljšave. Prva bi bila npr. filtriranje podatkov na vhodu s pomočjo ocenjevalca kakovosti prstnih sledi, saj bi tako iz učenja odstranili primere, ki ne prispevajo, ali pa celo negativno prispevajo k učenju modela. S tem pristopom bi lahko zmanjšali število lažno pozitivnih pojavitev v identifikaciji.

Obravnave nizkokakovostnih prstnih sledi bi se sicer lahko lotili tudi na drugačen način. Nekatere podatkovne baze ponujajo že izluščene podatke o minucijah. Z vključitvijo teh podatkov bi se lahko izognili negativnemu prispevku nizkokakovostnih slik prstnih sledi. Druga možna izboljšava bi lahko bila tudi uporaba kosinusne razdalje v funkciji izgube (trojna izguba), kjer smo do zdaj uporabljali evklidsko razdaljo. Ta bi morda bolje zajela razmerje med vzorci v latentnem prostoru. Lahko bi poskusili tudi z manipulacijo roba v enaki funkciji izgube, saj je mogoče, da model nekaterih lažnih parov v latentnem prostoru ni "potisnil" dovolj narazen in je zato posledično prišlo do napačne klasifikacije. Kljub napredku torej še vedno obstajajo možnosti za optimizacije, ki bi povečale učinkovitost modelov. Prihodnje raziskave bodo ključnega pomena za nadaljnji razvoj ter uspešno vpeljavo metod globokega učenja v prakso na forenzičnem področju.

ZAHVALA. Zahvaljujem se mentorju prof. dr. Petru Peeru za priložnost in vključitev v ekipo na tekmovanju, ki je zame predstavljalo pomembno izkušnjo. Posebej rada bi se zahvalila asist. Timu Oblaku za vse razlage, potrpežljivost in pomoč pri delu na diplomski nalogi. Nazadnje se zahvaljujem še družini in prijateljem, ki so me podpirali pri menjavi študija, in me spodbujali pri novem.

Literatura

1. Maltoni D, Maio D, Jain AK, Prabhakar S (2009) *Handbook of Fingerprint Recognition, 2nd edition*. (Springer Science & Business Media).
2. of Justice UD (2014) *The Fingerprint Sourcebook*. (CreateSpace Independent Publishing Platform).
3. (2024) *IEEE International Joint Conference on Biometrics* (<https://ijcb2024.ieee-biometrics.org/>). [Dostop: 29. avgust 2024].
4. K. Raja XL, Wang R (2024) Latent in the wild fingerprint recognition competition (2024 IEEE International Joint Conference on Biometrics (IJCB)). <https://sites.google.com/view/ijcb-latentinthewild-2024>. [Dostop: 18. avgust 2024].
5. Liu X et al. (2024) Latent in the wild fingerprint recognition competition in *Proceedings of the IEEE International Joint Conference on Biometrics*. Sprejeto v objavo.
6. Ko K (2007) User's guide to nist biometric image software (nbis), (National Institute of Standards and Technology, Gaithersburg, MD), Technical report.
7. Alonso-Fernandez F (2008) Doktorska disertacija (Universidad Politecnica de Madrid).
8. Ko K (2007) User's guide to export controlled distribution of nist biometric image software (nbis-ec), (National Institute of Standards and Technology, Gaithersburg, MD), Technical report.
9. Cappelli R, Ferrara M, Maltoni D (2010) Minutia cylinder-code: A new representation and matching technique for fingerprint recognition. *IEEE transactions on pattern analysis and machine intelligence* 32:2128–2141.
10. Cao K, Nguyen D, Tymoszek C, Jain AK (2019) End-to-end latent fingerprint search. *IEEE Transactions on Information Forensics and Security* 15:880–894.
11. Cao K, Jain AK (2019) Automated latent fingerprint recognition. *IEEE transactions on pattern analysis and machine intelligence* 41(4):788–800.
12. Engelsma JJ, Cao K, Jain AK (2021) Learning a fixed-length fingerprint representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 43(6):1981–1997.
13. Koch G, Zemel R, Salakhutdinov R, et al. (2015) Siamese neural networks for one-shot image recognition in *ICML deep learning workshop*. (Lille, France), pp. 1–30.
14. Chicco D (2021) *Siamese Neural Networks: An Overview*. (Springer US), pp. 73–94.
15. Bruballa RG (2024) Implementing content-based image retrieval with siamese networks in pytorch (Neptune Labs. <https://neptune.ai/blog/content-based-image-retrieval-with-siamese-networks>). [Dostop: 12. avgust 2024].
16. Schroff F, Kalenichenko D, Philbin J (2015) Facenet: A unified embedding for face recognition and clustering in *IEEE Conference on Computer Vision and Pattern Recognition*. pp. 815–823.
17. Jaderberg M, Simonyan K, Zisserman A, et al. (2015) Spatial transformer networks in *Advances in Neural Information Processing Systems*. (Curran Associates, Inc.), Vol. 28.
18. He K, Zhang X, Ren S, Sun J (2016) Deep residual learning for image recognition in *Proceedings of the IEEE conference on computer vision and pattern recognition*. pp. 770–778.
19. Oblak T, Haraksim R, Beslay L, Peer P (2023) Probabilistic fingermark quality assessment with quality region localisation. *Sensors* 23(8).
20. Gupta P (2020) Illustrated guide to siamese network (Medium. <https://towardsdatascience.com/illustrated-guide-to-siamese-network-3939da1b0c9d>). [Dostop: 16. avgust 2024].
21. Ronneberger O, Fischer P, Brox T (2015) U-net: Convolutional networks for biomedical image segmentation in *Conference on Medical image computing and computer-assisted intervention*. (Springer), pp. 234–241.