



Optimizacija portfelja z uporabo transformerjev in globalnih optimizacijskih algoritmov

Nejc Skrbec

Magistrski študijski program Računalništvo in informatika, smer Računalništvo in informatika

Fakulteta za računalništvo in informatiko

Mentor: doc. dr. Luka Fürst

Copyright: To delo je ponujeno pod licenco CC-BY-4.0.

Optimizacija naložbenega portfelja je klasičen in hkrati zahteven optimizacijski problem. Iskanje idealnega razmerja med pričakovanim donosom in tveganjem otežujeta predvsem nezanesljiva napoved prihodnjih donosov ter vpeljava kardinalne omejitve glede števila izbranih sredstev v portfelju. V tem magistrskem delu predstavljamo celovit cevovod, ki se obeh izzivov loti sistematično in ločeno. Pričakovane donose μ napovedujemo s pomočjo treh raznolikih transformerskih arhitektur (TACTIS-2, MASTER in TFT), katerih napovedi zaradi večje robustnosti sproti in prilagodljivo združujemo v ansambelski model s postopkom Hedge. Za napovedovanje matrike tveganja Σ uporabimo verjetnostni model TACTIS-2 ali zgodovinsko kovarianco. Iskanje optimalnih uteži ob striktni kardinalni omejitvi rešujemo z dvema globalnima optimizacijskima algoritmoma (rojenje delcev in simulirano ohlajanje). Razviti sistem smo strogo ovrednotili s postopnim (walk-forward) testiranjem skozi šest raznolikih tržnih režimov. Izkazalo se je, da je transformerski cevovod edini vir napovedi s pozitivno napovedno močjo zunaj vzorca, ki dosega visoke ocene uspešnosti (letni Sharpe količnik 0,97). Kljub temu pa statistični testi razkrivajo, da ostaja njegova prednost v primerjavi s klasičnimi preteklimi povprečji razmeroma tesna.

Optimizacija portfelja | Mean-variance | Kardinalna omejitev | Presečni transformer | Napovedovanje donosov | Kombinacija napovedi | Metahevrstike | Rojenje delcev | Simulirano ohlajanje

Problem optimizacije naložbenega portfelja (v nadaljevanju ONP) predstavlja enega temeljnih problemov kvantitativnih financ. Cilj reševanja tega problema je razporediti razpoložljivi kapital med več finančnih sredstev, pri čemer želimo dosežati čim večji donos pri čim manjšem tveganju.

Obravnavamo trg z N finančnimi sredstvi, ki jih spremljamo v diskretnih časovnih korakih $t = 0, 1, \dots, T$. Naj bo $p_{i,t} > 0$ prilagojena zaključna cena sredstva i ob času t . Enostavni $r_{i,t}$ in logaritemski $\tilde{r}_{i,t}$ donos sredstva definiramo z enačbo (1). Logaritemski donosi so priročni pri modeliranju, ker se skozi zaporedna obdobja seštevajo, enostavni donosi pa so neposredno uporabni pri vrednotenju realiziranega donosa portfelja.

$$r_{i,t} = \frac{p_{i,t} - p_{i,t-1}}{p_{i,t-1}} = \frac{p_{i,t}}{p_{i,t-1}} - 1, \quad \tilde{r}_{i,t} = \ln \left(\frac{p_{i,t}}{p_{i,t-1}} \right). \quad (1)$$

Donose vseh sredstev v času t zberemo v vektor $\mathbf{r}_t = (r_{1,t}, \dots, r_{N,t})^\top$. Portfelj opišemo z vektorjem uteži $\mathbf{w} = (w_1, \dots, w_N)^\top$, kjer w_i predstavlja delež kapitala v sredstvu i . Donos portfelja je podan z enačbo (2):

$$r_t^p = \mathbf{w}^\top \mathbf{r}_t. \quad (2)$$

Klasično izhodišče za reševanje ONP predstavlja Markowitzev model [1]. Ta portfelj optimizira na podlagi dveh informacij: pričakovanih donosov posameznih sredstev in njihovega medsebojnega tveganja. Prvo opišemo z vektorjem pričakovanih donosov μ , drugo pa s kovariančno matriko Σ . Obe količini definiramo z enačbo (3):

$$\mu = \mathbb{E}[\mathbf{r}], \quad \Sigma = \mathbb{E}[(\mathbf{r} - \mu)(\mathbf{r} - \mu)^\top]. \quad (3)$$

Če bi poznali prihodnje vrednosti obeh teh količin, bi bil osnovni optimizacijski problem razmeroma enostaven. V praksi pa jih ne poznamo in jih moramo oceniti, zato v nadaljevanju uporabljamo njuni oceni $\hat{\mu}$ in $\hat{\Sigma}$. V klasičnih praktičnih pristopih se pričakovani donosi in kovariančna matrika pogosto ocenijo iz zgodovinskih donosov. Preteklo povprečje donosov pa ni nujno dobra napoved prihodnosti, saj preteklo vedenje nekega finančnega sredstva ni vedno dober pokazatelj prihodnosti. Podobno se lahko skozi čas spreminjajo tudi volatilnosti in povezave med sredstvi, zato je lahko nezanesljiva tudi ocena kovariance, ki temelji zgolj na zgodovinskih vrednostih. Nenatančno ocenjeni pričakovani donosi in kovariančna matrika lahko zato vodijo do neugodnega portfelja, tudi če sam optimizacijski postopek deluje pravilno.

Portfolio optimization using transformers and global optimization algorithms

Constructing an investment portfolio is a classical optimization problem: Markowitz's trade-off between return and risk is hampered by the unreliable estimation of expected returns and by the cardinality constraint on the number of held assets, which turns the task into an NP-hard mixed-integer problem. We present a hybrid pipeline that addresses both separately: the return moments μ and Σ are estimated by three off-the-shelf transformers (TACTIS-2, MASTER and TFT) whose forecasts are combined online with the historical mean through the Hedge rule as a robustness layer, and the cardinality-constrained mean-variance problem is solved by three C++ metaheuristics. The pipeline is evaluated by walk-forward testing across six market regimes. The transformer pipeline is the only forecast source with positive out-of-sample predictive power and the only strategy to survive a selection-adjusted (deflated) Sharpe-ratio test (annual Sharpe 0.97), though its advantage over the plain historical mean remains statistically marginal.

Portfolio optimization | Mean-variance | Cardinality constraint | Cross-sectional transformer | Return forecasting | Forecast combination | Metaheuristics | Particle swarm optimization | Simulated annealing

V tem delu zato preverjamo, ali lahko vhodne ocene izboljšamo s sodobnimi napovednimi modeli. Uporabimo tri različne transformerske arhitekture. TFT [2] je namenjen napovedovanju časovnih vrst prek več prihodnjih korakov, MASTER [3] pri napovedovanju upošteva tudi povezave med različnimi delnicami, TACTiS-2 [4] pa napove skupno verjetnostno porazdelitev več časovnih vrst. Iz slednje lahko z vzorčenjem ocenimo tako prihodnje pričakovane donose kot njihovo kovariančno matriko. Napovedi primerjamo s preprostejšimi zgodovinskimi ocenami in s tem preverimo, ali naprednejši model dejansko zagotovi uporabnejše informacije za sestavo portfelja.

Drugi pomemben problem se pojavi pri določitvi uteži w . Osnovni Markowitzev model lahko kapital razporedi med veliko število sredstev, tudi tako, da v nekatera vloži le zelo majhen delež. To pomeni, da morajo biti vse vrednosti uteži w neničelne. Takšen portfelj je v praksi pogosto nezaželen zaradi transakcijskih stroškov, zahtevnosti upravljanja in omejitev glede velikosti posameznih pozicij. Zato v našem delu zahtevamo, da portfelj vsebuje natanko K izbranih sredstev, njihove uteži pa so omejene s spodnjo in zgornjo mejo. S tem dobimo kardinalno omejeni ONP [5].

Denimo, da za vsako sredstvo uvedemo binarno spremenljivko $z_i \in \{0, 1\}$, kjer $z_i = 1$ pomeni, da je sredstvo vključeno v portfelj. Kardinalno omejeni ONP zapišemo s ciljno funkcijo v enačbi (4) in omejitvami (5)–(7). Ciljna funkcija (4) združuje ocenjeni pričakovani donos portfelja $\hat{\mu}^\top \mathbf{w}$ in njegovo ocenjeno varianco $\mathbf{w}^\top \hat{\Sigma} \mathbf{w}$. Parameter $P \in [0, 1]$ določa relativni poudarek med obema členoma: večji P poveča pomen pričakovanega donosa, manjši P pa pomen zmanjševanja variance. Proračunska omejitev (5) zahteva popolno razporeditev kapitala, kardinalna omejitev (6) natanko K aktivnih pozicij, omejitev (7) pa spodnjo in zgornjo dovoljeno utež posameznega izbranega sredstva. Če je $z_i = 0$, sledi $w_i = 0$, če je $z_i = 1$, pa mora veljati $\varepsilon_i \leq w_i \leq \delta_i$.

$$\max_{\mathbf{w}, \mathbf{z}} \quad P \hat{\mu}^\top \mathbf{w} - (1 - P) \mathbf{w}^\top \hat{\Sigma} \mathbf{w} \quad (4)$$

$$\text{p.p.} \quad \sum_{i=1}^N w_i = 1, \quad (5)$$

$$\sum_{i=1}^N z_i = K, \quad (6)$$

$$\varepsilon_i z_i \leq w_i \leq \delta_i z_i, \quad z_i \in \{0, 1\}, \quad i = 1, \dots, N. \quad (7)$$

Opazimo lahko, da že izbor K sredstev izmed N omogoča $\binom{N}{K}$ različnih kombinacij sredstev v portfelju. Kardinalna omejitev tako v zvezni optimizacijski problem uvede kombinatorično izbiro. Kardinalno omejena optimizacija pričakovanega donosa in variance je v splošnem računsko zelo zahtevna [5], saj bi pri izčrpnem iskanju bi morali obravnavati vseh $\binom{N}{K}$ možnih podmnožic sredstev in za vsako še določiti optimalne uteži. Že kombinatorični del izčrpnega postopka ima zato zahtevnost $O\left(\binom{N}{K}\right)$. Če K raste skupaj z N , število kombinacij hitro raste eksponentno, zato izčrпно iskanje postane nepraktično.

V delu zato preučujemo dva uveljavljena globalne optimizacijska pristopa za reševanje kardinalnega problema: rojenje delcev (v nadaljevanju RD) in simulirano ohlajanje (v nadaljevanju SO). Glavni cilj magistrskega dela je združiti koraka ocenjevanja vhodnih vrednosti ter optimizacije v enoten postopek. V prvem delu ocenimo prihodnje pričakovane donose in kovariančno matriko, v drugem pa iz teh ocen sestavimo kardinalno omejeni portfelj.

Oba dela preverjamo ločeno, saj lahko tako ugotovimo, ali morebitna izboljšava končnega rezultata izvira iz boljših napovedi, iz boljšega optimizacijskega postopka ali iz njune kombinacije. Posebno pozornost namenjamo vrednotenju zunaj vzorca. Kakovost optimizacijskih algoritmov najprej neodvisno preverimo na standardnih testnih problemih. Celoten postopek nato ovrednotimo s postopnim (angl. *walk-forward*) testiranjem skozi šest različnih tržnih režimov, pri čemer ima model v vsakem trenutku dostop samo do podatkov, ki bi bili takrat dejansko na voljo. Rezultate primerjamo z več klasičnimi in sodobnimi referenčnimi strategijami, njihovo statistično zanesljivost pa preverimo z robustnimi testi in z dodatnima primerjavama po protokolih dveh objavljenih študij [6, 7].

Cilj ni pokazati, da sodobni napovedni modeli vedno nadomestijo klasične pristope, temveč preveriti, ali lahko v povezavi z ustrezno optimizacijo ponudijo uporabno izboljšavo tudi na podatkih, ki jih med razvojem niso videli.

Delo je organizirano takole: v razdelku 1 pregledamo sorodne pristope in naše delo umestimo v obstoječo literaturo. V razdelku 2 predstavimo uporabljene napovedne in optimizacijske metode. V razdelku 3 predstavimo implementacijo in postopek vrednotenja, v razdelku 4 analiziramo rezultate, v razdelku 6 pa podamo sklepne ugotovitve.

1. Sorodna dela

Raziskave, povezane z našim problemom, lahko razdelimo na tri področja: optimizacijo portfeljev, napovedovanje prihodnjih donosov in ocenjevanje tveganja. Na vseh treh se je razvoj postopoma premikal od preprostejših statističnih pristopov k metodam, ki lahko obravnavajo več podatkov, več omejitev in zahtevnejše povezave med sredstvi. V našem delu te tri dele obravnavamo ločeno in jih nato povežemo v skupen postopek.

1.1. Optimizacija naloženih portfeljev. Po Markowitzevem delu [1] se je velik del raziskav osredotočil na vprašanje, kako zanesljivi so optimizirani portfelji, kadar so njihovi vhodni podatki ocenjeni iz omejenega vzorca. Michaud [8] je opozoril, da lahko že majhne napake v ocenjenih donosih povzročijo velike spremembe v sestavi portfelja. Razvili so se zato pristopi, ki skušajo zmanjšati vpliv teh napak. Med najbolj znanimi je Black-Littermanov model [9, 10], ki pri oblikovanju ocen prihodnjih donosov upošteva dodatne informacije o trgu. Empirične primerjave so hkrati pokazale, da zahtevnejša optimizacija zunaj vzorca ni vedno uspešnejša od preprostih strategij [11–13].

Druga pomembna smer vključuje praktične omejitve, predvsem kardinalnost, ki združuje diskretno izbiro sredstev in zvezno določanje uteži, kar njegovo bistveno oteži reševanje problema. Zgodnejše raziskave so uporabljale natančne matematične postopke [14, 15], vzporedno pa so se razvijali tudi hevristični pristopi, ki iščejo kakovostne rešitve brez preiskovanja vseh možnih kombinacij [5]. Kasnejše metode so problem poskušale poenostaviti tako, da spodbujajo manjše število aktivnih uteži [16, 17], ali pa so združile več različnih načinov iskanja in določanja uteži [18]. V našem delu se osredotočimo na tri metahevristične algoritme in preverjamo, kako uspešno rešujejo tak kardinalno ONP.

1.2. Napovedovanje pričakovanih donosov. Zgodnejše raziskave napovedovanja donosov so iskale predvsem ponavljajoče se zakonitosti v preteklih podatkih in ekonomskih značilnostih sredstev. Primer je moment, pri katerem imajo sredstva z relativno boljšimi preteklimi donosi v določenih obdobjih težnjo, da ostanejo uspešnejša tudi v bližnji prihodnosti [19, 20]. Takšni pristopi temeljijo predvsem na vnaprej določenih signalih. Z večjo količino razpoložljivih podatkov pa so se začele uporabljati metode strojnega učenja, ki lahko same poiščejo uporabne nelinearne povezave med večjim številom značilk [21]. Med takšne pristope sodijo tudi modeli, kot je LightGBM [22].


Naslednji korak je bilo neposredno modeliranje časovnega razvoja podatkov z nevronske mreže. Selvin in sod. [23] so pri napovedovanju cen delnic primerjali več rekurentnih in konvolucijskih arhitektur. Modeli, kot je LSTM [24], so bili pri tem zanimivi predvsem zato, ker lahko pri napovedi upoštevajo informacije iz daljšega zaporedja preteklih opazovanj. Napovedni modeli so se začeli vključevati tudi neposredno v postopke sestave portfeljev. Barua in Sharma [25] sta na primer napovedi nevronskega modela uporabila kot vhod v Black-Littermanov pristop.

Novejši razvoj predstavljajo arhitekture s pozornostjo in transformerji [26]. Ti omogočajo, da model pri napovedi neposredno ovrednoti pomen različnih delov vhodnega zaporedja, zato so postali zanimivi tudi za finančne časovne vrste [27, 28]. Vzporedno so se razvili splošnejši modeli za napovedovanje časovnih vrst [29, 30]. Raziskave se hkrati vse bolj oddaljujejo od obravnave posamezne delnice kot izoliranega zaporedja. Nekateri modeli upoštevajo povezave med različnimi delnicami [31, 32], drugi pa cenovne podatke dopolnjujejo z novicami, besedili in informacijami o podjetjih [33, 34]. V našem delu iz tega širšega razvoja izberemo TFT [2], MASTER [3] in TACTiS-2 [4], ki omogočajo različne načine obravnave časovnih in večrazsežnih podatkov.

1.3. Ocenjevanje tveganja in kovariančne matrike. Pri sestavi portfelja moramo poleg prihodnjih donosov oceniti tudi tveganje in povezanost med sredstvi. Osnovna težava je, da pri večjem številu sredstev hitro naraste število povezav, ki jih moramo oceniti iz omejenega števila opazovanj. Raziskave so zato iskale načine, kako ocenjevanje poenostaviti ali stabilizirati. Faktorski modeli skupno gibanje velikega števila sredstev opišejo z manjšim številom skupnih dejavnikov [35]. Druga smer upošteva, da se tveganje in povezanost med sredstvi skozi čas spreminjata, zato ju modelira dinamično [36, 37].

Pomemben pristop je tudi neposredna stabilizacija kovariančne matrike. Vzorčna kovariančna matrika je lahko pri omejenem številu opazovanj zelo nestabilna, zato Ledoit in Wolf [38] predlagata njeno krčenje proti bolj strukturirani oceni. Novejše raziskave podobno težavo rešujejo z metodami strojnega učenja. Nekateri pristopi se iz podatkov učijo skupnih dejavnikov tveganja [39], drugi pa poskušajo izboljšati samo oceno kovariančne matrike [40]. Še druga možnost je, da namesto posameznih kovarianc modeliramo skupno porazdelitev več časovnih vrst; tak primer je GPVar [41]. Iz takšne porazdelitve lahko nato ocenimo tudi pričakovane vrednosti, negotovost in medsebojne povezave med sredstvi. V našem delu primerjamo Ledoit-Wolfovo oceno s kovariančno matriko, pridobljeno iz napovedne porazdelitve modela TACTiS-2 [4].

2. Metode



Slika 1. Arhitektura modela TACTIS-2. Model uporablja ločena kodirnika za marginalne porazdelitve in kopulsko odvisnost, učenje pa poteka v dveh stopnjah. Povzeto po [4].

2.1. Napovedovanje prihodnjih donosov.

2.1.1. TACTIS-2. [4] uporabljamo za skupno napovedovanje več časovnih vrst. V našem primeru posamezna časovna vrsta predstavlja gibanje donosov enega sredstva. Model ne napove vsakega sredstva ločeno, ampak prihodnje vrednosti vseh sredstev obravnava skupaj. To nam omogoča, da iz iste napovedi ocenimo tako prihodnje donose kot tudi njihove medsebojne povezave.

Vhod v model sestavljajo pretekle vrednosti časovnih vrst in informacije, ki opisujejo posamezno opazovanje. Za vsako vrednost model prejme tudi časovni podatek, ki določa, kdaj je bila vrednost izmerjena, ter masko, ki pove, ali je vrednost znana ali jo želimo napovedati. Model lahko poleg tega uporablja dodatne značilke oziroma kovariate. TACTIS-2 ne predpisuje njihove vsebine, zato so te odvisne od konkretnega problema. Vrednosti, ki jih želimo napovedati, so na vhodu zakrite, model pa jih ocenjuje na podlagi preteklih opazovanih vrednosti in preostalih razpoložljivih informacij [4].

Izhod TACTIS-2 ni ena sama napovedana vrednost. Model oceni napovedno porazdelitev prihodnjih vrednosti. Iz nje lahko zato ustvarimo več možnih prihodnjih scenarijev. Če napovedujemo N sredstev, posamezen vzorec vsebuje možne prihodnje donose vseh N sredstev hkrati. Sredstva pri tem niso vzorčena neodvisno, zato scenariji ohranijo povezave, ki se jih je model naučil iz podatkov.

Da lahko model takšno skupno napoved zgradi, problem razdeli na dva dela. Prvi del opisuje možne prihodnje vrednosti vsake časovne vrste posebej. Drugi del opisuje, kako so časovne vrste med seboj povezane. Za opis teh povezav model uporablja kopulo, ki jo lahko razumemo kot način za povezovanje posameznih napovednih porazdelitev v eno skupno porazdelitev.

Arhitektura zato uporablja dva kodirnika, kot prikazuje Slika 1. Prvi kodirnik pripravlja informacije za napoved posameznih časovnih vrst, drugi pa informacije o njihovih medsebojnih povezavah. Oba obdelujeta iste vhodne podatke, vendar se učita za različni nalogi [4].

Tudi učenje poteka v dveh korakih. Najprej se model nauči, kakšne prihodnje vrednosti so verjetne za posamezne časovne vrste. Nato se ta del modela zamrzne in v drugem koraku se model nauči še povezav med časovnimi vrstami. Tako sta napoved posameznega sredstva in opis povezav med sredstvi ločena, vendar sta pri končni napovedi ponovno združena.

Za portfeljsko optimizacijo iz napovedne porazdelitve vzorčimo S skupnih scenarijev prihodnjih donosov. Naj bo

$$\mathbf{C} = [\mathbf{C}_{:,1} \quad \dots \quad \mathbf{C}_{:,S}] \in \mathbb{R}^{N \times S}$$

matrika teh scenarijev, kjer vsak stolpec $\mathbf{C}_{:,s}$ predstavlja en možen prihodnji izid za vseh N sredstev.


Oceno pričakovanih donosov določimo kot povprečje vseh scenarijev:

$$\hat{\mu}_{\text{TACTIS}} = \frac{1}{S} \sum_{s=1}^S \mathbf{C}_{:,s}. \quad (8)$$

Iz istih scenarijev ocenimo tudi kovariančno matriko:

$$\hat{\Sigma}_{\text{TACTiS}} = \text{Cov}(\mathbf{C}). \quad (9)$$

Enačba (8) poda povprečni napovedani donos posameznega sredstva, enačba (9) pa oceni, kako se napovedani donosi različnih sredstev spreminjajo skupaj. TACTiS-2 torej $\hat{\mu}$ in $\hat{\Sigma}$ ne vrača neposredno. Njegov dejanski izhod je skupna napovedna porazdelitev, iz katere ustvarimo scenarije, nato pa iz njih izračunamo obe količini, ki ju potrebujemo pri optimizaciji portfelja.



Slika 2. Arhitektura modela MASTER. Model najprej prilagodi pomen vhodnih značilk stanju trga, nato izmenično združuje informacije skozi čas in med delnicami ter na koncu oblikuje napoved za posamezno sredstvo. Povzeto po [3].

2.1.2. MASTER. je model, razvit posebej za napovedovanje delnic. Njegova glavna ideja je, da gibanja posamezne delnice ne obravnava ločeno od preostalega trga. Pri napovedi zato povezuje časovni razvoj posamezne delnice, informacije iz drugih delnic in trenutno stanje širšega trga.

Za vsako delnico model uporablja 158 značilk iz nabora Alpha158. Te značilke so izpeljane iz zgodovinskih podatkov o cenah in trgovanju ter vključujejo različne informacije o donosih, cenovnih razmerjih, trgovalnem obsegu in drugih tehničnih kazalnikih. V izvirnih poskusih MASTER uporablja zadnjih osem trgovanih dni teh značilk in napoveduje normalizirani donos v naslednjih petih trgovanih dneh [3].

Poleg značilk posameznih delnic model uporablja še ločen opis trenutnega stanja trga. Avtorji ga sestavijo iz indeksov CSI300, CSI500 in CSI800. Za vsak indeks vključijo informacije o njegovi vrednosti ter o gibanju cen in obsega trgovanja skozi več preteklih obdobij dolžine 5, 10, 20, 30 in 60 dni. Tako dobijo 63 tržnih značilk, ki opisujejo širše razmere na trgu [3].


Tržne značilke imajo posebno vlogo. MASTER jih ne preprosto doda značilkam posamezne delnice, temveč jih uporabi za prilagajanje njihove pomembnosti. Mehanizem *market-guided gating* iz stanja trga določi utež za vsako vhodno značilko. Značilke, ki so v trenutnih razmerah bolj uporabne za napoved, lahko dobijo večji vpliv, manj uporabne pa manjši. Model se teh uteži nauči skupaj z ostalimi parametri [3].

Po tem koraku MASTER izmenično povezuje informacije znotraj posamezne delnice in med različnimi delnicami. Pri združevanju znotraj delnice primerja različne časovne trenutke istega sredstva in tako išče pomembne časovne vzorce. Nato pri združevanju med delnicami primerja predstavitve različnih sredstev v istem časovnem trenutku in ugotavlja, katere druge delnice vsebujejo koristne informacije za trenutno napoved.

Takšno izmenjevanje je pomembno, ker povezave med delnicami niso nujno stalne ali časovno poravnane. Gibanje ene delnice lahko na primer vsebuje informacijo, ki se pri drugi pokaže šele nekaj dni pozneje. MASTER lahko takšne medčasovne povezave zajame zato, ker informacije najprej združuje skozi čas znotraj posamezne delnice, nato pa med delnicami, postopek pa večkrat ponovi [3].

Na koncu model za vsako delnico še enkrat združi informacije iz celotnega vhodnega obdobja in oblikuje končni napovedni signal. Celotna arhitektura je zato sestavljena iz petih glavnih korakov: prilagajanja značilk stanju trga, združevanja informacij znotraj delnice, združevanja informacij med delnicami, končnega združevanja skozi čas in napovedi [3].

V našem cevovodu izhod modela MASTER uporabimo kot presečni signal za oblikovanje ocene pričakovanih prihodnjih donosov $\hat{\mu}_{\text{MASTER}}$. Model ne napoveduje skupne verjetnostne porazdelitve prihodnjih donosov, zato iz njegovega izhoda ne dobimo neposredne ocene kovariančne matrike $\hat{\Sigma}$. To ocenimo ločeno, kot opisujemo v Razdelku 2.2.



Slika 3. Arhitektura modela TFT. Model izbira pomembne vhodne značilke, lokalne časovne vzorce obdeluje z omrežji LSTM, daljše časovne povezave pa s samopozornostjo. Povzeto po [2].

2.1.3. Temporal Fusion Transformer. je splošna arhitektura za večhorizontno napovedovanje časovnih vrst. To pomeni, da lahko hkrati napove več prihodnjih časovnih korakov. Model je zasnovan tako, da lahko uporablja več različnih vrst vhodnih podatkov in pri tem sam oceni, katere informacije so za posamezno napoved pomembne.

TFT razlikuje med tremi vrstami značilk. Prva skupina so statične značilke, ki se skozi čas ne spreminjajo. Druga skupina so časovno odvisne značilke, ki jih poznamo samo do trenutka napovedi. Tretja skupina so značilke, katerih prihodnje vrednosti poznamo vnaprej, na primer koledarske informacije. Model te skupine obravnava ločeno, ker imajo pri napovedovanju različne vloge [2].

Pomemben del arhitekture so omrežja za izbiro spremenljivk. Na posameznem časovnem koraku TFT določi uteži vhodnih značilk in s tem oceni, katere so trenutno bolj uporabne za napoved. Manj pomembnim ali šumnim značilkam lahko pripiše zelo majhen vpliv. Tak način obdelave omogoča, da se model ne zanaša vedno na iste vhodne podatke, ampak lahko njihov pomen prilagaja posameznemu primeru [2].

Časovne povezave TFT obravnava v dveh korakih. Najprej uporablja LSTM za obdelavo lokalnih vzorcev med bližnjimi časovnimi trenutki. Nato uporabi samopozornost, ki lahko neposredno poveže tudi bolj oddaljene dele časovnega zaporedja. S tem model združuje prednosti rekurentne obdelave za kratkoročno dinamiko in pozornosti za daljše časovne odvisnosti [2].

V arhitekturi so uporabljena tudi vrata, ki nadzorujejo pretok informacij skozi posamezne dele omrežja. Če določen del modela za konkretne podatke ni posebej koristen, lahko vrata zmanjšajo njegov vpliv in informacijo prenesejo naprej po neposrednejši poti. Avtorji za ta namen uporabljajo tako imenovana preostankovna omrežja z vrati, ki povezujejo nelinearno obdelavo s preskočnimi povezavami [2].

TFT je zasnovan tudi za verjetnostno napovedovanje. Namesto ene same prihodnje vrednosti lahko za vsak napovedni horizont napove več kvantilov, na primer 10., 50. in 90. percentil. Tako poleg osrednje napovedi poda tudi informacijo o negotovosti posamezne časovne vrste. Model se pri tem uči s kvantilno izgubno funkcijo, ki posebej kaznuje prenizke in previsoke napovedi glede na izbrani kvantil [2].

Glavne dele arhitekture prikazuje Slika 3. Na njej so ločeno prikazani izbor vhodnih spremenljivk, LSTM-obdelava, samopozornost in vrata, ki povezujejo posamezne dele modela.

Za razliko od MASTER TFT ni zasnovan posebej za finančne podatke in nima posebnega mehanizma za modeliranje presečnih odnosov med različnimi delnicami. V našem delu zato predstavlja splošnejši napovedni model, s katerim preverjamo, ali lahko uporaben signal prihodnjih donosov dobimo predvsem iz časovnega razvoja in vhodnih značilk posameznega sredstva.

Iz napovednega izhoda TFT oblikujemo oceno pričakovanih prihodnjih donosov $\hat{\mu}_{\text{TFT}}$. Ker model ne napoveduje skupne porazdelitve donosov vseh sredstev, iz njegovega izhoda ne dobimo neposredne ocene kovariančne matrike $\hat{\Sigma}$. To ocenimo ločeno, kot opisujemo v Razdelku 2.2.

2.2. Ocena kovariančne matrike. Modeli MASTER in TFT zagotavljajo oceno pričakovanih donosov, ne pa tudi skupne napovedne kovariančne matrike. Pri teh scenarijih zato $\hat{\Sigma}$ ocenimo iz zgodovinskih donosov.

TACTIS-2 predstavlja drugačen primer, saj iz njegove skupne napovedne porazdelitve dobimo tako $\hat{\mu}_{\text{TACTIS}}$ kot $\hat{\Sigma}_{\text{TACTIS}}$, kot določata enačbi (8) in (9).

Kot klasično primerjalno metodo uporabljamo tudi Ledoit-Wolfov krčenje kovariančne matrike [38]. Krčenje kombinira vzorčno kovariančno matriko s strukturirano ciljno matriko in s tem zmanjšuje občutljivost cenilke na omejeno količino podatkov.

2.3. Globalni optimizacijski algoritmi. Kardinalna omejitev razdeli prostor rešitev na veliko možnih kombinacij izbranih sredstev. Za vsako kombinacijo je nato treba določiti še njihove uteži. Namesto izčrpnega pregledovanja vseh kombinacij uporabljamo dva metahevrstična algoritma: rojenje delcev in simulirano ohlajanje. Ta ne zagotavljata globalno optimalne rešitve, vendar lahko učinkovito preiskujeta velik in nekonvexen prostor rešitev.

Vsi trije algoritmi rešujejo isti problem in uporabljajo iste ocene $\hat{\mu}$ in $\hat{\Sigma}$. Razlikujejo se samo v strategiji iskanja. PSO hkrati premika več rešitev in uporablja informacije o doslej uspešnih delih prostora, SA preiskuje okolico ene rešitve in začasno dovoljuje tudi poslabšanja, GA pa ustvarja nove rešitve s kombiniranjem in spreminjanjem obstoječih kandidatov.

Ker implementacija uporablja minimizacijo, ciljno funkcijo iz enačbe (4) zapišemo v ekvivalentni obliki

$$g(\mathbf{w}) = (1 - P)\mathbf{w}^\top \hat{\Sigma} \mathbf{w} - P\hat{\mu}^\top \mathbf{w}. \quad (10)$$

Minimiziranje enačbe (10) je ekvivalentno maksimiranju prvotne ciljne funkcije.

Ker je v dopustnem portfelju aktivnih natanko K sredstev, lahko kovariančni člen izračunamo samo nad njihovimi utežmi. Če aktivne indekse najprej poiščemo v vektorju dolžine N , je strošek enega ovrednotenja približno $O(N + K^2)$.

2.3.1. Rojenje delcev.

2.3.2. Rojenje delcev. Rojenje delcev (PSO) [42] je populacijski optimizacijski algoritem. Hkrati vzdržuje več kandidatnih rešitev, ki jih imenujemo delci. Vsak delec se skozi prostor rešitev premika glede na svojo trenutno rešitev, najboljšo rešitev, ki jo je našel sam, in najboljšo rešitev, ki jo je našel celoten roj. Pri portfeljski optimizaciji uporabljamo prilagoditev Cure [43], ki poleg uteži posebej obravnava tudi izbor sredstev.

Predstavitev delca. Posamezen delec predstavlja en portfelj. Za vsako sredstvo i vsebuje binarno spremenljivko z_i , ki pove, ali je sredstvo vključeno v portfelj, in zvezno spremenljivko x_i , ki predstavlja njegovo utež. Delec zato hkrati določa izbor sredstev in njihove uteži. Poleg trenutnega položaja hrani tudi svojo najboljšo do sedaj najdeno rešitev.

Hitrost in premik. Vsak delec ima poleg položaja tudi hitrost. Hitrost določa, kako se bodo pri naslednjem koraku spremenile njegove spremenljivke. Pri posodobitvi uporabljamo dve smeri: smer proti najboljši rešitvi celotnega roja in smer proti najboljši rešitvi trenutnega delca. Vpliv obeh smeri je v vsaki iteraciji pomnožen z naključnima vrednostma iz intervala $[0, 2]$, kot v pristopu Cure [43]. S tem se delci ne premikajo vedno po isti poti, ampak še naprej raziskujejo različne dele prostora rešitev.

Za binarne spremenljivke najprej posodobimo hitrost v_i^z , nato pa novo vrednost pretvorimo v verjetnost s sigmoidno funkcijo. Iz nje določimo, ali bo sredstvo vključeno v portfelj. Če je sredstvo izbrano, na podoben način posodobimo še hitrost njegove uteži v_i^x in trenutno utež x_i . Če sredstvo ni izbrano, njegovo utež nastavimo na nič. Implementacija pri binarnem premiku uporablja tudi majhen odmik α , ki preprečuje neželen vklop sredstva pri ničelni hitrosti, kot predlaga Cura [43].

Osebnost in globalna najboljša rešitev. Po vsakem premiku izračunamo vrednost ciljne funkcije. Če je novi položaj delca boljši od njegove dosedanje najboljše rešitve, osebno najboljšo rešitev posodobimo. Če je boljši tudi od vseh rešitev, ki jih je do takrat našel roj, postane nova globalno najboljša rešitev. Na ta način se informacija o dobrih rešitvah postopoma širi po celotnem roju.

Popravljanje kardinalnosti. Premik delca sam po sebi ne zagotavlja, da bo izbranih natanko K sredstev. Po vsakem premiku zato izvedemo postopek popravljanja. Če je izbranih premalo sredstev, dodajamo nova, dokler jih ni natanko K ; če jih je preveč, jih odstranjujemo. Pri izbiri uporabljamo kombinacijo naključnega odločanja in problemsko odvisne mere c_i , povzete po Curi [43]. Z verjetnostjo $1/2$ sredstvo izberemo naključno, sicer pa pri dodajanju izberemo sredstvo z največjo vrednostjo c_i , pri odstranjevanju pa sredstvo z najmanjšo vrednostjo c_i . Mera c_i združuje informacijo o pričakovanem donosu in tveganju sredstva ter se za posamezno optimizacijsko okno izračuna samo enkrat.

Popravljanje uteži. Po določitvi natanko K aktivnih sredstev njihove uteži normaliziramo tako, da je njihov seštevek enak ena, hkrati pa morajo ostati znotraj spodnjih in zgornjih meja. S tem je vsak ovrednoten delec dopusten portfelj glede na omejitve iz enačb (??)–(7).

Algoritem 1 povzema celoten postopek. Najprej ustvarimo roj naključnih dopustnih portfeljev in določimo njihove osebne ter globalno najboljšo rešitev. Nato v vsaki iteraciji posodobimo izbiro sredstev in uteži vsakega delca, rešitev popravimo na dopustno množico ter ponovno ovrednotimo. Po koncu iskanja vrnemo najboljšo rešitev, ki jo je obiskal roj.

Algoritem 1 povzema postopek.

Algoritem 1. PSO za kardinalno omejeni portfelj

Require: $\hat{\mu}$, $\hat{\Sigma}$, K , meje uteži, velikost roja M , št. iteracij G

Ensure: najboljša rešitev $\mathbf{w}^*$

```
1: inicializiraj  $M$  dopustnih delcev
2: ovrednoti delce
3: določi osebne in globalni optimum
4: for  $g = 1, \dots, G$  do
5:   for vsak delec do
6:     posodobi izbiro sredstev in uteži
7:     popravi kardinalnost na  $K$ 
8:     projiciraj uteži na dopustno množico
9:     ovrednoti rešitev
10:    if rešitev izboljša osebni optimum then
11:      posodobi osebni optimum
12:    if rešitev izboljša globalni optimum then
13:      posodobi globalni optimum
14: return globalni optimum
```

2.3.3. Simulirano ohlajanje. Simulirano ohlajanje (SA) [44] preiskuje prostor rešitev z eno trenutno rešitvijo. V vsakem koraku iz nje ustvari bližnjo rešitev in se nato odloči, ali jo bo sprejelo. Boljšo rešitev vedno sprejme, slabšo pa lahko sprejme z določeno verjetnostjo. Ta možnost algoritmu omogoča, da se začasno premakne v slabši del prostora in se tako izogne lokalnemu optimumu. Naša prilagoditev sledi pristopu za kompleksne portfeljske probleme Crame in Schynsa [45]. Takšni problemi vsebujejo diskretne in zvezne omejitve, zato so naraven primer uporabe simuliranega ohlajanja. :contentReference[oaicite:5]index=5

Trenutna in najboljša rešitev. SA ves čas hrani trenutno rešitev $\mathbf{w}$ ter najboljšo rešitev $\mathbf{w}^*$, ki jo je našel do trenutnega koraka. Začetni portfelj ustvarimo tako, da naključno izberemo natanko K sredstev, jim dodelimo začetne uteži in uteži nato prilagodimo omejitvam problema. Začetna rešitev zato ne uporablja informacije o pričakovanih donosih ali tveganju pri samem izboru sredstev.

Sosednja rešitev. Osrednji del SA je način, kako iz trenutne rešitve ustvarimo novo, podobno rešitev. V naši implementaciji uporabljamo dve vrsti premikov. Najpogostejši premik spremeni uteži dveh trenutno aktivnih sredstev: utež prvega povečamo za naključno vrednost, utež drugega pa zmanjšamo za enako vrednost. Na ta način se skupna vsota uteži pred popravljanjem ne spremeni. Drugi premik spremeni samo sestavo portfelja: naključno izbrano aktivno sredstvo odstranimo in ga zamenjamo z naključno izbranim neaktivnim sredstvom. Tako lahko algoritem preiskuje tako uteži znotraj istega nabora sredstev kot tudi različne nabore sredstev.

Dopustnost rešitve. Po vsakem premiku uteži ponovno prilagodimo tako, da so izpolnjene spodnje in zgornje meje ter proračunska omejitev. Pri zamenjavi sredstva ostane aktivnih natanko K sredstev, zato je tudi kardinalna omejitev neposredno ohranjena. Ciljna funkcija torej vedno ocenjuje dopustne portfelje.

Sprejem nove rešitve. Naj bo

$$\Delta = g(\mathbf{w}') - g(\mathbf{w})$$

razlika med vrednostjo kandidata $\mathbf{w}'$ in trenutno rešitvijo $\mathbf{w}$. Ker ciljno funkcijo minimiziramo, kandidata vedno sprejmemo, kadar je $\Delta < 0$. Če je kandidat slabši, torej $\Delta > 0$, ga sprejmemo z verjetnostjo

$$\Pr(\text{sprejem}) = \exp\left(-\frac{\Delta}{T}\right), \quad (11)$$

kjer je T trenutna temperatura. Pri visoki temperaturi lahko algoritem relativno pogosto sprejme tudi slabše rešitve. Ko temperatura pada, postaja takšno sprejemanje vedno manj verjetno in iskanje se osredotoča na bližnje izboljšave.

Začetna temperatura. Začetne temperature ne določimo neposredno. Najprej ustvarimo več naključnih sosednjih rešitev in izračunamo povprečno pozitivno poslabšanje $\bar{\Delta}^+$. Iz zelene začetne verjetnosti sprejemanja slabših rešitev v_0 nato določimo

$$T_0 = \frac{\bar{\Delta}^+}{-\ln v_0}. \quad (12)$$

Enačba (12) izhaja neposredno iz pravila sprejema v enačbi (11). S tem se začetna temperatura prilagodi dejanski velikosti sprememb ciljne funkcije v trenutnem optimizacijskem problemu.

Ohlajanje. Iskanje je razdeljeno na temperaturne stopnje. Na posamezni stopnji izvedemo določeno število sosednjih premikov, nato pa temperaturo geometrijsko zmanjšamo po pravilu $T \leftarrow \alpha T$, kjer je $0 < \alpha < 1$ faktor ohlajanja. Višji α pomeni počasnejše ohlajanje in daljše raziskovanje prostora, nižji pa hitrejši prehod k lokalnemu iskanju.

Velikost premika. Tudi velikost spremembe uteži se med iskanjem prilagaja. Na začetku uporabljamo večji polmer premika q_1 . Če je na temperaturni stopnji sprejetih malo kandidatov, polmer zmanjšamo na q_2 . Tako lahko algoritem na začetku izvaja večje spremembe portfelja, pozneje pa natančnejše preiskuje okolico dobre rešitve.

Ustavitveni pogoj. Postopek se konča, ko dosežemo največje dovoljeno število temperaturnih stopenj ali ko v več zaporednih stopnjah ni sprejeta nobena nova rešitev. Vrnemo najboljšo rešitev $\mathbf{w}^*$, ki jo je algoritem našel med celotnim iskanjem.

Algoritem 2. SA za kardinalno omejeni portfelj

Require: $\hat{\mu}$, $\hat{\Sigma}$, K , meje uteži

Ensure: najboljša rešitev $\mathbf{w}^*$

```

1: ustvari začetno dopustno rešitev  $\mathbf{w}$ 
2:  $\mathbf{w}^* \leftarrow \mathbf{w}$ 
3: določi začetno temperaturo  $T$ 
4: while ni dosežen ustavitveni pogoj do
5:   for vsak korak temperaturne stopnje do
6:     ustvari sosednjo rešitev  $\mathbf{w}'$ 
7:     projiciraj  $\mathbf{w}'$  na dopustno množico
8:      $\Delta \leftarrow g(\mathbf{w}') - g(\mathbf{w})$ 
9:     if  $\Delta \leq 0$  then
10:      sprejmi  $\mathbf{w}'$ 
11:     else if  $u < \exp(-\Delta/T)$ ,  $u \sim U(0, 1)$  then
12:       sprejmi  $\mathbf{w}'$ 
13:     if sprejeta rešitev izboljša  $\mathbf{w}^*$  then
14:       posodobi  $\mathbf{w}^*$ 
15:   znižaj temperaturo  $T$ 
16: return  $\mathbf{w}^*$ 

```

2.4. Mere uspešnosti in tveganja. Portfelje vrednotimo z realiziranimi donosi $\{r_t^P\}_{t=1}^T$. Poleg kumulativnega in letnega donosa uporabljamo mere, ki upoštevajo tudi tveganje. Naj bo $\bar{r}$ povprečni dnevni donos in s njegov standardni odklon.

Sharpov količnik [46] pri ničelni brezrtvegani obrestni meri definiramo kot

$$\text{SR} = \frac{\bar{r}}{s}. \quad (13)$$

Sortinov količnik [47] v imenovalcu uporablja samo spodnjo deviacijo s^- glede na ciljni donos τ :

$$\text{Sortino} = \frac{\bar{r} - \tau}{s^-}. \quad (14)$$

Omega razmerje [48] primerja presežke nad pragom τ s primanjkljaji pod njim:

$$\Omega(\tau) = \frac{\sum_t \max(r_t^P - \tau, 0)}{\sum_t \max(\tau - r_t^P, 0)}. \quad (15)$$

Kumulativno vrednost portfelja določimo kot

$$W_t = \prod_{s=1}^t (1 + r_s^P), \quad (16)$$

največji upad pa kot

$$\text{MDD} = \max_t \left[\frac{\max_{s \leq t} W_s - W_t}{\max_{s \leq t} W_s} \right]. \quad (17)$$

Letno volatilnost dnevnih donosov ocenimo z

$$\sigma_{\text{letno}} = s\sqrt{252}. \quad (18)$$

Mere skupaj zajemajo donos, splošno volatilnost, negativna odstopanja, obliko empirične porazdelitve donosov in največjo realizirano izgubo od predhodnega vrha.

3. Implementacija in vrednotenje

V tem poglavju opišemo, kako metode iz prejšnjega poglavja povežemo v celoten postopek za sestavo in vrednotenje portfeljev. Najprej poenotimo izhode različnih napovednih modelov in iz njih pripravimo oceni pričakovanih donosov $\hat{\mu}$ ter kovariančne matrike $\hat{\Sigma}$. Nato opišemo tehnično izvedbo, postopno vrednotenje na prihodnjih podatkih ter način primerjave napovednih modelov in optimizacijskih algoritmov.

3.1. Priprava napovedi za optimizacijo.

3.1.1. Primerljivost napovednih signalov. Izhodi različnih napovednih modelov niso nujno na enaki numerični skali. To je pomembno, ker velikost $\hat{\mu}$ neposredno vpliva na razmerje med členom pričakovanega donosa in členom variance v ciljni funkciji (4). Če bi izhode modelov uporabili neposredno, bi lahko razlike med dobljenimi portfelji izhajale predvsem iz njihove različne numerične skale in ne iz kakovosti napovedi.

Za modele, katerih izhod obravnavamo predvsem kot relativni signal med sredstvi, označimo surove napovedi z

$$\mathbf{s} = (s_1, \dots, s_N)^\top.$$

Signal najprej standardiziramo po preseku sredstev, nato pa ga preslikamo na povprečje in standardni odklon zgodovinske ocene pričakovanih donosov:

$$\hat{\mu}_{\text{model}} = \frac{\mathbf{s} - \bar{\mathbf{s}}}{\sigma_s} \sigma_{\hat{\mu}_{\text{zgod}}} + \bar{\mu}_{\text{zgod}}. \quad (19)$$

S preslikavo iz enačbe (19) ohranimo relativni vrstni red sredstev, ki ga poda napovedni model, njegovo skalo pa približamo skali zgodovinskih donosov. Tako zmanjšamo možnost, da bi rezultat optimizacije določala predvsem arbitrarna velikost izhoda posameznega modela.

Kakovost presečnega napovednega signala dodatno ocenjujemo z informacijskim koeficientom (IC), ki ga izračunamo kot Spearmanovo rang-korelacijo med napovedanim signalom in pozneje realiziranimi donosi [49]. Pozitivni IC pomeni, da imajo sredstva z višjim napovedanim signalom v povprečju tudi višje prihodnje donose, vrednost blizu nič pa pomeni, da napoved ne vsebuje jasne informacije o njihovem relativnem vrstnem redu.

3.1.2. Oceni pričakovanih donosov in kovariance. Vsak optimizacijski korak potrebuje oceno pričakovanih prihodnjih donosov $\hat{\mu}$ in oceno kovariančne matrike $\hat{\Sigma}$. Način njune priprave je odvisen od uporabljenega napovednega modela.

Pri klasičnem zgodovinskem scenariju pričakovane donose ocenimo iz preteklih realiziranih donosov. Kovariančno matriko ocenimo iz istega zgodovinskega okna z Ledoit-Wolfovimi krčenjem [38]. Ta scenarij predstavlja osnovno referenco, s katero primerjamo uporabo napovednih modelov.

TACTiS-2 obravnavamo drugače, ker model napoveduje skupno porazdelitev prihodnjih donosov vseh sredstev. Iz množice skupnih napovednih scenarijev zato izračunamo tako $\hat{\mu}_{\text{TACTiS}}$ kot $\hat{\Sigma}_{\text{TACTiS}}$, kot določata enačbi (8) in (9). Obe oceni tako izhajata iz iste napovedne porazdelitve.

MASTER in TFT ne napovedujeta skupne porazdelitve prihodnjih donosov vseh sredstev. Njuna izhoda zato uporabimo za oblikovanje ocen $\hat{\mu}_{\text{MASTER}}$ in $\hat{\mu}_{\text{TFT}}$, kovariančno matriko pa ocenimo ločeno iz preteklih donosov z Ledoit-Wolfovimi krčenjem [38].

Optimizacijska algoritma tako ne uporabljata neposrednih izhodov napovednih modelov, temveč vedno prejmeta enako oblikovan par $(\hat{\mu}, \hat{\Sigma})$. S tem ostane optimizacijski problem v vseh scenarijih enak, razlikuje se le način priprave njegovih vhodnih ocen.

3.2. Tehnična izvedba. Napovedni del cevovoda je implementiran v jeziku Python. TACTiS-2 uporabljamo prek njegove implementacije v paketu `tactis`, TFT prek knjižnice `pytorch-forecasting`, MASTER pa na podlagi izvirne implementacije avtorjev.

Optimizacijska algoritma PSO in SA sta implementirana v jeziku C++. Pri optimizaciji je treba v posameznem zagonu ovrednotiti veliko kandidatnih portfeljev, zato izvedba tega dela v prevedenem jeziku zmanjša računski čas.

Python pred vsakim zagonom optimizatorju posreduje število sredstev, vektor pričakovanih donosov $\hat{\mu}$, kovariančno matriko $\hat{\Sigma}$, parameter P , zahtevano kardinalnost K ter spodnje in zgornje meje uteži. Program v jeziku C++ nato izvede izbrani optimizacijski algoritem in vrne vektor portfeljskih uteži $\mathbf{w}$.

PSO in SA pri istem scenariju uporabljata popolnoma enake vhodne ocene in omejitve. Razlikujeta se samo v načinu preiskovanja prostora rešitev, opisanem v Razdelku 2.3. Tako lahko vpliv napovednega modela ločimo od vpliva izbranega optimizacijskega algoritma.

3.3. Postopno vrednotenje. Celoten postopek vrednotimo s postopnim oziroma *walk-forward* testiranjem. Osnovna zahteva takšnega vrednotenja je, da pri posamezni napovedi in sestavi portfelja uporabljamo samo podatke, ki bi bili v tistem trenutku dejansko na voljo.

Za posamezno testno obdobje najprej določimo učno obdobje, ki se konča pred začetkom testiranja. Napovedni model zato med učenjem ne vidi prihodnjih realiziranih donosov iz testnega dela podatkov.

Testno obdobje nato razdelimo na zaporedna nepokrivajoča se okna. Na začetku vsakega okna iz do takrat razpoložljivih podatkov pripravimo $\hat{\mu}$ in $\hat{\Sigma}$. Na podlagi teh ocen s PSO oziroma SA določimo portfeljske uteži, dobljeni portfelj pa ovrednotimo na realiziranih donosih naslednjega obdobja.

Po koncu posameznega okna postopek premaknemo naprej in ponovimo z novimi razpoložljivimi podatki. Tako dobimo zaporedje odločitev in realiziranih donosov, ki posnema dejansko uporabo modela skozi čas.

Vsak napovedni pristop obravnavamo kot samostojen cevovod. Pri TACTiS-2 sta $\hat{\mu}$ in $\hat{\Sigma}$ izračunana iz skupnih napovednih scenarijev. Pri MASTER in TFT napovedni model določi $\hat{\mu}$, medtem ko $\hat{\Sigma}$ ocenimo z Ledoit-Wolfovimi krčenjem. Zgodovinski scenarij uporablja samo informacije iz preteklih realiziranih donosov in služi kot klasična referenca.

Za vsak scenarij izvedemo optimizacijo posebej s PSO in SA. S tem lahko ločeno preverimo, ali način priprave $\hat{\mu}$ in $\hat{\Sigma}$ vpliva na kakovost portfelja ter ali so končne ugotovitve občutljive na izbiro optimizacijskega algoritma.

3.4. Testna obdobja. Ker se lastnosti finančnih trgov skozi čas spreminjajo, cevovoda ne vrednotimo samo na enem neprekinjenem testnem obdobju. Uporabimo več ločenih obdobj z različnimi tržnimi razmerami. Namen takšne razdelitve ni vnaprej določiti, kateri model bi moral biti v posameznem obdobju najboljši, temveč preveriti, ali so njegove prednosti oziroma slabosti prisotne v različnih okoljih.

Vrednotenje vključuje mirnejša obdobja rasti, obdobja izrazitih tržnih padcev in okrevanj ter obdobja povečanih sprememb v denarni politiki. Poleg tega primerjamo dve različici istega časovnega obdobja z različno sestavo investicijskega univerzuma, s čimer preverimo občutljivost rezultatov na prisotnost največjih tehnoloških družb.

Tabela 1 povzema uporabljena testna obdobja.

Tabela 1. Tržna obdobja, uporabljena pri postopnem vrednotenju.

Režim	Obdobje	Tržni značaj
2013–2017	2013–2017	umirjeno obdobje rasti
GFC	2007–2010	globalna finančna kriza in okrevanje
COVID	2019–2021	hiter padec in hitro okrevanje
2022–2024	2022–2024	dvigovanje obrestnih mer in okrevanje
divuniverse	2019–2022	brez največjih tehnoloških družb
headline	2019–2022	z največjimi tehnološkimi družbami

3.5. Vrednotenje napovedi in portfeljev. Vrednotenje izvajamo na dveh ravneh. Najprej preverjamo kakovost napovednega signala, nato pa ocenimo uspešnost portfelja, ki ga iz tega signala sestavi optimizator. Takšna ločitev je pomembna, ker dober napovedni signal ne zagotavlja nujno dobrega portfelja, prav tako pa lahko omejitve optimizacijskega problema zmanjšajo vpliv razlik med napovedmi.

Kakovost ocene pričakovanih donosov merimo z informacijskim koeficientom. IC meri predvsem, ali model pravilno razvršča sredstva po njihovih prihodnjih donosih, zato je primeren tudi za modele, katerih izhod predstavlja predvsem relativni presečni signal.

Končne portfelje vrednotimo na realiziranih donosih z merami iz Razdelka 2.4. Med glavne mere spadajo kumulativni in letni donos, Sharpov količnik, Sortinov količnik, razmerje Omega, največji upad in letna volatilitnost.

Poleg tega spremljamo tudi obrat portfelja. Ta meri velikost spremembe portfeljskih uteži med zaporednima rebalansiranjema in zato kaže, kako intenzivno posamezna strategija trguje. Višji obrat praviloma pomeni tudi višje transakcijske stroške.

Pri vrednotenju zato upoštevamo tudi transakcijske stroške. Ob vsakem rebalansiranju jih določimo na podlagi spremembe uteži med starim in novim portfeljem ter jih odštujemo od realiziranega donosa. Tako primerjamo neto rezultate strategij in ne samo njihovih donosov pred stroški.

3.6. Preverjanje optimizacijskih algoritmov. Pred vrednotenjem celotnega napovednega cevovoda ločeno preverimo tudi kakovost optimizacijskih algoritmov. Namen tega koraka je ugotoviti, ali PSO in SA smiselno rešujeta kardinalno omejeni problem, neodvisno od kakovosti napovednih modelov.

Za to uporabljamo standardne primere portfeljske optimizacije iz knjižnice OR-
Library [5, 50]. Na teh primerih so v literaturi na voljo referenčne učinkovite fronte, zato
lahko rešitve naših algoritmov primerjamo z uveljavljeno referenco.

Pri posamezni vrednosti parametra, ki določa razmerje med donosom in tveganjem, z
algoritmom poiščemo kardinalno omejeni portfelj in izračunamo njegovo odstopanje od
referenčne fronte. Manjše odstopanje pomeni, da je algoritem našel kakovostnejšo rešitev.

Ta preizkus ne dokazuje globalne optimalnosti dobljenih rešitev. Omogoča pa ne-
odvisno preverjanje, ali PSO in SA na standardnih problemih dosegata rešitve blizu
referenčne fronte, preden ju uporabimo v celotnem napovednem cevovodu.

3.7. Statistično vrednotenje. Rezultati zaporednih testnih oken niso med seboj povsem
neodvisni, saj izhajajo iz istega finančnega trga in časovno povezanih podatkov. Pri
statistični primerjavi strategij zato ne obravnavamo posameznih dnevnih donosov kot
neodvisnih opazovanj.

Osnovno enoto primerjave predstavlja rezultat posameznega testnega okna. Ker je
znotraj posameznega tržnega obdobja število takšnih oken omejeno, rezultate poleg
analize po posameznih obdobjih vrednotimo tudi na združenem naboru vseh testnih oken.

Za primerjavo parov strategij uporabljamo parne statistične teste. Kjer je treba
upoštevati časovno odvisnost opazovanj, uporabljamo oceno variance s popravkom Newey-
West [51]. Pri večjem številu hkratnih primerjav upoštevamo tudi problem mnogoterih
statističnih testov. Končni nabor testov in pripadajoče vrednosti bomo poročali skupaj s
končnimi eksperimentalnimi rezultati.

Glavni namen statističnega vrednotenja ni pokazati samo, kateri cevovod doseže
najvišjo vrednost posamezne mere, temveč oceniti, ali so opažene razlike dovolj velike in
dovolj dosledne skozi testna obdobja, da jih ni mogoče preprosto pripisati naključnemu
nihanju donosov.

4. Rezultati

V tem poglavju najprej preverimo kakovost implementacij PSO in SA na standardnih problemih OR-Library. Nato primerjamo napovedne modele na realnih podatkih s postopnim vrednotenjem. Rezultate obravnavamo ločeno z vidika kakovosti napovednega signala, uspešnosti dobljenih portfeljev in občutljivosti na izbiro optimizacijskega algoritma.

4.1. Rezultati na OR-Library. PSO in SA najprej ovrednotimo na standardnih primerih iz knjižnice OR-Library [5, 50]. Za vsak primer izračunamo kardinalno omejeno učinkovito fronto in jo primerjamo z referenčno fronto.

Uporabljamo enake kardinalne omejitve in meje uteži kot v standardnih primerjavah iz literature. Namen tega eksperimenta ni primerjati napovedne modele, saj so vhodni podatki za oba algoritma enaki, temveč preveriti, kako blizu referenčni fronti prideta implementaciji PSO in SA.

Tabela 2 bo po končnem zagonu eksperimentov prikazovala povprečno in mediano odstopanje dobljenih front.

Tabela 2. Odstotno odstopanje kardinalno omejene fronte od referenčne fronte OR-Library. Nižja vrednost pomeni manjše odstopanje od reference.

Algoritem	Hang Seng ($N = 31$)		DAX 100 ($N = 85$)	
	povpr.	mediana	povpr.	mediana
PSO	–	–	–	–
SA	–	–	–	–

Majhno odstopanje od referenčne fronte bi pokazalo, da algoritem na teh standardnih primerih najde kakovostne rešitve. Pri interpretaciji pa ne trdimo, da je dobljena rešitev globalno optimalna, saj sta PSO in SA metahevristična algoritma.

4.2. Postopno testiranje na realnih podatkih. Drugi del eksperimentov vrednoti celoten cevovod na realnih podatkih. Za vsak testni režim uporabljamo isti investicijski univerzum oziroma njegovo vnaprej določeno različico, enake omejitve portfelja, enak parameter P in enak model transakcijskih stroškov.

Med scenariji se zato spreminja predvsem način priprave $\hat{\mu}$ in $\hat{\Sigma}$. Primerjamo zgodovinski pristop, TACTiS-2, MASTER in TFT. Vsakega optimiziramo posebej s PSO in SA.

4.2.1. Kakovost napovednega signala. Najprej primerjamo informacijski koeficient posameznih modelov. Pozitivni IC pomeni, da model uspešno razvršča sredstva glede na njihove prihodnje donose, medtem ko vrednost blizu nič kaže na odsotnost jasne presečne napovedne informacije.

Tabela 3 bo prikazovala povprečni IC posameznega modela na združenem vzorcu in po posameznih tržnih režimih.

Tabela 3. Informacijski koeficient napovednih pristopov. Končne vrednosti bodo dodane po ponovnem zagonu eksperimentov.

Model	skupaj	2013–17	GFC	COVID	2022–24	divuniverse	headline
Zgodovinski	–	–	–	–	–	–	–
TACTiS-2	–	–	–	–	–	–	–
MASTER	–	–	–	–	–	–	–
TFT	–	–	–	–	–	–	–

Pri interpretaciji nas ne zanima samo največja povprečna vrednost IC. Pomembno je tudi, ali je predznak napovedne moči stabilen skozi različna obdobja in ali rezultat izhaja iz enega samega izrazitega režima.

4.2.2. Vpliv optimizacijskega algoritma. Vsak napovedni scenarij optimiziramo s PSO in SA. Ker algoritma uporabljata isti $\hat{\mu}$, isti $\hat{\Sigma}$ in enake omejitve, razlika med njima izhaja samo iz načina preiskovanja prostora rešitev.

Če PSO in SA pri istem napovednem scenariju dosežeta podobne rezultate, lahko sklepamo, da glavni rezultat ni močno odvisen od izbire konkretnega optimizacijskega algoritma. Takšno ujemanje pa samo po sebi ne dokazuje globalne optimalnosti dobljenih rešitev.

4.3. Združeni rezultati. Za skupno primerjavo napovednih pristopov združimo rezultate vseh testnih obdobj. S tem dobimo večje število testnih oken in zmanjšamo odvisnost zaključkov od enega specifičnega tržnega režima.

Tabela 4. Združeni rezultati napovednih scenarijev čez vsa testna obdobja. Končne vrednosti bodo dodane po ponovnem zagonu eksperimentov.

Scenarij	donos	Sharpe	Sortino	Omega	največji upad	volatilitnost
Zgodovinski	–	–	–	–	–	–
TACTiS-2	–	–	–	–	–	–
MASTER	–	–	–	–	–	–
TFT	–	–	–	–	–	–

Tabela 4 bo prikazovala glavne mere uspešnosti posameznih cevovodov. Rezultate bomo poročali ločeno za PSO in SA oziroma, če bosta algoritma dajala praktično enake rezultate, bomo enega uporabili za glavno tabelo, drugega pa kot preverjanje robustnosti.

Sharpov količnik predstavlja osnovno mero tvegano prilagojenega donosa, vendar ga ne interpretiramo ločeno. Sortinov količnik dodatno poudari negativna odstopanja, razmerje Omega upošteva celotno empirično porazdelitev donosov, največji upad pa pokaže največjo realizirano izgubo od predhodnega vrha. Skupaj zato podajo bolj celovito sliko uspešnosti posameznega cevovoda.

Posebej spremljamo tudi obrat portfelja in rezultate po transakcijskih stroških. Model, ki doseže višji donos samo z bistveno pogostejšim trgovanjem, je lahko po stroških manj privlačen od stabilnejšega pristopa.

Tabela 5. Obrat portfelja in vpliv transakcijskih stroškov. Končne vrednosti bodo dodane po ponovnem zagonu eksperimentov.

Scenarij	povprečni obrat	donos pred stroški	donos po stroških
Zgodovinski	–	–	–
TACTiS-2	–	–	–
MASTER	–	–	–
TFT	–	–	–

4.4. Rezultati po posameznih režimih. Združeni rezultat lahko prikrije velike razlike med posameznimi tržnimi obdobji. Zato rezultate dodatno analiziramo po vsakem režimu posebej.

Tabela 6 bo povzela glavno tvegano prilagojeno mero za vse napovedne scenarije.

Tabela 6. Sharpov količnik posameznih scenarijev po tržnih režimih. Končne vrednosti bodo dodane po ponovnem zagonu eksperimentov.

Režim	Zgodovinski	TACTiS-2	MASTER	TFT
2013–2017	–	–	–	–
GFC	–	–	–	–
COVID	–	–	–	–
2022–2024	–	–	–	–
divuniverse	–	–	–	–
headline	–	–	–	–

Tabela 7 bo poleg tvegano prilagojenih mer prikazovala tudi končne kumulativne donose.

4.4.1. 2013–2017: umirjeno obdobje rasti. Obdobje 2013–2017 predstavlja razmeroma umirjen bikovski trg z nižjo volatilitnostjo in daljšimi obdobji stabilnih trendov. Takšno okolje omogoča preverjanje, ali napovedni modeli ustvarjajo uporaben presečni signal tudi takrat, ko na trgu ni izrazitega sistemskega šoka.

Pri rezultatih nas zanima predvsem, ali napovedni modeli izboljšajo razvrščanje sredstev glede na zgodovinsko oceno in ali se morebitna prednost prenese tudi v višji tvegano prilagojeni donos portfelja.

4.4.2. Globalna finančna kriza 2007–2010. Globalna finančna kriza predstavlja najbolj izrazit sistemski stresni dogodek v uporabljenem naboru. Obdobje vključuje močan padec finančnih trgov in poznejše okrevanje, zato se statistične lastnosti donosov skozi testno obdobje hitro spreminjajo.

Ta režim je posebej uporaben za preverjanje kakovosti ocene tveganja. Pri TACTiS-2 kovariančna matrika izhaja iz napovedane skupne porazdelitve, medtem ko pri MASTER, TFT in zgodovinski referenci uporabljamo Ledoit-Wolfov oceno iz preteklih donosov. Pri merjavi zato omogoča tudi presojo, ali se različni načini priprave $\hat{\Sigma}$ v izrazito nestabilnem obdobju pokažejo v končnih portfeljih.

Pri interpretaciji bomo primerjali predvsem največji upad, volatilitnost, Sharpov količnik in sposobnost portfelja sodelovati v poznejšem okrevanju.

Tabela 7. Končni kumulativni donosi posameznih scenarijev po tržnih režimih, neto po transakcijskih stroških.

Režim	Zgodovinski	TACTIS-2	MASTER	TFT	1/N
2013–2017	–	–	–	–	–
GFC	–	–	–	–	–
COVID	–	–	–	–	–
2022–2024	–	–	–	–	–
divuniverse	–	–	–	–	–
headline	–	–	–	–	–

4.4.3. Pandemija COVID 2019–2021. Obdobje pandemije vsebuje zelo hiter padec marca 2020 in prav tako hitro okrevanje. Zaradi nenadne spremembe smeri trga predstavlja drugačen problem kot dolgotrajnejša finančna kriza.

Režim je zato uporaben za preverjanje, kako se modeli odzovejo na nenaden prelom v odnosih med preteklimi in prihodnjimi donosi. Če model preveč poudarja vzorce iz neposredne preteklosti, se lahko pri hitrem obratu njegova napovedna kakovost začasno zmanjša.

Pri analizi bomo zato poleg donosov posebej primerjali tudi IC pred zlomom, med zlomom in v začetnem obdobju okrevanja.

4.4.4. Obdobje dvigovanja obrestnih mer 2022–2024. Leto 2022 je zaznamovalo hitro zviševanje obrestnih mer in padec številnih delniških trgov, poznejši leti pa ponovno rast, ki je bila izrazitejša pri nekaterih sektorjih in večjih družbah.

To obdobje je zato primerno za preverjanje presečne napovedne sposobnosti modelov v okolju, kjer se donosi med posameznimi delnicami močno razlikujejo.

Pri analizi bomo preverili, ali modeli uspešno razlikujejo med relativno močnejšimi in šibkejšimi sredstvi ter ali se ta informacija prenese v boljšo sestavo kardinalno omejenega portfelja.

4.4.5. 2019–2022 brez največjih tehnoloških družb. V režimu *divuniverse* iz investicijskega univerzuma odstranimo največje tehnološke družbe. Namen tega eksperimenta je preveriti, ali je uspešnost napovednih modelov močno odvisna od majhnega števila izrazito uspešnih delnic.

Če model ohrani primerljivo napovedno in portfeljsko uspešnost tudi po njihovi odstranitvi, je manj verjetno, da rezultat izhaja predvsem iz statične izpostavljenosti tem družbam.

Primerjavo zato obravnavamo kot preizkus občutljivosti na sestavo investicijskega univerzuma in ne kot ločen tržni režim v ekonomskem smislu.

4.4.6. 2019–2022 z največjimi tehnološkimi družbami. Režim *headline* uporablja enako časovno obdobje kot *divuniverse*, vendar vključuje tudi največje tehnološke družbe. Neposredna primerjava obeh univerzumov tako pokaže, koliko je uspešnost posameznega pristopa občutljiva na prisotnost nekaj zelo velikih in uspešnih sredstev.

Če se rezultati med obema univerzumoma močno razlikujejo, je treba pri interpretaciji upoštevati, da lahko sestava investicijskega univerzuma pomembno vpliva na navidezno kakovost napovednega modela.

4.5. Statistična primerjava rezultatov. Opisne mere uspešnosti same po sebi ne povedo, ali so opažene razlike med strategijami dovolj dosledne, da jih lahko ločimo od naključnega nihanja donosov. Zato rezultate primerjamo tudi statistično.

Osnovna primerjava uporablja rezultate posameznih testnih oken. Za vsak napovedni model primerjamo njegovo uspešnost z zgodovinsko referenco na istih časovnih oknih. Ker so opazovanja časovno povezana, pri ocenjevanju variance uporabljamo popravek Newey-West [51].

Končne *p*-vrednosti in intervale zaupanja bomo dodali po ponovnem zagonu celotnega eksperimentalnega postopka. Pri interpretaciji bomo poleg statistične značilnosti upoštevali tudi velikost učinka. Majhna, vendar statistično značilna razlika namreč ni nujno ekonomsko pomembna, medtem ko je lahko večja razlika pri omejenem številu testnih oken statistično manj natančno ocenjena.

Tabela 8. Statistična primerjava napovednih scenarijev z zgodovinsko referenco. Končne vrednosti bodo dodane po ponovnem zagonu eksperimentov.

Model	razlika donosa	razlika Sharpa	<i>p</i> -vrednost
TACTIS-2	–	–	–
MASTER	–	–	–
TFT	–	–	–

4.6. Umestitev med sorodno literaturo. Neposredna številčna primerjava z drugimi študijami je zahtevna, saj se razlikujejo investicijski univerzumi, testna obdobja, omejitve portfeljev, modeli transakcijskih stroškov in način vrednotenja. Rezultatov zato ne primerjamo samo na podlagi absolutnih Sharpovih količnikov.

Bolj smiselna je primerjava zasnove eksperimenta. Naš pristop združuje napovedovanje donosov z modeli transformer, kardinalno omejeno mean-variance optimizacijo, dolgo-only portfelje, transakcijske stroške in postopno vrednotenje skozi več različnih tržnih obdobj.

Tabela 9 povzema izbrane sorodne študije in njihove glavne metodološke značilnosti.

Tabela 9. Umestitev med sorodne študije, ki povezujejo napovedne modele in sestavo portfelja. Vrednosti uspešnosti med študijami niso neposredno primerljive zaradi različnih univerzumov, obdobj, omejitev in stroškovnih modelov.

Študija	Model → portfelj	Univerzum in obdobje	Vrednotenje	Glavna značilnost
To delo	TACTiS-2 / MASTER / TFT → kardinalno omejeni MV	ameriške delnice velike kapitalizacije, več režimov	walk-forward, dolgo-only, stroški	primerjava treh transformerjev ter PSO in SA
Fernandes & Desell [7]	AttentionLSTM → portfelj	delnice S&P 500	walk-forward	napovedovanje donosov z mehanizmom pozornosti
Zhu & Yen [52]	Transformer-GAN → Black-Litterman	ameriške delnice	out-of-sample	vključevanje naučenih pogledov v Black-Litterman
Barua & Sharma [25]	CNN-BiLSTM → dinamični Black-Litterman	azijsko-pacifiški trgi	rolling	napovedni model povezan z alokacijo portfelja
Gu, Kelly & Xiu [21]	nevronska mreža → dolgo-kratki portfelji	velik presek ameriških delnic	rolling	strojno učenje za presečno napovedovanje donosov

Primerjava z literaturo tako služi predvsem umestitvi metodologije. Končne številčne rezultate bomo interpretirali glede na omejitve našega protokola in ne kot neposredno tekmovanje z rezultati drugih študij.

5. Omejitve

Pri interpretaciji rezultatov je treba upoštevati več omejitev.

Prva omejitev je količina podatkov. Finančne časovne vrste vsebujejo veliko dnevnih opazovanj, vendar se tržni režimi spreminjajo, zato starejši podatki niso nujno enako informativni za prihodnost. To omejuje količino podatkov, na katerih lahko napovedne modele smiselno učimo in vrednotimo.

Druga omejitev je izbira investicijskega univerzuma. Uporabljamo ameriške delnice velike kapitalizacije, zato rezultatov ni mogoče neposredno posplošiti na manjša podjetja, druge države ali druge razrede sredstev. Primerjava univerzumov *headline* in *divuniverse* delno preverja občutljivost na sestavo nabora sredstev, vendar ne nadomešča vrednotenja na drugih trgih.

Tretja omejitev je ocenjevanje prihodnje kovariance. TACTiS-2 jo ocenjuje iz skupne napovedne porazdelitve, medtem ko pri MASTER in TFT uporabljamo Ledoit-Wolfovno oceno iz zgodovinskih donosov. Razlike med temi scenariji zato ne izhajajo samo iz napovedi pričakovanih donosov, temveč pri TACTiS-2 tudi iz drugačnega načina ocenjevanja tveganja. To je namerna lastnost primerjave celotnih cevovodov, vendar jo je treba upoštevati pri interpretaciji rezultatov.

Četrta omejitev izhaja iz uporabe metahevrstik. PSO in SA lahko učinkovito preiskujeta velik in nekonvexen prostor portfeljev, vendar ne zagotavljata globalno optimalne rešitve. Preverjanje na OR-Library zato uporabljamo kot empirično oceno kakovosti optimizacije, ne kot dokaz optimalnosti.

Peta omejitev je model transakcijskih stroškov. Dejanski stroški trgovanja so odvisni od likvidnosti, velikosti naročila, razmika med nakupno in prodajno ceno ter tržnega vpliva. Uporabljeni poenostavljeni model omogoča primerljivo vrednotenje strategij, ne zajame pa vseh stroškov dejanskega trgovanja.

Nazadnje rezultati ostajajo odvisni od izbranih testnih obdobj. Z uporabo več tržnih režimov zmanjšamo tveganje, da bi zaključki izhajali samo iz enega specifičnega obdobja, vendar šest režimov še vedno predstavlja omejen vzorec možnih prihodnjih tržnih razmer.

6. Sklep

V magistrskem delu preučujemo povezavo med napovedovanjem prihodnjih donosov in kardinalno omejeno optimizacijo portfelja. Osnovna ideja je problem razdeliti na dva dela. Napovedni modeli pripravijo oceni pričakovanih donosov $\hat{\mu}$ in tveganja $\hat{\Sigma}$, optimizacijska algoritma pa na podlagi teh ocen poiščeta portfelj z natanko K sredstvi.

Za napovedovanje uporabljamo tri obstoječe modele transformer: TACTiS-2, MASTER in TFT. Modeli se razlikujejo v načinu, kako obravnavajo časovne in medsebojne povezave med sredstvi ter v obliki svojega izhoda.

TACTiS-2 napoveduje skupno porazdelitev prihodnjih donosov. Iz iste množice napovednih scenarijev zato ocenimo tako $\hat{\mu}_{\text{TACTiS}}$ kot $\hat{\Sigma}_{\text{TACTiS}}$. MASTER in TFT uporabljamo za oblikovanje napovedi pričakovanih donosov, njuno kovariančno matriko pa ocenimo iz zgodovinskih donosov z Ledoit-Wolfovimi krčenjem. S tem lahko vse tri modele povežemo z istim mean-variance optimizacijskim problemom.

Kardinalno omejeni problem rešujemo z rojenjem delcev in simuliranim ohlajanjem. Algoritma uporabljata različna načina preiskovanja prostora rešitev. PSO hkrati premika populacijo kandidatnih portfeljev in uporablja informacije o njihovih najboljših doslej najdenih položajih. SA preiskuje okolico ene trenutne rešitve in lahko pri višji temperaturi začasno sprejme tudi slabši portfelj. Oba algoritma uporabljata isto ciljno funkcijo in enake omejitve.

Pred uporabo na realnih podatkih kakovost optimizatorjev preverimo na standardnih primerih OR-Library. Namen tega koraka je ločiti kakovost optimizacije od kakovosti napovednih modelov. Celoten cevovod nato vrednotimo s postopnim testiranjem na več različnih tržnih obdobjih, pri čemer pri vsaki odločitvi uporabljamo samo podatke, ki bi bili v tistem trenutku dejansko na voljo.

Končni empirični del bo odgovoril predvsem na tri vprašanja. Prvo je, ali modeli TACTiS-2, MASTER in TFT vsebujejo zunaj-vzorčno informacijo o prihodnjem relativnem gibanju sredstev. Drugo je, ali se ta napovedna informacija po vključitvi tveganja, kardinalne omejitve in transakcijskih stroškov prenese tudi v boljše portfelje. Tretje je, ali so ugotovitve stabilne pri uporabi dveh različnih optimizacijskih algoritmov in skozi različne tržne režime.

Pri interpretaciji rezultatov bo pomembno ločiti med napovedno in portfeljsko uspešnostjo. Višji IC še ne zagotavlja boljšega portfelja, saj na končne uteži vplivajo tudi kovariančna matrika, omejitve in parameter P . Podobno višji kumulativni donos sam po sebi ni dovolj, če ga spremljajo bistveno večja volatilitnost, največji upad ali obrat portfelja. Zato rezultate obravnavamo z več medsebojno dopolnjujočimi se merami.

Delo je mogoče nadgraditi v več smereh. Napovedne modele bi lahko razširili z dodatnimi tržnimi, makroekonomskimi in temeljnimi značilkami. Pri ocenjevanju tveganja bi bilo mogoče primerjati dodatne metode regularizacije kovariančne matrike ali uporabiti realizirane kovariance iz podatkov višje frekvence.

Optimizacijski del bi lahko razširili z dodatnimi realističnimi omejitvami, kot so sektorske omejitve, omejitve obrata in neposredno vključevanje transakcijskih stroškov v ciljno funkcijo. Smiselna bi bila tudi primerjava z natančnimi metodami mešanega celoštevilskega kvadratnega programiranja na manjših problemih, kjer je mogoče globalni optimum izračunati v sprejemljivem času.

Nazadnje bi bilo cevovod smiselno ovrednotiti na več trgih, širšem naboru sredstev in daljših časovnih obdobjih. S tem bi lahko natančneje ocenili, ali so morebitne prednosti napovednih modelov značilne za uporabljeni ameriški delniški univerzum ali pa se ohranijo tudi v drugačnih tržnih okoljih.

Literatura

1. Markowitz H (1952) Portfolio selection. *The Journal of Finance* 7(1):77–91.
2. Lim B, Arık SÖ, Loeff N, Pfister T (2021) Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting* 37(4):1748–1764.
3. Li T et al. (2024) MASTER: Market-guided stock transformer for stock price forecasting in *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 38, pp. 162–170.
4. Ashok A, Marcotte É, Zantedeschi V, Chapados N, Drouin A (2024) TACTiS-2: Better, faster, simpler attentional copulas for multivariate time series in *International Conference on Learning Representations (ICLR)*.
5. Chang TJ, Meade N, Beasley JE, Sharaiha YM (2000) Heuristics for cardinality constrained portfolio optimisation. *Computers & Operations Research* 27(13):1271–1302.
6. Ramos HP, Righi MB, Guedes PC, Müller FM (2023) A comparison of risk measures for portfolio optimization with cardinality constraints. *Expert Systems with Applications* 228:120412.
7. Fernandes R, Desell T (2026) Financially guided deep portfolio optimization. *arXiv preprint arXiv:2605.28853*.
8. Michaud RO (1989) The Markowitz optimization enigma: Is 'optimized' optimal? *Financial Analysts Journal* 45(1):31–42.
9. Black F, Litterman R (1992) Global portfolio optimization. *Financial Analysts Journal* 48(5):28–43.
10. He G, Litterman R (1999) The intuition behind Black-Litterman model portfolios, (Goldman Sachs Investment Management Research), Technical report.
11. DeMiguel V, Garlappi L, Uppal R (2009) Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies* 22(5):1915–1953.
12. Bessler W, Opfer H, Wolff D (2017) Multi-asset portfolio optimization and out-of-sample performance: An evaluation of Black-Litterman, mean-variance, and naive diversification approaches. *The European Journal of Finance* 23(1):1–30.
13. Tu J, Zhou G (2011) Markowitz meets talmud: A combination of sophisticated and naive diversification strategies. *Journal of Financial Economics* 99(1):204–215.
14. Bienstock D (1996) Computational study of a family of mixed-integer quadratic programming problems. *Mathematical Programming* 74(2):121–140.
15. Gao J, Li D (2013) Optimal cardinality constrained portfolio selection. *Operations Research* 61(3):745–761.
16. Brodie J, Daubechies I, De Mol C, Giannone D, Loris I (2009) Sparse and stable Markowitz portfolios. *Proceedings of the National Academy of Sciences of the United States of America*

- 106(30):12267–12272.
17. Kim MJ, Lee Y, Kim JH, Kim WC (2016) Sparse tangent portfolio selection via semi-definite relaxation. *Operations Research Letters* 44(4):540–543.
 18. Akbay MA, Kalayci CB, Polat O (2020) A parallel variable neighborhood search algorithm with quadratic programming for cardinality constrained portfolio optimization. *Knowledge-Based Systems* 198:105944.
 19. Jegadeesh N, Titman S (1993) Returns to buying winners and selling losers: Implications for stock market efficiency. *The Journal of Finance* 48(1):65–91.
 20. Carhart MM (1997) On persistence in mutual fund performance. *The Journal of Finance* 52(1):57–82.
 21. Gu S, Kelly B, Xiu D (2020) Empirical asset pricing via machine learning. *The Review of Financial Studies* 33(5):2223–2273.
 22. Ke G et al. (2017) LightGBM: A highly efficient gradient boosting decision tree in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 3146–3154.
 23. Selvin S, Vinayakumar R, Gopalakrishnan EA, Menon VK, Soman KP (2017) Stock price prediction using LSTM, RNN and CNN-sliding window model in 2017 *International Conference on Advances in Computing, Communications and Informatics (ICACCI)*. pp. 1643–1647.
 24. Hochreiter S, Schmidhuber J (1997) Long short-term memory. *Neural Computation* 9(8):1735–1780.
 25. Barua R, Sharma AK (2022) Dynamic Black Litterman portfolios with views derived via CNN-BiLSTM predictions. *Finance Research Letters* 49:103111.
 26. Vaswani A et al. (2017) Attention is all you need in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 5998–6008.
 27. Wang C, Chen Y, Zhang S, Zhang Q (2022) Stock market index prediction using deep Transformer model. *Expert Systems with Applications* 208:118128.
 28. Zhang Q et al. (2022) Transformer-based attention network for stock movement prediction. *Expert Systems with Applications* 202:117239.
 29. Wu H, Xu J, Wang J, Long M (2021) Autoformer: Decomposition transformers with Auto-Correlation for long-term series forecasting in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 34.
 30. Das A, Kong W, Sen R, Zhou Y (2024) A decoder-only foundation model for time-series forecasting in *Proceedings of the 41st International Conference on Machine Learning (ICML)*.
 31. Ye J, Zhao J, Ye K, Xu C (2021) Multi-graph convolutional network for relationship-driven stock movement prediction in 2020 *25th International Conference on Pattern Recognition (ICPR)*. pp. 6702–6709.
 32. Li W et al. (2020) Modeling the stock relation with graph network for overnight stock movement prediction in *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence*. pp. 4541–4547.
 33. Sawhney R, Agarwal S, Wadhwa A, Shah RR (2020) Deep attentive learning for stock movement prediction from social media text and company correlations in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. (Association for Computational Linguistics), pp. 8415–8426.
 34. Cheng D, Yang F, Xiang S, Liu J (2022) Financial time series forecasting with multi-modality graph neural network. *Pattern Recognition* 121:108218.
 35. Fan J, Fan Y, Lv J (2008) High dimensional covariance matrix estimation using a factor model. *Journal of Econometrics* 147(1):186–197.
 36. Engle R (2002) Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics* 20(3):339–350.
 37. Chiriac R, Voev V (2011) Modelling and forecasting multivariate realized volatility. *Journal of Applied Econometrics* 26(6):922–947.
 38. Ledoit O, Wolf M (2004) A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis* 88(2):365–411.
 39. Lin H, Zhou D, Liu W, Bian J (2021) Deep risk model: A deep learning solution for mining latent risk factors to improve covariance matrix estimation in *Proceedings of the Second ACM International Conference on AI in Finance (ICAIF)*.
 40. Yang R, et al. (2025) Neural nonlinear shrinkage of covariance matrices for minimum variance portfolio optimization. *arXiv preprint arXiv:2601.15597*.
 41. Salinas D, Bohlke-Schneider M, Callot L, Medico R, Gasthaus J (2019) High-dimensional multivariate forecasting with low-rank Gaussian copula processes in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 32, pp. 6824–6834.
 42. Kennedy J, Eberhart R (1995) Particle swarm optimization in *Proceedings of the IEEE International Conference on Neural Networks*. Vol. 4, pp. 1942–1948.
 43. Cura T (2009) Particle swarm optimization approach to portfolio optimization. *Nonlinear Analysis: Real World Applications* 10(4):2396–2406.
 44. Kirkpatrick S, Gelatt CD, Vecchi MP (1983) Optimization by simulated annealing. *Science* 220(4598):671–680.
 45. Crama Y, Schyns M (2003) Simulated annealing for complex portfolio selection problems. *European Journal of Operational Research* 150(3):546–571.
 46. Sharpe WF (1994) The Sharpe ratio. *The Journal of Portfolio Management* 21(1):49–58.
 47. Sortino FA, Price LN (1994) Performance measurement in a downside risk framework. *The Journal of Investing* 3(3):59–64.
 48. Keating C, Shadwick WF (2002) A universal performance measure. *Journal of Performance Measurement* 6(3):59–84.
 49. Grinold RC, Kahn RN (2000) *Active Portfolio Management: A Quantitative Approach for Producing Superior Returns and Controlling Risk*. (McGraw-Hill, New York), 2nd edition.
 50. Beasley JE (1990) OR-Library: Distributing test problems by electronic mail. *Journal of the Operational Research Society* 41(11):1069–1072.
 51. Newey WK, West KD (1987) A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica* 55(3):703–708.
 52. Zhu E, Yen J (2024) Enhancing portfolio optimization with transformer-GAN integration: A novel approach in the Black-Litterman framework. *arXiv preprint arXiv:2404.02029*.