

Optimizacija naložbenih portfeljev z uporabo transformerjev in globalnih optimizacijskih algoritmov

Nejc Škrbec

Magistrski študijski program Računalništvo in informatika, smer Računalništvo in informatika

Fakulteta za računalništvo in informatiko

Mentor: doc. dr. Luka Fürst

Copyright: To delo je ponujeno pod licenco CC-BY-4.0. Razvita programska oprema in rezultati dela so na voljo v okviru GPL-3.0-or-later na <https://github.com/nejcskrbec/portfolio-optimization-using-transformers-and-global-optimization-algorithms>.

V magistrskem delu obravnavamo kardinalno omejeno optimizacijo naložbenih portfeljev, pri kateri sta ključna izziva ocenjevanje pričakovanih donosov in iskanje optimalnih uteži ob zahtevi, da portfelj vsebuje natanko K pozicij. Pričakovane donose ocenjujemo s tremi arhitekturno različnimi transformerskimi modeli (MASTER, TFT in PatchTST), katerih nevronska jedra povzamemo po uradnih izvedbah avtorjev. Kovariančno matriko pri vseh pristopih ocenimo enako iz zgodovinskih donosov, zato primerjava izolira vpliv napovednega signala. Uteži nato optimiziramo z rojenjem delcev in simuliranim ohlajanjem. Oba dela našega optimizacijskega pristopa najprej ovrednotimo ločeno, nato pa skupaj postopno vrednotimo na tes treh objavljenih študij in na lastnem primeru dolgoročnega vlaganja. V vseh petih preizkusih vsaj en transformerski model preseže svoje ujemaajoče zgodovinsko povprečje. PatchTST je najuspešnejši v dolgoročnem primeru in na naboru DJIA, MASTER na naboru NASDAQ 100, TFT pa v kriznem obdobju.

Optimizacija portfelja | Kardinalna omejitev | Transformerji | Napovedovanje donosov | Metahevrstike | Rojenje delcev

Optimizacija naložbenih portfeljev (v nadaljevanju ONP) predstavlja enega temeljnih problemov kvantitativnih financ. Cilj njenega reševanja je razporediti razpoložljivi kapital med več finančnih sredstev tako, da dosežemo čim ugodnejše razmerje med pričakovanim donosom in tveganjem.

Denimo, da imamo nabor N finančnih sredstev, ki jih spremljamo v diskretnih časovnih korakih $t = 0, 1, \dots, T$. Ob koncu vsakega trgovalnega dne ima vsako sredstvo določeno zaključno ceno $p_{i,t}$. Enostavni donos $r_{i,t}$ in logaritemski donos $\tilde{r}_{i,t}$ definiramo z enačbama (1). Enostavni donos izraža relativno spremembo vrednosti sredstva, logaritemski pa je priročnejši pri modeliranju.

$$r_{i,t} = \frac{p_{i,t} - p_{i,t-1}}{p_{i,t-1}} = \frac{p_{i,t}}{p_{i,t-1}} - 1, \quad \tilde{r}_{i,t} = \ln \left(\frac{p_{i,t}}{p_{i,t-1}} \right). \quad (1)$$

Portfelj sestavimo v odločitvenem trenutku t , to sestavo pa imenujemo odločitev. Nato vstopimo v napovedno obdobje od $t+1$ do $t+H$, v katerem portfelj ostane nespremenjen do naslednjega uravnoveženja. Napovedno obdobje torej obsega H prihodnjih trgovalnih dni in je hkrati obdobje, za katero napovedni model tvori napoved. Glede na uporabljeni model se lahko razlikujeta definicija ciljne spremenljivke in način, kako dnevne napovedi združimo v skupno oceno za napovedno obdobje. Konkretno oblikovanje napovedi zato opišemo pri posameznih modelih v razdelku 2.

Donose vseh sredstev v času t zberemo v vektor $\mathbf{r}_t = (r_{1,t}, \dots, r_{N,t})^\top$. Portfelj opišemo z vektorjem uteži $\mathbf{w} = (w_1, \dots, w_N)^\top$, kjer w_i predstavlja delež kapitala, vloženega v sredstvo i . Donos portfelja r_t^p opišemo z enačbo (2).

$$r_t^p = \mathbf{w}^\top \mathbf{r}_t. \quad (2)$$

Klasično izhodišče za reševanje ONP predstavlja Markowitzev model [1], ki portfelj obravnava na podlagi pričakovanih donosov sredstev ter njihovega tveganja in medsebojne povezanosti. Prvo opišemo z vektorjem μ , tveganje pa s kovariančno matriko Σ . Enačbi obeh zapišemo kot (3).

$$\mu = \mathbb{E}[\mathbf{r}], \quad \Sigma = \mathbb{E}[(\mathbf{r} - \mu)(\mathbf{r} - \mu)^\top]. \quad (3)$$

V praksi točnih prihodnjih vrednosti μ in Σ ne moremo poznati preden se lotimo optimizacije, zato moramo najprej poiskati in kasneje pri optimizaciji uporabiti njuni oceni $\hat{\mu}$ in $\hat{\Sigma}$. Pri tem je treba upoštevati, da lahko nenatančne ocene pričakovanih donosov vodijo do neugodnega končnega razmerja med donosom in tveganjem v portfelju, tudi kadar je sam optimizacijski postopek izveden optimalno. V razdelku 2 podrobneje predstavimo načine ocenjevanja obeh količin, pri čemer se osredotočimo predvsem na uporabo transformerskih modelov za ocenjevanje pričakovanih donosov.

V tej nalogi klasično ONP razširimo z omejitvami, ki bolje odražajo praktične zahteve pri sestavi portfelja. Najpomembnejša je kardinalna omejitev, ki zahteva, da portfelj vsebuje natanko K različnih sredstev. Tako lahko na primer pri oblikovanju portfelja iz univerzuma indeksa S&P 500 omejimo število izbranih sredstev na vnaprej določeno

Investment Portfolio Optimization Using Transformers and Global Optimization Algorithms

This thesis studies cardinality-constrained portfolio optimization, where the two central challenges are estimating expected returns and finding optimal weights subject to the requirement that the portfolio holds exactly K active positions. Expected returns are estimated with three architecturally distinct transformer models (MASTER, TFT and PatchTST), whose neural cores follow the authors' official implementations; our own modifications are restricted to the data interface and to converting the model output into an expected-return estimate. The covariance matrix is estimated identically from historical returns for all approaches, so the comparison isolates the effect of the forecasting signal. Portfolio weights are then optimized with particle swarm optimization and simulated annealing. The forecasting and optimization stages are first evaluated separately, the former with cross-sectional forecasting measures and the latter on the standard OR-Library instances. The complete pipeline is then tested out of sample with walk-forward evaluation on the protocols of three published studies and in an additional long-term investor scenario. In all five experiments at least one transformer clearly beats its matched historical mean, but which model does so changes systematically with the asset universe and the protocol: PatchTST is strongest in the long-term scenario (Sharpe ratio 1.38 against 1.10 for its historical mean) and on DJIA, MASTER on NASDAQ 100 (1.23 against 1.03), and TFT in the crisis period. Differences between the two optimizers are small and inconsistent, indicating that the quality of the expected-return estimate is the dominant driver of portfolio performance.

Portfolio optimization | Cardinality constraint | Transformers | Return forecasting | Metaheuristics | Particle swarm optimization

vrednost K . Izbira optimalne vrednosti K predstavlja ločen problem, ki ga v tem delu ne obravnavamo. Za vsako izbrano sredstvo dodatno določimo še najmanjši in največji dovoljeni delež v portfelju. Tako dobimo kardinalno omejeno optimizacijo naložbenega portfelja (v nadaljevanju KONP).

KONP je zahtevnejša od osnovne ONP, ker poleg določanja uteži vključuje tudi diskretno izbiro sredstev: optimizator mora hkrati določiti, katerih K sredstev izmed N bo vključil in kako bo mednje razporedil kapital. Že sam izbor omogoča $\binom{N}{K}$ kombinacij, zato izčrpno iskanje pri večjih problemih hitro postane nepraktično [2]. V razdelku 4 zato predstavimo dva stohastična globalna optimizacijska algoritma, ki ju uporabimo za reševanje tega problema.

KONP zapišemo z enačbo (4), ki združuje ocenjeni pričakovani donos portfelja $\hat{\mu}^\top \mathbf{w}$ in njegovo ocenjeno tveganje, izraženo s kovariančno matriko $\mathbf{w}^\top \hat{\Sigma} \mathbf{w}$. Parameter $P \in [0, 1]$ določa razmerje med njima: večja vrednost daje večjo težo pričakovanemu donosu, manjša pa zmanjševanju tveganja.

Poleg osnovne enačbe moramo nabor veljavnih rešitev KONP omejiti še z nekaj omejitvami. Proračunska omejitev (5) zahteva, da je vsota vseh uteži enaka ena, zato je ves razpoložljivi kapital razporejen med sredstva. Kardinalna omejitev (6) zahteva, da je v portfelj vključenih natanko K sredstev, pri čemer binarna spremenljivka z_i določa, ali je sredstvo i vključeno v portfelj. Utežna omejitev (7) povezuje izbiro sredstva z njegovo utežjo: pri $z_i = 0$ mora biti $w_i = 0$, pri $z_i = 1$ pa mora utež ležati med spodnjo mejo ε_i , ki preprečuje zanemarljivo majhne pozicije, in zgornjo mejo δ_i , ki omejuje koncentracijo kapitala v posameznem sredstvu.

$$\max_{\mathbf{w}, \mathbf{z}} \quad P \hat{\mu}^\top \mathbf{w} - (1 - P) \mathbf{w}^\top \hat{\Sigma} \mathbf{w} \quad (4)$$

$$\text{p.p.} \quad \sum_{i=1}^N w_i = 1, \quad (5)$$

$$\sum_{i=1}^N z_i = K, \quad (6)$$

$$\varepsilon_i z_i \leq w_i \leq \delta_i z_i, \quad z_i \in \{0, 1\}, \quad i = 1, \dots, N. \quad (7)$$

V našem delu za reševanje KONP vpeljemo dvostopenjski eksperimentalni postopek:

1. Najprej ocenimo pričakovane donose $\hat{\mu}$. Namesto zgolj zgodovinskega povprečja uporabimo tri arhitekturno različne transformerske modele: PatchTST [3], Temporal Fusion Transformer (TFT) [4] in MASTER [5]. Njihovo delovanje in način vrednotenja predstavimo v razdelku 2. Pred reševanjem KONP napovedne ocene in oceno tveganja postavimo na skupno skalo, podrobnosti tega postopka pa opišemo v razdelku 2. Kovariančno matriko $\hat{\Sigma}$ enostavno ocenimo iz zgodovinskih donosov.
2. Tako dobljene ocene pričakovanih donosov uporabimo pri reševanju KONP z dvema stohastičnima globalnima optimizacijskima algoritmoma: rojenjem delcev (RD) in simuliranim ohlajanjem (SO). Oba algoritma omogočata iskanje kakovostnih rešitev brez izčrpnega pregleda vseh kombinacij sredstev, vendar prostor rešitev raziskujeta na različna načina. Algoritma podrobneje predstavimo v razdelku 4.

Evalvacija eksperimentalnega postopka poteka v dveh delih. Najprej napovedni in optimizacijski del ovrednotimo ločeno. Napovedne modele ocenimo z merami povezanosti med napovedanimi in realiziranimi donosi, algoritma RD in SO pa na standardnih testnih problemih z znanimi referenčnimi rezultati. Metodologijo vrednotenja in uporabljene mere podrobneje opišemo v razdelku 5.

Nato ovrednotimo še celoten eksperimentalni postopek s postopnim vrednotenjem zunaj učnega vzorca (angl. *out-of-sample walk-forward evaluation*) na eksperimentih treh predhodnih raziskav [6–8], ki se razlikujejo po naboru sredstev, časovnem obdobju, pogostosti uravnoteževanja in napovednem obdobju, ter v dodatnem primeru dolgoročnega vlaganja, v katerem preverimo praktično uporabnost našega pristopa. Rezultate eksperimentalne evalvacije predstavimo v razdelku 6, kjer ločeno obravnavamo napovedne in optimizacijske rezultate ter rezultate celotnega eksperimentalnega postopka.

Osrednji prispevek dela je povezava sodobnih transformerskih napovednih modelov z metahevrističnim reševanjem KONP ter ločeno vrednotenje obeh delov našega pristopa. Tako lahko analiziramo dve povezani vprašanji: ali kakovostnejše napovedi pričakovanih donosov vodijo do uspešnejših portfeljev in koliko je končni rezultat odvisen od uporabljenega optimizacijskega postopka. V sklepu v razdelku 7 povzamemo glavne ugotovitve in možnosti za nadaljnje raziskovanje.

1. Sorodna dela

Znanstvene članke, ki si delijo raziskovalno področje z našim delom, lahko razdelimo na tri skupine: optimizacijo portfeljev, napovedovanje prihodnjih donosov in ocenjevanje tveganja. Na vseh treh se je razvoj postopoma premikal od preprostejših statističnih pristopov k metodam, ki lahko obravnavajo več podatkov, več omejitev in zahtevnejše povezave med sredstvi.

1.1. Optimizacija naložbenih portfeljev. Po Markowitzevem modelu [1] se je velik del raziskav osredotočil na vprašanje, kako zanesljivi so optimizirani portfelji, kadar so njihovi vhodni podatki ocenjeni iz omejenega nabora. Michaud [9] je opozoril, da lahko že majhne napake v ocenjenih donosih povzročijo velike spremembe v sestavi portfelja. Zato so se razvili pristopi, ki skušajo zmanjšati vpliv teh napak. Med najbolj znanimi je Black–Littermanov model [10, 11], ki pri oblikovanju ocen prihodnjih donosov upošteva dodatne informacije o trgu. Empirične primerjave so hkrati pokazale, da zahtevnejša optimizacija ni vedno uspešnejša od preprostih strategij [12–14].

Omenimo še pristope k reševanju KONP. Zgodnejše raziskave so uporabljale natančne matematične postopke [15, 16], vzporedno pa so se razvijali tudi hevristični pristopi, ki iščejo kakovostne rešitve brez preiskovanja vseh možnih kombinacij [2]. Kasnejše metode so problem poskušale poenostaviti tako, da spodbujajo manjše število izbranih sredstev [17, 18], ali pa so združile več različnih načinov iskanja in določanja uteži [19].

1.2. Napovedovanje pričakovanih donosov. Zgodnejše raziskave napovedovanja donosov so iskale predvsem ponavljajoče se zakonitosti v preteklih podatkih in ekonomskih značilnostih sredstev. Primer je moment, pri katerem imajo sredstva z relativno boljšimi preteklimi donosi v določenih obdobjih težnjo, da ostanejo uspešnejša tudi v bližnji prihodnosti [20, 21]. Takšni pristopi temeljijo predvsem na vnaprej določenih signalih. Z večjo količino razpoložljivih podatkov pa so se začele uporabljati metode strojnega učenja, ki lahko same poiščejo uporabne nelinearne povezave med večjim številom značilk [22]. Med takšne pristope sodijo tudi modeli, kot je LightGBM [23].

Naslednji korak je bil neposredno modeliranje časovnega razvoja podatkov z nevronske mrežami. Selvin in sod. [24] so pri napovedovanju cen delnic primerjali več rekurentnih in konvolucijskih arhitektur. Modeli, kot je LSTM [25], so bili pri tem zanimivi predvsem zato, ker lahko pri napovedi upoštevajo informacije iz daljšega zaporedja preteklih opazovanj. Napovedni modeli so se začeli vključevati tudi neposredno v postopke sestave portfeljev. Barua in Sharma [26] sta na primer napovedi nevronskega modela uporabila kot vhod v Black–Littermanov pristop.

Novejši razvoj predstavljajo arhitekture s pozornostjo in transformerji [27]. Ti omogočajo, da model pri napovedi neposredno ovrednoti pomen različnih delov vhodnega zaporedja, zato so postali zanimivi tudi za finančne časovne vrste [28, 29]. Vzporedno so se razvili splošnejši modeli za napovedovanje časovnih vrst [30, 31]. Raziskave se hkrati vse bolj oddaljujejo od obravnave posamezne delnice kot izoliranega zaporedja. Nekateri modeli upoštevajo povezave med različnimi delnicami [32, 33], drugi pa cenovne podatke dopolnjujejo z novicami, besedili in informacijami o podjetjih [34, 35]. Leow in sod. [6] so na primer razpoložnje iz družbenih omrežij, ki ga zajamejo z modelom BERT, prek genetskega algoritma vključili v klasično sestavo portfelja; njihovo delo uporabimo kot zunanjo referenčno primerjavo v razdelku 6.2. V našem delu iz tega širšega razvoja izberemo TFT [4], MASTER [5] in PatchTST [3], ki predstavljajo tri različne načine uporabe transformerjev za napovedovanje časovnih vrst in finančnih donosov.

1.3. Ocenjevanje tveganja in kovariančne matrike. Pri sestavi portfelja moramo poleg prihodnjih donosov oceniti tudi tveganje in povezanost med sredstvi. Osnovna težava je, da pri večjem številu sredstev hitro naraste število povezav, ki jih moramo oceniti iz omejenega števila opazovanj. Raziskave so zato iskale načine, kako ocenjevanje poenostaviti ali stabilizirati. Faktorski modeli skupno gibanje velikega števila sredstev opišejo z manjšim številom skupnih dejavnikov [36]. Druga smer upošteva, da se tveganje in povezanost med sredstvi skozi čas spreminjata, zato ju modelira dinamično [37, 38].

Pomemben pristop je tudi neposredna stabilizacija kovariančne matrike, saj je vzorčna cenilka pri omejenem številu opazovanj lahko zelo nestabilna. Novejše raziskave to težavo rešujejo z metodami strojnega učenja. Nekateri pristopi se iz podatkov učijo skupnih dejavnikov tveganja [39], drugi pa poskušajo izboljšati samo oceno kovariančne matrike [40]. Še druga možnost je, da namesto posameznih kovarianc modeliramo skupno porazdelitev več časovnih vrst; tak primer je GPVar [41]. V tej nalogi se osredotočimo predvsem na vpliv napovedi pričakovanih donosov, zato pri vseh treh transformerskih modelih uporabimo isto vzorčno kovariančno matriko zgodovinskih donosov. S tem pri primerjavi napovednih modelov ohranimo nespremenjen vhod, ki opisuje tveganje.

2. Napovedovanje pričakovanih donosov

V našem delu $\hat{\mu}$ ocenimo z zgodovinskim povprečjem in s tremi transformerskimi modeli: PatchTST [3], Temporal Fusion Transformer (TFT) [4] in MASTER [5]. Postopek učenja je skupen vsem trem napovednim modelom in je opisan v razdelku 5.2.

2.1. Zgodovinsko povprečje. Pričakovani donos sredstva i ocenimo kot njegov povprečni dnevni donos $r_{t,i}$ v zadnjih L trgovalnih dneh pred odločitvenim trenutkom t , preračunan na napovedno obdobje H , kar opišemo z enačbo (8). Na ta način tudi izvori članki naših optimizacijskih algoritmov dobijo vhodne podatke za optimizacijski postopek [2, 42].

$$\hat{\mu}_{t,i} = H \cdot \frac{1}{L} \sum_{k=0}^{L-1} r_{t-k,i}. \quad (8)$$

2.2. PatchTST. [3] je transformerski model za napovedovanje večspremenljivih časovnih vrst. Večspremenljiva časovna vrsta vsebuje več spremenljivk, opazovanih skozi čas, medtem ko univariatna časovna vrsta vsebuje le eno spremenljivko. Njegovi ključni značilnosti sta razdelitev vhodnega zaporedja na krajše odseke (angl. *patches*) in neodvisna obravnava posameznih kanalov. Kanal predstavlja eno univariatno časovno vrsto. V našem primeru posamezen kanal predstavlja dnevne logaritemske donose enega finančnega sredstva. Če spremljamo N sredstev v L zaporednih dneh, vhod predstavlja matrika velikosti $L \times N$, pri čemer vsak stolpec predstavlja en kanal. PatchTST kanale obravnava ločeno, vendar med njimi deli iste naučene parametre, kar avtorji imenujejo neodvisnost kanalov (angl. *channel independence*).

Naj bo L dolžina vhodnega zaporedja, P dolžina posameznega odseka in S korak med začetkoma dveh zaporednih odsekov. Če je $S < P$, se odseki prekrivajo. Večji L omogoča uporabo daljšega zgodovinskega konteksta, večji P pa zajame več lokalnega časovnega konteksta v posameznem žetonu. Razdelitev na odseke zmanjša število vhodnih žetonov, kar zmanjša računsko in pomnilniško zahtevnost modela.

Vsak odsek se z naučljivo linearno preslikavo preslika v notranji prostor dimenzije D , nato pa se mu doda pozicijska vdelava, ki ohrani informacijo o njegovem položaju v zaporedju. Zaporedje tako dobljenih žetonov nato obdela transformerski kodirnik, ki s samopozornostjo modelira odvisnosti med različnimi odseki. Končna predstavitev se uporabi za napoved prihodnjih vrednosti.

Osnovne arhitekture modela ne spreminjamo, saj uporabljamo repozitorij avtorjev [43]. Za reševanje KONP z modelom za posamezno sredstvo napovedujemo dnevne logaritemske donose $\hat{r}_{i,t+h}$ za naslednjih H dni ($h = 1, \dots, H$). Iz njih izračunamo H -dnevni enostavni donos po enačbi (9), napovedi vseh sredstev pa nato zberemo v vektor $\hat{\mu}_{\text{PatchTST}}$.

$$r_{i,t}^{(H)} = \exp \left(\sum_{h=1}^H \tilde{r}_{i,t+h} \right) - 1. \quad (9)$$

2.3. Temporal Fusion Transformer. [4] je transformerski model za večhorizontno napovedovanje časovnih vrst, zasnovan za delo z različnimi vrstami vhodnih značilk. Model podpira tri glavne skupine značilk, ki jih obravnava z mehanizmom izbire spremenljivk (angl. *variable selection*), rekurentnimi plastmi LSTM in časovno samopozornostjo (angl. *temporal self-attention*). Tri vrste značilk so naslednje:

1. **Statične značilke** (angl. *static covariates*) se skozi čas ne spreminjajo (npr. kategorija, identifikator). Pri reševanju KONP posamezno sredstvo predstavlja eno časovno vrsto zato kot statično značilko uporabimo oznako sredstva (angl. *ticker*). Statične značilke model predstavi z naučljivo vdelavo, s čimer lahko pri skupnem učenju razlikuje med posameznimi časovnimi vrstami.
2. **Časovno spremenljive opazovane značilke** (angl. *time-varying observed variables*) imajo vrednosti, ki so nam znane do trenutka napovedi, prihodnje vrednosti pa niso znane (npr. zgodovinske vrednosti). Pri reševanju KONP sem spadajo dnevni logaritemski donosi $\tilde{r}_{i,t}$. Poleg njih pa uporabimo še 20-dnevni momentum, ki povzame kumulativno gibanje cene sredstva in pa 20-dnevno volatilnost, ki meri variabilnost dnevnih donosov v zadnjem obdobju. Vse tri časovno spremenljive opazovane značilke v naši implementaciji izračunamo iz zaključnih cen sredstev.
3. **Časovno spremenljive znane značilke** (angl. *time-varying known variables*) so značilnosti, katerih prihodnje vrednosti so ob trenutku napovedi že znane (npr. datum, dan v tednu, praznik ali vnaprej določen urnik). Takšnih značilk pri reševanju KONP ne uporabljamo.

TFT implementiramo z modelom `TemporalFusionTransformer` iz knjižnice `pytorch-forecasting`. Ciljna spremenljivka je dnevni logaritemski donos $\tilde{r}_{i,t}$ posameznega sredstva. Model je zasnovan za kvantilno regresijo, pri kateri za vsak prihodnji dan napove več kvantilov ciljnega donosa. Kvantil določa mejo določenega deleža napovedanih vrednosti, pri čemer $q = 0,5$ predstavlja mediano. V naši implementaciji iz izračunanih kvantilov uporabimo kvantil $q = 0,5$ in tako dobimo eno napovedano vrednost dnevnega logaritemskega donosa $\tilde{r}_{i,t+h}$ za vsakega od naslednjih H dni ($h = 1, \dots, H$). Te dnevne napovedi nato združimo v napoved H -dnevnega enostavnega donosa po enačbi (9), napovedi vseh N sredstev pa zberemo v vektor $\hat{\mu}_{\text{TFT}}$.

2.4. MASTER. [5] je transformerski model, namenjen napovedovanju standardizirane vrednosti prihodnjega donosa delnic. Za posamezno sredstvo u in napovedno obdobje H je osnova za ciljno spremenljivko prihodnji H -dnevni enostavni donos, ki ga definiramo z enačbo (10).

$$r_{u,t}^{\text{MASTER}} = \frac{p_{u,t+H}}{p_{u,t+1}} - 1. \quad (10)$$

Pri učenju ta donos za vsak datum presečno standardiziramo, zato MASTER napoveduje relativni položaj sredstva glede na druga sredstva na istem datumu. Poleg časovnih vzorcev znotraj posameznega sredstva modelira tudi presečne povezave med sredstvi. Njegova ključna značilnost je tržno vodeno uteževanje značilk (angl. *market-guided gating*), pri katerem tržni kontekst vpliva na uteževanje vhodnih značilk. Model nato informacije obdeluje z agregacijo znotraj sredstva (angl. *intra-stock aggregation*), agregacijo med sredstvi (angl. *inter-stock aggregation*) in časovno agregacijo (angl. *temporal aggregation*) [5].

Arhitekture modela ne spreminjamo, saj smo jo povzeli iz uradnega repozitorija avtorjev [45], prilagodili pa smo pripravo vhodnih značilk za uporabo modela na ameriških delnicah. MASTER je bil izvirno razvit in ovrednoten na kitajskih delnicah ter uporablja podatkovno infrastrukturo Qlib [46], odprtokodno platformo za kvantitativne raziskave in strojno učenje na finančnih podatkih. Za posamezno sredstvo model prejme 158 značilk Alpha158 [46], izpeljanih iz dnevnih podatkov OHLCV (cena ob odprtju, najvišja in najnižja cena, cena ob zaprtju ter promet). Značilke Alpha158 smo v naši implementaciji ponovno izračunali iz podatkov OHLCV, prenesenih prek knjižnice `yfinance`. Vse vhodne značilke robustno normaliziramo na podlagi mediane in mediane absolutnih odklonov (MAD), da zmanjšamo vpliv ekstremnih vrednosti na napovedi modela. Parametre normalizacije ocenimo izključno na učnem obdobju, normalizirane vrednosti omejimo na interval $[-3, 3]$, manjkajoče vrednosti pa nadomestimo z nič.

Poleg značilk posameznega sredstva model uporablja tudi skupni tržni vektor $\mathbf{m}_t$, ki je enak za vsa sredstva. V naši implementaciji ga sestavlja 63 značilk, izpeljanih iz treh ameriških ETF-ov SPY, IWM in VTI ter njihovih dnevnih donosov, kotalnega povprečja in standardnega odklona donosov ter kotalnega povprečja in standardnega odklona zneska trgovanja na oknih 5, 10, 20, 30 in 60 dni. Za posamezen napovedni dan model uporablja časovno okno osmih trgovalnih dni, zato je vhodni tenzor oblike $[N, 8, 221]$, kjer je N število sredstev, 221 pa 158 značilk posameznega sredstva in 63 skupnih tržnih značilk. Ciljna spremenljivka je shranjena v 222. stolpcu.

Za razliko od PatchTST in TFT MASTER ne napoveduje dnevnih logaritemskih donosov, iz katerih bi nato izračunali večdnevni donos, temveč neposredno vrne en napovedni signal za posamezno sredstvo. Napovedi za vsa razpoložljiva sredstva zberemo v vektor $\hat{\mu}_{\text{MASTER}}$, ki ga uporabimo kot napovedni vhod v portfeljski optimizaciji.

3. Ocena kovariančne matrike

Pri primerjavi napovednih modelov želimo spreminjati predvsem vir ocene $\hat{\mu}$, zato kovariančno matriko pri vseh pristopih ocenimo na enak način. Naj bo v trenutnem ocenjevalnem oknu na voljo T_w vektorjev donosov $\mathbf{r}_t$. Vzorčno povprečje donosov in vzorčno kovariančno matriko definiramo z enačbo (11).

$$\bar{\mathbf{r}} = \frac{1}{T_w} \sum_{t=1}^{T_w} \mathbf{r}_t, \quad \hat{\Sigma} = \frac{1}{T_w - 1} \sum_{t=1}^{T_w} (\mathbf{r}_t - \bar{\mathbf{r}})(\mathbf{r}_t - \bar{\mathbf{r}})^\top. \quad (11)$$

Če je zaradi numerične natančnosti potrebno, matriki $\hat{\Sigma}$ dodamo majhen diagonalni popravek. Ker je kovariančna matrika pri zgodovinskem povprečju, TFT, MASTER in PatchTST ocenjena na enak način po enačbi (11), lahko razlike v končnih portfeljih lažje povežemo z razlikami v ocenah pričakovanih donosov. Dolžino ocenjevalnega okna T_w izberemo enako najdaljšemu vhodnemu oknu med modeli v posameznem eksperimentu. S tem sta oba vhoda optimizatorja, $\hat{\mu}$ in $\hat{\Sigma}$, ocenjena na primerljivi nedavni zgodovini: noben model ni v primerjavi s kovarianco, ocenjeno iz bistveno daljšega obdobja, ki ga sam nikoli ne vidi.

4. Globalni optimizacijski algoritmi

Ker algoritmi KONP rešujejo z minimizacijo, ciljno funkcijo iz enačbe (4) zapišemo v ekvivalentni obliki (12), kjer manjša vrednost $g(\mathbf{w})$ pomeni boljše rešitev.

$$g(\mathbf{w}) = (1 - P)\mathbf{w}^\top \hat{\Sigma} \mathbf{w} - P\hat{\mu}^\top \mathbf{w}. \quad (12)$$

Ker ima zaradi kardinalne omejitve neničelno utež le $K \ll N$ sredstev, pri izračunu variance $\mathbf{w}^\top \hat{\Sigma} \mathbf{w}$ upoštevamo samo aktivna sredstva, torej podmatriko $\hat{\Sigma}$, ki ustreza izbranim sredstvom. S tem zahtevnost kvadratnega dela zmanjšamo z $O(N^2)$ na $O(K^2)$, ne da bi spremenili vrednost ciljne funkcije, saj so vsi izpuščeni členi enaki nič.

4.1. Rojenje delcev (RD). (angl. *Particle Swarm Optimization*, PSO) [47] je populacijski optimizacijski algoritem, navdihnjen z vedenjem skupin živali, kot so jate ptic ali rib ter roji žuželk. V našem delu RD za reševanje KONP implementiramo zvesto po Curi [42].

Denimo, da imamo populacijo delcev, kjer vsak delec predstavlja kandidatno rešitev in pri iskanju rešitve upošteva svojo najboljšo doslej najdeno rešitev ter najboljšo rešitev celotne populacije. Nek delec m opišemo z dvojico $(\mathbf{x}_m, \mathbf{z}_m)$, kjer $\mathbf{x}_m$ predstavlja položaj delca oziroma vektor uteži izbranih sredstev, $\mathbf{z}_m$ pa označuje izbor sredstev. Za obe komponenti delec hrani hitrosti $\mathbf{v}_m^x$ in $\mathbf{v}_m^z$ ter svojo najboljšo doslej obiskano rešitev $(\mathbf{x}_m^*, \mathbf{z}_m^*)$. Najboljšo rešitev celotnega roja določimo z delcem z najboljšo osebno rešitvijo. V vsaki iteraciji za vsak delec m in vsako sredstvo i izvedemo naslednje korake:

1. **Posodobitev izbora sredstev.** Neodvisno vzorčimo $\omega_1, \omega_2 \sim U[0, 2]$. Binarno hitrost določimo z enačbo (13), pri čemer prva komponenta usmerja delec proti globalno najboljši rešitvi, druga pa proti njegovi osebno najboljši rešitvi.

$$v_{m,i}^{z,t+1} = v_{m,i}^{z,t} + \omega_1 (z_i^G - z_{m,i}^t) + \omega_2 (z_{m,i}^* - z_{m,i}^t). \quad (13)$$

Novo vrednost vsake komponente vektorja izbora sredstev $z_{m,i}$ določimo tako, da vrednost $z_{m,i}^t + v_{m,i}^{z,t+1}$ najprej s sigmoidno funkcijo preslikamo v interval $(0, 1)$, nato pa jo glede na prag pretvorimo v binarno vrednost $z_{m,i}^{t+1} \in \{0, 1\}$, kot določa enačba (14). $\alpha = 0,06$ je odmik, ki vpliva na prag izbora sredstva.

$$z_{m,i}^{t+1} = \left\lfloor S(z_{m,i}^t + v_{m,i}^{z,t+1}) - \alpha + \frac{1}{2} \right\rfloor, \quad S(a) = \frac{1}{1 + e^{-a}}, \quad (14)$$

2. **Posodobitev uteži sredstev.** Če je sredstvo pri prejšnjem koraku izbrano, hitrost posodobimo z enačbo (15), pri čemer se delec pomika proti globalno in osebno najboljši rešitvi. Nato položaj posodobimo po enačbi (16). Če je sredstvo ni izbrano njegovo vrednost $x_{m,i}^{t+1}$ nastavimo na nič, hitrost $v_{m,i}^{x,t+1}$ pa ohranimo.

$$v_{m,i}^{x,t+1} = v_{m,i}^{x,t} + \omega_1 (x_i^G - x_{m,i}^t) + \omega_2 (x_{m,i}^* - x_{m,i}^t). \quad (15)$$

$$x_{m,i}^{t+1} = x_{m,i}^t + v_{m,i}^{x,t+1}. \quad (16)$$

3. **Popravljanje kardinalnosti.** Posodobitev izbora ne zagotavlja natanko K izbranih sredstev, zato po vsakem premiku izvedemo popravljanje kardinalnosti. Če je izbranih manj kot K sredstev, z enako verjetnostjo dodamo naključno neizbrano sredstvo ali pa neko neizbrano sredstvo z največjo vrednostjo c_i . Če jih je izbranih več kot K , na enak način odstranimo naključno sredstvo ali pa sredstvo z najmanjšo vrednostjo c_i . Avtorji [42] mero c_i definirajo iz pričakovanega donosa in povprečne kovariance sredstva glede na stopnjo averzije do tveganja. Vmesne količine θ_i in ρ_i ter korekcijska odmika Ω in Ψ določimo po enačbi (17). Ker so $\hat{\mu}$, $\hat{\Sigma}$ in λ v posameznem optimizacijskem oknu nespremenljivi, c_i v naši implementaciji izračunamo le enkrat pred začetkom iteracij.


$$\begin{aligned} \theta_i &= 1 + (1 - \lambda)\hat{\mu}_i, & \rho_i &= 1 + \lambda \frac{1}{N} \sum_{j=1}^N \hat{\Sigma}_{ij}, \\ c_i &= \frac{\theta_i + \Omega}{\rho_i + \Psi}, & \Omega &= -\min \left(0, \min_j \theta_j \right), & \Psi &= -\min \left(0, \min_j \rho_j \right). \end{aligned} \quad (17)$$

4. **Projekcija uteži.** Po popravilu kardinalnosti uporabimo funkcijo `normalize_weights`, ki izbranim sredstvom določi uteži, skladne s proračunsko ter spodnjo in zgornjo utežno omejitvijo.

Algoritem 1. Rojenje delcev za KONP [42]

```
1: Vhod: ocene donosov  $\hat{\mu}$ , kovariančna matrika  $\hat{\Sigma}$ , parameter tveganja  $P$ , kardinalnost  
    $K$ , velikost roja  $M$ , število iteracij  $T$   
2: Izhod: najboljše uteži  $best\_weights$   
3: izračunaj  $c_i$  za vsa sredstva po (17)  
4: ustvari  $M$  naključnih delcev z natanko  $K$  izbranimi sredstvi in dopustnimi utežmi  
5: for all  $particle \in swarm$  do  
6:    $particle.fit \leftarrow f(particle)$   
7:    $particle.best\_fit \leftarrow particle.fit$   
8:    $particle.best\_weights \leftarrow particle.weights$   
9:    $particle.best\_selection \leftarrow particle.selection$   
10:  $leader \leftarrow$  delec z najmanjšo vrednostjo  $best\_fit$   
11: for  $t = 1, \dots, T$  do  
12:   for all  $particle \in swarm$  do  
13:     for  $i = 1, \dots, N$  do  
14:        $\omega_1, \omega_2 \sim U[0, 2]$   
15:       posodobi  $v_{m,i}^{z,t+1}$  po (13)  
16:       posodobi  $z_{m,i}^{t+1}$  po (14)  
17:       if  $z_{m,i}^{t+1} = 1$  then  
18:         posodobi  $v_{m,i}^{x,t+1}$  po (15)  
19:         posodobi  $x_{m,i}^{t+1}$  po (16)  
20:       else  
21:          $x_{m,i}^{t+1} \leftarrow 0$   
22:       popravi izbor tako, da je izbranih natanko  $K$  sredstev, z uporabo  $c_i$   
23:       projiciraj uteži na dopustno množico  
24:        $particle.fit \leftarrow f(particle)$   
25:       if  $particle.fit < particle.best\_fit$  then  
26:         posodobi osebno najboljšo rešitev delca  
27:       if  $particle.best\_fit < leader.best\_fit$  then  
28:          $leader \leftarrow particle$   
29:  $best\_weights \leftarrow leader.best\_weights$   
30: return  $best\_weights$ 
```

Slika 1 prikazuje poenostavljeno ponazoritev delovanja roja delcev v dvodimenzionalnem prostoru, kjer posamezna točka predstavlja eno možno rešitev. Izolinije prikazujejo vrednosti dejanske ciljne funkcije $g(\mathbf{w})$ iz enačbe (12) (povprečje–varianca), pri čemer nižje vrednosti pomenijo boljše rešitve, minimum pa predstavlja optimalno rešitev $\mathbf{w}^*$. V prvi iteraciji je pet delcev (I–V) naključno razporejenih po prostoru, vsak pa svojo začetno pozicijo shrani kot osebno najboljšo rešitev. V drugi iteraciji se delci premaknejo na podlagi svojih hitrosti; na smer in velikost premika vplivata njihova osebno najboljša rešitev ter najboljša rešitev celotnega roja. V iteraciji t je za delec II podrobneje prikazano, kako se njegova nova hitrost sestavi iz predhodne hitrosti ter komponent, usmerjenih proti osebno najboljši in globalno najboljši rešitvi. Posodobljena hitrost nato določi nov položaj delca. Z večanjem števila iteracij se roj zaradi skupnega vpliva teh dveh informacij postopoma pomika proti območjem z nižjo vrednostjo ciljne funkcije.



Slika 1. Poenostavljena ponazoritev gibanja roja delcev v dvodimenzionalnem prostoru.

4.2. Simulirano ohlajanje (SO). (angl. *Simulated Annealing*) [48] je metahevrstični algoritem, navdihnjeno s fizikalnim ohlajanjem kovine. Njegova osnovna ideja je, da poleg izboljšav občasno sprejme tudi slabšo rešitev, da se izogiba lokalnim minimumom. Verjetnost sprejema z ohlajanjem temperature T pada. Za razliko od RD vzdržuje eno samo trenutno rešitev $\mathbf{w}$, katere sosesčino zaporedno preiskuje po temperaturnem urniku (angl. *cooling schedule*) z začetno temperaturo T_0 in geometrijskim faktorjem ohlajanja α_{SO} .

Pri implementaciji SO za reševanje KONP smo izvirali iz dela Crama in Schynsa [49], ki rešujeta soroden, a drugačen problem: minimizirata samo varianco ob omejitvi na zahtevenga donosa, poleg tega pa upoštevata prometne, mejne in trgovalne stroške. Nekaterih mehanizmov iz njunega algoritma zato ne moremo prevzeti dobesedno. Kjer smo jih priredili ali dodali sami, to označimo pri posameznem koraku spodaj. Iskanje poteka po naslednjih korakih:

1. **Inicializacija portfelja.** Začnemo z naključno izbranimi K sredstvi in vsakemu priredimo utež $1/K$. To že zadošča kardinalni, proračunski in utežni omejitvi KONP. Crama in Schynsa začetno rešitev namesto tega konstruirata iz natanko dveh sredstev (z najnižjim in najvišjim donosom) po zaprti obliki, ki natančno zadosti zahtevanemu donosu. Ker ga pri nas ni in je K fiksno že od začetka, sredstva raje izberemo naključno.
2. **Generiranje sosednje rešitve.** Sosednostna funkcija (angl. *neighborhood function*) iz trenutne rešitve ustvari eno kandidatno rešitev na enega od dveh načinov:
 - (a) **Zamenjava sredstva.** Z verjetnostjo 0,10 (naša izbira) celotno utež naključnega sredstva v portfelju prenesemo na naključno sredstvo izven njega. To omogoča raziskovanje različnih izborov sredstev ob nespremenjeni kardinalnosti in vsoti uteži.
 - (b) **Premik uteži.** V preostalih primerih uteži spreminjamo s tridelnim premikom [49]: če je v portfelju vsaj tri sredstva, naključno izberemo tri in določimo spremembe (d_1, d_2, d_3) s pogojem $d_1 + d_2 + d_3 = 0$, velikost premika pa omejitva trenutni polmer q in utežne meje. V izvirnem članku je smer premika dodatno vezana na zahtevani donos (izbor sredstev je usmerjen proti njemu, velikost pa določa zaprta oblika, ki natančno ohrani tudi donosno omejitev); ker pri nas donos ni omejitev, temveč del ciljne funkcije (12), sredstva izberemo enakomerno naključno, velikost premika pa vzorčimo enakomerno znotraj dopustnega razpona namesto po zaprti obliki. Pri manj kot treh sredstvih oziroma numerično neizvedljivem tridelnem premiku uporabimo dvodelni premik ($U(-q, q)$ med dvema naključnima sredstvom). To je naš lasten dodatek za ta robni primer.
3. **Sprejemanje sosednje rešitve.** Kakovost kandidatne rešitve $\mathbf{w}'$ primerjamo s trenutno rešitvijo prek spremembe ciljne funkcije $\Delta = g(\mathbf{w}') - g(\mathbf{w})$. Ker funkcijo g minimiziramo, kandidat pri $\Delta \leq 0$ vedno sprejmemo. Če je $\Delta > 0$, ga sprejmemo z verjetnostjo sprejema [48]:

$$\Pr(\text{sprejem}) = \exp\left(-\frac{\Delta}{T}\right), \quad (18)$$

kjer je T trenutna temperatura. Odločitev izvedemo s slučajno spremenljivko $U \sim U(0, 1)$: slabšo rešitev sprejmemo, če velja $U < \exp(-\Delta/T)$, kar ustreza verjetnosti iz enačbe (18).

4. **Kalibracija temperature in ohlajanje.** Začetne temperature T_0 ne določimo vnaprej, temveč jo kalibriramo: izvedemo poskusno verigo L premikov s polmerom q_1 . Vsako kandidatno rešitev sprejmemo brez uporabe verjetnosti sprejema in povprečimo pozitivne spremembe $\overline{\Delta}^+$ (privzeto 0,01, če ne zaznamo poslabšanj). Če je v_0 zelena začetna verjetnost sprejema značilnega poslabšanja, začetno temperaturo in nadaljnje ohlajanje določimo po pristopu izvirnega članka [49], kot prikazuje enačba (19):


$$T_0 = \frac{\overline{\Delta}^+}{-\ln v_0}, \quad T_{\ell+1} = \alpha_{SO} T_{\ell}, \quad 0 < \alpha_{SO} < 1. \quad (19)$$

5. **Prilagajanje polmera in ustavitev iskanja.** Pri vsaki stopnji izvedemo L premikov (L je sorazmeren številu sredstev). Polmer q_1 ob prenizkem številu sprejetih kandidatov zmanjšamo na $q_2 < q_1$. To pravilo prehoda prav tako sledi izvirnemu članku [49] (pri njima deset sprejemov na stopnjo; pri nas je prag $A_{\min}$ nastavljen parameter). Poleg trenutne rešitve hranimo tudi najboljše doslej najdeno $\mathbf{w}^*$. Iskanje ustavimo po S zaporednih stopnjah brez sprejema ali po doseženem največjem številu stopenj $G_{\max}$.

Algoritem 2. Simulirano ohlajanje za KONP

```
1: Vhod: ocene donosov  $\hat{\mu}$ , kovariacijska matrika  $\hat{\Sigma}$ , averzija do tveganja  $\lambda$ , kardinalnost  $K$ , dolžina stopnje  $L$ , začetna verjetnost sprejema  $v_0$ , faktor ohlajanja  $\alpha_{SO}$ , polmera  $q_1$  in  $q_2$ , prag sprejemov  $A_{\min}$ , prag mirovanja  $S$ , največ stopenj  $G_{\max}$ 
2: Izhod: uteži  $best\_weights$ 
3:  $weights, selected \leftarrow$  naključen dopusten portfelj
4:  $T \leftarrow$  kalibracija z  $L$  poskusnimi premiki pri  $q_1$  in  $v_0$ 
5:  $current\_value \leftarrow g(weights; \hat{\mu}, \hat{\Sigma}, \lambda)$ 
6:  $best\_weights \leftarrow weights$ 
7:  $best\_value \leftarrow current\_value$ 
8:  $q \leftarrow q_1, \quad idle\_stages \leftarrow 0$ 
9: for  $\ell = 1, \dots, G_{\max}$  do
10:    $accepted \leftarrow 0$ 
11:   for  $j = 1, \dots, L$  do
12:      $candidate \leftarrow$  sosed rešitve  $weights$  pri polmeru  $q$ 
13:      $\Delta \leftarrow g(candidate; \hat{\mu}, \hat{\Sigma}, \lambda) - current\_value$ 
14:      $r \leftarrow rand(0, 1)$ 
15:     if  $\Delta \leq 0$  ali  $e^{-\Delta/T} > r$  then
16:        $weights \leftarrow candidate$ 
17:        $current\_value \leftarrow current\_value + \Delta$ 
18:        $accepted \leftarrow accepted + 1$ 
19:       if  $current\_value < best\_value$  then
20:          $best\_value \leftarrow current\_value$ 
21:          $best\_weights \leftarrow weights$ 
22:   if  $accepted < A_{\min}$  then
23:      $q \leftarrow q_2$ 
24:    $T \leftarrow \alpha_{SO} T$ 
25:   if  $accepted = 0$  then
26:      $idle\_stages \leftarrow idle\_stages + 1$ 
27:   else
28:      $idle\_stages \leftarrow 0$ 
29:   if  $idle\_stages \geq S$  then
30:     break
31: return  $best\_weights$ 
```

Slika 2 prikazuje, kako temperatura T in polmer sosesčine q vplivata na iskanje po prostoru portfeljev. V prvem delu je temperatura visoka in polmer velik (q_1), zato algoritem raziskuje širše območje in sprejema tudi slabše rešitve; prikazan korak spremeni uteži tako, da se izboljša utežena kombinacija ocenjenega pričakovanega donosa in tveganja, zato je sprejet. V drugem delu je temperatura nižja, algoritem pa poskuša korak v slabšo rešitev, ki jo zaradi manjše verjetnosti sprejema zavrne. V tretjem delu je temperatura še nižja, polmer pa se zmanjša na $q_2 < q_1$, zato so premiki manjši in iskanje bolj lokalno.




Slika 2. Poenostavljena ponazoritev delovanja simuliranega ohlajanja v enodimenzionalnem prostoru portfeljev.

5. Implementacija in vrednotenje

5.1. Programska zasnova. Pripravo podatkov, učenje modelov, vodenje eksperimentov in vrednotenje rezultatov izvajamo v jeziku Python, transformerske modele pa v okolju PyTorch. Optimizacijski del je implementiran v C++17. Obe komponenti komunicirata prek preprostega datotečnega vmesnika, kar omogoča njun neodvisen razvoj in testiranje. Celoten eksperimentalni postopek je prikazan na Sliki 3.

Podatke o finančnih sredstvih prenesemo prek knjižnice **yfinance**. Izjema je primerjava z delom Wang in sod., kjer uporabimo podatke avtorjev. Podatke, donose in kovariančne matrike obdelamo s knjižnicama **pandas** in **NumPy**, grafe pripravimo z **matplotlib**, transformerske modele pa učimo s knjižnico **PyTorch**.

Vsak eksperiment je opisan s svojo konfiguracijsko datoteko, kjer definiramo obdobje eksperimenta, nabor sredstev, parametre modelov in optimizatorjev itd. Napovedni modeli si delijo skupni vmesnik učenja in napovedi, kar omogoča dodajanje novih modelov v prihodnosti. $\hat{\mu}_t$, njihove napovedi pa pred optimizacijo standardiziramo po postopku, ki ga bomo opisali v nadaljevanju.




Slika 3. Shema eksperimentalnega postopka od tržnih podatkov do vrednotenja.

5.2. Eksperimentalni postopek. Naš eksperimentalni postopek je postopno vrednotenje (angl. *walk-forward*): ob vsakem odločitvenem trenutku t izvede korake I–VII (Slika 3) in se ponavlja skozi celotno testno obdobje.

Tržni podatki. Iz tržnih podatkov do trenutka t izračunamo dnevne donose sredstev. Vsi nadaljnji koraki uporabljajo samo te podatke, zato prihodnji podatki ne vplivajo na pretekle odločitve.

Napovedovanje. Vhod v napovedne modele predstavljajo podatki zadnjih L trgovalnih dni pred odločitvenim trenutkom, ki jih imenujemo vhodno okno (Slika 4). Modeli se učijo na učnem oknu, ki se konča v trenutku t . Če eksperiment zahteva ponovno učenje, se model v predpisanih trenutkih ponovno nauči na takrat razpoložljivih podatkih. Zgodnje ustavljanje pri TFT in PatchTST poteka po validacijski izgubi na zadnjem delu učnega okna, MASTER pa sledi zasnovi avtorjev, ki uporablja presečni informacijski koeficient (IC). $\hat{\mu}_t$ ocenimo tudi z zgodovinskim povprečjem. Njegovo okno L izberemo enako, kot ga bere model, s katerim ga primerjamo, zato obe oceni uporabljata enake nedavne podatke in razlika med njima izvira iz načina ocenjevanja. Ker imajo modeli lahko različna okna, za vsak model izračunamo lastno ujemaajoče zgodovinsko povprečje.

Ocena kovariančne matrike. Vzorčno kovarianco $\hat{\Sigma}_t$ ocenimo iz zadnjih $L_{\max}$ trgovalnih dni, kjer je $L_{\max}$ najdaljše vhodno okno med vključenimi modeli, in jo enako uporabimo pri vseh modelih in zgodovinskem povprečju. Vsa ocenjevalna okna se končajo v odločitvenem trenutku ali pred njim. Konkretna vrednosti L , $L_{\max}$, H , pogostost ponovnega učenja in druge nastavitve posameznih eksperimentov so zbrane v Tabeli 1.



Slika 4. Zgradba postopnega vrednotenja za en odločitveni trenutek. Okna ne segajo v osenčeno prihodnost.

Standardizacija. Oba vhoda optimizatorja standardiziramo. Ciljna funkcija (4) združuje pričakovani donos in tveganje portfelja, razmerje med njima pa določa parameter P . Ocene $\hat{\mu}_t$ imajo različne enote in velikosti, ocenjeno tveganje $\hat{\Sigma}_t$ pa je po velikosti odvisno od napovednega obdobja H , nabora sredstev in volatilitnosti trga (v kriznih obdobjih so variance bistveno višje kot v mirnih). Pri nespremenjenem P bi imel zato pričakovani donos vsakič drugačno težo glede na tveganje, portfelji pa bi se razlikovali zaradi velikosti ocen, ne zaradi razvrstitve sredstev. Standardizacija je enaka za vse napovedne modele in zgodovinsko povprečje, računamo pa jo samo iz vhodov v odločitvenem trenutku t .

Napovedi presečno standardiziramo: od vsake napovedi odštejemo povprečje napovedi vseh sredstev ob istem odločitvenem trenutku in rezultat delimo z njihovim standardnim odklonom (enačba (20)).

$$\tilde{\mu}_{t,i} = \frac{\hat{\mu}_{t,i} - \bar{\mu}_t}{s_t}, \quad \bar{\mu}_t = \frac{1}{N} \sum_{j=1}^N \hat{\mu}_{t,j}, \quad s_t = \sqrt{\frac{1}{N} \sum_{j=1}^N (\hat{\mu}_{t,j} - \bar{\mu}_t)^2}. \quad (20)$$

Kovariančno matriko delimo s povprečjem njene diagonale, to je s povprečno varianco sredstev (enačba (21)).

$$\tilde{\Sigma}_t = \frac{\hat{\Sigma}_t}{\bar{d}_t}, \quad \bar{d}_t = \frac{1}{N} \sum_{i=1}^N \hat{\Sigma}_{t,ii}. \quad (21)$$

Zato imata $\tilde{\mu}_t$ in $\tilde{\Sigma}_t$ povsod isto skalo, razvrstitev sredstev, korelacije in razmerja med variancami pa se ne spremenijo.

Optimizacija. Optimizator iz standardiziranih $\tilde{\mu}_t$ in $\tilde{\Sigma}_t$ določi portfeljske uteži $\mathbf{w}_t$. Poročane mere računamo iz nestandardiziranih $\hat{\mu}_t$ in $\hat{\Sigma}_t$.

Napovedno obdobje. Po odločitvi v trenutku t vstopimo v napovedno obdobje od $t + 1$ do $t + H$, v katerem portfelj $\mathbf{w}_t$ ostane nespremenjen.

Vrednotenje. Z vrednotenjem ocenimo, kako uspešen je izbrani portfelj. Realizirani donos portfelja r_t^p (2) izračunamo iz dejanskih prihodnjih cen. Pri vseh portfeljskih eksperimentih uporabljamo iste skupne metrike, ki so v tabelah vedno navedene najprej in v istem vrstnem redu. Pri zunanjih primerjavah jim dodamo še metrike avtorjev, da je primerjava neposredna.

Naj bo $\{r_t^p\}_{t=1}^T$ zaporedje realiziranih periodičnih donosov portfelja, $\bar{r}$ njihovo aritmetično povprečje, s standardni odklon in p število takih obdobji na leto. Pri dnevni donosih uporabimo $p = 252$, pri tedenskih $p = 52$ in pri mesečnih $p = 12$.

Kumulativno vrednost portfelja določa enačba (22). Pove, v kolikšno vrednost zraste ena enota vloženega kapitala do obdobja t , če dobiček sproti reinvestiramo.

$$W_t = \prod_{j=1}^t (1 + r_j^p). \quad (22)$$

Letni donos po enačbi (23) je povprečni donos obdobja, preračunan na eno leto.

$$R_{\text{letno}} = p \bar{r}. \quad (23)$$

Letna volatilitnost po enačbi (24) je standardni odklon donosov, preračunan na eno leto. Meri razpršenost donosov okoli povprečja, torej realizirano tveganje: nižja vrednost pomeni mirnejše gibanje vrednosti portfelja.

$$\sigma_{\text{letno}} = s\sqrt{p}. \quad (24)$$

Sharpov količnik [50] v enačbi (25) je razmerje med letnim donosom in letno volatilitnostjo ob predpostavki ničelne breztvegane donosnosti. Pove, koliko donosa dobimo na enoto tveganja, zato omogoča primerjavo portfeljev z različnim tveganjem; višja vrednost je ugodnejša.

$$\text{SR} = \frac{\bar{r}}{s} \sqrt{p}. \quad (25)$$

Kot dopolnilno analizo poročamo še promet portfelja, ki meri velikost spremembe uteži med zaporednima uravnoveženjema in ga za posamezno uravnoveženje izračunamo z enačbo (26):

$$\text{TO}_t = \sum_{i=1}^N |w_{i,t} - w_{i,t-1}|. \quad (26)$$

Vrednost 0 pomeni, da portfelja ne spreminjamo, vrednost 2 pa popolno zamenjavo vseh sredstev. Višji promet pomeni več trgovanja in zato višje transakcijske stroške.

Vse nastavitve modelov, optimizatorjev in posameznih eksperimentalnih protokolov, uporabljene pri eksperimentih, so zbrane v Prilogi A.

6. Rezultati

Predstavimo pet eksperimentov: štiri z nastavitvami iz literature in en lasten dolgoročni primer. Prvi trije izhajajo iz predhodnih raziskav Leow in sod. [6], Wang in sod. [7] ter Aprea in Sbaiz [8]; zadnja ju obravnava na dveh naborih (DJIA in NASDAQ 100), zato so skupaj štirje. S tem lahko naš pristop postavimo v kontekst že objavljenih eksperimentov. To niso replikacije izvornih metod: podatke, časovna okna in portfeljske nastavitve prevzamemo kot referenčni okvir, naš napovedni in optimizacijski postopek pa ostane enak.

Peti, dolgoročni primer oblikujemo sami. Z njim preverimo, ali se ugotovitve o napovednem signalu ohranijo tudi v daljšem obdobju in v različnih tržnih razmerah. Dodatno vključimo še pasivni indeks S&P 500 kot nemodelirano referenco.

Tabela 1 povzema obdobja in glavne nastavitve vseh petih eksperimentov. Podrobnosti postopnega vrednotenja (časovna okna, ponovno učenje, preprečevanje uhajanja prihodnjih informacij) so v razdelku 5.2. Tukaj za vsak eksperiment povemo, kaj preverja, in predstavimo rezultate.

Rezultate predstavimo v tem vrstnem redu:

1. kakovost optimizatorjev, ki smo ju implementirali sami, zato ju najprej preverimo neodvisno na standardnih primerih;
2. eksperimenta Leow in Wang;
3. eksperimenta Aprea in Sbaiz na naborih DJIA in NASDAQ 100;
4. dolgoročni primer;
5. dopolnilna analiza stabilnosti portfeljev in računskega časa.

Računski časi, ki jih poročamo (npr. v Tabeli 4), so vezani na uporabljeno strojno opremo, opisano v razdelku 6.8.

Tabela 1. Nastavitve postopnega vrednotenja po eksperimentih. H je napovedno obdobje, K kardinalnost, »Val.« pa dolžina validacijskega dela učnega okna (v trgovalnih dneh).

Eksperiment	Učenje	Preizkus	Ponovno učenje	H	K	Val.
Leow All-Weather	2018–2019	jan.–apr. 2020	ob vsaki odločitvi	5	5	63
Wang S&P 500	2018–2020	2021	enkratna	120	20	120
Aprea DJIA	2007–2015	2016–2020	letna	21	10	126
Aprea NASDAQ 100	2007–2015	2016–2020	letna	21	10	126
Dolgoročno vlaganje	2005–2010	2011–2024	letna	21	20	126

6.1. Kakovost optimizatorjev na standardnih primerih. Preden vključimo napovedne modele, preverimo, ali optimizator pravilno rešuje kardinalno omejeni problem povprečja in variance. Vprašanje je: ali RD in SO najdeta portfelje blizu optimalne efektivne fronte?

Chang in sod. [2] so problem reševali s tremi metaheuristicami (genetski algoritem, tabu iskanje in simulirano ohlajanje) na petih podatkovnih nizih zbirke OR-Library [51]. Za vsak niz so izračunali kardinalno omejeno efektivno fronto in jo primerjali z neomejeno fronto (USEF). Ker omogoča neposredno primerjavo z objavljenimi rezultati, je ta nabor primerov postal običajno merilo za kardinalno omejene portfeljske optimizatorje.

Uporabimo pet primerov zbirke OR-Library: Hang Seng (31 sredstev), DAX 100 (85), FTSE 100 (89), S&P 100 (98) in Nikkei (225 sredstev). Fronto računamo pri 50 vrednostih parametra tveganja po postopku Chang in sod. [2], s kardinalnostjo $K = 10$ ter spodnjo in zgornjo mejo uteži izbranih sredstev $\varepsilon_i = 0,01$ in $\delta_i = 1$. $\hat{\mu}$ in $\hat{\Sigma}$ vzamemo neposredno iz referenčnih podatkovnih datotek, da napovedni model ne vpliva na rezultat.


Kakovost točke (r, v) kardinalno omejene fronte, kjer je r donos in v varianca, merimo kot njeno relativno oddaljenost od USEF. Naj bo $v^*(r)$ varianca USEF pri donosu r in $r^*(v)$ donos USEF pri varianci v (obe z linearno interpolacijo med točkami referenčne fronte). Napaka točke je manjša od dveh relativnih odstopanj, navzdol omejena z nič (enačba (27)):

$$e(r, v) = \max \left\{ 0, \min \left\{ 100 \frac{v - v^*(r)}{|v^*(r)|}, 100 \frac{r^*(v) - r}{|r^*(v)|} \right\} \right\}. \quad (27)$$

Prvi člen pove, za koliko odstotkov je varianca višja od najboljše pri istem donosu, drugi pa za koliko odstotkov je donos nižji od najboljšega pri isti varianci. Vrednost 0 pomeni, da se točka ujema z USEF, večja vrednost pa slabšo rešitev. Ker za vsak primer preverimo 50 točk, poročamo povprečje in mediano napak e . Mediana je manj občutljiva na posamezne točke z veliko napako, zato razlika med njima kaže, kako debel je rep

Instanca (N)	RD		SO	
	povpr.	med.	povpr.	med.
Hang Seng (31)	1,27	1,28	1,12	1,22
DAX 100 (85)	3,26	2,78	2,49	2,61
FTSE 100 (89)	2,09	1,29	0,98	1,08
S&P 100 (98)	2,92	1,50	1,76	1,16
Nikkei (225)	2,03	1,21	0,60	0,59
Povprečje	2,32	1,61	1,39	1,33

Tabela 2. Standardna odstotna napaka (%) kardinalno omejene fronte glede na USEF na primerih OR-Library.



Slika 5. Kardinalno omejena fronta na primeru S&P 100: RD in SO v primerjavi z neomejeno fronto (USEF); vsaka točka predstavlja eno vrednost parametra tveganja.

porazdelitve. Računski čas poročamo kot spremljevalni podatek o zahtevnosti, ne kot mero kakovosti.

Tabela 2 kaže, da oba optimizatorja dosegata rešitve blizu objavljene neomejene fronte. Povprečna napaka je pri štirih od petih primerov pod 3 % (pri RD sta izjemi DAX 100 s 3,26 % in blizu meje S&P 100 z 2,92 %), mediana pa je pri obeh algoritmihi v povprečju nižja od 2 %. SO ima nižjo povprečno in mediansko napako kot RD pri vseh petih primerih (v povprečju 1,39 % proti 2,32 %). Razlika je največja pri Nikkei (0,60 % proti 2,03 %).

Pri RD je mediana pogosto precej nižja od povprečja (npr. S&P 100: 1,50 % proti 2,92 %). Razlog so posamezne točke fronte z veliko napako: največja napaka RD je pri štirih primerih med 17 % (Nikkei) in 21 % (S&P 100), pri SO pa nikjer ne preseže 12 % (največ 11,7 % pri S&P 100). Pri Hang Sengu, najmanjšem primeru, sta obe največji napaki pod 2 %.

Slika 5 rezultat ponazori na primeru S&P 100, kjer se točke obeh kardinalno omejenih postopkov v večjem delu razpona tesno približajo neomejeni fronti. To zmanjšuje verjetnost, da bi bile razlike med napovednimi modeli v nadaljnjih poskusih predvsem posledica očitno neakovostnega optimizacijskega postopka.

Računska zahtevnost obeh optimizatorjev je pri teh problemih majhna. Posamezno reševanje traja pri RD med 46 ms (Hang Seng) in 244 ms (Nikkei), pri SO med 13 in 139 ms. SO je torej na posameznem primeru 1,8- do 3,5-krat hitrejši. Celoten pregled petih primerov s po 50 vrednostmi parametra tveganja traja približno 42 s (RD 29,0 s, SO 13,3 s), kar je 2,2-krat hitreje pri SO.

6.2. Zunanja primerjava z delom Leow in sod.. Leow in sod. [6] razširijo klasično optimizacijo portfelja z razpoloženjem, pridobljenim iz družbenih omrežij. Besedilne objave obdelajo z modelom BERT in iz njih izluščijo razpoloženski signal, ki ga vključijo v kriterij optimizacije skupaj z genetskim algoritmom. Njihova najboljša metoda (SAW) v kriznem obdobju COVID-19 doseže Sharpev količnik 2,14.

Prevzamemo njihovo časovno delitev (januar–april 2020, 13 tedenskih odločitev). Namesto razpoloženskega signala v postopek vstavimo naše napovedi $\hat{\mu}$, zato gre za primerjavo napovednega in optimizacijskega pristopa v sorodnem protokolu, ne za reprodukcijo njihovega signala. Testiramo njihov petsredstveni nabor All-Weather (VTI, TLT, IEF, GLD, DBC; kardinalnost $K=5$) – edini nabor, za katerega Leow in sod. poročajo številčne rezultate (njihovi tabeli 4 in 6). Sektorski nabor SPDR v njihovem delu nastopa le kot slika brez poročanih mer in ga zato ne uporabljamo za primerjavo. Vprašanje je, ali naš transformerski signal v krizi dosega primerljive rezultate z njihovim razpoloženskim pristopom.

Ker isti P pri različnih virih $\hat{\mu}$ pomeni različno realizirano tveganje, vsak model poročamo pri tistem P , pri katerem je njegova realizirana letna volatilitnost najbližja volatilitnosti ujemajočega zgodovinskega povprečja; s tem so donosi in Sharpev količnik primerjani pri enakem realiziranem tveganju. Vsak transformer je primerjan z lastnim zgodovinskim povprečjem: »Zgodovinsko povprečje (L dni)« označuje vzorčno povprečje čez L trgovalnih dni, kjer L ustreza vhodnemu oknu tistega modela (PatchTST: $L=45$, TFT: $L=64$). Ta konvencija in oznaka veljata za vse portfeljske tabele v nadaljevanju. Stolpca »Št. učenj« in »Čas/učenje« podajata število učenj modela čez vse ponovitve in semena (65 učenj na model) ter povprečni čas enega učenja; pri zgodovinskem povprečju sta označena z »-«. Stolpca »Opt. RD« in »Opt. SO« sta povprečni čas enega reševanja optimizatorja RD oziroma SO (ena odločitev) pri P iz tega razporednega prikaza.

Ker vsak model bere svoje vhodno okno, ni enega samega zgodovinskega povprečja: vzorčno povprečje čez 45 dni doseže Sharpe 1,42 (letni donos 29,6 %), čez 64 dni pa le 0,46 (11,2 %). Že ta razlika – devetnajst dodatnih dni zgodovine prepolovi Sharpev količnik –


Tabela 3. Portfeljska uspešnost v protokolu Leow in sod. [6] (jan.–apr. 2020, 13 tedenskih odločitev, nabor All-Weather, optimizator RD, bruto). Referenčne vrednosti iz njihove Tabele 6.

Nabor	Metoda	Donos	Volatilnost	Sharpe	Št. učenj	Čas/učenje	Opt. RD	Opt. SO
All-Weather	Leow: SPY (pasivno)	−65,4 %	55,1 %	−1,65	–	–	–	–
All-Weather	Leow: CRB (pasivno)	−8,5 %	17,8 %	−0,41	–	–	–	–
All-Weather	Leow: MPT (Markowitz)	13,6 %	18,0 %	0,80	–	–	–	–
All-Weather	Leow: SAW (najboljši)	53,9 %	21,2 %	2,14	–	–	–	–
All-Weather	Zgodovinsko povprečje (45 dni)	29,6 %	20,9 %	1,42	–	–	68 ms	17 ms
All-Weather	Zgodovinsko povprečje (64 dni)	11,2 %	24,4 %	0,46	–	–	66 ms	16 ms
All-Weather	PatchTST	14,6 %	22,7 %	0,64	65	17,0 s	68 ms	17 ms
All-Weather	TFT	28,6 %	22,2 %	1,29	65	18,6 s	67 ms	17 ms

pokaže, da je dolžina okna v tem obdobju enako pomembna kot izbira napovednika. TFT doseže Sharpe 1,29 (28,6 %) in tako za +0,83 jasno prekaša svoje ujemajoče zgodovinsko povprečje, medtem ko PatchTST s Sharpom 0,64 (14,6 %) svojemu zgodovinskemu povprečju občutno podleže (−0,77). TFT s Sharpom 1,29 preseže tudi Leowov MPT z maksimizacijo Sharpovega količnika (0,80) in se približa njihovevemu modelu z minimizacijo volatilitnosti (1,51), ne doseže pa najvišje vrednosti Leow in sod. (2,14, model SAW z maksimizacijo donosa); PatchTST s Sharpom 0,64 v tej ponovitvi ne doseže niti njihovega MPT.

Rezultate je treba brati previdno. Izhajajo iz le 13 tedenskih odločitev v izjemno kratkem kriznem obdobju, zato so občutljivi na posamezne realizirane donose in na podrobnosti učenja. Kako občutljivi, kaže naslednja primerjava z zgodnejšo ponovitvijo istega protokola: zgolj sprememba dolžine validacijskega okna za zgodnje ustavljanje (pri TFT skupaj s spremembo potrpežljivosti), torej učinkovitostna nastavitvev, ki ne spremeni niti podatkov niti arhitekture, je Sharpov količnik TFT premaknila z 0,21 na 1,29, pri PatchTST pa v nasprotno smer, z 1,09 na 0,64. Velik del razpona med modeloma v tem obdobju je torej šum pri izbiri ustavitvene točke učenja in ne stabilna napovedna vsebina; primerjava je zato zgolj usmeritvena, vrstni red modelov pa se lahko z drugačno nastavitvijo zgodnjega ustavljanja ponovno obrne.

Gibanje vrednosti posameznih portfeljev skozi to obdobje prikazuje Slika 6. Visok ali nizek rezultat posameznega napovednika v tem kratkem obdobju torej ne odraža splošne superiornosti modela.



Slika 6. Gibanje vrednosti portfelja All-Weather med COVID-19 zlomom (protokol Leow in sod., bruto). Vsak model je prikazan pri ujemajočem P iz Tabele 3.

6.3. Zunanja primerjava z delom Wang in sod.. Wang in sod. [7] predlagajo enkratni nevronske reševalnik CardNN-GS za kardinalno omejeni portfeljski problem. Namesto ločenega napovednega in optimizacijskega koraka reševalnik oba združi v enoten model z diferenciablem plastjo optimalnega transporta, ki neposredno maksimizira Sharpov količnik. Kot primerjalno metodo vključijo tudi pristop »napovej, nato optimiziraj«: LSTM oceni pričakovane donose, Gurobi pa na podlagi teh ocen poišče optimalne uteži. Ta pristop je strukturno najbližji našemu.

Prezramemo njihov podatkovni nabor: 494 sredstev iz indeksa S&P 500, leto 2021 kot testno obdobje, 120-dnevno napovedno obdobje, kardinalnost $K=20$. Kovariančno matriko fiksiramo na učnem obdobju 2018–2020; to je odstopanje od njihovega protokola, kjer $\hat{\Sigma}$ ni fiksna, temveč jo za vsako odločitev izračunajo iz napovedanih prihodnjih donosov modela LSTM. Naš pristop take napovedane $\hat{\Sigma}$ nima, zato uporabimo vzorčno oceno iz učnega obdobja, ki v testno obdobje ne pogleda. Ker Wang in sod. neposredno maksimizirajo Sharpov količnik, naša ciljna funkcija povprečje–varianca pri $P=0,5$ temu

ni enakovredna – primerjava je smiselna na ravni Sharpa, ki tveganje že upošteva. Vprašanje je, ali metahevrstična optimizacija s standardno ciljno funkcijo doseže primerljivo kakovost kot specializirani nevronske reševalci.

Poleg skupnih metrik iz koraka VII v Tabeli 4 ohranimo še objavljene portfeljske metrike donosa, tveganja in Sharpovega količnika Wang in sod., saj le tako omogočimo neposredno primerjavo z referenčnimi vrednostmi. Ker njihov način agregiranja rezultatov sledi lastnemu 120-dnevnu investicijskemu protokolu, te vrednosti v tabeli označimo ločeno od skupnih metrik in jih ne uporabljamo kot nadomestilo za skupni letni donos, volatilitnost in Sharpov količnik.

Dve opombi pred branjem Tabele 4: Wang in sod. Sharpov količnik računajo z netvegano mero 3 %, mi pa brez nje, zato so naše vrednosti v tem stolpcu za 0,15 ugodnejše. Poleg tega so standardni odkloni Sharpovih količnikov v tem protokolu večji od samih vrednosti (od 0,58 do 1,39), zato tabela dopušča le umestitev v razred, ne razvrstitve med posameznimi modeli.

Tabela 4. Primerjava z delom Wang in sod. [7] (S&P 500 2021, 120-dnevna okna, $K=20$, optimizator RD). Št. učenj in čas enega učenja sta enkratno učenje modela; opt. RD in SO sta povprečna časa ene odločitve ($P=0,5$). Referenčne vrednosti iz njihove Tabele 3 in Slike 5; njihovih časov ne poročamo.

Metoda	Donos	Volatilitnost	Sharpe	Št. učenj	Čas/učenje	Opt. RD	Opt. SO
Wang: zgodovinski (Gurobi)	13,9 %	16,2 %	0,67	–	–	–	–
Wang: napovej-nato (LSTM+Gurobi)	24,1 %	19,5 %	1,08	–	–	–	–
Zgodovinsko povprečje (67 dni)	22,3 %	22,5 %	0,86	–	–	2,0 s	1,6 s
Zgodovinsko povprečje (271 dni)	27,8 %	25,4 %	1,08	–	–	2,0 s	1,6 s
Zgodovinsko povprečje (336 dni)	35,8 %	25,6 %	1,41	–	–	2,0 s	1,6 s
MASTER	29,6 %	23,1 %	1,12	1	33,7 min	2,0 s	1,6 s
PatchTST	36,3 %	22,7 %	1,64	1	1,8 min	2,0 s	1,6 s
TFT	40,2 %	24,6 %	1,79	1	1,04 h	2,1 s	1,5 s
Wang: napovej-in (CardNN-GS)	40,0 %	18,8 %	1,97	–	–	–	–

Naš pristop se objavljenim metodam dobro primerja. TFT doseže Sharpe 1,79, tik pred njim PatchTST z 1,64; oba se uvrstita med Wangov pristop »napovej, nato optimiziraj« (LSTM+Gurobi, 1,08) in njihov enkratni nevronske reševalnik CardNN-GS (1,97), ki neposredno maksimizira Sharpov količnik. Pri tem je naš letni donos (40,2 %) skoraj enak CardNN-GS (40,0 %), a ob občutno višjem realiziranem tveganju (24,6 % proti 18,8 %): del razlike v Sharpovem količniku torej ni posledica boljših napovedi, temveč večje izpostavljenosti.

Dva rezultata je treba navesti odkrito. Prvič, MASTER s Sharpom 1,12 ostaja najšibkejši od treh transformerjev v tem protokolu, čeprav svoje ujemaajoče zgodovinsko povprečje (0,86) prekaša le za +0,26; njegova prednost pred zgodovino je torej postranska in bistveno manjša kot pri TFT in PatchTST. Drugič, že samo zgodovinsko povprečje čez 336 dni doseže Sharpe 1,41 in s tem prekaša Wangov LSTM+Gurobi (1,08) – brez vsakršnega napovednega modela. Razpon zgodovinskih povprečij (0,86, 1,08, 1,41 pri 67, 271 in 336 dneh) je primerljiv z razponom med modeli, kar pomeni, da dolžina okna v tem protokolu opravi približno toliko dela kot izbira napovednika.

Skupna ugotovitev je zato zadržana: odprtokodna metahevrstična optimizacija s standardno ciljno funkcijo povprečje–varianca dosega kakovost v razredu specializiranih nevronske reševalcev brez potrebe po komercialni infrastrukturi, vendar protokol s sedmimi odločitvami in 83 % prekrivanjem napovednih obdobj (kar ustreza približno dvema neodvisnima opazovanjema) ne dopušča razvrstitve med posameznimi napovedniki.

6.4. Zunanja primerjava z delom Aprea in Sbaiz: DJIA. Aprea in Sbaiz [8] predlagajo globoko naučen pristop k izbiri portfelja, ki namesto variance kot mere tveganja minimizira agregiran ΔCoVaR (sistemsko tveganje, ocenjeno z LSTM) ob dodatnih omejitvah ESG, prometa in minimalnega donosa. Nastali nekonveksni problem rešujejo z izboljšanim rojenjem delcev, pri katerem parametre roja (w, c_1, c_2) sproti prilagaja nevronska mreža, omejitve pa obravnavajo s projekcijo na proračunsko simpleks in kazensko funkcijo. Njihova ciljna funkcija in omejitve so torej bistveno drugačne od našega povprečje–variančnega kriterija, zato gre za primerjavo metod na skupnih naknadno izračunanih merah (Sharpov količnik, letni donos), ne za replikacijo; skupna pa je izbira rojenja delcev kot reševalnika.

Prevzamemo njihov nabor 28 sredstev indeksa DJIA (poravnan z njihovim investicijskim naborom na presečni datum 31. 12. 2020, rekonstruiran iz javno dostopnih cen) in njihovo časovno shemo: učenje na obdobju 2007–2015, mesečno odločanje v obdobju 2016–2020 (60 razporeditev; njun $T_f=59$ šteje ponovna uravnoteženja po začetni razporeditvi) in $w_{\max}=0,2$ (zgornja meja uteži, skladna z eno od dveh mej Aprea in sod.). Kardinalnost $K=10$ je naš dodatek: njun model kardinalne omejitve ne vsebuje – njune omejitve so proračunska, intervalna ($x_i \in [l_i, u_i]$), ESG, prometna in minimalni

donos, brez binarnih spremenljivk. Število pozicij pri njih ni nastavitve, temveč posledica intervalne meje: zadnja vrstica njunih tabel 7 in 8 poroča *povprečno* število sredstev z neničelno utežjo zunaj vzorca, in to je 10 pri $u_i=0,2$ ter 16 pri $u_i=0,06$, torej $\lfloor 1/u_i \rfloor$. Naš $K=10$ pri $w_{\max}=0,2$ tako eksplicitno predpiše prav tisto število pozicij, ki pri njihju nastane samo od sebe. Njihova omejitev prometa ($\leq 0,2$ na odločitve), omejitev ESG in kriterij minimalnega donosa v našem pristopu niso implementirani, zato je neposredna primerjava s to referenco zgolj usmeritvena.

Tabela 5. Primerjava z delom Aprea in Sbaiz [8] na naboru sredstev DJIA (28 sredstev, 2016–2020, 60 mesečnih odločitev, $K=10$, $P=0,5$, optimizator RD, bruto). Pet letnih učenj; čas/učenje je povprečje enega učenja, opt. RD in SO sta povprečna časa ene odločitve.

Metoda	Donos	Volatilitnost	Sharpe	Št. učenj	Čas/učenje	Opt. RD	Opt. SO
Zgodovinsko povprečje (67 dni)	14,1 %	15,3 %	0,75	–	–	186 ms	43 ms
Zgodovinsko povprečje (271 dni)	12,4 %	15,5 %	0,64	–	–	187 ms	43 ms
Zgodovinsko povprečje (336 dni)	14,8 %	15,5 %	0,80	–	–	186 ms	43 ms
MASTER	16,3 %	17,2 %	0,76	5	22,3 min	186 ms	43 ms
PatchTST	19,3 %	15,4 %	1,09	5	2,0 min	185 ms	43 ms
TFT	16,9 %	16,9 %	0,79	5	25,2 min	186 ms	44 ms
Aprea in Sbaiz: B^+ ($p=1$ %, $u_i=0,2$)	20,8 %	5,0 % ¹	1,21 ²	–	–	–	–

Rezultate zbira Tabela 5. Na tem naboru vsi trije transformerji presežejo svoje ujemajoče zgodovinsko povprečje. PatchTST doseže najvišji Sharpe (1,09 proti 0,80 za zgodovinsko povprečje čez 336 dni) in edini preseže tudi Apreovo referenco (1,21 letno normalizirano), čeprav ob občutno višji volatilitnosti. TFT (0,79 proti 0,64) in MASTER (0,76 proti 0,75, komaj) prav tako presežeta svoji zgodovinski povprečji, a z manjšo razliko; MASTER je tu na robu.

6.5. Zunanja primerjava z delom Aprea in Sbaiz: NASDAQ 100. Aprea in Sbaiz [8] svojo metodo preizkusita tudi na večjem naboru indeksa NASDAQ 100. Isti protokol ponovimo na njihovem naboru 54 sredstev (poravnanem z njihovim polnozgodovinskim naborom), da preverimo, ali se ugotovitve iz razdelka 6.4 prenesejo na širši, bolj tehnološko nagnjen nabor. Nastavitve (obdobje, $K=10$, $w_{\max}=0,2$, 60 mesečnih odločitev) so enake kot pri DJIA.

Tabela 6. Primerjava z delom Aprea in Sbaiz [8] na naboru NASDAQ 100 (54 sredstev, 2016–2020, 60 mesečnih odločitev, $K=10$, $P=0,5$, optimizator RD, bruto). Pet letnih učenj; čas/učenje je povprečje enega učenja, opt. RD in SO sta povprečna časa ene odločitve.

Metoda	Donos	Volatilitnost	Sharpe	Št. učenj	Čas/učenje	Opt. RD	Opt. SO
Zgodovinsko povprečje (67 dni)	28,0 %	21,7 %	1,03	–	–	269 ms	76 ms
Zgodovinsko povprečje (271 dni)	28,3 %	23,3 %	0,94	–	–	269 ms	76 ms
Zgodovinsko povprečje (336 dni)	30,6 %	23,9 %	1,00	–	–	269 ms	76 ms
MASTER	27,0 %	18,4 %	1,23	5	25,6 min	269 ms	76 ms
PatchTST	30,9 %	24,9 %	0,96	5	3,6 min	269 ms	74 ms
TFT	18,9 %	22,7 %	0,55	5	63,7 min	269 ms	75 ms
Aprea in Sbaiz: B^+ ($p=1$ %, $u_i=0,2$)	22,9 %	6,3 % ¹	1,08 ²	–	–	–	–

Rezultate zbira Tabela 6. Na tem večjem, bolj tehnološko nagnjenem naboru se vrstni red modelov obrne glede na DJIA. MASTER je tu edini, ki jasno preseže svoje zgodovinsko povprečje (1,23 proti 1,03 čez 67 dni) in edini preseže tudi Apreovo referenco (1,08 letno normalizirano). PatchTST ostane praktično na ravni svojega zgodovinskega povprečja (0,96 proti 1,00, neznatno nižje). TFT je edini model, ki v tem naboru izrazito zaostane za svojim zgodovinskim povprečjem (0,55 proti 0,94) – v nasprotju z njegovo vlogo v Leow All-Weather in dolgoročnem primeru (razdelek 6.6), kjer zgodovinsko povprečje presega. Diagnostika kaže, da gre pri TFT deloma za arhitekturno omejitev pri tem večjem naboru: TFT za razliko od MASTER nima presečne (medsredstvene) pozornosti in torej svoje kapacitete ne prilagaja velikosti nabora, kar je pri 54 sredstvih izrazitejša ovira kot pri 28 (DJIA) ali petih (Leow). Rezultat je zato treba brati kot opozorilo, da uspešnost posameznega transformerja ni univerzalna lastnost modela, temveč je odvisna tudi od velikosti in narave nabora sredstev.

6.6. Praktični primer: dolgoročno vlaganje. Za ta primer ni izvirnega članka: nastavitve smo oblikovali sami, zato referenčne vrednosti iz literature ne obstajajo. Vprašanje je, ali transformerski signal ostaja koristen prek daljšega obdobja z več tržnimi razmerami, ne le v kratkem kriznem oknu.

Testiramo na naboru ameriških sredstev v obdobju 2011–2024 z letnim ponovnim učenjem in mesečnim odločanjem (168 odločitev). Ker primer ni vezan na referenčno študijo, referenčna točka je naše lastno zgodovinsko povprečje in pasivni indeks S&P 500

(dodan kot ločena, nemodelirana referenca; ker nima prometa, velja bruto = neto). Opozorilo: nabor vsebuje samo sredstva, ki so preživela celotno obdobje (survivorship bias), zato so absolutni rezultati navzgor pristrani; primerjava med napovednimi pristopi je kljub temu neposredna, saj vsi delijo isti rekonstruirani nabor sredstev. Tabela 7 poroča bruto in neto mere, kjer neto upošteva 10 bazičnih točk (b.t.) stroška na enoto letnega prometa (L1 uteži) – standardna groba ocena transakcijskih stroškov za likvidna ameriška sredstva.


Tabela 7. Praktični primer dolgoročnega vlaganja (2011–2024, $K=20$, $P=0,5$, optimizator RD). Bruto in neto mere pri 10 b.t. transakcijskih stroškov. Promet je letna vsota TO_t (enačba 26); 1 ustreza prometu vrednosti celotnega portfelja. 14 letnih učenj; čas/učenje je povprečje enega učenja, opt. RD in SO sta povprečna časa ene odločitve.

Strategija	Bruto		Neto (10 b.t.)		Promet	Št. učenj	Čas/učenje	Opt. RD	Opt. SO
	Donos	Sharpe	Donos	Sharpe					
Zgodovinsko povprečje (67 dni)	14,0 %	1,01	12,9 %	0,93	11,5	–	–	403 ms	143 ms
Zgodovinsko povprečje (271 dni)	13,6 %	0,99	13,0 %	0,94	6,2	–	–	404 ms	142 ms
Zgodovinsko povprečje (336 dni)	14,7 %	1,10	14,2 %	1,06	5,8	–	–	404 ms	143 ms
MASTER	11,6 %	0,73	9,8 %	0,61	18,3	14	15,3 min	403 ms	143 ms
PatchTST	17,6 %	1,38	16,2 %	1,27	14,4	14	1,9 min	403 ms	142 ms
TFT	16,4 %	1,10	15,6 %	1,04	8,5	14	41,1 min	402 ms	142 ms
S&P 500 (indeks)	12,1 %	0,85	12,1 %	0,85	0,0	–	–	–	–

Tabela 7 zbira bruto in neto mere. PatchTST doseže najvišji Sharpe (1,38; 17,6 %) in tako jasno prekaša svoje ujemaajoče zgodovinsko povprečje čez 336 dni (1,10; 14,7 %). TFT doseže Sharpe 1,10 (16,4 %) in prav tako preseže svoje (krajše, šibkejšje) zgodovinsko povprečje čez 271 dni (0,99; 13,6 %). MASTER je edini transformer, ki v tem primeru zaostane za svojim zgodovinskim povprečjem: Sharpe 0,73 (11,6 %) proti 1,01 (14,0 %) čez 67 dni. Vsa tri zgodovinska povprečja in TFT presežejo pasivni S&P 500 (0,85; 12,1 %); PatchTST ga preseže z največjo razliko. PatchTST torej vzdržuje prednost pred svojim zgodovinskim povprečjem prek celotnega 14-letnega obdobja, ki zajema tako krizna (2020, 2022) kot mirnejša leta, TFT enako, medtem ko MASTER v tem dolgoročnem, velikem naboru (61 sredstev) zgodovini podleže.

Vpliv transakcijskih stroškov. Gibanje vrednosti portfeljev v bruto in neto različici prikazuje Slika 7. Pri 10 b.t. na enoto letnega prometa se vrstni red ohrani: PatchTST in TFT ostaneta jasno pred svojim ujemaajočim zgodovinskim povprečjem in pred S&P 500 tudi neto, MASTER pa ostane edini transformer pod svojim zgodovinskim povprečjem, tokrat še bolj izrazito. Stroški niso nevtralni glede na model – MASTER ima daleč najvišji letni promet (18,3), zato ga strošek prizadene najbolj (Sharpe 0,73 → 0,61, –0,12); TFT ima med transformerji najnižji promet (8,5, blizu ravni zgodovinskih povprečij) in je zato do stroškov najbolj odporen (1,10 → 1,04, –0,06); PatchTST je vmes (14,4 promet, 1,38 → 1,27, –0,11). Ugotovitev torej ostane robustna na realistične transakcijske stroške, promet portfelja pa je pomembna dodatna dimenzija pri izbiri modela za praktično uporabo (glej tudi razdelek 6.7).

V vsakem od petih eksperimentov (Leow, Wang, DJIA, NASDAQ 100 in dolgoročni primer) vsaj en transformer preseže svoje ujemaajoče zgodovinsko povprečje, vendar ni vedno isti model: TFT je najuspešnejši v krizi (Leow) in pri Wang, PatchTST na DJIA in v dolgoročnem primeru, MASTER pa na večjem naboru NASDAQ 100, kjer TFT zaostane. Uspešnost posameznega modela torej ni univerzalna lastnost, ampak je odvisna od protokola in nabora sredstev, zato rezultatov ne posplošujemo na en sam »najboljši« model.



Slika 7. Gibanje vrednosti portfelja v dolgoročnem primeru (2011–2024, $P=0,5$): bruto (levo) in neto pri 10 b.t. (desno). Prisoten je survivorship bias.

6.7. Stabilnost napovedi in promet portfelja. Ta analiza ni povzeta po izvornem članku, ampak je naša dopolnilna analiza prejšnjih razdelkov: portfeljska uspešnost se ne ujema vedno z vrstnim redom modelov po drugih lastnostih, zato v Tabeli 8 primerjamo še

povprečni promet portfelja na odločitev (enačba 26). Odločitve so v eksperimentih različno pogoste (tedenske pri Leow, na 120 dni pri Wang, mesečne pri ostalih), zato vrednosti med vrsticami niso neposredno primerljive, med stolpci posamezne vrstice pa so.

Tabela 8. Povprečni promet portfelja na odločitev za transformerske modele (optimizator RD, $P=0,5$).

Eksperiment	TFT	MASTER	PatchTST
Leow All-Weather	0,17	–	0,34
Wang S&P 500	0,52	1,33	1,38
Aprea DJIA	0,70	1,46	1,07
Aprea NASDAQ 100	0,66	1,65	1,16
Dolgoročno vlaganje	0,71	1,54	1,21

TFT ima v vseh petih eksperimentih najnižji promet, MASTER pa v vseh štirih, kjer nastopa, najvišji ali skoraj najvišji. Razlika je največja pri NASDAQ 100 (0,66 proti 1,65) in v dolgoročnem primeru, kjer se prenese v neto rezultat (razdelek 6.6). Nižji promet pomeni manj izrazite spremembe izbora in uteži med zaporednimi odločitvami in praviloma manj trgovanja. Portfeljski izid je zato odvisen od celotnega eksperimentalnega postopka: poleg same napovedi so pomembni tudi velikost napovedanih donosov, odziv optimizatorja nanje in stabilnost portfeljskih odločitev.

6.8. Računski čas. Vse eksperimente smo pognali na enem samem osebem računalniku Apple Mac s procesorjem Apple M4 Pro (14-jedrni CPU, 20-jedrni GPU) in 64 GB pomnilnika, pod sistemom macOS 27. Učenje transformerskih modelov (PyTorch 2.12, Python 3.10) pospešujemo prek Appleovega vmesnika Metal Performance Shaders (MPS); optimizacijski del, implementiran v C++17, teče izključno na CPU. Poročani časi so zato vezani na to strojno opremo in jih ne gre neposredno posploševati na druge konfiguracije.

Časi učenja in optimizacije so podani v tabelah posameznih eksperimentov; čas učenja je prikazan na eno učenje, optimizacija pa kot povprečni čas ene odločitve pri $P=0,5$.

Prvič, učenje popolnoma prevlada nad optimizacijo. Najcenejše učenje je pri PatchTST (2–4 min, razen pri Leow, kjer sta modela po ceni skoraj enaka: 17 in 19 s), najdražje pri TFT (do 63 min), MASTER je vmes. Ena odločitev optimizatorja traja med 16 ms in 2,1 s, torej je eno učenje od približno 50-krat (PatchTST pri Wang) do več kot 10 000-krat (TFT na NASDAQ 100) dražje od enega reševanja; pri Leow, kjer se modeli ob vsaki odločitvi ponovno učijo, je razmerje okoli 250. Izbira napovednega modela in pogostost ponovnega učenja sta tako glavni vzvod računskega stroška, ne izbira optimizatorja.

Drugič, PatchTST je skoraj neodvisen od velikosti nabora (1,8–3,6 min od 28 do 494 sredstev), saj kanale obravnava ločeno z istimi parametri. Čas učenja TFT in MASTER s N ne narašča monotono: TFT potrebuje 25,2 min pri $N=28$, 63,7 min pri $N=54$ in 41,1 min pri $N=61$, kar kaže, da je čas odvisen tudi od dolžine učnega okna in zgodnjega ustavljanja, ne le od števila sredstev.

Tretjič, čas optimizacije določajo N , K in proračun reševalnika, ne vir $\hat{\mu}$: znotraj posameznega eksperimenta se razlikuje manj kot 5 % med vsemi viri. SO je v eksperimentih z napovednimi modeli približno 2,8- do 4,3-krat hitrejša od RD (DJIA 4,3-krat, NASDAQ 100 3,5-krat, dolgoročni primer 2,8-krat), pri 494 sredstvih pa le 1,3-krat. Na OR-Library je pospešitev podobna (1,8- do 3,5-krat na posamezno reševanje); SO je tam poleg tega tudi natančnejši (razdelek 6.1).

Cena modela ne napoveduje uspešnosti. Pri Wang je TFT približno petintrideset-krat dražji od PatchTST (62,6 proti 1,8 min na učenje) in najboljši po Sharpovem količniku, na NASDAQ 100 pa je ob najvišji ceni (63,7 min) najslabši; PatchTST je najcenejši in hkrati najboljši na DJIA in v dolgoročnem primeru. Celoten eksperimentalni postopek ostane izvedljiv na enem prenosnem računalniku: najdražji posamezni eksperiment (TFT, dolgoročno vlaganje) skupaj zahteva 9,59 h učenja, optimizacija pa približno minuto (168 odločitev po okoli 0,4 s).

7. Sklep

V magistrskem delu smo zasnovali eksperimentalni postopek za sestavo kardinalno omejenega portfelja, ki napovedovanje pričakovanih donosov in optimizacijo uteži obravnava kot dva ločena, vendar zaporedno povezana problema. Pričakovane donose $\hat{\mu}$ ocenjujemo s tremi arhitekturno različnimi transformerskimi modeli (MASTER, TFT in PatchTST), uteži pa iščeta rojenje delcev in simulirano ohlajanje. Pravilnost lastne izvedbe optimizatorjev smo neodvisno preverili na standardnih problemih OR-Library, celoten eksperimentalni postopek pa ovrednotili v postopnem testiranju na treh eksperimentih iz literature (Leow, Wang, Aprea in Sbaiz) ter na dolgoročnem primeru.

Transformerski napovedni signal pozitivno vpliva na vrednost portfelja, a ne prek enega samega, dosledno najboljšega modela: v vsakem od petih eksperimentov vsaj

en transformer jasno preseže svoje ujemajoče zgodovinsko povprečje, kateri model je to, pa se menja z naborom sredstev in protokolom. Razlike med rojenjem delcev in simuliranim ohlajanjem so majhne in nekonsistentne prek eksperimentov, kar kaže, da je kakovost napovednega signala $\hat{\mu}$ pomembnejši dejavnik portfeljske uspešnosti kot izbira optimizatorja. Računsko je učenje modelov za več velikostnih razredov dražje od optimizacije, zato je izbira napovednega modela tudi glavni vzvod računskega stroška.

V prihodnje bi lahko eksperimentalni postopek razširili z natančnejšim modeliranjem transakcijskih stroškov in davkov, z robustnejšimi ocenami kovariančne matrike, s samodejnim izborom napovednega modela glede na tržni režim ter z merami repnega tveganja. Druga smer je tesnejša sklopitev napovedovanja in optimizacije v enoten pristop, naučen skozi optimizacijo [7]. Poleg tega bi bilo smiselno napovedno kakovost modelov ovrednotiti tudi neposredno, na standardnih presečnih merah in daljših testnih obdobjih, ter preveriti, v kolikšni meri portfeljsko prednost pojasnjuje napovedna korelacija in v kolikšni drugi dejavniki, na primer velikost napovedi in odziv optimizatorja.

Literatura

- Markowitz H (1952) Portfolio selection. *The Journal of Finance* 7(1):77–91.
- Chang TJ, Meade N, Beasley JE, Sharaiha YM (2000) Heuristics for cardinality constrained portfolio optimisation. *Computers & Operations Research* 27(13):1271–1302.
- Nie Y, Nguyen NH, Sinthong P, Kalagnanam J (2023) A time series is worth 64 words: Long-term forecasting with transformers in *Proceedings of the Eleventh International Conference on Learning Representations (ICLR)*. <https://doi.org/10.48550/arXiv.2211.14730>.
- Lim B, Arik SÖ, Loeff N, Pfister T (2021) Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting* 37(4):1748–1764.
- Li T et al. (2024) MASTER: Market-guided stock transformer for stock price forecasting in *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 38, pp. 162–170.
- Leow EKW, Nguyen BP, Chua MCH (2021) Robo-advisor using genetic algorithm and BERT sentiments from tweets for hybrid portfolio optimisation. *Expert Systems with Applications* 179:115060.
- Wang R et al. (2023) Towards one-shot neural combinatorial solvers: Theoretical and empirical notes on the cardinality-constrained case in *International Conference on Learning Representations (ICLR)*. Na voljo na: <https://openreview.net/forum?id=h21yJhdzwbw>. Dostopano: 18. 9. 2026.
- Aprea IL, Sbaiz G (2026) A neural network-particle swarm solver for sustainable portfolio optimization problems. *Decisions in Economics and Finance* 49(1):25–64.
- Michaud RO (1989) The Markowitz optimization enigma: Is 'optimized' optimal? *Financial Analysts Journal* 45(1):31–42.
- Black F, Litterman R (1992) Global portfolio optimization. *Financial Analysts Journal* 48(5):28–43.
- He G, Litterman R (1999) The intuition behind Black-Litterman model portfolios, (Goldman Sachs Investment Management Research), Technical report. <https://doi.org/10.2139/ssrn.334304>.
- DeMiguel V, Garlappi L, Uppal R (2009) Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies* 22(5):1915–1953.
- Bessler W, Opfer H, Wolff D (2017) Multi-asset portfolio optimization and out-of-sample performance: An evaluation of Black-Litterman, mean-variance, and naive diversification approaches. *The European Journal of Finance* 23(1):1–30.
- Tu J, Zhou G (2011) Markowitz meets talmud: A combination of sophisticated and naive diversification strategies. *Journal of Financial Economics* 99(1):204–215.
- Bienstock D (1996) Computational study of a family of mixed-integer quadratic programming problems. *Mathematical Programming* 74(2):121–140.
- Gao J, Li D (2013) Optimal cardinality constrained portfolio selection. *Operations Research* 61(3):745–761.
- Brodie J, Daubechies I, De Mol C, Giannone D, Loris I (2009) Sparse and stable Markowitz portfolios. *Proceedings of the National Academy of Sciences of the United States of America* 106(30):12267–12272.
- Kim MJ, Lee Y, Kim JH, Kim WC (2016) Sparse tangent portfolio selection via semi-definite relaxation. *Operations Research Letters* 44(4):540–543.
- Akbar MA, Kalayci CB, Polat O (2020) A parallel variable neighborhood search algorithm with quadratic programming for cardinality constrained portfolio optimization. *Knowledge-Based Systems* 198:105944.
- Jegadeesh N, Titman S (1993) Returns to buying winners and selling losers: Implications for stock market efficiency. *The Journal of Finance* 48(1):65–91.
- Carhart MM (1997) On persistence in mutual fund performance. *The Journal of Finance* 52(1):57–82.
- Gu S, Kelly B, Xiu D (2020) Empirical asset pricing via machine learning. *The Review of Financial Studies* 33(5):2223–2273.
- Ke G et al. (2017) LightGBM: A highly efficient gradient boosting decision tree in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 3146–3154. Na voljo na: https://papers.nips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html. Dostopano: 18. 9. 2026.
- Selvin S, Vinayakumar R, Gopalakrishnan EA, Menon VK, So-man KP (2017) Stock price prediction using LSTM, RNN and CNN-sliding window model in *2017 International Conference on Advances in Computing, Communications and Informatics (ICACCI)*. pp. 1643–1647.
- Hochreiter S, Schmidhuber J (1997) Long short-term memory. *Neural Computation* 9(8):1735–1780.
- Barua R, Sharma AK (2022) Dynamic Black Litterman portfolios with views derived via CNN-BiLSTM predictions. *Finance Research Letters* 49:103111.
- Vaswani A et al. (2017) Attention is all you need in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 5998–6008.
- Wang C, Chen Y, Zhang S, Zhang Q (2022) Stock market index prediction using deep Transformer model. *Expert Systems with Applications* 208:118128.
- Zhang Q et al. (2022) Transformer-based attention network for stock movement prediction. *Expert Systems with Applications* 202:117239.
- Wu H, Xu J, Wang J, Long M (2021) Autoformer: Decomposition transformers with Auto-Correlation for long-term series forecasting in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 34, pp. 22419–22430.
- Das A, Kong W, Sen R, Zhou Y (2024) A decoder-only foundation model for time-series forecasting in *Proceedings of the 41st International Conference on Machine Learning (ICML)*. Vol. 235, pp. 10148–10167.
- Ye J, Zhao J, Ye K, Xu C (2021) Multi-graph convolutional network for relationship-driven stock movement prediction in *2020 25th International Conference on Pattern Recognition (ICPR)*. pp. 6702–6709.
- Li W et al. (2020) Modeling the stock relation with graph network for overnight stock movement prediction in *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence*. pp. 4541–4547.
- Sawhney R, Agarwal S, Wadhwa A, Shah RR (2020) Deep attentive learning for stock movement prediction from social media text and company correlations in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. (Association for Computational Linguistics), pp. 8415–8426.
- Cheng D, Yang F, Xiang S, Liu J (2022) Financial time series forecasting with multi-modality graph neural network. *Pattern Recognition* 121:108218.
- Fan J, Fan Y, Lv J (2008) High dimensional covariance matrix estimation using a factor model. *Journal of Econometrics* 147(1):186–197.
- Engle R (2002) Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics* 20(3):339–350.
- Chiriac R, Voev V (2011) Modelling and forecasting multivariate realized volatility. *Journal of Applied Econometrics* 26(6):922–947.
- Lin H, Zhou D, Liu W, Bian J (2021) Deep risk model: A deep learning solution for mining latent risk factors to improve covariance matrix estimation in *Proceedings of the Second ACM International Conference on AI in Finance (ICAIF)*. <https://doi.org/10.1145/3490354.3494377>.
- Yang L, Zhao S, Chai S (2026) Neural nonlinear shrinkage of covariance matrices for minimum variance portfolio optimization (arXiv preprint arXiv:2601.15597 [q-fin.PM]). <https://doi.org/10.48550/arXiv.2601.15597>.
- Salinas D, Bohlke-Schneider M, Callot L, Medico R, Gasthaus J (2019) High-dimensional multivariate forecasting with low-rank Gaussian copula processes in *Advances in Neural Information*

- Processing Systems (NeurIPS). Vol. 32, pp. 6824–6834.
42. Cura T (2009) Particle swarm optimization approach to portfolio optimization. *Nonlinear Analysis: Real World Applications* 10(4):2396–2406.
 43. Nie Y (2023) PatchTST: A time series is worth 64 words: Long-term forecasting with transformers (uradna koda). Na voljo na: <https://github.com/yuqinie98/PatchTST>. Dostopano: 27. 9. 2026.
 44. Beitner J (2020) pytorch-forecasting: Time series forecasting with PyTorch. Na voljo na: <https://github.com/jdb78/pytorch-forecasting>. Dostopano: 24. 9. 2026.
 45. SJTU-DMTai (2024) MASTER: Market-guided stock transformer for stock price forecasting (uradna koda). Na voljo na: <https://github.com/SJTU-DMTai/MASTER>. Dostopano: 27. 9. 2026.
 46. Yang X, Liu W, Zhou D, Bian J, Liu TY (2020) Qlib: An AI-oriented quantitative investment platform. *arXiv preprint arXiv:2009.11189*. <https://arxiv.org/abs/2009.11189>.
 47. Kennedy J, Eberhart R (1995) Particle swarm optimization in *Proceedings of the IEEE International Conference on Neural Networks*. Vol. 4, pp. 1942–1948.
 48. Kirkpatrick S, Gelatt CD, Vecchi MP (1983) Optimization by simulated annealing. *Science* 220(4598):671–680.
 49. Crama Y, Schyns M (2003) Simulated annealing for complex portfolio selection problems. *European Journal of Operational Research* 150(3):546–571.
 50. Sharpe WF (1994) The Sharpe ratio. *The Journal of Portfolio Management* 21(1):49–58.
 51. Beasley JE (1990) OR-Library: Distributing test problems by electronic mail. *Journal of the Operational Research Society* 41(11):1069–1072.

Priloge

A. Nastavitve in ponovljivost. Vse nastavitve, uporabljene pri eksperimentih, so zbrane v Tabelah 9 in 10; tu navedemo le tiste, na katere se neposredno sklicujemo v besedilu, celoten nabor konfiguracijskih datotek pa je del objavljenega repozitorija. V osnovnih konfiguracijah uporabljamo naključno seme 42 pri TFT in MASTER ter 2021 pri PatchTST; protokolno specifične izjeme in morebitna ponavljanja z več semeni so navedeni neposredno ob posameznem eksperimentu.

Tabela 9. Ključne nastavitve napovednih modelov in optimizacijskih algoritmov. Preostali hiperparametri so del objavljenega repozitorija.

Sklop	Uporabljene nastavitve
RD	velikost roja 200; največ 1500 generacij.
SO	$L = 2N$; prag mirovanja $S = 5$.
TFT	hitrost učenja 10^{-3} ; največ 100 epoh; potrpežljivost 10.
MASTER	hitrost učenja 10^{-5} ; največ 100 epoh; potrpežljivost 10.
PatchTST	vhodno okno 336; hitrost učenja 10^{-4} ; največ 100 epoh; potrpežljivost 10.

Tabela 10. Osnovne nastavitve posameznih eksperimentalnih problemov.

Nastavitev	Leow All-Weather	Wang S&P 500	Dolgoročno vlaganje
N	5	494	61
K	5	20	20
Uteži	0,01–0,40	0,001–1,0	0,01–0,1
Učenje	2018–2019	2018–2020	2005–2010
Test	2020	2021	2011–2024
Uravnoteževanje	tedensko	mesečno	mesečno
H	5	120	21
Ponovno učenje	ob vsaki odločitvi	enkrat	letno
Optimizator	RD in SO	RD	RD
Stroški	bruto	bruto	10 b. t.
P	0,05–0,95 (11 točk)	0,2	0,5

Napovedno obdobje H ni lastnost ene same arhitekture, temveč ga določa eksperiment. Enako velja za nabor sredstev, kardinalnost, omejitve uteži, pogostost uravnoteževanja, ponovno učenje in parameter P .