



Optimizacija naložbenih portfeljev z uporabo transformerjev in globalnih optimizacijskih algoritmov

Nejc Škrbec

Magistrski študijski program Računalništvo in informatika, smer Računalništvo in informatika

Fakulteta za računalništvo in informatiko

Mentor: doc. dr. Luka Fürst

Copyright: To delo je ponujeno pod licenco CC-BY-4.0. Razvita programska oprema in rezultati dela so na voljo v okviru GPL-3.0-or-later na <https://github.com/nejcscrbec/portfolio-optimization-using-transformers-and-global-optimization-algorithms>.

V magistrskem delu obravnavamo kardinalno omejeno optimizacijo naložbenih portfeljev. Pričakovane donose ocenjujemo s tremi transformerskimi modeli (MASTER, TFT in PatchTST), uteži pa iščeta rojenje delcev in simulirano ohlajanje. Optimizatorja preverimo na problemih OR-Library, celoten eksperimentalni postopek pa v postopnem vrednotenju na treh eksperimentih iz literature in na lastnem dolgoročnem vlaganju s transakcijskimi stroški. Vsak model primerjamo z zgodovinskim povprečjem z enakim oknom. V vseh štirih eksperimentih vsaj en transformer preseže svoje zgodovinsko povprečje, vendar ni vedno isti: TFT je najuspešnejši pri polletnem in kriznem vlaganju, PatchTST pa pri mesečnem in dolgoročnem (Sharpev količnik 1,38 proti 1,10). Razlike med optimizatorjema so majhne.

Optimizacija portfelja | Kardinalna omejitev | Transformerji | Napovedovanje donosov | Rojenje delcev | Simulirano ohlajanje

Optimizacija naložbenih portfeljev (v nadaljevanju ONP) predstavlja enega temeljnih problemov kvantitativnih financ. Cilj njenega reševanja je razporediti razpoložljivi kapital med več finančnih sredstev tako, da dosežemo čim ugodnejše razmerje med pričakovanim donosom in tveganjem.

Denimo, da imamo nabor N finančnih sredstev, ki jih spremljamo v diskretnih časovnih korakih $t = 0, 1, \dots, T$. Ob koncu vsakega trgovalnega dne ima vsako sredstvo določeno zaključno ceno $p_{i,t}$. Enostavni donos $r_{i,t}$ in logaritemski donos $\tilde{r}_{i,t}$ definiramo z enačbama (1). Enostavni donos izraža relativno spremembo vrednosti sredstva, logaritemski pa je priročnejši pri modeliranju.

$$r_{i,t} = \frac{p_{i,t} - p_{i,t-1}}{p_{i,t-1}} = \frac{p_{i,t}}{p_{i,t-1}} - 1, \quad \tilde{r}_{i,t} = \ln \left(\frac{p_{i,t}}{p_{i,t-1}} \right). \quad (1)$$

Portfelj sestavimo v odločitvenem trenutku t , to sestavo pa imenujemo odločitev. Nato vstopimo v napovedno obdobje od $t+1$ do $t+H$, v katerem portfelj ostane nespremenjen do naslednje odločitve. Napovedno obdobje torej obsega H prihodnjih trgovalnih dni in je hkrati obdobje, za katero napovedni model tvori napoved. Glede na uporabljeni model se lahko razlikujeta definicija ciljne spremenljivke in način, kako dnevne napovedi združimo v skupno oceno za napovedno obdobje. Konkretno oblikovanje napovedi zato opišemo pri posameznih modelih v razdelku 2.

Donose vseh sredstev v času t zberemo v vektor $\mathbf{r}_t = (r_{1,t}, \dots, r_{N,t})^\top$. Portfelj opišemo z vektorjem uteži $\mathbf{w} = (w_1, \dots, w_N)^\top$, kjer w_i predstavlja delež kapitala, vloženega v sredstvo i . Donos portfelja $\mathbf{r}_t^\top \mathbf{w}$ opišemo z enačbo (2).

$$\mathbf{r}_t^\top \mathbf{w} = \mathbf{w}^\top \mathbf{r}_t. \quad (2)$$

Klasično izhodišče za reševanje ONP predstavlja Markowitzev model [1], ki portfelj obravnava na podlagi pričakovanih donosov sredstev ter njihovega tveganja in medsebojne povezanosti. Prvo opišemo z vektorjem μ , tveganje pa s kovariančno matriko Σ . Enačbi obeh zapišemo kot (3).

$$\mu = \mathbb{E}[\mathbf{r}], \quad \Sigma = \mathbb{E}[(\mathbf{r} - \mu)(\mathbf{r} - \mu)^\top]. \quad (3)$$

V praksi točnih prihodnjih vrednosti μ in Σ ne moremo poznati preden se lotimo optimizacije, zato moramo najprej poiskati in kasneje pri optimizaciji uporabiti njuni oceni $\hat{\mu}$ in $\hat{\Sigma}$. Pri tem je treba upoštevati, da lahko nenatančne ocene pričakovanih donosov vodijo do neugodnega končnega razmerja med donosom in tveganjem v portfelju, tudi kadar je sam optimizacijski postopek izveden optimalno. V razdelku 2 podrobneje predstavimo načine ocenjevanja obeh količin, pri čemer se osredotočimo predvsem na uporabo transformerskih modelov za ocenjevanje pričakovanih donosov.

V tej nalogi klasično ONP razširimo z omejitvami, ki bolje odražajo praktične zahteve pri sestavi portfelja. Najpomembnejša je kardinalna omejitev, ki zahteva, da portfelj vsebuje natanko K različnih sredstev. Tako lahko na primer pri oblikovanju portfelja iz univerzuma indeksa S&P 500 omejimo število izbranih sredstev na vnaprej določeno vrednost K . Izbira optimalne vrednosti K predstavlja ločen problem, ki ga v tem delu ne obravnavamo. Za vsako izbrano sredstvo dodatno določimo še najmanjši in največji

Investment Portfolio Optimization Using Transformers and Global Optimization Algorithms

This thesis studies cardinality-constrained portfolio optimization. Expected returns are estimated with three transformer models (MASTER, TFT and PatchTST), and weights are found with particle swarm optimization and simulated annealing. We verify the optimizers on the OR-Library instances and test the complete experimental procedure with walk-forward evaluation on three experiments from the literature and on our own long-term scenario with transaction costs. Each model is compared with its matched historical mean. In all four experiments at least one transformer beats its historical mean, but not always the same one: TFT is strongest in the half-year and crisis scenarios, and PatchTST in the monthly and long-term ones (Sharpe ratio 1.38 against 1.10). Differences between the optimizers are small.

Portfolio optimization | Cardinality constraint | Transformers | Return forecasting | Particle swarm optimization | Simulated annealing

dovoljeni delež v portfelju. Tako dobimo kardinalno omejeno optimizacijo naložbenega portfelja (v nadaljevanju KONP).

KONP je zahtevnejša od osnovne ONP, ker poleg določanja uteži vključuje tudi diskretno izbiro sredstev: optimizator mora hkrati določiti, katerih K sredstev izmed N bo vključil in kako bo mednje razporedil kapital. Že sam izbor omogoča $\binom{N}{K}$ kombinacij, zato izčrpno iskanje pri večjih problemih hitro postane nepraktično [2]. V razdelku 4 zato predstavimo dva stohastična globalna optimizacijska algoritma, ki ju uporabimo za reševanje tega problema.

KONP zapišemo z enačbo (4), ki združuje ocenjeni pričakovani donos portfelja $\hat{\mu}^\top \mathbf{w}$ in njegovo ocenjeno tveganje, izraženo s kovariančno matriko $\mathbf{w}^\top \hat{\Sigma} \mathbf{w}$. Parameter $P \in [0, 1]$ določa razmerje med njima: večja vrednost daje večjo težo pričakovanemu donosu, manjša pa zmanjševanju tveganja.

Poleg osnovne enačbe moramo nabor veljavnih rešitev KONP omejiti še z nekaj omejitvami. Proračunska omejitev (5) zahteva, da je vsota vseh uteži enaka ena, zato je ves razpoložljivi kapital razporejen med sredstva. Kardinalna omejitev (6) zahteva, da je v portfelj vključenih natanko K sredstev, pri čemer binarna spremenljivka z_i določa, ali je sredstvo i vključeno v portfelj. Utežna omejitev (7) povezuje izbiro sredstva z njegovo utežjo: pri $z_i = 0$ mora biti $w_i = 0$, pri $z_i = 1$ pa mora utež ležati med spodnjo mejo ε_i , ki preprečuje zanemarljivo majhne pozicije, in zgornjo mejo δ_i , ki omejuje koncentracijo kapitala v posameznem sredstvu.

$$\max_{\mathbf{w}, \mathbf{z}} \quad P \hat{\mu}^\top \mathbf{w} - (1 - P) \mathbf{w}^\top \hat{\Sigma} \mathbf{w} \quad (4)$$

$$\text{p.p.} \quad \sum_{i=1}^N w_i = 1, \quad (5)$$

$$\sum_{i=1}^N z_i = K, \quad (6)$$

$$\varepsilon_i z_i \leq w_i \leq \delta_i z_i, \quad z_i \in \{0, 1\}, \quad i = 1, \dots, N. \quad (7)$$

V našem delu za reševanje KONP vpeljemo dvostopenjski eksperimentalni postopek:

1. Najprej ocenimo pričakovane donose $\hat{\mu}$. Namesto zgolj zgodovinskega povprečja uporabimo tri arhitekturno različne transformerske modele: PatchTST [3], Temporal Fusion Transformer (TFT) [4] in MASTER [5]. Njihovo delovanje in način vrednotenja predstavimo v razdelku 2. Pred reševanjem KONP napovedne ocene in oceno tveganja postavimo na skupno skalo, podrobnosti tega postopka pa opišemo v razdelku 2. Kovariančno matriko $\hat{\Sigma}$ enostavno ocenimo iz zgodovinskih donosov.
2. Tako dobljene ocene pričakovanih donosov uporabimo pri reševanju KONP z dvema stohastičnima globalnima optimizacijskima algoritmoma: rojenjem delcev (RD) in simuliranim ohlajanjem (SO). Oba algoritma omogočata iskanje kakovostnih rešitev brez izčrpnega pregleda vseh kombinacij sredstev, vendar prostor rešitev raziskujeta na različna načina. Algoritma podrobneje predstavimo v razdelku 4.

Evalvacija eksperimentalnega postopka poteka v dveh delih. Najprej napovedni in optimizacijski del ovrednotimo ločeno. Napovedne modele ocenimo z merami povezanosti med napovedanimi in realiziranimi donosi, algoritma RD in SO pa na standardnih testnih problemih z znanimi referenčnimi rezultati. Metodologijo vrednotenja in uporabljene mere podrobneje opišemo v razdelku 5.

Nato ovrednotimo še celoten eksperimentalni postopek s postopnim vrednotenjem zunaj učnega vzorca (angl. *out-of-sample walk-forward evaluation*) na eksperimentih treh predhodnih raziskav [6–8], ki se razlikujejo po naboru sredstev, časovnem obdobju, pogostosti odločanja in napovednem obdobju, ter v dodatnem primeru dolgoročnega vlaganja, v katerem preverimo praktično uporabnost našega pristopa. Rezultate eksperimentalne evalvacije predstavimo v razdelku 6, kjer ločeno obravnavamo napovedne in optimizacijske rezultate ter rezultate celotnega eksperimentalnega postopka.

Osrednji prispevek dela je povezava sodobnih transformerskih napovednih modelov z metahevrističnim reševanjem KONP ter ločeno vrednotenje obeh delov našega pristopa. Tako lahko analiziramo dve povezani vprašanji: ali kakovostnejše napovedi pričakovanih donosov vodijo do uspešnejših portfeljev in koliko je končni rezultat odvisen od uporabljenega optimizacijskega postopka. V sklepu v razdelku 7 povzamemo glavne ugotovitve in možnosti za nadaljnje raziskovanje.

1. Sorodna dela

Znanstvene članke, ki si delijo raziskovalno področje z našim delom, lahko razdelimo na tri skupine: optimizacijo portfeljev, napovedovanje prihodnjih donosov in ocenjevanje tveganja. Na vseh treh se je razvoj postopoma premikal od preprostejših statističnih pristopov k metodam, ki lahko obravnavajo več podatkov, več omejitev in zahtevnejše povezave med sredstvi.

1.1. Optimizacija naložbenih portfeljev. Po Markowitzevem modelu [1] se je velik del raziskav osredotočil na vprašanje, kako zanesljivi so optimizirani portfelji, kadar so njihovi vhodni podatki ocenjeni iz omejenega nabora. Michaud [9] je opozoril, da lahko že majhne napake v ocenjenih donosih povzročijo velike spremembe v sestavi portfelja. Zato so se razvili pristopi, ki skušajo zmanjšati vpliv teh napak. Med najbolj znanimi je Black–Littermanov model [10, 11], ki pri oblikovanju ocen prihodnjih donosov upošteva dodatne informacije o trgu. Empirične primerjave so hkrati pokazale, da zahtevnejša optimizacija ni vedno uspešnejša od preprostih strategij [12–14].

Omenimo še pristope k reševanju KONP. Zgodnejše raziskave so uporabljale natančne matematične postopke [15, 16], vzporedno pa so se razvijali tudi heuristični pristopi, ki iščejo kakovostne rešitve brez preiskovanja vseh možnih kombinacij [2]. Kasnejše metode so problem poskušale poenostaviti tako, da spodbujajo manjše število izbranih sredstev [17, 18], ali pa so združile več različnih načinov iskanja in določanja uteži [19].

1.2. Napovedovanje pričakovanih donosov. Zgodnejše raziskave napovedovanja donosov so iskale predvsem ponavljajoče se zakonitosti v preteklih podatkih in ekonomskih značilnostih sredstev. Primer je moment, pri katerem imajo sredstva z relativno boljšimi preteklimi donosi v določenih obdobjih težnjo, da ostanejo uspešnejša tudi v bližnji prihodnosti [20, 21]. Takšni pristopi temeljijo predvsem na vnaprej določenih signalih. Z večjo količino razpoložljivih podatkov pa so se začele uporabljati metode strojnega učenja, ki lahko same poiščejo uporabne nelinearne povezave med večjim številom značilk [22]. Med takšne pristope sodijo tudi modeli, kot je LightGBM [23].

Naslednji korak je bil neposredno modeliranje časovnega razvoja podatkov z nevronske mreže. Selvin in sod. [24] so pri napovedovanju cen delnic primerjali več rekurentnih in konvolucijskih arhitektur. Modeli, kot je LSTM [25], so bili pri tem zanimivi predvsem zato, ker lahko pri napovedi upoštevajo informacije iz daljšega zaporedja preteklih opazovanj. Napovedni modeli so se začeli vključevati tudi neposredno v postopke sestave portfeljev. Barua in Sharma [26] sta na primer napovedi nevronskega modela uporabila kot vhod v Black–Littermanov pristop.

Novejši razvoj predstavljajo arhitekture s pozornostjo in transformerji [27]. Ti omogočajo, da model pri napovedi neposredno ovrednoti pomen različnih delov vhodnega zaporedja, zato so postali zanimivi tudi za finančne časovne vrste [28, 29]. Vzporedno so se razvili splošnejši modeli za napovedovanje časovnih vrst [30, 31]. Raziskave se hkrati vse bolj oddaljujejo od obravnave posamezne delnice kot izoliranega zaporedja. Nekateri modeli upoštevajo povezave med različnimi delnicami [32, 33], drugi pa cenovne podatke dopolnjujejo z novicami, besedili in informacijami o podjetjih [34, 35]. Leow in sod. [6] so na primer razpoložene iz družbenih omrežij, ki ga zajamejo z modelom BERT, prek genetskega algoritma vključili v klasično sestavo portfelja. Njihovo delo uporabimo kot zunanjo referenčno primerjavo v razdelku 6.3. V našem delu iz tega širšega razvoja izberemo TFT [4], MASTER [5] in PatchTST [3], ki predstavljajo tri različne načine uporabe transformerjev za napovedovanje časovnih vrst in finančnih donosov.

1.3. Ocenjevanje tveganja in kovariančne matrike. Pri sestavi portfelja moramo poleg prihodnjih donosov oceniti tudi tveganje in povezanost med sredstvi. Osnovna težava je, da pri večjem številu sredstev hitro naraste število povezav, ki jih moramo oceniti iz omejenega števila opazovanj. Raziskave so zato iskale načine, kako ocenjevanje poenostaviti ali stabilizirati. Faktorski modeli skupno gibanje velikega števila sredstev opišejo z manjšim številom skupnih dejavnikov [36]. Druga smer upošteva, da se tveganje in povezanost med sredstvi skozi čas spreminjata, zato ju modelira dinamično [37, 38].

Pomemben pristop je tudi neposredna stabilizacija kovariančne matrike, saj je vzorčna cenilka pri omejenem številu opazovanj lahko zelo nestabilna. Novejše raziskave to težavo rešujejo z metodami strojnega učenja. Nekateri pristopi se iz podatkov učijo skupnih dejavnikov tveganja [39], drugi pa poskušajo izboljšati samo oceno kovariančne matrike [40]. Še druga možnost je, da namesto posameznih kovarianc modeliramo skupno porazdelitev več časovnih vrst. Tak primer je GPVar [41]. V tej nalogi se osredotočimo predvsem na vpliv napovedi pričakovanih donosov, zato pri vseh treh transformerskih modelih uporabimo isto vzorčno kovariančno matriko zgodovinskih donosov. S tem pri primerjavi napovednih modelov ohranimo nespremenjen vhod, ki opisuje tveganje.

2. Napovedovanje pričakovanih donosov

V našem delu $\hat{\mu}$ ocenimo z zgodovinskim povprečjem in s tremi transformerskimi modeli: PatchTST [3], Temporal Fusion Transformer (TFT) [4] in MASTER [5]. Postopek učenja je skupen vsem trem napovednim modelom in je opisan v razdelku 5.2.

2.1. Zgodovinsko povprečje. Pričakovani donos sredstva i ocenimo kot njegov povprečni dnevni donos $r_{t,i}$ v zadnjih L trgovalnih dneh pred odločitvenim trenutkom t , preračunan na napovedno obdobje H , kar opišemo z enačbo (8). Na ta način tudi izvori članki naših optimizacijskih algoritmov dobijo vhodne podatke za optimizacijski postopek [2, 42].

$$\hat{\mu}_{t,i} = H \cdot \frac{1}{L} \sum_{k=0}^{L-1} r_{t-k,i}. \quad (8)$$

2.2. PatchTST. [3] je transformerski model za napovedovanje večspremenljivih časovnih vrst. Večspremenljiva časovna vrsta vsebuje več spremenljivk, opazovanih skozi čas, medtem ko univariatna časovna vrsta vsebuje le eno spremenljivko. Njegovi ključni značilnosti sta razdelitev vhodnega zaporedja na krajše odseke (angl. *patches*) in neodvisna obravnava posameznih kanalov. Kanal predstavlja eno univariatno časovno vrsto. V našem primeru posamezen kanal predstavlja dnevne logaritemske donose enega finančnega sredstva. Če spremljamo N sredstev v L zaporednih dneh, vhod predstavlja matrika velikosti $L \times N$, pri čemer vsak stolpec predstavlja en kanal. PatchTST kanale obravnava ločeno, vendar med njimi deli iste naučene parametre, kar avtorji imenujejo neodvisnost kanalov (angl. *channel independence*).

Naj bo L dolžina vhodnega zaporedja, P dolžina posameznega odseka in S korak med začetkoma dveh zaporednih odsekov. Če je $S < P$, se odseki prekrivajo. Večji L omogoča uporabo daljšega zgodovinskega konteksta, večji P pa zajame več lokalnega časovnega konteksta v posameznem žetonu. Razdelitev na odseke zmanjša število vhodnih žetonov, kar zmanjša računsko in pomnilniško zahtevnost modela.

Vsak odsek se z naučljivo linearno preslikavo preslika v notranji prostor dimenzije D , nato pa se mu doda pozicijska vdelava, ki ohrani informacijo o njegovem položaju v zaporedju. Zaporedje tako dobljenih žetonov nato obdela transformerski kodirnik, ki s samopozornostjo modelira odvisnosti med različnimi odseki. Končna predstavitev se uporabi za napoved prihodnjih vrednosti.

Osnovne arhitekture modela ne spreminjamo, saj uporabljamo repozitorij avtorjev [43]. Za reševanje KONP z modelom za posamezno sredstvo napovedujemo dnevne logaritemske donose $\hat{r}_{i,t+h}$ za naslednjih H dni ($h = 1, \dots, H$). Iz njih izračunamo H -dnevni enostavni donos po enačbi (9), napovedi vseh sredstev pa nato zberemo v vektor $\hat{\mu}_{\text{PatchTST}}$.

$$r_{i,t}^{(H)} = \exp \left(\sum_{h=1}^H \tilde{r}_{i,t+h} \right) - 1. \quad (9)$$

2.3. Temporal Fusion Transformer. [4] je transformerski model za večhorizontno napovedovanje časovnih vrst, zasnovan za delo z različnimi vrstami vhodnih značilk. Model podpira tri glavne skupine značilk, ki jih obravnava z mehanizmom izbire spremenljivk (angl. *variable selection*), rekurentnimi plastmi LSTM in časovno samopozornostjo (angl. *temporal self-attention*). Tri vrste značilk so naslednje:

1. **Statične značilke** (angl. *static covariates*) se skozi čas ne spreminjajo (npr. kategorija, identifikator). Pri reševanju KONP posamezno sredstvo predstavlja eno časovno vrsto zato kot statično značilko uporabimo oznako sredstva (angl. *ticker*). Statične značilke model predstavi z naučljivo vdelavo, s čimer lahko pri skupnem učenju razlikuje med posameznimi časovnimi vrstami.
2. **Časovno spremenljive opazovane značilke** (angl. *time-varying observed variables*) imajo vrednosti, ki so nam znane do trenutka napovedi, prihodnje vrednosti pa niso znane (npr. zgodovinske vrednosti). Pri reševanju KONP sem spadajo dnevni logaritemski donosi $\tilde{r}_{i,t}$. Poleg njih pa uporabimo še 20-dnevni momentum, ki povzame kumulativno gibanje cene sredstva in pa 20-dnevno volatilnost, ki meri variabilnost dnevnih donosov v zadnjem obdobju. Vse tri časovno spremenljive opazovane značilke v naši implementaciji izračunamo iz zaključnih cen sredstev.
3. **Časovno spremenljive znane značilke** (angl. *time-varying known variables*) so značilnosti, katerih prihodnje vrednosti so ob trenutku napovedi že znane (npr. datum, dan v tednu, praznik ali vnaprej določen urnik). Takšnih značilk pri reševanju KONP ne uporabljamo.

TFT implementiramo z modelom **TemporalFusionTransformer** iz knjižnice **pytorch-forecasting** [44]. Ciljna spremenljivka je dnevni logaritemski donos $\tilde{r}_{i,t}$ posameznega sredstva. Model je zasnovan za kvantilno regresijo, pri kateri za vsak prihodnji dan napove več kvantilov ciljnega donosa. Kvantil določa mejo določenega deleža napovedanih vrednosti, pri čemer $q = 0,5$ predstavlja mediano. V naši implementaciji iz izračunanih kvantilov uporabimo kvantil $q = 0,5$ in tako dobimo eno napovedano vrednost dnevnega logaritemskega donosa $\hat{r}_{i,t+h}$ za vsakega od naslednjih H dni ($h = 1, \dots, H$). Te dnevne napovedi nato združimo v napoved H -dnevnega enostavnega donosa po enačbi (9), napovedi vseh N sredstev pa zberemo v vektor $\hat{\mu}_{\text{TFT}}$.

2.4. MASTER. [5] je transformerski model, namenjen napovedovanju standardizirane vrednosti prihodnjega donosa delnic. Za posamezno sredstvo u in napovedno obdobje H je osnova za ciljno spremenljivko prihodnji H -dnevni enostavni donos, ki ga definiramo z enačbo (10).

$$r_{u,t}^{\text{MASTER}} = \frac{p_{u,t+H}}{p_{u,t+1}} - 1. \quad (10)$$

Pri učenju ta donos za vsak datum presečno standardiziramo, zato MASTER napoveduje relativni položaj sredstva glede na druga sredstva na istem datumu. Poleg časovnih vzorcev znotraj posameznega sredstva modelira tudi presečne povezave med sredstvi. Njegova ključna značilnost je tržno vodeno uteževanje značilk (angl. *market-guided gating*), pri katerem tržni kontekst vpliva na uteževanje vhodnih značilk. Model nato informacije obdeluje z agregacijo znotraj sredstva (angl. *intra-stock aggregation*), agregacijo med sredstvi (angl. *inter-stock aggregation*) in časovno agregacijo (angl. *temporal aggregation*) [5].

Arhitekture modela ne spreminjamo, saj smo jo povzeli iz uradnega repozitorija avtorjev [45], prilagodili pa smo pripravo vhodnih značilk za uporabo modela na ameriških delnicah. MASTER je bil izvirno razvit in ovrednoten na kitajskih delnicah ter uporablja podatkovno infrastrukturo Qlib [46], odprtokodno platformo za kvantitativne raziskave in strojno učenje na finančnih podatkih. Za posamezno sredstvo model prejme 158 značilk Alpha158 [46], izpeljanih iz dnevnih podatkov OHLCV (cena ob odprtju, najvišja in najnižja cena, cena ob zaprtju ter promet). Značilke Alpha158 smo v naši implementaciji ponovno izračunali iz podatkov OHLCV, prenesenih prek knjižnice **yfinance**. Vse vhodne značilke robustno normaliziramo na podlagi mediane in mediane absolutnih odklonov (MAD), da zmanjšamo vpliv ekstremnih vrednosti na napovedi modela. Parametre normalizacije ocenimo izključno na učnem obdobju, normalizirane vrednosti omejimo na interval $[-3, 3]$, manjkajoče vrednosti pa nadomestimo z nič.

Poleg značilk posameznega sredstva model uporablja tudi skupni tržni vektor $\mathbf{m}_t$, ki je enak za vsa sredstva. V naši implementaciji ga sestavlja 63 značilk, izpeljanih iz treh ameriških ETF-ov SPY, IWM in VTI ter njihovih dnevnih donosov, kotalnega povprečja in standardnega odklona donosov ter kotalnega povprečja in standardnega odklona zneska trgovanja na oknih 5, 10, 20, 30 in 60 dni. Za posamezen napovedni dan model uporablja časovno okno osmih trgovalnih dni, zato je vhodni tenzor oblike $[N, 8, 221]$, kjer je N število sredstev, 221 pa 158 značilk posameznega sredstva in 63 skupnih tržnih značilk. Ciljna spremenljivka je shranjena v 222. stolpcu.

Za razliko od PatchTST in TFT MASTER ne napoveduje dnevnih logaritemskih donosov, iz katerih bi nato izračunali večdnevni donos, temveč neposredno vrne en napovedni signal za posamezno sredstvo. Napovedi za vsa razpoložljiva sredstva zberemo v vektor $\hat{\mu}_{\text{MASTER}}$, ki ga uporabimo kot napovedni vhod v portfeljski optimizaciji.

3. Ocena kovariančne matrike

Pri primerjavi napovednih modelov želimo spreminjati predvsem vir ocene $\hat{\mu}$, zato kovariančno matriko pri vseh pristopih ocenimo na enak način. Naj bo v trenutnem ocenjevalnem oknu na voljo T_w vektorjev donosov $\mathbf{r}_t$. Vzorčno povprečje donosov in vzorčno kovariančno matriko definiramo z enačbo (11).

$$\bar{\mathbf{r}} = \frac{1}{T_w} \sum_{t=1}^{T_w} \mathbf{r}_t, \quad \hat{\Sigma} = \frac{1}{T_w - 1} \sum_{t=1}^{T_w} (\mathbf{r}_t - \bar{\mathbf{r}})(\mathbf{r}_t - \bar{\mathbf{r}})^\top. \quad (11)$$

Če je zaradi numerične natančnosti potrebno, matriki $\hat{\Sigma}$ dodamo majhen diagonalni popravek. Ker je kovariančna matrika pri zgodovinskem povprečju, TFT, MASTER in PatchTST ocenjena na enak način po enačbi (11), lahko razlike v končnih portfeljih lažje povežemo z razlikami v ocenah pričakovanih donosov. Dolžino ocenjevalnega okna T_w izberemo enako najdaljšemu vhodnemu oknu med modeli v posameznem eksperimentu. S tem sta oba vhoda optimizatorja, $\hat{\mu}$ in $\hat{\Sigma}$, ocenjena na primerljivi nedavni zgodovini: noben model ni v primerjavi s kovarianco, ocenjeno iz bistveno daljšega obdobja, ki ga sam nikoli ne vidi.

4. Globalni optimizacijski algoritmi

Ker algoritmi KONP rešujejo z minimizacijo, ciljno funkcijo iz enačbe (4) zapišemo v ekvivalentni obliki (12), kjer manjša vrednost $g(\mathbf{w})$ pomeni boljšo rešitev.

$$g(\mathbf{w}) = (1 - P)\mathbf{w}^\top \hat{\Sigma} \mathbf{w} - P\hat{\mu}^\top \mathbf{w}. \quad (12)$$

Ker ima zaradi kardinalne omejitve neničelno utež le $K \ll N$ sredstev, pri izračunu variance $\mathbf{w}^\top \hat{\Sigma} \mathbf{w}$ upoštevamo samo aktivna sredstva, torej podmatriko $\hat{\Sigma}$, ki ustreza izbranim sredstvom. S tem zahtevnost kvadratnega dela zmanjšamo z $O(N^2)$ na $O(K^2)$, ne da bi spremenili vrednost ciljne funkcije, saj so vsi izpuščeni členi enaki nič.

4.1. Rojenje delcev (RD). (angl. *Particle Swarm Optimization*, PSO) [47] je populacijski optimizacijski algoritem, navdihnjen z vedenjem skupin živali, kot so jate ptic ali rib ter roji žuželk. V našem delu RD za reševanje KONP implementiramo po Curi [42]. Od njegove izvedbe se razlikujemo le pri popravljanju uteži (korak Projekcija uteži spodaj).

Denimo, da imamo populacijo delcev, kjer vsak delec predstavlja kandidatno rešitev in pri iskanju rešitve upošteva svojo najboljšo doslej najdeno rešitev ter najboljšo rešitev celotne populacije. Nek delec m opišemo z dvojico $(\mathbf{x}_m, \mathbf{z}_m)$, kjer $\mathbf{x}_m$ predstavlja položaj delca oziroma vektor uteži izbranih sredstev, $\mathbf{z}_m$ pa označuje izbor sredstev. Za obe komponenti delec hrani hitrosti $\mathbf{v}_m^x$ in $\mathbf{v}_m^z$ ter svojo najboljšo doslej obiskano rešitev $(\mathbf{x}_m^*, \mathbf{z}_m^*)$. Najboljšo rešitev celotnega roja določimo z delcem z najboljšo osebno rešitvijo. V vsaki iteraciji za vsak delec m in vsako sredstvo i izvedemo naslednje korake:

1. **Posodobitev izbora sredstev.** Neodvisno vzorčimo $\omega_1, \omega_2 \sim U[0, 2]$. Binarno hitrost določimo z enačbo (13), pri čemer prva komponenta usmerja delec proti globalno najboljši rešitvi, druga pa proti njegovi osebno najboljši rešitvi.

$$v_{m,i}^{z,t+1} = v_{m,i}^{z,t} + \omega_1 (z_i^G - z_{m,i}^t) + \omega_2 (z_{m,i}^* - z_{m,i}^t). \quad (13)$$

Novo vrednost vsake komponente vektorja izbora sredstev $z_{m,i}$ določimo tako, da vrednost $z_{m,i}^t + v_{m,i}^{z,t+1}$ najprej s sigmoidno funkcijo preslikamo v interval $(0, 1)$, nato pa jo glede na prag pretvorimo v binarno vrednost $z_{m,i}^{t+1} \in \{0, 1\}$, kot določa enačba (14). $\alpha = 0,06$ je odmik, ki vpliva na prag izbora sredstva.

$$z_{m,i}^{t+1} = \left\lfloor S(z_{m,i}^t + v_{m,i}^{z,t+1}) - \alpha + \frac{1}{2} \right\rfloor, \quad S(a) = \frac{1}{1 + e^{-a}}, \quad (14)$$

2. **Posodobitev uteži sredstev.** Če je sredstvo pri prejšnjem koraku izbrano, hitrost posodobimo z enačbo (15), pri čemer se delec pomika proti globalno in osebno najboljši rešitvi. Nato položaj posodobimo po enačbi (16). Če je sredstvo ni izbrano njegovo vrednost $x_{m,i}^{t+1}$ nastavimo na nič, hitrost $v_{m,i}^{x,t+1}$ pa ohranimo.

$$v_{m,i}^{x,t+1} = v_{m,i}^{x,t} + \omega_1 (x_i^G - x_{m,i}^t) + \omega_2 (x_{m,i}^* - x_{m,i}^t). \quad (15)$$

$$x_{m,i}^{t+1} = x_{m,i}^t + v_{m,i}^{x,t+1}. \quad (16)$$

3. **Popravljanje kardinalnosti.** Posodobitev izbora ne zagotavlja natanko K izbranih sredstev, zato po vsakem premiku izvedemo popravljanje kardinalnosti. Če je izbranih manj kot K sredstev, z enako verjetnostjo dodamo naključno neizbrano sredstvo ali pa neko neizbrano sredstvo z največjo vrednostjo c_i . Če jih je izbranih več kot K , na enak način odstranimo naključno sredstvo ali pa sredstvo z najmanjšo vrednostjo c_i . Avtorji [42] mero c_i definirajo iz pričakovanega donosa in povprečne kovariance sredstva glede na stopnjo averzije do tveganja. Vmesne količine θ_i in ρ_i ter korekcijska odmika Ω in Ψ določimo po enačbi (17). Ker so $\hat{\mu}$, $\hat{\Sigma}$ in λ v posameznem optimizacijskem oknu nespremenljivi, c_i v naši implementaciji izračunamo le enkrat pred začetkom iteracij.


$$\begin{aligned} \theta_i &= 1 + (1 - \lambda)\hat{\mu}_i, & \rho_i &= 1 + \lambda \frac{1}{N} \sum_{j=1}^N \hat{\Sigma}_{ij}, \\ c_i &= \frac{\theta_i + \Omega}{\rho_i + \Psi}, & \Omega &= -\min \left(0, \min_j \theta_j \right), & \Psi &= -\min \left(0, \min_j \rho_j \right). \end{aligned} \quad (17)$$

4. **Projekcija uteži.** Po popravilu kardinalnosti uporabimo funkcijo `normalize_weights`, ki izbranim sredstvom določi uteži, skladne s proračunsko ter spodnjo in zgornjo utežno omejitvijo.

Algoritem 1. Rojenje delcev za KONP [42]

```
1: Vhod: ocene donosov  $\hat{\mu}$ , kovariacijska matrika  $\hat{\Sigma}$ , parameter tveganja  $P$ , kardinalnost  
    $K$ , velikost roja  $M$ , število iteracij  $T$   
2: Izhod: najboljše uteži  $best\_weights$   
3: izračunaj  $c_i$  za vsa sredstva po (17)  
4: ustvari  $M$  naključnih delcev z natanko  $K$  izbranimi sredstvi in dopustnimi utežmi  
5: for all  $particle \in swarm$  do  
6:    $particle.fit \leftarrow f(particle)$   
7:    $particle.best\_fit \leftarrow particle.fit$   
8:    $particle.best\_weights \leftarrow particle.weights$   
9:    $particle.best\_selection \leftarrow particle.selection$   
10:  $leader \leftarrow$  delec z najmanjšo vrednostjo  $best\_fit$   
11: for  $t = 1, \dots, T$  do  
12:   for all  $particle \in swarm$  do  
13:     for  $i = 1, \dots, N$  do  
14:        $\omega_1, \omega_2 \sim U[0, 2]$   
15:       posodobi  $v_{m,i}^{z,t+1}$  po (13)  
16:       posodobi  $z_{m,i}^{t+1}$  po (14)  
17:       if  $z_{m,i}^{t+1} = 1$  then  
18:         posodobi  $v_{m,i}^{x,t+1}$  po (15)  
19:         posodobi  $x_{m,i}^{t+1}$  po (16)  
20:       else  
21:          $x_{m,i}^{t+1} \leftarrow 0$   
22:       popravi izbor tako, da je izbranih natanko  $K$  sredstev, z uporabo  $c_i$   
23:       projiciraj uteži na dopustno množico  
24:        $particle.fit \leftarrow f(particle)$   
25:       if  $particle.fit < particle.best\_fit$  then  
26:         posodobi osebno najboljšo rešitev delca  
27:       if  $particle.best\_fit < leader.best\_fit$  then  
28:          $leader \leftarrow particle$   
29:  $best\_weights \leftarrow leader.best\_weights$   
30: return  $best\_weights$ 
```

Slika 1 prikazuje poenostavljeno ponazoritev delovanja roja delcev v dvodimenzionalnem prostoru, kjer posamezna točka predstavlja eno možno rešitev. Izolinije prikazujejo vrednosti dejanske ciljne funkcije $g(\mathbf{w})$ iz enačbe (12), to je povprečje-variančne ciljne funkcije, pri čemer nižje vrednosti pomenijo boljše rešitve, minimum pa predstavlja optimalno rešitev $\mathbf{w}^*$. V prvi iteraciji je pet delcev (I–V) naključno razporejenih po prostoru, vsak pa svojo začetno pozicijo shrani kot osebno najboljšo rešitev. V drugi iteraciji se delci premaknejo na podlagi svojih hitrosti. Na smer in velikost premika vplivata njihova osebno najboljša rešitev ter najboljša rešitev celotnega roja. V iteraciji t je za delec II podrobneje prikazano, kako se njegova nova hitrost sestavi iz predhodne hitrosti ter komponent, usmerjenih proti osebno najboljši in globalno najboljši rešitvi. Posodobljena hitrost nato določi nov položaj delca. Z večanjem števila iteracij se roj zaradi skupnega vpliva teh dveh informacij postopoma pomika proti območjem z nižjo vrednostjo ciljne funkcije.



Slika 1. Poenostavljena ponazoritev gibanja roja delcev v dvodimenzionalnem prostoru.

4.2. Simulirano ohlajanje (SO). (angl. *Simulated Annealing*) [48] je metahevrstični algoritem, navdihnjeno s fizikalnim ohlajanjem kovine. Njegova osnovna ideja je, da poleg izboljšav občasno sprejme tudi slabšo rešitev, da se izogiba lokalnim minimumom. Verjetnost sprejema z ohlajanjem temperature T pada. Za razliko od RD vzdržuje eno samo trenutno rešitev $\mathbf{w}$, katere sosesčino zaporedno preiskuje po temperaturnem urniku (angl. *cooling schedule*) z začetno temperaturo T_0 in geometrijskim faktorjem ohlajanja α_{SO} .

Pri implementaciji SO za reševanje KONP smo izvirali iz dela Crama in Schynsa [49], ki rešujeta soroden, a drugačen problem: minimizirata samo varianco ob omejitvi na zahtevenga donosa, poleg tega pa upoštevata prometne, mejne in trgovalne omejitve. Nekaterih mehanizmov iz njunega algoritma zato ne moremo prevzeti dobesedno. Kjer smo jih priredili ali dodali sami, to označimo pri posameznem koraku spodaj. Iskanje poteka po naslednjih korakih:

1. **Inicializacija portfelja.** Začnemo z naključno izbranimi K sredstvi in vsakemu priredimo utež $1/K$. To že zadošča kardinalni, proračunski in utežni omejitvi KONP. Crama in Schynsa začetno rešitev namesto tega konstruirata iz natanko dveh sredstev (z najnižjim in najvišjim donosom) po zaprti obliki, ki natančno zadosti zahtevanemu donosu. Ker ga pri nas ni in je K fiksno že od začetka, sredstva raje izberemo naključno.
2. **Generiranje sosednje rešitve.** Sosednostna funkcija (angl. *neighborhood function*) iz trenutne rešitve ustvari eno kandidatno rešitev na enega od dveh načinov:
 - (a) **Zamenjava sredstva.** Z verjetnostjo 0,10 (naša izbira) celotno utež naključnega sredstva v portfelju prenesemo na naključno sredstvo izven njega. To omogoča raziskovanje različnih izborov sredstev ob nespremenjeni kardinalnosti in vsoti uteži.
 - (b) **Premik uteži.** V preostalih primerih uteži spreminjamo s tridelnim premikom [49]: če je v portfelju vsaj tri sredstva, naključno izberemo tri in določimo spremembe (d_1, d_2, d_3) s pogojem $d_1 + d_2 + d_3 = 0$, velikost premika pa omejitva trenutni polmer q in utežne meje. V izvirnem članku je smer premika dodatno vezana na zahtevani donos (izbor sredstev je usmerjen proti njemu, velikost pa določa zaprta oblika, ki natančno ohrani tudi donosno omejitve). Ker pri nas donos ni omejitev, temveč del ciljne funkcije (12), sredstva izberemo enakomerno naključno, velikost premika pa vzorčimo enakomerno znotraj dopustnega razpona namesto po zaprti obliki. Pri manj kot treh sredstvih oziroma numerično neizvedljivem tridelnem premiku uporabimo dvodelni premik ($U(-q, q)$ med dvema naključnima sredstvoma). To je naš lasten dodatek za ta robni primer.
3. **Sprejemanje sosednje rešitve.** Kakovost kandidatne rešitve $\mathbf{w}'$ primerjamo s trenutno rešitvijo prek spremembe ciljne funkcije $\Delta = g(\mathbf{w}') - g(\mathbf{w})$. Ker funkcijo g minimiziramo, kandidat pri $\Delta \leq 0$ vedno sprejmemo. Če je $\Delta > 0$, ga sprejmemo z verjetnostjo sprejema [48]:

$$\Pr(\text{sprejem}) = \exp\left(-\frac{\Delta}{T}\right), \quad (18)$$

kjer je T trenutna temperatura. Odločitev izvedemo s slučajno spremenljivko $U \sim U(0, 1)$: slabšo rešitev sprejmemo, če velja $U < \exp(-\Delta/T)$, kar ustreza verjetnosti iz enačbe (18).

4. **Kalibracija temperature in ohlajanje.** Začetne temperature T_0 ne določimo vnaprej, temveč jo kalibriramo: izvedemo poskusno verigo L premikov s polmerom q_1 . Vsako kandidatno rešitev sprejmemo brez uporabe verjetnosti sprejema in povprečimo pozitivne spremembe $\overline{\Delta}^+$ (privzeto 0,01, če ne zaznamo poslabšanj). Če je v_0 zelena začetna verjetnost sprejema značilnega poslabšanja, začetno temperaturo in nadaljnje ohlajanje določimo po pristopu izvirnega članka [49], kot prikazuje enačba (19):


$$T_0 = \frac{\overline{\Delta}^+}{-\ln v_0}, \quad T_{\ell+1} = \alpha_{SO} T_{\ell}, \quad 0 < \alpha_{SO} < 1. \quad (19)$$

5. **Prilagajanje polmera in ustavitev iskanja.** Pri vsaki stopnji izvedemo L premikov (L je sorazmeren številu sredstev). Polmer q_1 ob prenizkem številu sprejetih kandidatov zmanjšamo na $q_2 < q_1$. To pravilo prehoda prav tako sledi izvirnemu članku [49] (pri njima deset sprejemov na stopnjo, pri nas je prag $A_{\min}$ nastavljen parameter). Poleg trenutne rešitve hranimo tudi najboljšo doslej najdeno $\mathbf{w}^*$. Iskanje ustavimo po S zaporednih stopnjah brez sprejema ali po doseženem največjem številu stopenj $G_{\max}$.

Algoritem 2. Simulirano ohlajanje za KONP

```
1: Vhod: ocene donosov  $\hat{\mu}$ , kovariacijska matrika  $\hat{\Sigma}$ , averzija do tveganja  $\lambda$ , kardinalnost  $K$ , dolžina stopnje  $L$ , začetna verjetnost sprejema  $v_0$ , faktor ohlajanja  $\alpha_{SO}$ , polmera  $q_1$  in  $q_2$ , prag sprejemov  $A_{\min}$ , prag mirovanja  $S$ , največ stopenj  $G_{\max}$ 
2: Izhod: uteži  $best\_weights$ 
3:  $weights, selected \leftarrow$  naključen dopusten portfelj
4:  $T \leftarrow$  kalibracija z  $L$  poskusnimi premiki pri  $q_1$  in  $v_0$ 
5:  $current\_value \leftarrow g(weights; \hat{\mu}, \hat{\Sigma}, \lambda)$ 
6:  $best\_weights \leftarrow weights$ 
7:  $best\_value \leftarrow current\_value$ 
8:  $q \leftarrow q_1, \quad idle\_stages \leftarrow 0$ 
9: for  $\ell = 1, \dots, G_{\max}$  do
10:    $accepted \leftarrow 0$ 
11:   for  $j = 1, \dots, L$  do
12:      $candidate \leftarrow$  sosed rešitve  $weights$  pri polmeru  $q$ 
13:      $\Delta \leftarrow g(candidate; \hat{\mu}, \hat{\Sigma}, \lambda) - current\_value$ 
14:      $r \leftarrow rand(0, 1)$ 
15:     if  $\Delta \leq 0$  ali  $e^{-\Delta/T} > r$  then
16:        $weights \leftarrow candidate$ 
17:        $current\_value \leftarrow current\_value + \Delta$ 
18:        $accepted \leftarrow accepted + 1$ 
19:       if  $current\_value < best\_value$  then
20:          $best\_value \leftarrow current\_value$ 
21:          $best\_weights \leftarrow weights$ 
22:   if  $accepted < A_{\min}$  then
23:      $q \leftarrow q_2$ 
24:    $T \leftarrow \alpha_{SO} T$ 
25:   if  $accepted = 0$  then
26:      $idle\_stages \leftarrow idle\_stages + 1$ 
27:   else
28:      $idle\_stages \leftarrow 0$ 
29:   if  $idle\_stages \geq S$  then
30:     break
31: return  $best\_weights$ 
```

Slika 2 prikazuje, kako temperatura T in polmer sosesčine q vplivata na iskanje po prostoru portfeljev. V prvem delu je temperatura visoka in polmer velik (q_1), zato algoritem raziskuje širše območje in sprejema tudi slabše rešitve. Prikazan korak spremeni uteži tako, da se izboljša utežena kombinacija ocenjenega pričakovanega donosa in tveganja, zato je sprejet. V drugem delu je temperatura nižja, algoritem pa poskuša korak v slabšo rešitev, ki jo zaradi manjše verjetnosti sprejema zavrne. V tretjem delu je temperatura še nižja, polmer pa se zmanjša na $q_2 < q_1$, zato so premiki manjši in iskanje bolj lokalno.




Slika 2. Poenostavljena ponazoritev delovanja simuliranega ohlajanja v enodimenzionalnem prostoru portfeljev.

5. Implementacija in vrednotenje

5.1. Programska zasnova. Pripravo podatkov, učenje modelov, vodenje eksperimentov in vrednotenje rezultatov izvajamo v jeziku Python, transformerske modele pa v okolju PyTorch. Optimizacijski del je implementiran v C++17. Obe komponenti komunicirata prek preprostega datotečnega vmesnika, kar omogoča njun neodvisen razvoj in testiranje. Celoten eksperimentalni postopek je prikazan na Sliki 3.

Podatke o finančnih sredstvih prenesemo prek knjižnice **yfinance**. Izjema je primerjava z delom Wang in sod., kjer uporabimo podatke avtorjev. Podatke, donose in kovariančne matrice obdelamo s knjižnicama **pandas** in **NumPy**, grafe pripravimo z **matplotlib**, transformerske modele pa učimo s knjižnico **PyTorch**.

Vsak eksperiment je opisan s svojo konfiguracijsko datoteko, kjer definiramo obdobje eksperimenta, nabor sredstev, parametre modelov in optimizatorjev itd. Napovedni modeli si delijo skupni vmesnik učenja in napovedi, kar omogoča dodajanje novih modelov v prihodnosti. $\hat{\mu}_t$, njihove napovedi pa pred optimizacijo standardiziramo po postopku, ki ga bomo opisali v nadaljevanju.




Slika 3. Shema eksperimentalnega postopka od tržnih podatkov do vrednotenja.

5.2. Eksperimentalni postopek. Naš eksperimentalni postopek je postopno vrednotenje (angl. *walk-forward*): ob vsakem odločitvenem trenutku t izvede korake I–VII (Slika 3) in se ponavlja skozi celotno testno obdobje.

Tržni podatki. Iz tržnih podatkov do trenutka t izračunamo dnevne donose sredstev. Vsi nadaljnji koraki uporabljajo samo te podatke, zato prihodnji podatki ne vplivajo na pretekle odločitve.

Napovedovanje. Vhod v napovedne modele predstavljajo podatki zadnjih L trgovalnih dni pred odločitvenim trenutkom, ki jih imenujemo vhodno okno (Slika 4). Modeli se učijo na učnem oknu, ki se konča v trenutku t . Če eksperiment zahteva ponovno učenje, se model v predpisanih trenutkih ponovno nauči na takrat razpoložljivih podatkih. Zgodnje ustavljanje pri TFT in PatchTST poteka po validacijski izgubi na zadnjem delu učnega okna, MASTER pa sledi zasnovi avtorjev, ki uporablja presečni informacijski koeficient (IC). $\hat{\mu}_t$ ocenimo tudi z zgodovinskim povprečjem. Njegovo okno L izberemo enako, kot ga bere model, s katerim ga primerjamo, zato obe oceni uporabljata enake nedavne podatke in razlika med njima izvira iz načina ocenjevanja. Ker imajo modeli lahko različna okna, za vsak model izračunamo lastno ujemaajoče zgodovinsko povprečje.

Ocena kovariančne matrice. Vzorčno kovarianco $\hat{\Sigma}_t$ ocenimo iz zadnjih $L_{\max}$ trgovalnih dni, kjer je $L_{\max}$ najdaljše vhodno okno med vključenimi modeli, in jo enako uporabimo pri vseh modelih in zgodovinskem povprečju. Vsa ocenjevalna okna se končajo v odločitvenem trenutku ali pred njim. Konkretna vrednosti L , $L_{\max}$, H , pogostost ponovnega učenja in druge nastavitve posameznih eksperimentov navedemo ob vsakem eksperimentu.



Slika 4. Zgradba postopnega vrednotenja za en odločitveni trenutek. Okna ne segajo v osenčeno prihodnost.

Standardizacija. Oba vhoda optimizatorja standardiziramo. Ciljna funkcija (4) združuje pričakovani donos in tveganje portfelja, razmerje med njima pa določa parameter P . Ocene $\hat{\mu}_t$ imajo različne enote in velikosti, ocenjeno tveganje $\hat{\Sigma}_t$ pa je po velikosti odvisno od napovednega obdobja H , nabora sredstev in volatilitnosti trga (v kriznih obdobjih so variance bistveno višje kot v mirnih). Pri nespremenjenem P bi imel zato pričakovani donos vsakič drugačno težo glede na tveganje, portfelji pa bi se razlikovali zaradi velikosti ocen, ne zaradi razvrstitve sredstev. Standardizacija je enaka za vse napovedne modele in zgodovinsko povprečje, računamo pa jo samo iz vhodov v odločitvenem trenutku t .

Napovedi presečno standardiziramo: od vsake napovedi odštejemo povprečje napovedi vseh sredstev ob istem odločitvenem trenutku in rezultat delimo z njihovim standardnim odklonom, kot prikazuje enačba (20). Kovariančno matriko delimo s povprečjem njene diagonale, to je s povprečno varianco sredstev, kot prikazuje enačba (21). Zato imata $\tilde{\mu}_t$ in $\tilde{\Sigma}_t$ povsod isto skalo, razvrstitev sredstev, korelacije in razmerja med variancami pa se ne spremenijo.

$$\tilde{\mu}_{t,i} = \frac{\hat{\mu}_{t,i} - \bar{\mu}_t}{s_t}, \quad \bar{\mu}_t = \frac{1}{N} \sum_{j=1}^N \hat{\mu}_{t,j}, \quad s_t = \sqrt{\frac{1}{N} \sum_{j=1}^N (\hat{\mu}_{t,j} - \bar{\mu}_t)^2}. \quad (20)$$

$$\tilde{\Sigma}_t = \frac{\hat{\Sigma}_t}{d_t}, \quad d_t = \frac{1}{N} \sum_{i=1}^N \hat{\Sigma}_{t,ii}. \quad (21)$$

Optimizacija. Optimizator iz standardiziranih $\tilde{\mu}_t$ in $\tilde{\Sigma}_t$ določi portfeljske uteži $\mathbf{w}_t$. Poročane mere računamo iz nestandardiziranih $\hat{\mu}_t$ in $\hat{\Sigma}_t$.

Napovedno obdobje. Po odločitvi v trenutku t vstopimo v napovedno obdobje od $t + 1$ do $t + H$, v katerem portfelj $\mathbf{w}_t$ ostane nespremenjen.

Vrednotenje. Z vrednotenjem ocenimo, kako uspešen je izbrani portfelj. Realizirani donos portfelja r_t^p (2) izračunamo iz dejanskih prihodnjih cen. Pri vseh portfeljskih eksperimentih uporabljamo iste skupne metrike, ki so v tabelah vedno navedene najprej in v istem vrstnem redu. Pri zunanjih primerjavah jim dodamo še metrike avtorjev, da je primerjava neposredna.

Naj bo $\{r_t^p\}_{t=1}^T$ zaporedje realiziranih periodičnih donosov portfelja, $\bar{r}$ njihovo aritmetično povprečje, s standardni odklon in p število takih obdobj na leto. Pri dnevni donosih uporabimo $p = 252$, pri tedenskih $p = 52$ in pri mesečnih $p = 12$.

Kumulativno vrednost portfelja določa enačba (22). Pove, v kolikšno vrednost zraste ena enota vloženega kapitala do obdobja t , če dobiček sproti reinvestiramo. V tabelah poročamo končno vrednost W_n (stolpec W_n). Pri polletnem vlaganju je ne podajamo, ker se napovedna obdobja prekrivajo in jih ni mogoče verižiti v eno krivuljo vrednosti.

$$W_t = \prod_{j=1}^t (1 + r_j^p). \quad (22)$$

Letni donos po enačbi (23) je povprečni donos obdobja, preračunan na eno leto.

$$R_{\text{letno}} = p \bar{r}. \quad (23)$$

Letna volatilitnost po enačbi (24) je standardni odklon donosov, preračunan na eno leto; množimo ga s $\sqrt{p}$, saj varianca neodvisnih donosov raste sorazmerno s številom obdobj. Meri razpršenost donosov okoli povprečja, torej realizirano tveganje: nižja vrednost pomeni mirnejše gibanje vrednosti portfelja.

$$\sigma_{\text{letno}} = s \sqrt{p}. \quad (24)$$

Sharpov količnik [50] v enačbi (25) je razmerje med letnim donosom in letno volatilitnostjo ob predpostavki, da je netvegana donosnost enaka nič. Pove, koliko donosa dobimo na enoto tveganja, zato omogoča primerjavo portfeljev z različnim tveganjem. Višja vrednost je ugodnejša.

$$\text{SR} = \frac{\bar{r}}{s} \sqrt{p}. \quad (25)$$

Promet portfelja, ki meri velikost spremembe uteži med zaporednima odločitvama, poročamo kot dopolnilno analizo in uporabimo za transakcijske stroške pri dolgoročnem vlaganju (razdelek 6.5). Izračunamo ga z enačbo (26):

$$\text{TO}_t = \sum_{i=1}^N |w_{i,t} - w_{i,t-1}|. \quad (26)$$

Vrednost 0 pomeni, da portfelja ne spreminjamo, vrednost 2 pa popolno zamenjavo vseh sredstev. Višji promet pomeni več trgovanja in zato višje transakcijske stroške.

6. Rezultati

Vse eksperimente smo pognali na računalniku s procesorjem Apple M4 Pro in 64 GB pomnilnika. Transformerske modele učimo na grafičnem procesorju prek Appleovega vmesnika Metal Performance Shaders (MPS), ki omogoča izvajanje nevronske mreže na GPU računalnikov Apple, optimizatorje (C++17) pa poganjamo na CPU. Najprej oba optimizatorja neodvisno preverimo na primerih OR-Library, nato pa celoten eksperimentalni postopek ovrednotimo na štirih portfeljskih eksperimentih: polletnem vlaganju [7], kriznem vlaganju [6], mesečnem vlaganju [8] in lastnem dolgoročnem vlaganju. Pri prvih treh prevzamemo podatke, časovna okna in nastavitve avtorjev. Nato naše rezultate primerjamo z njihovimi objavljenimi. Z dolgoročnim primerom preverimo, ali naše metode delujejo tudi v daljšem obdobju in različnih tržnih razmerah. Vsak model primerjamo z zgodovinskim povprečjem z enakim oknom.

6.1. Preverjanje optimizatorjev. Uspešnost celotnega postopka je odvisna od kakovosti napovedi $\hat{\mu}$ in $\hat{\Sigma}$ ter kakovosti optimizatorja, zato optimizatorja vrednotimo ločeno na problemu z vnaprej znanimi podatki. Ker za KONP ni mogoče najti natančne rešitve, Chang in sod. [2] predlagajo vrednotenje glede na optimalno krivuljo v ravnini tveganje-donos, ki povezuje portfelje z najmanjšim tveganjem pri danem donosu. Pri ONP brez kardinalnosti taki krivulji rečemo optimalna krivulja za neomejeno število sredstev (angl. *unconstrained efficient frontier*, v nadaljevanju KON). Ker v našem primeru nimamo neomejeno sredstev, govorimo o kardinalno omejeni optimalni krivulji, ki pa ne more biti boljša od KON. Krivulja, ki jo najdemo RD in SO, pa je približek kardinalno omejene krivulje.

OR-Library [51] je javno dostopna zbirka testnih problemov, ki vključuje portfeljske nabore, sestavljene iz tedenskih cen delnic petih indeksov med marcem 1992 in septembrom 1997 (291 vrednosti na delnico). Za vsak indeks so podani število sredstev, povprečni donos, standardni odkloni in korelacije, iz katerih sestavimo $\hat{\Sigma}$. Pripadajoča datoteka vsebuje tudi točke OKN za 2000 vrednosti donosa, med katerimi je izvedena linearna interpolacija.

Kakovost točke (r, σ) optimalne krivulje, kjer sta r donos in σ standardni odklon, merimo z relativnim odstopanjem od OKN. Naj bosta $\sigma^*(r)$ standardni odklon OKN pri donosu r in $r^*(\sigma)$ donos OKN pri σ . Napaka točke je manjša od obeh odstopanj, kot prikazuje enačba (27). Vrednost 0 pomeni ujemanje z OKN, večja vrednost pa slabšo rešitev. Ker kardinalna omejitev krivuljo že sama oddalji od OKN, napaka ne more biti blizu nič. Za vsak primer poročamo povprečje $\bar{e}$ in mediano $\tilde{e}$ napak za 50 točk.


$$e(r, \sigma) = \min \left\{ 100 \frac{|\sigma - \sigma^*(r)|}{\sigma^*(r)}, 100 \frac{|r - r^*(\sigma)|}{|r^*(\sigma)|} \right\}. \quad (27)$$

Uporabimo vseh pet naborov: Hang Seng (31 sredstev), DAX 100 (85 sredstev), FTSE 100 (89 sredstev), S&P 100 (98 sredstev) in Nikkei (225 sredstev). Za vsak nabor kardinalno omejeno optimalno krivuljo izračunamo pri 50 enakomerno razporejenih vrednostih P , s $K = 10$, $\varepsilon_i = 0,01$ in $\delta_i = 1$.

Tabela 1. Povprečna ($\bar{e}$) in mediana ($\tilde{e}$) napake glede na OKN v odstotkih ter povprečni čas t za naše izvedbe in algoritme Chang in sod. (genetski algoritem GA, tabu iskanje TS in simulirano ohlajanje SO), pri čemer je $\Delta \bar{e}$ povprečna absolutna razlika $\bar{e}$ od povprečja njihovih treh algoritmov, $\emptyset$ pa povprečje po petih naborih.

	Hang Seng		DAX 100		FTSE 100		S&P 100		Nikkei		$\emptyset$		$\Delta \bar{e}$	t [s]
	$\bar{e}$	$\tilde{e}$	$\bar{e}$	$\tilde{e}$	$\bar{e}$	$\tilde{e}$	$\bar{e}$	$\tilde{e}$	$\bar{e}$	$\tilde{e}$	$\bar{e}$	$\tilde{e}$		
GA (Chang)	1,10	1,22	2,54	2,55	1,11	1,08	1,93	1,22	0,80	0,61	1,50	1,34	0,30	
TS (Chang)	1,12	1,22	3,30	2,64	1,61	1,08	3,31	1,29	0,90	0,61	2,05	1,37	0,25	
SO (Chang)	1,10	1,22	2,93	2,57	1,46	1,08	3,07	1,18	0,67	0,61	1,85	1,33	0,10	
RD (naš)	1,34	1,29	2,87	2,74	1,60	1,29	3,08	1,50	1,51	1,14	2,08	1,59	0,31	5,7
SO (naš)	1,09	1,22	3,01	2,57	0,85	1,08	1,40	1,16	0,58	0,59	1,38	1,32	0,44	2,7

Tabela 1 kaže, da je kakovost naše implementacije SO in RD primerljiva z algoritmi Chang in sod. $\bar{e}$ RD in SO se od njihovih algoritmov razlikuje za $\Delta \bar{e} = 0,31\%$ oziroma $0,44\%$, kar je manj od razlike med njihovimi algoritmi ($0,58\%$). SO se v povprečju najbolj približa OKN, saj ima nižjo povprečno napako kot vsi trije njihovi algoritmi, RD pa je primerljiv s tabu iskanjem. Povprečje dvigujejo posamezne točke z veliko napako, največja je $43,5\%$ pri RD (S&P 100) in $38,5\%$ pri SO (DAX 100). Obe nastaneta pri $P = 0$, kjer je krivulja OKN skoraj navpična, zato že majhno povečanje tveganja zaradi kardinalne omejitve pomeni veliko relativno razliko v donosu. RD je v povprečju slabši od SO, razen na DAX 100, kjer je nekoliko boljši. Slika 5 kaže, da so točke obeh postopkov na vseh naborih večinoma blizu OKN. Po času izvajanja je SO v povprečju več kot dvakrat hitrejši od RD.



Slika 5. Portfelji RD in SO ter OKN na petih naborih OR-Library, kjer točka predstavlja eno vrednost P .

6.2. Polletno vlaganje. Denimo, da vsak mesec med sredstvi indeksa S&P 500 izberemo 20 sredstev, mednje razporedimo kapital in jih držimo šest mesecev. Preizkus postopka ima dva izziva. Prvič, izbirati moramo med skoraj petsto sredstvi, zato se mora napovedni model naučiti povezave med vsemi, optimizator pa mora med njimi najti pravih 20. Drugič, napoved sega šest mesecev naprej, kar je bistveno težje od napovedi za nekaj dni. Naj omenimo da se v tem eksperimentu zaporedna napovedna obdobja prekrivajo, saj vsak mesec znova napovedujemo za naslednjih šest. To pa ne pomeni uhajanja informacij, saj vsak portfelj sestavimo le iz podatkov do trenutka odločitve.

Wang in sod. [7] na takem scenariju ovrednotijo tri pristope za reševanje KONP: uteži na podlagi zgodovinskih podatkov poišče Gurobi, reševalnik za natančno reševanje optimizacijskih problemov; pri pristopu *napovej, nato optimiziraj* LSTM oceni pričakovane donose, Gurobi pa poišče uteži; nevronske reševalnik CardNN-GS pa napovedovanje in optimizacijo združi v en model in neposredno maksimizira Sharpov količnik.

Eksperiment vključuje 494 sredstev na testnem obdobju v letu 2021 in kardinalnost $K=20$. Vhodno okno modelov, ki ga ima enako tudi ujemajoče zgodovinsko povprečje, je 67 trgovalnih dni pri MASTER, 271 pri TFT in 336 pri PatchTST. Vzorčno kovariančno matriko ocenimo iz zadnjih 336 dni učnega obdobja 2018–2020 in jo med letom ne spreminjamo, saj napovedane matrike $\hat{\Sigma}$, kot jo uporabljajo Wang in sod. (iz napovedi modela LSTM), naš pristop nima.

Pri primerjavi našega postopka z izvirnim člankom uporabljamo enake metrike kot avtorji. Vsako od 7 odločitev $k = 1, \dots, 7$ v letu 2021 ovrednotimo z dnevnimi donosi portfelja $r_{k,d}^P$ v 120-dnevem napovednem obdobju ($d = 1, \dots, H$, $H = 120$). Iz njih za vsako odločitev po enačbah (23) in (24) s $p = 252$ (število trgovalnih dni v letu) določimo letni donos R_k in letno volatiliteto σ_k , pri čemer sta $\bar{r}_k$ in s_k povprečje in standardni odklon dnevnih donosov $r_{k,d}^P$. Sharpov količnik S_k pa se od splošne definicije (25) razlikuje, saj meri presežni donos nad netvegano mero $r_f = 0,03$ (letno donosnostjo naložbe brez tveganja, npr. državnih obveznic) na enoto volatiliteti, kot kaže enačba (28). V tabeli so povprečja metrik za 7 odločitev.

$$S_k = \frac{R_k - r_f}{\sigma_k}. \quad (28)$$

Tabela 2. Primerjava $\bar{R}$, $\bar{\sigma}$ in $\bar{S}$ med našimi metodami ter delom Wang in sod. [7].

	$\bar{R}$	$\bar{\sigma}$	$\bar{S}$
Wang: zgodovinski (Gurobi)	13,9 %	16,2 %	0,67
Wang: napovej-nato (LSTM+Gurobi)	24,1 %	19,5 %	1,08
Wang: napovej-in (CardNN-GS)	40,0 %	18,8 %	1,97

	RD	SO	RD	SO	RD	SO
Zgodovinsko povprečje (67 dni)	22,3 %	22,6 %	22,5 %	22,2 %	0,86	0,89
Zgodovinsko povprečje (271 dni)	27,8 %	26,9 %	25,4 %	25,4 %	1,08	1,05
Zgodovinsko povprečje (336 dni)	35,8 %	35,7 %	25,6 %	25,4 %	1,41	1,42
MASTER	29,6 %	28,9 %	23,1 %	22,7 %	1,12	1,12
PatchTST	36,3 %	37,3 %	22,7 %	22,7 %	1,64	1,72
TFT	40,2 %	39,6 %	24,6 %	24,4 %	1,79	1,79

Sharpov količnik v tabeli 2 ni neposredno primerljiv s količniki v drugih tabelah, kjer netvegane mere ne odštevamo. TFT + RD (Sharpe 1,79) in PatchTST + SO (1,72) se uvrstita med LSTM+Gurobi (1,08) in CardNN-GS (1,97). Letni donos TFT + RD (40,2 %) je skoraj enak donosu CardNN-GS (40,0 %), a ob višjem realiziranem tveganju (24,6 % proti 18,8 %), zato je njegov Sharpov količnik nižji zaradi višje volatiliteti, ne zaradi nižjega donosa. Vsi trije transformerji prekašajo svoje ujemajoče zgodovinsko povprečje (z istim optimizatorjem): MASTER + RD s Sharpom 1,12 le za +0,26, TFT + RD in PatchTST + SO pa z večjo razliko. Že samo zgodovinsko povprečje + SO čez 336 dni (1,42) prekaša LSTM+Gurobi brez napovednega modela. Naše metode tako dosegajo kakovost specializiranih nevronske reševalnikov.

6.3. Krizno vlaganje. Predstavljajmo si previdnega vlagatelja, ki hrani premoženje v petih skladih: v delnicah, dolgoročnih in srednjeročnih obveznicah, zlatu in surovinah. Vsak teden presodi, kolikšen del kapitala nameni posameznemu skladu, ko se trgi januarja 2020 zaradi pandemije COVID-19 nenadoma sesujejo. Preizkus našega postopka na takem scenariju ima dva izziva. Prvič, začetna učna množica (2018–2019) takega padca ne vsebuje, zato se morajo modeli prilagoditi razmeram, ki jih prej niso videli, kar jim omogoča ponovno učenje ob vsaki odločitvi na doslej znanih podatkih. Drugič, preizkus obsega le 13 tedenskih odločitev, zato lahko že en sam slab ali dober teden bistveno spremeni rezultat posameznega modela.

Na takem scenariju svoje pristope ovrednotijo Leow in sod. [6]. Njihova najboljša metoda (SAW) iz objav na družbenih omrežjih z modelom BERT izlušči razpoloženski signal in ga skupaj z genetskim algoritmom vključi v optimizacijo portfelja in doseže Sharpov količnik 2,14. Kot primerjavo poročajo še pasivni nakup SPY (sklad, ki sledi indeksu S&P 500) in CRB (indeks cen surovin) ter Markowitzev model (MPT).


Pri primerjavi uporabimo njihovo časovno delitev (januar–april 2020, 13 tedenskih odločitev), nabor All-Weather (delnice VTI, dolgoročne obveznice TLT, srednjeročne obveznice IEF, zlato GLD in surovine DBC) in kardinalnost $K=5$. Vhodno okno modelov, ki ga ima enako tudi ujemajoče zgodovinsko povprečje, obsega 64 trgovalnih dni pri TFT in 45 pri PatchTST. Vzorčno kovariančno matriko ocenimo iz zadnjih 64 dni in jo ob vsaki odločitvi posodobimo. Donos, volatilitet in Sharpov količnik izračunamo po splošnih definicijah. Ker isti P pri različnih virih $\hat{\mu}$ pomeni različno realizirano tveganje, vsak model poročamo pri tistem P , pri katerem je njegova realizirana letna volatilitet najbližja volatilitetu ujemajočega zgodovinskega povprečja.

Tabela 3. Primerjava R_{letno} , σ_{letno} , SR in W_n med našimi metodami ter delom Leow in sod. [6].

	R_{letno}	σ_{letno}	SR	W_n
SPY (pasivno)	−65,4 %	55,1 %	−1,65	−
CRB (pasivno)	−8,5 %	17,8 %	−0,41	−
MPT (Markowitz)	13,6 %	18,0 %	0,80	−
Leow: SAW (najboljši)	53,9 %	21,2 %	2,14	−

	RD	SO	RD	SO	RD	SO	RD	SO
Zgodovinsko povprečje (45 dni)	29,6 %	31,7 %	20,9 %	21,0 %	1,42	1,51	1,07	1,08
Zgodovinsko povprečje (64 dni)	11,2 %	12,4 %	24,4 %	24,2 %	0,46	0,51	1,02	1,02
PatchTST	14,6 %	15,2 %	22,7 %	22,7 %	0,64	0,67	1,03	1,03
TFT	28,6 %	28,8 %	22,2 %	22,1 %	1,29	1,30	1,07	1,07

Ta scenarij je za naše modele posebej težaven, a kljub temu oba transformerja ohranita kapital: TFT + SO konča z vrednostjo 1,07, PatchTST + SO z 1,03, indeks S&P 500 pa pade na 0,77 (Slika 6). Oba tudi močno presežeta pasivna nakupa SPY (Sharpe −1,65) in CRB (−0,41). Pri primerjavi z ujemajočim zgodovinskim povprečjem (tabela 3) je TFT + SO jasno boljši: doseže Sharpe 1,30 (28,8 %), zgodovinsko povprečje + SO čez 64 dni pa le 0,51 (12,4 %), razlika je +0,79. PatchTST + SO s Sharpom 0,67 (15,2 %) zaostaja za svojim povprečjem + SO čez 45 dni (1,51, 31,7 %; razlika −0,84), vendar je zgodovinsko povprečje v tem scenariju zelo občutljivo na dolžino okna: s 64 namesto 45 dnevi pade s 1,51 na 0,51. Glede izvorni članek TFT + SO preseže klasični Markowitzev model (MPT, 0,80), ne pa njihove najboljše metode SAW (2,14), PatchTST + SO pa ne doseže niti MPT. Naš postopek tako v kriznem scenariju preseže pasivna indeksa, v primeru TFT + SO pa tudi klasični pristop iz izvirnega članka, ne doseže pa metode SAW. Za modele bi bilo ugodneje, če bi učno obdobje vsebovalo vsaj en zlom. SAW je verjetno uspešen zato, ker razpoloženski signal iz družbenih omrežij zajame novice o nastajajočem zlomu, še preden padejo cene.



Slika 6. Vrednost portfelja med COVID-19 zlomom: modeli proti zgodovinskemu povprečju.

6.4. Mesečno vlaganje. Indeks DJIA (angl. *Dow Jones Industrial Average*) obsega 30 velikih ameriških podjetij iz različnih panog, na njegovo vrednost pa bolj vplivajo delnice z višjo ceno. Predstavljajmo si vlagatelja, ki enkrat mesečno izmed osemindvajsetih delnic indeksa DJIA izbere deset, mednje razporedi kapital in jih drži en mesec. To počne pet let (2016–2020), v katerih se tržne razmere precej spreminjajo, med drugim v začetku leta 2020 nastopi nenaden padec. Mesečna obdobja se ne prekrivajo, zato ima preizkus 60 neodvisnih odločitev, majhen nabor pa optimizatorju olajša izbiro desetih sredstev. Vhodno okno modelov, ki ga ima enako tudi ujemaajoče zgodovinsko povprečje, obsega 67 trgovalnih dni pri MASTER, 271 pri TFT in 336 pri PatchTST. Vzorčno kovariančno matriko ocenimo iz zadnjih 336 dni in jo posodobimo ob letnem ponovnem učenju.

Aprea in Sbaiz [8] predlagata globoko naučen pristop k izbiri portfelja, ki namesto variance kot mere tveganja minimizira agregiran ΔCoVaR (sistemsko tveganje, ocenjeno z LSTM) ob dodatnih omejitvah ESG, prometa in minimalnega donosa. Nastali nekonveksni problem rešujeta z izboljšanim rojenjem delcev, pri katerem parametre roja (w , c_1 , c_2) sproti prilagaja nevronska mreža. Njuna ciljna funkcija in omejitve so torej bistveno drugačne od povprečje–variančne ciljne funkcije (4).

Pri primerjavi poročamo iste skupne mere kot pri drugih eksperimentih, poleg njih pa še letno sestavljeno rast R_{CAGR} , ki jo poročata avtorja. Ta pove, s kolikšno stalno letno stopnjo bi kapital zrasel do končne vrednosti portfelja in predstavlja neto vrednost po transakcijskih stroških, naša pa bruto. Za naše metode jo iz vrednosti določimo W_n po enačbi (29). Njuno volatilnost in Sharpov količnik, ki jo objavljata za mesečno obdobje, preračunamo na letne vrednosti za $p=12$ po enačbah (24) in (25).


$$R_{\text{CAGR}} = W_n^{p/n} - 1. \quad (29)$$

Prevzamemo njihov nabor 28 sredstev indeksa DJIA in njihovo časovno shemo: učenje na obdobju 2007–2015, mesečno odločanje v obdobju 2016–2020 (60 razporeditev, v članku $T_f=59$) in $w_{\text{max}}=0,2$ (zgornja meja uteži, skladna z eno od dveh mej v izvornem članku). Kardinalnost $K=10$ je naš dodatek, saj njun model kardinalne omejitve ne vsebuje. Pri njih število pozicij sledi iz zgornje meje uteži (povprečno 10 pri $u_i=0,2$), zato naš $K=10$ predpiše prav to število.

Tabela 4. Primerjava R_{letno} , σ_{letno} , SR, W_n in R_{CAGR} med našimi metodami ter delom Aprea in Sbaiz [8].

	R_{letno}		σ_{letno}		SR		W_n		R_{CAGR}	
Aprea in Sbaiz	–		17,4 %		1,21		–		20,8 %	
	RD	SO	RD	SO	RD	SO	RD	SO	RD	SO
Zgodovinsko povprečje (67 dni)	14,1 %	14,3 %	15,3 %	15,1 %	0,75	0,77	1,90	1,92	13,7 %	14,0 %
Zgodovinsko povprečje (271 dni)	12,4 %	12,6 %	15,5 %	15,4 %	0,64	0,66	1,74	1,77	11,8 %	12,1 %
Zgodovinsko povprečje (336 dni)	14,8 %	15,4 %	15,5 %	15,4 %	0,80	0,84	1,97	2,03	14,5 %	15,2 %
MASTER	16,3 %	16,1 %	17,2 %	17,3 %	0,76	0,74	2,09	2,07	15,9 %	15,7 %
PatchTST	19,3 %	19,5 %	15,4 %	15,3 %	1,09	1,11	2,46	2,49	19,7 %	20,0 %
TFT	16,9 %	17,1 %	16,9 %	16,8 %	0,79	0,80	2,16	2,19	16,7 %	17,0 %

Rezultate lahko vidimo v tabeli 4. Na tem naboru vsi trije transformerji presežejo svoje ujemaajoče zgodovinsko povprečje. PatchTST + SO doseže najvišji Sharpe (1,11 proti 0,84 za zgodovinsko povprečje + SO čez 336 dni) in se približa referenci izvornega članka: njegov donos je 20,0 % proti 20,8 %, vrednost portfelja 2,49 proti 2,54, Sharpe 1,11 proti 1,21. Volatilnost je pri vseh naših metodah (15,3–17,2 %) nižja kot pri njih (17,4 %). TFT + SO (0,80 proti 0,66) in MASTER + RD (0,76 proti 0,75, komaj) prav tako presežeta svoji zgodovinski povprečji z istim optimizatorjem, a z manjšo razliko. Naš postopek tako na naboru DJIA doseže vrednosti, primerljive z metodo v izvornem članku, ampak je ne preseže. Slika 7 kaže, da vsi portfelji ob zlomu v začetku leta 2020 izgubijo del vrednosti in si nato opomorejo.



Slika 7. Vrednost portfelja pri mesečnem vlaganju (DJIA, 2016–2020): modeli proti zgodovinskemu povprečju.

6.5. Dolgoročno vlaganje. Denimo, da vlagamo dolgoročno tako, da npr. štirinajst let vsak mesec izmed 61 ameriških delnic (seznam je v razdelku B) izberemo 20, med njih razporedimo svoj kapital in jih držimo en mesec, nato pa postopek ponovimo. V preiskusu našega optimizacijskega postopka na tem načinu vlaganja napovedi modelov izboljšujemo tudi s tem, da jih enkrat letno ponovno učimo. Ker tak preizkus obsega več različnih tržnih razmer in največ obdobj, ki se ne prekrivajo (168 mesečnih odločitev), lahko z njim zelo dobro preverimo, ali napovedi transformerjev ostajajo koristne skozi različne tržne razmere in časovna obdobja, ter če ima naš postopek praktično vrednost. Vhodno okno modelov, ki ga ima enako tudi ujemajoče zgodovinsko povprečje, obsega 67 trgovalnih dni pri MASTER, 271 pri TFT in 336 pri PatchTST. Vzorčno kovariančno matriko ocenimo iz zadnjih 336 dni in jo posodobimo ob letnem ponovnem učenju. Za ta primer ni izvirnega članka, zato referenčnih vrednosti iz literature ni.

Ima pa ta eksperiment nekaj omejitev. Nabor sredstev vsebuje samo delnice, ki so preživele celotno obdobje (angl. *survivorship bias*). Novih sredstev, ki so se dodale med obdobjem ali pa sredstev, ki so bila v njem ukinjena, v nabor ne vključimo. To do neke mere zviša absolutne donose vseh strategij, zato je razlika do indeksa S&P 500 lahko precenjena. Vendar pa primerjava transformerskih modelov z zgodovinskimi povprečji pa ostaja zanesljivejša, saj vsi delijo isti nabor.

Pomembna razlika med tem in preostalimi eksperimenti je upoštevanje transakcijskih stroškov. Zaradi mesečnega sestavljanja portfelja vlagatelj namreč plačuje stroške trgovanja, ki jih pri preostalih eksperimentih nismo upoštevali. Ker želimo preveriti tudi praktično vrednost naših metod, smo jih v tem eksperimentu vključili. Transakcijske stroške smo ocenili z 10 bazičnimi točkami (b.t.) na enoto prometa. Bazična točka je stotinka odstotka (1 b.t. = 0,01 %), zato 10 b.t. pomeni 0,1 % trgovane vrednosti. Promet TO_t je določen z enačbo (26) in sešteva absolutne spremembe uteži, torej nakupe in prodaje skupaj. Enota prometa tako ustreza trgovanju v vrednosti celotnega portfelja: vrednost 1 pomeni, da smo kupili in prodali skupaj toliko, kolikor je vredna naložba, popolna zamenjava vseh pozicij pa ustreza vrednosti 2 in pri 10 b.t. stane 0,2 % vrednosti portfelja. Neto donos obdobja je bruto donos, zmanjšan za strošek, neto vrednost portfelja pa izračunamo iz neto donosov, pri čemer je $c = 10 \cdot 10^{-4}$, kot prikazuje enačba (30). Rezultate preverimo tudi pri drugih stroških.

$$r_t^{p,neto} = r_t^p - c TO_t, \quad W_t^{neto} = \prod_{j=1}^t (1 + r_j^{p,neto}). \quad (30)$$


Za posamezen model poročamo povprečni promet na odločitev $\overline{TO}$. To je povprečje prometa po vseh odločitvah (brez začetne razporeditve). Pri 12 odločitvah na leto je letno znižanje donosa zaradi stroškov približno $12 c \overline{TO}$, pri MASTER $12 \cdot 0,1 \% \cdot 1,54 \approx 1,8 \%$.

Ker primer ni vezan na referenčno študijo, sta referenčni točki naše zgodovinsko povprečje in pasivni indeks S&P 500 (brez prometa, zato velja bruto = neto). Vsi pristopi delijo isti nabor sredstev.

Tabela 5. Primerjava R_{letno} , SR, W_n in $\overline{TO}$ (bruto, neto) med našimi metodami ter indeksom S&P 500.


	Bruto						Neto							
	R_{letno}		SR		W_n		R_{letno}		SR		W_n		$\overline{TO}$	
S&P 500 (indeks)	12,1 %		0,85		4,68		12,1 %		0,85		4,68		0,00	
	RD	SO	RD	SO	RD	SO	RD	SO	RD	SO	RD	SO	RD	SO
Zgodovinsko povprečje (67 dni)	14,0 %	13,5 %	1,01	0,99	6,16	5,75	12,9 %	12,3 %	0,93	0,91	5,25	4,91	0,96	0,96
Zgodovinsko povprečje (271 dni)	13,6 %	13,5 %	0,99	0,98	5,84	5,76	13,0 %	12,9 %	0,94	0,94	5,36	5,30	0,52	0,51
Zgodovinsko povprečje (336 dni)	14,7 %	14,3 %	1,10	1,08	6,87	6,51	14,1 %	13,8 %	1,06	1,03	6,34	6,04	0,48	0,46
MASTER	11,6 %	11,8 %	0,73	0,73	4,23	4,33	9,8 %	10,0 %	0,61	0,62	3,28	3,36	1,54	1,52
PatchTST	17,6 %	17,3 %	1,38	1,36	10,34	9,92	16,2 %	15,9 %	1,27	1,25	8,47	8,13	1,21	1,21
TFT	16,4 %	16,7 %	1,10	1,14	8,41	8,85	15,6 %	15,9 %	1,04	1,08	7,48	7,90	0,71	0,69

V tabeli 5 lahko vidimo bruto in neto rezultate. PatchTST + RD doseže najvišji Sharpe (1,38) in donos (17,6 %) in tako jasno prekaša svoje ujemajoče zgodovinsko povprečje + RD čez 336 dni (Sharpe 1,10, donos 14,7 %). TFT + SO doseže Sharpe 1,14 (16,7 %) in prav tako preseže svoje (krajše, šibkejšje) zgodovinsko povprečje + SO čez 271 dni (Sharpe 0,98, donos 13,5 %). MASTER + SO je edini transformer, ki v tem primeru zaostane za svojim zgodovinskim povprečjem + SO: Sharpe 0,73 (11,8 %) proti 0,99 (13,5 %) čez 67 dni. Vsa tri zgodovinska povprečja in TFT + SO presežejo pasivni S&P 500 (Sharpe 0,85, donos 12,1 %). PatchTST + RD ga preseže z največjo razliko. PatchTST + RD in TFT + SO tako prednost pred svojim zgodovinskim povprečjem vzdržujeta prek celotnega 14-letnega obdobja, ki zajema krizna (2020, 2022) in mirnejša leta, MASTER + SO pa ostaja pod njim. Neto, torej po odštetih stroških, PatchTST + RD doseže Sharpe 1,27 (zgodovinsko povprečje + RD 1,06), TFT + SO 1,08 (0,94) in MASTER + SO 0,62 (0,91).



Slika 8. Vrednost portfelja pri dolgoročnem vlaganju (2011–2024), bruto.

Slika 8 kaže, da se prednost PatchTST + RD pred zgodovinskim povprečjem + RD gradi skozi vse obdobje: vrednost njegovega portfelja je v vsakem mesecu vsaj enaka vrednosti zgodovinskega povprečja in ob koncu doseže 1,5-kratnik. TFT + SO je nad svojim povprečjem + SO v 88 % mesecev in od februarja 2016 neprekinjeno, ob koncu pa doseže 1,5-kratnik. MASTER + SO je nad svojim povprečjem + SO le v 1 % mesecev, ob koncu pa doseže 0,75 njegove vrednosti. Največji padec (brez stroškov) je pri PatchTST + RD le malo večji od padca zgodovinskega povprečja + RD (−19 % proti −17 %), pri TFT + SO pa izrazitejši (−27 % proti −17 % pri zgodovinskem povprečju + SO), zato je prednost pri donosu delno plačana z večjim tveganjem. Zaostanek MASTER je najverjetneje povezan z njegovim prometom: ta je najvišji (1,52 proti 0,96 pri zgodovinskem povprečju čez 67 dni), kar kaže, da se njegove napovedi in s tem portfelj iz meseca v mesec močno spreminjajo in da napovedi niso najboljše. Pri mesečnem vlaganju ima MASTER prav tako visok promet, a se zgodovinskemu povprečju vseeno približno izenači, zato je del zaostanka lahko tudi posledica naključja, saj imamo le eno seme.



Slika 9. Vrednost portfelja pri dolgoročnem vlaganju (2011–2024), neto.

Neto gibanje vrednosti portfeljev prikazuje slika 9. Vrsten red se ohrani: PatchTST + RD in TFT + SO ostaneta jasno pred svojim ujemajočim zgodovinskim povprečjem in pred S&P 500, MASTER + SO pa ostane edini transformirani pod svojim zgodovinskim povprečjem, tokrat še bolj izrazito. Stroški so sorazmerni prometu portfelja, zato modele prizadene različno. MASTER + SO z najvišjim prometom izgubi največ: Sharpe pade z 0,73 na 0,62 (−0,11), končna vrednost pa z 4,33 na 3,36 (−22 %). PatchTST + RD (promet 1,21) je vmes: Sharpe z 1,38 na 1,27 (−0,11), končna vrednost z 10,34 na 8,47 (−18 %). TFT + SO ima najnižji promet (0,69, blizu ravni zgodovinskih povprečij) in je do stroškov najbolj odporen: Sharpe z 1,14 na 1,08 (−0,06), končna vrednost z 8,85 na 7,90 (−11 %). Ker je ocena stroškov za likvidne ameriške delnice realna, prednost PatchTST + RD in TFT + SO ni posledica zanemarnjenih stroškov, promet portfelja pa je pomembna dodatna dimenzija pri izbiri modela za praktično uporabo, o čemer spregovorimo v naslednjem poglavju.

6.6. Stabilnost napovedi in promet portfelja. Modele smo doslej primerjali po donosu, volatilitnosti, Sharpovem količniku in vrednosti portfelja, ne pa po stabilnosti portfelja. Promet, ki jo meri, smo že uporabili pri dolgoročnem vlaganju (razdelek 6.5) za izračun transakcijskih stroškov; tu ga v tabeli 6 primerjamo pri vseh eksperimentih kot povprečje na odločitev po enačbi (26). Pove, kolikšen del portfelja zamenjamo ob vsaki odločitvi. Ker so odločitve pri kriznem vlaganju tedenske, pri ostalih eksperimentih pa mesečne, promet primerjamo le med modeli v isti vrstici.

Tabela 6. Povprečni promet portfelja na odločitev za transformerske modele ($P=0,5$, optimizatorja RD in SO).

	TFT		MASTER		PatchTST	
	RD	SO	RD	SO	RD	SO
Polletno vlaganje	0,52	0,47	1,33	1,33	1,38	1,40
Krizno vlaganje	0,17	0,18	–	–	0,34	0,34
Mesečno vlaganje	0,70	0,69	1,46	1,46	1,07	1,07
Dolgoročno vlaganje	0,71	0,69	1,54	1,52	1,21	1,21

TFT ima v vseh štirih eksperimentih najnižji promet, MASTER pa v vseh treh, kjer nastopa, najvišji ali skoraj najvišji. Razlika je največja v dolgoročnem primeru (TFT + SO 0,69 proti MASTER + SO 1,52), kjer se vidi tudi v neto rezultatu. Ker je promet vsota absolutnih sprememb uteži, vrednost 2 ustreza popolni zamenjavi portfelja: pri MASTER in PatchTST se tako ob vsaki odločitvi zamenja več kot polovica vrednosti portfelja, pri TFT pa približno tretjina ali manj. Nižji promet pomeni manj izrazite spremembe izbora in uteži med zaporednimi odločitvami, torej manj trgovanja, nižje transakcijske stroške in praviloma višjo neto vrednost portfelja.

6.7. Računski čas. Poročani časi so vezani na strojno opremo, opisano na začetku poglavja, in jih ne gre neposredno posploševati na druge konfiguracije.

Tabela 7 podaja povprečni čas enega učenja in ene odločitve optimizatorjev RD in SO pri $P=0,5$ (pri kriznem vlaganju pri P iz tabele 3; v oklepaju je število učenj) ter skupne čase. Skupni čas učenja je vsota vseh učenj modela, skupni čas optimizacije vsota vseh reševanj za vse modele, zgodovinska povprečja in vrednosti P , skupni čas eksperimenta pa vsota obojega. Pri zgodovinskem povprečju učenja ni.

Tabela 7. Povprečni in skupni čas učenja po modelih ter optimizacije po optimizatorjih.

	Učenje			Optimizacija		Skupaj
	MASTER	PatchTST	TFT	RD	SO	
Povprečje (število učenj)						
Polletno vlaganje (1)	33,7 min	1,8 min	1,04 h	2,0 s	1,6 s	
Krizno vlaganje (65)	–	17,0 s	18,6 s	67 ms	17 ms	
Mesečno vlaganje (5)	22,3 min	2,0 min	25,2 min	186 ms	43 ms	
Dolgoročno vlaganje (14)	15,3 min	1,9 min	41,1 min	403 ms	143 ms	
Skupaj						
Polletno vlaganje	33,7 min	1,8 min	1,04 h	15,7 min	11,3 min	2,08 h
Krizno vlaganje	–	18,4 min	20,1 min	39,1 s	9,6 s	39,3 min
Mesečno vlaganje	1,86 h	10,1 min	2,10 h	12,3 min	2,6 min	4,38 h
Dolgoročno vlaganje	3,58 h	26,0 min	9,59 h	1,24 h	25,8 min	15,27 h

Učenje traja bistveno dlje kot optimizacija in predstavlja večino skupnega časa vsakega eksperimenta, od približno 78 % pri polletnem do 98 % pri kriznem vlaganju. Najhitreje se uči PatchTST (okoli 2 min, razen pri kriznem vlaganju, kjer sta TFT in PatchTST skoraj enako hitra), najpočasneje TFT (do 63 min), MASTER je vmes. Ena odločitev optimizatorja traja med 16 ms in 2,1 s, zato eno učenje traja od približno 50-krat do več kot 8000-krat dlje kot eno reševanje. PatchTST je skoraj neodvisen od velikosti nabora (1,8–2,0 min od 28 do 494 sredstev), čas učenja MASTER pa s številom sredstev ne narašča monotono (22,3 min pri $N=28$, 15,3 min pri $N=61$, 33,7 min pri $N=494$), saj je odvisen tudi od dolžine učnega okna in zgodnjega ustavljanja.

Čas optimizacije določajo N , K in proračun reševalnika, ne izbira napovednega modela (razlika med modeli je manj kot 5%). SO je z napovednimi modeli približno 2,8- do 4,3-krat hitrejši od RD, pri 494 sredstvih pa le 1,3-krat. Na OR-Library je pospešitev podobna (1,7- do 3,4-krat), SO pa je tam tudi natančnejši (razdelek 6.1).

Čas učenja ne napoveduje uspešnosti: pri polletnem vlaganju je TFT najboljši po Sharpovem količniku kljub približno petintridesetkrat daljšemu učenju kot PatchTST (62,6 proti 1,8 min), pri mesečnem in dolgoročnem vlaganju pa je najboljši PatchTST, ki se uči najhitreje. Celoten eksperimentalni postopek je izvedljiv na osebnem računalniku. Najdlje traja dolgoročno vlaganje (15,3 h), vsi štirje eksperimenti skupaj pa okoli 22,4 h.

7. Sklep

Cilj dela je bil preveriti, ali transformerji kot ocenjevalci pričakovanih donosov $\hat{\mu}$ izboljšajo kardinalno omejene portfelje, sestavljene z rojenjem delcev in simuliranim ohlajanjem. Pri tem smo napovedovanje in optimizacijo uteži obravnavali kot dva zaporedna koraka, da lahko vpliv vsakega ocenimo posebej. Oba optimizatorja sta na problemih OR-Library dala rešitve, primerljive z algoritmi iz literature, zato lahko razlike med portfelji pripišemo napovedim pričakovanih donosov.

Rezultati kažejo, da transformerji res izboljšajo portfelje, vendar prednost ni univerzalna. V vseh štirih eksperimentih vsaj en model preseže zgodovinsko povprečje z enakim oknom, a zmagovalec je odvisen od nabora sredstev in obdobja. TFT se je izkazal pri polletnem in kriznem vlaganju ter ima najstabilnejši portfelj, PatchTST pri mesečnem in dolgoročnem, MASTER pa je pri dolgoročnem vlaganju slabši od zgodovinskega povprečja, predvsem zaradi visokega prometa portfelja. Pri 10 b.t. transakcijskih stroškov prednost PatchTST in TFT ostane. Izbira optimizatorja je pomembnejša za računski čas kot za uspešnost portfelja, saj so razlike v uspešnosti majhne, učenje modelov pa je daleč največji del računskih stroškov.

Ker se najuspešnejši model med eksperimenti spreminja, je najbolj obetavna nadaljnja smer ansambel: napovedi $\hat{\mu}$ posameznih modelov bi po standardizaciji povprečili ali jim dodelili uteži glede na nedavno uspešnost, skupni vmesnik za učenje in napovedovanje pa omogoča preprosto dodajanje modelov. Ansambel bi lahko šel še dlje, s samodejnim izborom napovednega modela glede na tržni režim. Druga možnost bi bila povezava napovedovanja in optimizacije v enoten pristop, naučen skozi optimizacijo, ter robustnejše ocenjevanje kovariančne matrike, saj jo zdaj ocenjujemo iz zgodovinskih donosov. Postopek bi lahko razširili tudi z natančnejšim modeliranjem transakcijskih stroškov in davkov ter z merami repnega tveganja. Poleg tega bi bilo smiselno napovedno kakovost modelov ovrednotiti neposredno, na standardnih presečnih merah in daljših testnih obdobjih, ter rezultate preveriti z več naključnimi semeni.

Literatura

1. Markowitz H (1952) Portfolio selection. *The Journal of Finance* 7(1):77–91.
2. Chang TJ, Meade N, Beasley JE, Sharaiha YM (2000) Heuristics for cardinality constrained portfolio optimisation. *Computers & Operations Research* 27(13):1271–1302.
3. Nie Y, Nguyen NH, Sinthong P, Kalagnanam J (2023) A time series is worth 64 words: Long-term forecasting with transformers in *Proceedings of the Eleventh International Conference on Learning Representations (ICLR)*. <https://doi.org/10.48550/arXiv.2211.14730>.
4. Lim B, Arik SO, Loeff N, Pfister T (2021) Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting* 37(4):1748–1764.
5. Li T et al. (2024) MASTER: Market-guided stock transformer for stock price forecasting in *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 38, pp. 162–170.
6. Leow EKW, Nguyen BP, Chua MCH (2021) Robo-advisor using genetic algorithm and BERT sentiments from tweets for hybrid portfolio optimisation. *Expert Systems with Applications* 179:115060.
7. Wang R et al. (2023) Towards one-shot neural combinatorial solvers: Theoretical and empirical notes on the cardinality-constrained case in *International Conference on Learning Representations (ICLR)*. Na voljo na: <https://openreview.net/forum?id=h21yJhdzbowz>. Dostopano: 18. 9. 2026.
8. Aprea IL, Sbaiz G (2026) A neural network-particle swarm solver for sustainable portfolio optimization problems. *Decisions in Economics and Finance* 49(1):25–64.
9. Michaud RO (1989) The Markowitz optimization enigma: Is 'optimized' optimal? *Financial Analysts Journal* 45(1):31–42.
10. Black F, Litterman R (1992) Global portfolio optimization. *Financial Analysts Journal* 48(5):28–43.
11. He G, Litterman R (1999) The intuition behind Black-Litterman model portfolios, (Goldman Sachs Investment Management Research), Technical report. <https://doi.org/10.2139/ssrn.334304>.
12. DeMiguel V, Garlappi L, Uppal R (2009) Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies* 22(5):1915–1953.
13. Bessler W, Opfer H, Wolff D (2017) Multi-asset portfolio optimization and out-of-sample performance: An evaluation of Black-Litterman, mean-variance, and naive diversification approaches. *The European Journal of Finance* 23(1):1–30.
14. Tu J, Zhou G (2011) Markowitz meets talmud: A combination of sophisticated and naive diversification strategies. *Journal of Financial Economics* 99(1):204–215.
15. Bienstock D (1996) Computational study of a family of mixed-integer quadratic programming problems. *Mathematical Programming* 74(2):121–140.
16. Gao J, Li D (2013) Optimal cardinality constrained portfolio selection. *Operations Research* 61(3):745–761.
17. Brodie J, Daubechies I, De Mol C, Giannone D, Loris I (2009) Sparse and stable Markowitz portfolios. *Proceedings of the National Academy of Sciences of the United States of America* 106(30):12267–12272.
18. Kim MJ, Lee Y, Kim JH, Kim WC (2016) Sparse tangent portfolio selection via semi-definite relaxation. *Operations Research Letters* 44(4):540–543.
19. Akbay MA, Kalayci CB, Polat O (2020) A parallel variable neighborhood search algorithm with quadratic programming for cardinality constrained portfolio optimization. *Knowledge-Based Systems* 198:105944.
20. Jegadeesh N, Titman S (1993) Returns to buying winners and selling losers: Implications for stock market efficiency. *The Journal of Finance* 48(1):65–91.
21. Carhart MM (1997) On persistence in mutual fund performance. *The Journal of Finance* 52(1):57–82.
22. Gu S, Kelly B, Xiu D (2020) Empirical asset pricing via machine learning. *The Review of Financial Studies* 33(5):2223–2273.
23. Ke G et al. (2017) LightGBM: A highly efficient gradient boosting decision tree in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 3146–3154. Na voljo na: https://papers.nips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html. Dostopano: 18. 9. 2026.
24. Selvin S, Vinayakumar R, Gopalakrishnan EA, Menon VK, Soman KP (2017) Stock price prediction using LSTM, RNN and CNN-sliding window model in 2017 *International Conference on Advances in Computing, Communications and Informatics (ICACCI)*. pp. 1643–1647.
25. Hochreiter S, Schmidhuber J (1997) Long short-term memory. *Neural Computation* 9(8):1735–1780.
26. Barua R, Sharma AK (2022) Dynamic Black Litterman portfolios with views derived via CNN-BiLSTM predictions. *Finance Research Letters* 49:103111.
27. Vaswani A et al. (2017) Attention is all you need in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 5998–6008.
28. Wang C, Chen Y, Zhang S, Zhang Q (2022) Stock market index prediction using deep Transformer model. *Expert Systems with Applications* 208:118128.
29. Zhang Q et al. (2022) Transformer-based attention network for stock movement prediction. *Expert Systems with Applications* 202:117239.
30. Wu H, Xu J, Wang J, Long M (2021) Autoformer: Decomposition transformers with Auto-Correlation for long-term series forecasting in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 34, pp. 22419–22430.
31. Das A, Kong W, Sen R, Zhou Y (2024) A decoder-only foundation model for time-series forecasting in *Proceedings of the 41st International Conference on Machine Learning (ICML)*. Vol. 235, pp. 10148–10167.
32. Ye J, Zhao J, Ye K, Xu C (2021) Multi-graph convolutional network for relationship-driven stock movement prediction in 2020

- 25th International Conference on Pattern Recognition (ICPR). pp. 6702–6709.
33. Li W et al. (2020) Modeling the stock relation with graph network for overnight stock movement prediction in *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence*. pp. 4541–4547.
 34. Sawhney R, Agarwal S, Wadhwa A, Shah RR (2020) Deep attentive learning for stock movement prediction from social media text and company correlations in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. (Association for Computational Linguistics), pp. 8415–8426.
 35. Cheng D, Yang F, Xiang S, Liu J (2022) Financial time series forecasting with multi-modality graph neural network. *Pattern Recognition* 121:108218.
 36. Fan J, Fan Y, Lv J (2008) High dimensional covariance matrix estimation using a factor model. *Journal of Econometrics* 147(1):186–197.
 37. Engle R (2002) Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics* 20(3):339–350.
 38. Chiriac R, Voev V (2011) Modelling and forecasting multivariate realized volatility. *Journal of Applied Econometrics* 26(6):922–947.
 39. Lin H, Zhou D, Liu W, Bian J (2021) Deep risk model: A deep learning solution for mining latent risk factors to improve covariance matrix estimation in *Proceedings of the Second ACM International Conference on AI in Finance (ICAIF)*. <https://doi.org/10.1145/3490354.3494377>.
 40. Yang L, Zhao S, Chai S (2026) Neural nonlinear shrinkage of covariance matrices for minimum variance portfolio optimization (arXiv preprint arXiv:2601.15597 [q-fin.PM]). <https://doi.org/10.48550/arXiv.2601.15597>.
 41. Salinas D, Bohlke-Schneider M, Callot L, Medico R, Gasthaus J (2019) High-dimensional multivariate forecasting with low-rank Gaussian copula processes in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 32, pp. 6824–6834.
 42. Cura T (2009) Particle swarm optimization approach to portfolio optimization. *Nonlinear Analysis: Real World Applications* 10(4):2396–2406.
 43. Nie Y (2023) PatchTST: A time series is worth 64 words: Long-term forecasting with transformers (uradna koda). Na voljo na: <https://github.com/yuqinie98/PatchTST>. Dostopano: 27. 9. 2026.
 44. Beitner J (2020) pytorch-forecasting: Time series forecasting with PyTorch. Na voljo na: <https://github.com/jdb78/pytorch-forecasting>. Dostopano: 24. 9. 2026.
 45. SJTU-DMTai (2024) MASTER: Market-guided stock transformer for stock price forecasting (uradna koda). Na voljo na: <https://github.com/SJTU-DMTai/MASTER>. Dostopano: 27. 9. 2026.
 46. Yang X, Liu W, Zhou D, Bian J, Liu TY (2020) Qlib: An AI-oriented quantitative investment platform. *arXiv preprint arXiv:2009.11189*. <https://arxiv.org/abs/2009.11189>.
 47. Kennedy J, Eberhart R (1995) Particle swarm optimization in *Proceedings of the IEEE International Conference on Neural Networks*. Vol. 4, pp. 1942–1948.
 48. Kirkpatrick S, Gelatt CD, Vecchi MP (1983) Optimization by simulated annealing. *Science* 220(4598):671–680.
 49. Crama Y, Schyns M (2003) Simulated annealing for complex portfolio selection problems. *European Journal of Operational Research* 150(3):546–571.
 50. Sharpe WF (1994) The Sharpe ratio. *The Journal of Portfolio Management* 21(1):49–58.
 51. Beasley JE (1990) OR-Library: Distributing test problems by electronic mail. *Journal of the Operational Research Society* 41(11):1069–1072.

Priloge

A. Nastavitve in ponovljivost

Tabela 8. Ključne nastavitve napovednih modelov in optimizacijskih algoritmov. Preostali hiperparametri so del objavljenega repozitorija.

Sklop	Uporabljene nastavitve
RD	velikost roja (M) 200, največ iteracij (T) 1500.
SO	dolžina stopnje (L) $2N$, prag mirovanja (S) 5.
TFT	hitrost učenja 10^{-3} , največ 100 epoh, potrpežljivost 10.
MASTER	hitrost učenja 10^{-5} , največ 100 epoh, potrpežljivost 10.
PatchTST	vhodno okno 336, hitrost učenja 10^{-4} , največ 100 epoh, potrpežljivost 10.

Tabela 9. Osnovne nastavitve posameznih eksperimentalnih problemov.

Nastavitev	Polletno vlaganje	Krizno vlaganje	Dolgoročno vlaganje
Število sredstev (N)	494	5	61
Kardinalnost (K)	20	5	20
Meje uteži ($\varepsilon_i - \delta_i$)	0,001–1,0	0,01–0,40	0,01–0,1
Učenje	2018–2020	2018–2019	2005–2010
Test	2021	2020	2011–2024
Odločanje	mesečno	tedensko	mesečno
Napovedni horizont (H)	120	5	21
Ponovno učenje	enkrat	ob vsaki odločitvi	letno
Optimizator	RD in SO	RD in SO	RD in SO
Stroški	bruto	bruto	10 b. t.
Parameter tveganja (P)	0,2	0,05–0,95 (11 točk)	0,5

B. Nabor delnic pri dolgoročnem vlaganju

Tabela 10. Delnice v naboru za dolgoročno vlaganje po panogah.

Panoga	Delnice
Tehnologija	AAPL, MSFT, INTC, CSCO, ORCL, IBM, QCOM, TXN, ADBE, HPQ
Finance	JPM, BAC, WFC, C, GS, AXP, USB, MS
Zdravstvo	JNJ, PFE, MRK, ABT, AMGN, GILD, UNH, MDT, BMY, LLY
Potrošniško blago in storitve	PG, KO, PEP, WMT, HD, MCD, NKE, COST, LOW, TGT, SBUX, CL
Industrija	GE, HON, UNP, CAT, BA, MMM, UPS, LMT, EMR
Energetika	XOM, CVX, COP, SLB
Komunalne storitve	DUK, SO, NEE
Komunikacije	DIS, VZ, T, CMCSA, GOOGL