



Optimizacija naložbenih portfeljev z uporabo transformerjev in globalnih optimizacijskih algoritmov

Nejc Škrbec

Magistrski študijski program Računalništvo in informatika, smer Računalništvo in informatika

Fakulteta za računalništvo in informatiko

Mentor: doc. dr. Luka Fürst

Copyright: To delo je ponujeno pod licenco CC-BY-4.0.

V magistrskem delu obravnavamo kardinalno omejeno optimizacijo naložbenih portfeljev, pri kateri sta ključna izziva ocenjevanje pričakovanih donosov in iskanje optimalnih uteži ob zahtevi, da portfelj vsebuje natanko K aktivnih pozicij. Pričakovane donose ocenjujemo s tremi arhitekturno različnimi transformerskimi modeli (MASTER, TFT in PatchTST), katerih nevronska jedra povzamemo po uradnih izvedbah avtorjev. Kovariančno matriko pri vseh pristopih ocenimo enako iz zgodovinskih donosov, zato primerjava izolira vpliv napovednega signala. Uteži nato optimiziramo z rojenjem delcev in simuliranim ohlajanjem. Oba dela cevovoda najprej ovrednotimo ločeno, celoten cevovod pa s postopnim testiranjem zunaj vzorca na protokolih treh objavljenih študij in v dolgoročnem scenariju vlagatelja. V vseh petih preizkusih vsaj en transformerski model preseže svojo ujemajočo zgodovinsko osnovno linijo, vendar se model, ki to doseže, menja z univerzumom sredstev in protokolom: PatchTST je najuspešnejši v dolgoročnem scenariju (Sharpev količnik 1,38 proti 1,10) in na naboru DJIA, MASTER na naboru NASDAQ 100 (1,23 proti 1,03), TFT pa v kriznem obdobju. Razlike med optimizatorjema so majhne in nekonsistentne, kar kaže, da je kakovost ocene pričakovanih donosov prevladujoči dejavnik uspešnosti portfelja.

Optimizacija portfelja | Kardinalna omejitev | Transformerji | Napovedovanje donosov | Metahevrstike | Rojenje delcev

Optimizacija naložbenih portfeljev (v nadaljevanju ONP) predstavlja enega temeljnih problemov kvantitativnih financ. Cilj je razporediti razpoložljivi kapital med več finančnih sredstev tako, da dosežemo čim ugodnejše razmerje med pričakovanim donosom in tveganjem.

Denimo, da imamo nabor N finančnih sredstev, ki jih spremljamo v diskretnih časovnih korakih $t = 0, 1, \dots, T$. Ob koncu vsakega trgovalnega dne ima vsako sredstvo določeno zaključno ceno. Ker nekateri dogodki, predvsem delitve delnic in izplačila dividend, spremenijo nominalno ceno, ne da bi spremenili ekonomsko vrednost sredstva, uporabljamo prilagojene zaključne cene, pri katerih so pretekle vrednosti popravljene tako, da časovna vrsta ostane primerljiva.

Naj bo $p_{i,t} > 0$ prilagojena zaključna cena sredstva i ob času t . Enostavni donos $r_{i,t}$ in logaritemski donos $\tilde{r}_{i,t}$ definiramo kot

$$r_{i,t} = \frac{p_{i,t} - p_{i,t-1}}{p_{i,t-1}} = \frac{p_{i,t}}{p_{i,t-1}} - 1, \quad \tilde{r}_{i,t} = \ln \left(\frac{p_{i,t}}{p_{i,t-1}} \right). \quad (1)$$

Enostavni donos izraža relativno spremembo vrednosti sredstva, logaritemski pa je priročnejši pri modeliranju, ker se skozi čas sešteva. Če z $r_{i,t}^{(H)}$ označimo enostavni donos sredstva i v naslednjih H trgovalnih dneh, zato velja

$$r_{i,t}^{(H)} = \exp \left(\sum_{h=1}^H \tilde{r}_{i,t+h} \right) - 1. \quad (2)$$

To zvezo bomo uporabili tudi pri napovednih modelih, kjer bo zaporedje napovedanih dnevnih logaritemskih donosov postalo ena sama ocena pričakovanega donosa na izbranem obzorju.

Donose vseh sredstev v času t zberemo v vektor $\mathbf{r}_t = (r_{1,t}, \dots, r_{N,t})^\top$. Portfelj opišemo z vektorjem uteži $\mathbf{w} = (w_1, \dots, w_N)^\top$, kjer w_i predstavlja delež kapitala, vloženega v sredstvo i . Donos portfelja je

$$\mathbf{r}_t^p = \mathbf{w}^\top \mathbf{r}_t. \quad (3)$$

Klasično izhodišče za reševanje ONP predstavlja Markowitzev model [1], ki portfelj obravnava na podlagi pričakovanih donosov sredstev ter njihovega tveganja in medsebojne povezanosti. Prve opišemo z vektorjem μ , tveganje pa s kovariančno matriko Σ :

$$\mu = \mathbb{E}[\mathbf{r}], \quad \Sigma = \mathbb{E}[(\mathbf{r} - \mu)(\mathbf{r} - \mu)^\top]. \quad (4)$$

V praksi točnih vrednosti μ in Σ ne poznamo, zato uporabljamo njuni oceni $\hat{\mu}$ in $\hat{\Sigma}$. Najpreprosteje ju ocenimo iz zgodovinskih donosov, vendar se pričakovani donosi, tveganje in povezave med sredstvi skozi čas spreminjajo. Nenatančne vhodne ocene

Investment Portfolio Optimization Using Transformers and Global Optimization Algorithms

This thesis studies cardinality-constrained portfolio optimization, where the two central challenges are estimating expected returns and finding optimal weights subject to the requirement that the portfolio holds exactly K active positions. Expected returns are estimated with three architecturally distinct transformer models (MASTER, TFT and PatchTST), whose neural cores follow the authors' official implementations; our own modifications are restricted to the data interface and to converting the model output into an expected-return estimate. The covariance matrix is estimated identically from historical returns for all approaches, so the comparison isolates the effect of the forecasting signal. Portfolio weights are then optimized with particle swarm optimization and simulated annealing. The forecasting and optimization stages are first evaluated separately, the former with cross-sectional forecasting measures and the latter on the standard OR-Library instances. The complete pipeline is then tested out of sample with walk-forward evaluation on the protocols of three published studies and in an additional long-term investor scenario. In all five experiments at least one transformer clearly beats its matched historical baseline, but which model does so changes systematically with the asset universe and the protocol: PatchTST is strongest in the long-term scenario (Sharpe ratio 1.38 against 1.10 for its baseline) and on DJIA, MASTER on NASDAQ 100 (1.23 against 1.03), and TFT in the crisis period. Differences between the two optimizers are small and inconsistent, indicating that the quality of the expected-return estimate is the dominant driver of portfolio performance.

Portfolio optimization | Cardinality constraint | Transformers | Return forecasting | Metaheuristics | Particle swarm optimization

zato vodijo do neugodnega portfelja tudi takrat, ko je optimizacijski postopek izveden pravilno.

V tej nalogi klasični ONP razširimo z omejitvami, ki bolje odražajo praktične zahteve pri sestavi portfelja. Najpomembnejša je kardinalna omejitev, ki zahteva, da portfelj vsebuje natanko K aktivnih pozicij; iz delnic indeksa S&P 500 tako namesto celotnega indeksa oblikujemo portfelj iz manjše skupine izbranih delnic. Poleg kardinalnosti za vsako izbrano sredstvo omejimo še najmanjši in največji dovoljeni delež kapitala. Tako dobimo kardinalno omejeni problem optimizacije naložbenega portfelja (v nadaljevanju KONP).

KONP je zahtevnejši od osnovnega ONP, ker poleg zveznega določanja uteži vključuje tudi diskretno izbiro sredstev: optimizator mora hkrati določiti, katerih K sredstev izmed N bo vključil in kako bo mednje razporedil kapital. Že sam izbor omogoča $\binom{N}{K}$ kombinacij, zato izčrpno iskanje pri večjih problemih hitro postane nepraktično [2]. Težavo povečuje še dejstvo, da sta μ in Σ v praksi neznana in ju moramo oceniti iz podatkov.

KONP zapišemo s ciljno funkcijo v enačbi (5) ter proračunsko, kardinalno in utežno omejitvijo v enačbah (6)–(8). Ciljna funkcija združuje ocenjeni pričakovani donos portfelja $\hat{\mu}^\top \mathbf{w}$ in njegovo ocenjeno varianco $\mathbf{w}^\top \hat{\Sigma} \mathbf{w}$, parameter $P \in [0, 1]$ pa določa razmerje med njima: večja vrednost daje večjo težo pričakovanemu donosu, manjša zmanjševanju variance.

Proračunska omejitev zahteva, da je vsota vseh uteži enaka ena, zato je ves kapital razporejen med sredstva, kardinalna pa, da je aktivnih natanko K sredstev; binarna spremenljivka z_i pove, ali je sredstvo i vključeno v portfelj. Utežna omejitev poveže obe odločitvi: pri $z_i = 0$ mora biti $w_i = 0$, pri $z_i = 1$ pa mora utež ležati med spodnjo mejo ε_i , ki preprečuje zanemarljivo majhne pozicije, in zgornjo mejo δ_i , ki omejuje koncentracijo kapitala v posameznem sredstvu.

$$\max_{\mathbf{w}, \mathbf{z}} \quad P \hat{\mu}^\top \mathbf{w} - (1 - P) \mathbf{w}^\top \hat{\Sigma} \mathbf{w} \quad (5)$$

$$\text{p.p.} \quad \sum_{i=1}^N w_i = 1, \quad (6)$$

$$\sum_{i=1}^N z_i = K, \quad (7)$$

$$\varepsilon_i z_i \leq w_i \leq \delta_i z_i, \quad z_i \in \{0, 1\}, \quad i = 1, \dots, N. \quad (8)$$

Reševanja KONP se lotimo v dveh ločenih korakih. Najprej ocenimo pričakovane donose $\hat{\mu}$: namesto zgolj zgodovinskega povprečja uporabimo tri arhitekturno različne transformerske modele, PatchTST [3], Temporal Fusion Transformer (TFT) [4] in MA-STER [5], njihove napovedi pa primerjamo z zgodovinsko oceno.

Pri vseh napovednih pristopih kovariančno matriko $\hat{\Sigma}$ ocenimo na enak način iz zgodovinskih donosov, zato pri primerjavi modelov spreminjamo predvsem način ocenjevanja pričakovanih donosov, ocena tveganja pa ostane enaka.

V drugem koraku tako dobljeni KONP rešujemo z dvema stohastičnima globalnima optimizacijskima algoritmoma: rojenjem delcev (RD) in simuliranim ohlajanjem (SO). Oba iščeta kakovostne rešitve brez izčrpnega pregleda vseh kombinacij sredstev, vendar prostor rešitev raziskujeta na različna načina.

Napovedni in optimizacijski del najprej vrednotimo ločeno: napovedne modele zunaj vzorca z merami povezave med napovedanimi in realiziranimi donosi, algoritma RD in SO pa na standardnih testnih problemih z znanimi referenčnimi rezultati. Nato ovrednotimo še celoten cevovod s postopnim testiranjem zunaj vzorca (angl. *walk-forward*) na eksperimentalnih protokolih dveh objavljenih študij [6, 7], ki se razlikujeta po univerzumu sredstev, časovnem obdobju, pogostosti uravnoteževanja in napovednem obzorju, ter v dodatnem dolgoročnem scenariju vlagatelja. V vsakem odločitvenem trenutku uporabljamo samo informacije, ki bi bile takrat dejansko na voljo.

Osrednji prispevek dela je povezava sodobnih transformerskih napovednih modelov z metahevrističnim reševanjem KONP ter ločeno vrednotenje obeh delov cevovoda. Tako lahko analiziramo dve povezani vprašanji: ali kakovostnejše napovedi pričakovanih donosov vodijo do uspešnejših portfeljev in koliko je končni rezultat odvisen od kakovosti optimizacijskega postopka.

Delo je organizirano takole. Razdelek 1 umesti nalogo med sorodna dela, razdelek 2 predstavi tri transformerske napovedne modele in oceno kovariančne matrike, razdelek 3 pa oba globalna optimizacijska algoritma. V razdelku 4 opišemo programsko zasnovo cevovoda, protokol vrednotenja zunaj vzorca in uporabljene mere. Razdelek 5 predstavi rezultate obeh delov cevovoda in vseh petih portfeljskih preizkusov, razdelek 6 pa povzame ugotovitve, omejitve in smeri nadaljnjega raziskovanja.

1. Sorodna dela

Znanstvene članke, ki si delijo raziskovalno področje z našim delom, lahko razdelimo na tri skupine: optimizacijo portfeljev, napovedovanje prihodnjih donosov in ocenjevanje tveganja. Na vseh treh se je razvoj postopoma premikal od preprostejših statističnih pristopov k metodam, ki lahko obravnavajo več podatkov, več omejitev in zahtevnejše povezave med sredstvi.

1.1. Optimizacija naložbenih portfeljev. Po Markowitzevem modelu [1] se je velik del raziskav osredotočil na vprašanje, kako zanesljivi so optimizirani portfelji, kadar so njihovi vhodni podatki ocenjeni iz omejenega vzorca. Michaud [8] je opozoril, da lahko že majhne napake v ocenjenih donosih povzročijo velike spremembe v sestavi portfelja. Zato so se razvili pristopi, ki skušajo zmanjšati vpliv teh napak. Med najbolj znanimi je Black-Littermanov model [9, 10], ki pri oblikovanju ocen prihodnjih donosov upošteva dodatne informacije o trgu. Empirične primerjave so hkrati pokazale, da zahtevnejša optimizacija zunaj vzorca ni vedno uspešnejša od preprostih strategij [11–13].

Omenimo še pristope k reševanju KONP. Zgodnejše raziskave so uporabljale natančne matematične postopke [14, 15], vzporedno pa so se razvijali tudi hevristični pristopi, ki iščejo kakovostne rešitve brez preiskovanja vseh možnih kombinacij [2]. Kasnejše metode so problem poskušale poenostaviti tako, da spodbujajo manjše število aktivnih uteži [16, 17], ali pa so združile več različnih načinov iskanja in določanja uteži [18].

1.2. Napovedovanje pričakovanih donosov. Zgodnejše raziskave napovedovanja donosov so iskale predvsem ponavljajoče se zakonitosti v preteklih podatkih in ekonomskih značilnostih sredstev. Primer je moment, pri katerem imajo sredstva z relativno boljšimi preteklimi donosi v določenih obdobjih težnjo, da ostanejo uspešnejša tudi v bližnji prihodnosti [19, 20]. Takšni pristopi temeljijo predvsem na vnaprej določenih signalih. Z večjo količino razpoložljivih podatkov pa so se začele uporabljati metode strojnega učenja, ki lahko same poiščejo uporabne nelinearne povezave med večjim številom značilk [21]. Med takšne pristope sodijo tudi modeli, kot je LightGBM [22].

Naslednji korak je bil neposredno modeliranje časovnega razvoja podatkov z nevronske mreže. Selvin in sod. [23] so pri napovedovanju cen delnic primerjali več rekurentnih in konvolucijskih arhitektur. Modeli, kot je LSTM [24], so bili pri tem zanimivi predvsem zato, ker lahko pri napovedi upoštevajo informacije iz daljšega zaporedja preteklih opazovanj. Napovedni modeli so se začeli vključevati tudi neposredno v postopke sestave portfeljev. Barua in Sharma [25] sta na primer napovedi nevronskega modela uporabila kot vhod v Black-Littermanov pristop.

Novejši razvoj predstavljajo arhitekture s pozornostjo in transformerji [26]. Ti omogočajo, da model pri napovedi neposredno ovrednoti pomen različnih delov vhodnega zaporedja, zato so postali zanimivi tudi za finančne časovne vrste [27, 28]. Vzporedno so se razvili splošnejši modeli za napovedovanje časovnih vrst [29, 30]. Raziskave se hkrati vse bolj oddaljujejo od obravnave posamezne delnice kot izoliranega zaporedja. Nekateri modeli upoštevajo povezave med različnimi delnicami [31, 32], drugi pa cenovne podatke dopolnjujejo z novicami, besedili in informacijami o podjetjih [33, 34]. Leow in sod. [6] so na primer razpoloženo iz družbenih omrežij, ki ga zajamejo z modelom BERT, prek genetskega algoritma vključili v klasično sestavo portfelja; njihovo delo uporabimo kot zunanjo referenčno primerjavo v razdelku 5.3. V našem delu iz tega širšega razvoja izberemo TFT [4], MASTER [5] in PatchTST [3], ki predstavljajo tri različne načine uporabe transformerjev za napovedovanje časovnih vrst in finančnih donosov.

1.3. Ocenjevanje tveganja in kovariančne matrike. Pri sestavi portfelja moramo poleg prihodnjih donosov oceniti tudi tveganje in povezanost med sredstvi. Osnovna težava je, da pri večjem številu sredstev hitro naraste število povezav, ki jih moramo oceniti iz omejenega števila opazovanj. Raziskave so zato iskale načine, kako ocenjevanje poenostaviti ali stabilizirati. Faktorski modeli skupno gibanje velikega števila sredstev opišejo z manjšim številom skupnih dejavnikov [35]. Druga smer upošteva, da se tveganje in povezanost med sredstvi skozi čas spreminjata, zato ju modelira dinamično [36, 37].

Pomemben pristop je tudi neposredna stabilizacija kovariančne matrike, saj je vzorčna cenilka pri omejenem številu opazovanj lahko zelo nestabilna. Novejše raziskave to težavo rešujejo z metodami strojnega učenja. Nekateri pristopi se iz podatkov učijo skupnih dejavnikov tveganja [38], drugi pa poskušajo izboljšati samo oceno kovariančne matrike [39]. Še druga možnost je, da namesto posameznih kovarianc modeliramo skupno porazdelitev več časovnih vrst; tak primer je GPVar [40]. V tej nalogi se osredotočimo predvsem na vpliv napovedi pričakovanih donosov, zato pri vseh treh transformerskih modelih uporabimo isto vzorčno kovariančno matriko zgodovinskih donosov. S tem pri primerjavi napovednih modelov ohranimo nespremenjen vhod, ki opisuje tveganje.

2. Napovedovanje pričakovanih donosov

V našem delu $\hat{\mu}$ pridobimo s tremi transformerskimi modeli: PatchTST [3], Temporal Fusion Transformer (TFT) [4] in MASTER [5]. Vsem trem modelom je skupen mehanizem samopozornosti, ki je eden temeljnih gradnikov transformerskih arhitektur [26]. Vhod v transformerski model predstavimo kot zaporedje žetonov (angl. *tokens*), samopozornost pa za vsak par žetonov oceni, koliko informacije naj se prenese med njima, in tako neposredno poveže tudi časovno oddaljene elemente. Pri večglavi različici samopozornost model tak izračun izvede večkrat vzporedno, zato lahko posamezne glave zaznajo različne vrste povezav med istimi vhodnimi elementi. Obravnavani modeli se med seboj razlikujejo prav po tem, kaj pri njih predstavlja žeton in med katerimi elementi se izračunava pozornost.


2.1. PatchTST. [3] je transformerski model za napovedovanje časovnih vrst. Njegova glavna posebnost je, da časovnih vrst ne obdeluje po posameznih časovnih točkah, temveč jih najprej razdeli na krajše *časovne odseke* (angl. *patches*). Posamezen odsek nato predstavlja en žeton.

Naj bo L dolžina vhodnega zaporedja, P dolžina posameznega odseka in S korak med začetkoma dveh zaporednih odsekov. Če je $S < P$, se odseki prekrivajo. Večji L pomeni daljši zgodovinski kontekst, večji P več informacij znotraj posameznega žetona, manjši S pa večje prekrivanje med sosednjimi odseki [3]. Takšna razdelitev zmanjša število žetonov v primerjavi z obravnavo vsake časovne točke posebej in tako omogoča učinkovitejšo obdelavo daljših vhodnih zaporedij. Vsak časovni odsek se pred vstopom v kodirnik preslika v notranjo predstavitev dimenzije D . Znotraj transformerskega kodirnika večglava samopozornost išče povezave med različnimi časovnimi odseki, naprej usmerjeno omrežje pa uporablja skrito dimenzijo F . Število glav pozornosti označimo z H_{att} , da ga ločimo od napovednega obzorja H .

Druga pomembna lastnost PatchTST je *neodvisnost kanalov* (angl. *channel independence*). Vsaka vhodna časovna vrsta se obdeluje ločeno, vendar vse uporabljajo isti transformer in iste naučene parametre [3]. Pri našem problemu to pomeni, da model časovne vzorce posamezne delnice obdeluje neodvisno od drugih delnic.

V našem cevovodu PatchTST za posamezno sredstvo napove dnevne logaritemske donose za naslednjih H dni. Napovedi po zvezi (2), uvedeni v uvodu, pretvorimo v pričakovani H -dnevni enostavni donos. Ocene vseh sredstev nato zberemo v vektor $\hat{\mu}_{PatchTST}$.

Tok podatkov prikazuje Slika 1. Vhodne časovne vrste n sredstev dolžine T (I) se razdelijo na L/S prekrivajočih se odsekov (II), ki vstopijo v transformerski kodirnik. Ker PatchTST obdeluje vsako sredstvo neodvisno z istimi parametri, se isti blok TST aplicira za vsako delnico posebej (III). Izhodni vektorji h_i pozornostnih glav (IV) se linearno preslikajo v napovedi donosov in po zvezi (2) pretvorijo v oceno $\hat{\mu}_{PatchTST}$ (V–VI).



Slika 1. Tok podatkov skozi PatchTST: vhod, arhitekturni koraki in pretvorba izhoda v $\hat{\mu}_{PatchTST, i}$.

Naše prilagoditve. Jedro modela smo prevzeli neposredno iz uradnega repozitorija avtorjev [3] brez sprememb arhitekture. Prilagodili smo izključno podatkovni vmesnik in postopek učenja:

- *Samo surovi donosi.* Izvorni PatchTST je bil razvit in preizkušen na standardnih merilnih naborih za napovedovanje časovnih vrst (npr. ETT, Weather), kjer so vhodi surove merjene vrednosti. V finančnih aplikacijah bi bil skušnjava vhod obogatiti z inženirskimi značilkami, a smo se odločili za izključno dnevne logaritemske donose.
- *Normalizacija brez uhajanja.* Avtorji v izvorni implementaciji za normalizacijo pred vstopom v model predlagajo RevIN, ki vzorec normalizira na podlagi statistik istega vzorca, torej pri sklepanju niso potrebni zunanji parametri. V našem protokolu postopnega vrednotenja zunaj vzorca RevIN ni ustrezen, saj bi statistike

na testnih vzorcih vsebovale informacijo iz prihodnosti. Namesto tega parametre **StandardScaler** (povprečje in standardna deviacija) izračunamo za vsako delnico ločeno in izključno iz učnega obdobja. Manjkajoče vrednosti po normalizaciji nadomestimo z nič.


- *Maskirana izguba.* Izvorni model predpostavlja popolna vhodna zaporedja. V finančnih podatkih nekatere delnice v učnem oknu niso kotirane celotno obdobje (npr. novouvrstitve ali umaknitve). Standardna izguba MSE bi ničelne vrednosti na teh pozicijah obravnavala kot veljavne cilje in izkrivila učenje; maskirana izguba jih izpusti.
- *Dvostopenjsko učenje z OneCycle urnikom.* Izvorni PatchTST se uči na fiksni učno-validacijski delitvi. Da bi model videl čim več učnih podatkov in hkrati ohranili neodvisno izbiro hiperparametrov, v prvi stopnji z zgodnjim ustavljanjem na validacijskem IC določimo optimalno število epoh, v drugi pa na polnem učnem oknu z OneCycle urnikom učenja naučimo svež model za toliko epoh, kolikor jih je izbrala prva stopnja.

2.2. Temporal Fusion Transformer. (TFT) [4] je model za napovedovanje časovnih vrst, pri katerih imamo na voljo več različnih vrst vhodnih informacij. Avtorji razlikujejo med statičnimi značilkami, zgodovinsko opazovanimi spremenljivkami in spremenljivkami, katerih prihodnje vrednosti poznamo že ob času napovedi.

Dolžino preteklega okna v izvornem delu označujejo s k , največje napovedno obzorje pa z $\tau_{\max}$ [4]. V našem skupnem cevovodu napovedno obzorje označujemo s H . Parameter k tako določa, koliko pretekle zgodovine je modelu na voljo, H pa, kako daleč v prihodnost napovedujemo. TFT najprej z omrežji za izbiro spremenljivk določi relativni pomen posameznih vhodnih informacij. Pomembnejšim spremenljivkam lahko pripiše večjo utež, manj uporabnim pa manjšo. Časovno zaporedje nato obdela z rekurentnimi plastmi LSTM, ki zajamejo predvsem lokalne časovne vzorce. Njihove izhodne predstavitve so vhod v časovno samopozornost, ki lahko neposredno povezuje tudi bolj oddaljene časovne korake [4]. Velikost notranjih predstavitev določa parameter d_{model} . Večja vrednost omogoča bogatejše predstavitve, vendar hkrati poveča število naučljivih parametrov in računsko zahtevnost modela.

Izvorni TFT uporablja kvantilno regresijo in napoveduje več kvantilov prihodnje ciljne spremenljivke [4]. V našem cevovodu kot točkovno napoved uporabimo osrednjo napoved modela. Napovedane dnevne logaritemske donose za naslednjih H dni po zvezi (2) pretvorimo v pričakovani H -dnevni enostavni donos, ocene vseh sredstev pa zberemo v vektor $\hat{\mu}_{\text{TFT}}$.

Tok podatkov prikazuje Slika 2. Vhodni tenzor N sredstev dolžine T (I) gre skozi omrežja za izbiro spremenljivk VSN (II), ki z utežmi σ določijo relevantnost posameznih vhodnih spremenljivk. Rekurentne plasti LSTM (III) nato zajamejo lokalne časovne vzorce, njihove izhodne predstavitve pa vstopijo v časovno samopozornost, ki modelira odvisnosti na razponu celotnega okna T (IV). Kvantilni izhodi se reducirajo na medianski $\hat{\mu}$ in po zvezi (2) pretvorijo v $\hat{\mu}_{\text{TFT}}$ (V–VI).



Slika 2. Tok podatkov skozi TFT: vhod, arhitekturni koraki in pretvorba izhoda v $\hat{\mu}_{\text{TFT},i}$.

Naše prilagoditve. TFT implementiramo neposredno prek knjižnice **pytorch-forecasting** [4] brez sprememb arhitekture. Prilagodili smo le vhodni vmesnik in postopek učenja:

- *Tri numerične značilke namesto bogatih kovariatov.* Izvorni TFT je bil razvit za domene z bogatimi vnaprej znanimi kovarijanti (npr. promocije v maloprodaji, praznike pri napovedovanju porabe energije). V finančnih podatkih prihodnja vrednost nobene relevantne spremenljivke ni znana vnaprej, zato vse vhodne spremenljivke spadajo med zgodovinsko opazovane. Izberemo tri: dnevni logaritemski donos,

20-dnevni moment in 20-dnevno volatilitnost; vsaka delnica dobi statični kategorični vložek, ki ga TFT naučljivo pripiše posamezni delnici in s tem kodira idiosinkratični profil vsake delnice.

- *Normalizacija po delnicah.* Izvorni model normalizacijo ciljne spremenljivke prepušča uporabniku. Ker imajo delnice med seboj zelo različne ravni in volatilitnosti donosov, bi skupna normalizacija sistematično favorizirala visoko-volatilna sredstva. `GroupNormalizer` parametre izračuna ločeno za vsako delnico in izključno iz učnih podatkov, kar preprečuje uhajanje informacij iz testnega obdobja.
- *Pretvorba kvantilnega izhoda.* Izvorni TFT je zasnovan za kvantilno napovedovanje in ne vrača neposredno točkovne ocene. V našem optimizacijskem cevovodu potrebujemo en sam vektor $\hat{\mu}$, zato kot točkovno napoved vzamemo mediano (kvantilov 0,5); mediana je bolj robustna od povprečja pri asimetričnih porazdelitvah finančnih donosov z debelimi repi.
- *Dvostopenjsko učenje.* Knjižnica `pytorch-forecasting` privzeto opravi eno samo učno fazo; model ob koncu ne vidi podatkov iz validacijskega obdobja. Ker Walk-forward ocenjevanje potrebuje model, učen na čim daljšem oknu, dodamo drugo fazo: svež model naučimo na polnem učnem oknu za toliko epoh, kolikor jih je z zgodnjim ustavljanjem na validacijskem IC izbrala prva faza.

2.3. MASTER. [5] je transformerski model, posebej zasnovan za napovedovanje prihodnjih donosov delnic. Za razliko od PatchTST in TFT obdeluje celoten nabor sredstev hkrati in tako neposredno modelira odvisnosti med delnicami. Model združuje delniško specifične značilke, skupni tržni vektor in presečne (medsredstvene) povezave.

Za posamezno sredstvo u ob časovnem koraku t model prejme vektor $\mathbf{x}_{u,t}$ z 158 tehničnimi značilkami nabora Alpha158, izpeljanimi iz podatkov OHLCV. Med preprostejšimi sta $KMID = (p_{u,t} - p_{u,t}^O)/p_{u,t}^O$ (relativna sprememba med odprtjem in zaprtjem) in $KLEN = (p_{u,t}^H - p_{u,t}^L)/p_{u,t}^O$ (relativni dnevni razpon); tu $p_{u,t}$ označuje zaključno ceno (kot v uvodu), $p_{u,t}^O$ odprtno, $p_{u,t}^H$ najvišjo in $p_{u,t}^L$ najnižjo. Nabor vključuje tudi kazalnike na več časovnih oknih (trend, volatilitnost, obseg). Poleg tega model prejme skupni tržni vektor $\mathbf{m}_t$, v izvornem delu izračunan iz indeksov CSI300, CSI500 in CSI800; v naši izvedbi smo ga nadomestili z ameriški indeksnimi skladi (SPY, IWM, VTI), Alpha158 pa izračunali iz podatkov OHLCV za ameriški trg.


Ključna posebnost je *tržno vodenno uteževanje značilk* (angl. *market-guided gating*): $\mathbf{m}_t$ določa, katere delniško specifične značilke so trenutno pomembnejše, in temu ustrezno prilagodi $\mathbf{x}_{u,t}$ [5]. Utežene značilke nato vstopijo v dve stopnji pozornosti: *združevanje znotraj delnice* (N_1 glav) poveže časovne korake iste delnice, *združevanje med delnicami* (N_2 glav) pa v vsakem časovnem koraku primerja vse delnice med seboj. Ker je izhod MASTER zasnovan kot presečni razvrščevalni signal in ne neposredna ocena donosa, ga pred vstopom v optimizator z-standardiziramo po preseku in tako dobimo $\hat{\mu}_{\text{MASTER}}$.

Naše prilagoditve. Nevronske jedro modela smo prevzeli neposredno iz uradnega repozitorija avtorjev [5] brez sprememb arhitekture. Prilagodili smo izključno podatkovni vmesnik:

- *Alpha158 brez Qlib.* Izvorni MASTER predpostavlja platformo Qlib, kitajski kvantitativni okvir, ki Alpha158 izračuna iz lokalnih podatkovnih virov kitajskega trga. Ker smo ciljali na ameriški trg in se želeli izogniti odvisnosti od Qlib, smo vseh 158 značilk reimplementirali neposredno v pandasu iz podatkov OHLCV, prenesenih prek knjižnice `yfinance`.
- *Ameriški tržni indeksi.* Tržni vektor $\mathbf{m}_t$ v izvornem modelu temelji na indeksih CSI300, CSI500 in CSI800, ki pokrivajo kitajski delniški trg. Nadomestili smo jih z ameriški indeksnimi skladi SPY, IWM in VTI kot funkcionalnimi ekvivalenti (trg velike tržne kapitalizacije, malih delnic in celotnega trga). Struktura ostaja enaka: za vsak indeks 21 značilk (dnevni donos ter drseče povprečje in standardni odklon donosov in obsega na oknih 5, 10, 20, 30 in 60 dni), skupaj 63 tržnih značilk.
- *Normalizacija brez uhajanja.* Izvorni MASTER je zasnovan za paketno (offline) obdelavo, kjer so normalizacijski parametri izračunani iz celotnega nabora podatkov vnaprej. V postopnem vrednotenju zunaj vzorca bi takšen pristop pomenil uhajanje informacij iz prihodnosti v normalizacijo. Parametri `RobustZScoreNorm` (mediana in MAD) se zato izračunajo izključno iz učnega obdobja vsakega okna in se med testiranjem ne posodablajo.
- *Dvostopenjsko učenje.* Izvorni model se uči na fiksni učno-validacijski delitvi, pri čemer validacijski podatki po izbiri modela ostanejo neuporabljivi. Da bi model videl celotno učno okno, v prvi stopnji z zgodnjim ustavljanjem na validacijskem

IC določimo optimalno število epoh, v drugi pa svež model naučimo na polnem učnem oknu za toliko epoh, kolikor jih je izbrala prva stopnja.

Tok podatkov povzema Slika 3. Vhodni tenzor dimenzij $N \times T \times F$ z značilkami Alpha158 (I) se uteži glede na tržni vektor $\mathbf{m}_t$ z mehanizmom tržno vodenega uteževanja (II). Samopozornost nato neodvisno za vsako od N delnic poveže različne časovne korake – to je združevanje znotraj delnice (III). Sledi presečna pozornost, ki v posameznem časovnem koraku primerja predstavitev vseh delnic med seboj – združevanje med delnicami (IV). Napovedni signal se skalira na donosno lestvico (V) in zbere v $\hat{\mu}_{\text{MASTER}}$ (VI).



Slika 3. Tok podatkov skozi MASTER: vhod, arhitekturni koraki in pretvorba izhoda v $\hat{\mu}_{\text{MASTER},i}$.

2.4. Ocena kovariančne matrice. Pri primerjavi napovednih modelov želimo spreminjati predvsem vir ocene $\hat{\mu}$, zato kovariančno matrico pri vseh pristopih ocenimo na enak način.

Naj bo v trenutnem ocenjevalnem oknu na voljo T_w vektorjev donosov $\mathbf{r}_t$. Vzorčno povprečje donosov in vzorčno kovariančno matrico definiramo z enačbo (9):

$$\bar{\mathbf{r}} = \frac{1}{T_w} \sum_{t=1}^{T_w} \mathbf{r}_t, \quad \hat{\Sigma} = \frac{1}{T_w - 1} \sum_{t=1}^{T_w} (\mathbf{r}_t - \bar{\mathbf{r}})(\mathbf{r}_t - \bar{\mathbf{r}})^\top. \quad (9)$$

Če je zaradi numerične natančnosti potrebno, matriki $\hat{\Sigma}$ dodamo majhen diagonalni popravek. Ker je kovariančna matrica pri zgodovinskem pristopu, TFT, MASTER in PatchTST ocenjena na enak način po enačbi (9), lahko razlike v končnih portfeljih lažje povežemo z razlikami v ocenah pričakovanih donosov.

Dolžino ocenjevalnega okna T_w izberemo enako najdaljšemu pogojnemu oknu med modeli v posameznem eksperimentu. S tem sta oba vhoda optimizatorja, $\hat{\mu}$ in $\hat{\Sigma}$, ocenjena na primerljivi nedavni zgodovini: noben model ni v primerjavi s kovarianco, ocenjeno iz bistveno daljšega obdobja, ki ga sam nikoli ne vidi.

3. Globalni optimizacijski algoritmi

Ker algoritmi KONP rešujejo z minimizacijo, ciljno funkcijo iz enačbe (5) zapišemo v ekvivalentni obliki (10); manjša vrednost $g(\mathbf{w})$ pomeni boljšo rešitev.

$$g(\mathbf{w}) = (1 - P)\mathbf{w}^\top \hat{\Sigma} \mathbf{w} - P\hat{\mu}^\top \mathbf{w}. \quad (10)$$

Kandidatna rešitev predstavlja portfelj, torej izbor sredstev in njihove uteži, in mora zadovoljiti vse omejitve iz enačb (6)–(8). Ker naključni premiki teh omejitev ne ohranijo samodejno, rešitve po potrebi popravimo in ciljno funkcijo vrednotimo le na dopustnih portfeljih. Projekcija uteži na dopustno množico pomeni normalizacijo vsote na 1 in obrez na meje $[w_{\min}, w_{\max}]$.

3.1. Rojenje delcev (RD). [41] je populacijski optimizacijski algoritem. Prilagoditev za KONP po Curi [42] vsak delec m opiše z dvojico $(\mathbf{x}_m, \mathbf{z}_m)$: zvezni vektor uteži $x_{m,i} \in [w_{\min}, w_{\max}]$ in binarni vektor $z_{m,i} \in \{0, 1\}$, ki označuje, ali je sredstvo i vključeno v portfelj. Vsak delec hrani hitrosti $\mathbf{v}_m^x, \mathbf{v}_m^z$, svojo osebno najboljšo doslej obiskano rešitev $(\mathbf{x}_m^*, \mathbf{z}_m^*)$ ter skupna najboljša rešitev celotnega roja $(\mathbf{x}^G, \mathbf{z}^G)$.

V vsaki iteraciji za vsak delec m in vsako sredstvo i vzorčimo $\omega_1, \omega_2 \sim U[0, 2]$ neodvisno. Binarno hitrost in položaj posodobimo po Curi (enačbi 14 in 16):

$$\begin{aligned} v_{m,i}^z &\leftarrow v_{m,i}^z + \omega_1(z_i^G - z_{m,i}) + \omega_2(z_{m,i}^* - z_{m,i}), \\ z_{m,i} &\leftarrow \text{clip}(\text{round}(S(z_{m,i} + v_{m,i}^z) - \alpha), 0, 1), \quad S(a) = \frac{1}{1+e^{-a}}, \end{aligned} \quad (11)$$

kjer je $\alpha = 0,06$ odmik, ki preprečuje neželene aktivacije pri ničelni hitrosti [42]. Zvezno hitrost in utež posodobimo le, če je sredstvo po binarni posodobitvi izbrano (enačbi 15 in 17):

$$\text{če } z_{m,i} = 1: \quad v_{m,i}^x \leftarrow v_{m,i}^x + \omega_1(x_i^G - x_{m,i}) + \omega_2(x_{m,i}^* - x_{m,i}), \quad x_{m,i} \leftarrow x_{m,i} + v_{m,i}^x. \quad (12)$$

Kadar $z_{m,i} = 0$, utež postavimo na nič ($x_{m,i} \leftarrow 0$), hitrost $v_{m,i}^x$ pa ohranimo; ker neaktivna sredstva k ciljni funkciji ne prispevajo, je to enakovredno Curini formulaciji. Hitrosti se med iteracijami prenašajo brez inercialnega koeficienta [42].

Ker binarna posodobitev ne zagotavlja natanko K aktivnih sredstev, po vsakem premiku popravimo kardinalnost. Cura [42] za to uvede mero c_i , ki tehtá ocenjeni donos sredstva proti njegovi povprečni kovarianci. Ker Cura uporablja parameter averzije do tveganja $\lambda = 1 - P$, zapišemo:


$$\theta_i = 1 + (1 - \lambda)\hat{\mu}_i, \quad \rho_i = 1 + \lambda \frac{1}{N} \sum_{j=1}^N \hat{\Sigma}_{ij}, \quad c_i = \frac{\theta_i + \Omega}{\rho_i + \Psi}, \quad (13)$$

kjer sta $\Omega = -\min(0, \min_j \theta_j)$ in $\Psi = -\min(0, \min_j \rho_j)$ korekcijska odnaka, ki zagotovita nenegativnost števca in imenovalca.

Če je po posodobitvi aktivnih manj kot K sredstev, dodajamo z enako verjetnostjo naključno neaktivno ali tisto z največjim c_i ; če jih je več kot K , analogno odstranjujemo [42]. Ko je kardinalnost urejena, uteži projiciramo na dopustno množico.

Slika 4 prikazuje, kako roj skupaj konvergira k optimumu.

Slika 4 ponazarja štiri značilne trenutke algoritma RD. V **iteraciji 1** je pet delcev (I–V) naključno razpršenih po prostoru portfeljev; vsak delec si kot osebni optimum p_i (vijolični rombič) zapomni svojo začetno pozicijo. V **iteraciji 2** se vsi delci premaknejo v smeri skupne hitrosti v_m (oranžne puščice); delec II, ki je začel v zgornjem levem kotu in tam našel dobro rešitev, nosi p_i blizu svojega izhodišča. V **iteraciji 3** vidimo hitrostno dekompozicijo za delec II: vijolična puščica $v_p = \omega_1 r_1(p_i - \mathbf{w}_m)$ ga vleče nazaj proti osebemu optimumu, rdeča puščica $v_g = \omega_2 r_2(g - \mathbf{w}_m)$ pa ga privlači k najboljši rešitvi celotnega roja g ; skupna hitrost $v_m = v_p + v_g$ (oranžna) kaže navzgor proti območju optimuma. V **konvergenci** se roj zbere v bližini $\mathbf{w}^*$.



Slika 4. Konvergenca roja delcev v poenostavljenem 2D prostoru portfeljev. Izolinije prikazujejo ciljno funkcijo $f(\mathbf{w}) = -\text{Sharpe}(\mathbf{w})$; rdeča zvezda je globalni minimum $\mathbf{w}^*$.

Algoritem 1. Rojenje delcev za KONP [42]

```

1: Vhod: ocene donosov  $\hat{\mu}$ , kovariančna matrika  $\hat{\Sigma}$ , averzija do tveganja  $\lambda$ , kardinalnost  $K$ , velikost roja  $M$ , število iteracij  $T$ 
2: Izhod: uteži  $best\_weights$  in izbor  $best\_selection$ 
3:  $selection\_score \leftarrow c_i$  za vsa sredstva
4:  $swarm \leftarrow M$  naključnih dopustnih delcev
5: for all  $particle \in swarm$  do
6:    $particle.best\_weights \leftarrow particle.weights$ 
7:    $particle.best\_selection \leftarrow particle.selection$ 
8:    $particle.best\_value \leftarrow particle.value$ 
9:  $leader \leftarrow$  delec z najmanjšo  $best\_value$ 
10: for  $t = 1, \dots, T$  do
11:   for all  $particle \in swarm$  do
12:      $\omega_1, \omega_2 \leftarrow rand(0, 2)$  za vsako sredstvo
13:     posodobi  $particle.selection\_velocity$  in  $particle.selection$  po (11),
       pri čemer vlečeta  $\omega_1$  proti  $leader$  in  $\omega_2$  proti  $particle.best\_selection$ 
14:     posodobi  $particle.weight\_velocity$  in  $particle.weights$  po (12)
15:     popravi kardinalnost s  $selection\_score$ 
16:     projiciraj  $particle.weights$  na dopustno množico
17:      $particle.value \leftarrow f(particle)$ 
18:     if  $particle.value < particle.best\_value$  then
19:        $particle.best\_value \leftarrow particle.value$ 
20:        $particle.best\_weights \leftarrow particle.weights$ 
21:        $particle.best\_selection \leftarrow particle.selection$ 
22:     if  $particle.best\_value < leader.best\_value$  then
23:        $leader \leftarrow particle$ 
24: return  $leader.best\_weights, leader.best\_selection$ 

```

Naše prilagoditve. Izvorni PSO [41] je zasnovan za zvezne, neomejene probleme: vsak delec je enojni realnoštevski vektor, premiki pa so vodeni z inercijo in privlačnostjo k osebni in skupni najboljši rešitvi. KONP uvede zahteve, ki jih izvorni PSO ne podpira: kardinalno omejitev (natanko K aktivnih sredstev) ter proračunsko in utežno dopustnost. Po Curi [42] uvedemo naslednje prilagoditve:

- *Dvojna predstavitev.* Namesto enega zveznega vektorja vsak delec hrani par $(\mathbf{x}_m, \mathbf{z}_m)$: zvezni utežni vektor in binarni selekcijski vektor. Izvorni PSO binarnega dela nima, zato je ta razširitev nujna za izražanje diskretne odločitve o vključitvi sredstva.
- *Ločene posodobitve.* Binarni del se posodablja prek sigmoidne funkcije z odmikom $\alpha = 0,06$, ki preprečuje neželene aktivacije pri ničelni hitrosti; zvezni del se posodablja samo za aktivna sredstva ($z_{m,i} = 1$). Standardni PSO pozna le eno enačbo za posodobitev hitrosti in položaja.

- *Popravek kardinalnosti.* Binarni premiki ne zagotavljajo natanko K aktivnih sredstev, zato po vsakem premiku selekcijo popravimo z mero c_i (13), ki tehta pričakovani donos napram povprečni kovarianci. Ker se $\hat{\mu}$ in $\hat{\Sigma}$ med enim klicem optimizatorja ne spremenita, c_i izračunamo enkrat pred začetkom iteracij.
- *Brez inercialnega koeficienta.* Standardni PSO dampira hitrosti z inercijo $\omega \in [0, 1]$; Cura [42] za KONP pokaže, da je izpustitev inercije učinkovitejša, in naša izvedba sledi tej odločitvi.

3.2. Simulirano ohlajanje (SO). [43] (angl. *simulated annealing*) najprej dopušča prehode v manj ugodna stanja, s čimer se izogne ujetosti v lokalnih optimumih, nato pa postopoma prehaja na vse strožje sprejemanje. Za razliko od RD ne vzdržuje populacije kandidatov, temveč eno trenutno rešitev $\mathbf{w}$, katere sosesčino zaporedno preiskuje. Ključna lastnost je temperatura T : pri višji temperaturi algoritem pogosteje sprejme slabšo rešitev in bolj raziskuje prostor rešitev, z nižanjem temperature pa postaja vse bolj selektiven. Temperaturni urnik (angl. *cooling schedule*) tvori začetna temperatura T_0 in geometrijsko nižanje s faktorjem α_{SO} [44].

Algoritem začnemo z naključno izbranimi K sredstvi, vsako dobi utež $1/K$, nato uteži projiciramo na dopustno množico. Začetni portfelj $\mathbf{w}$ tako že zadovoljuje kardinalno, proračunsko in utežne omejitve.

Sosednostna funkcija (angl. *neighborhood function*) iz trenutne rešitve ustvari natanko eno sosednjo, in sicer na enega od dveh načinov. Z verjetnostjo 0,10 – vrednost izhaja iz naše implementacije in ne iz referenčnih člankov – izvedemo *zamenjavo sredstva*: celotno utež naključno izbranega aktivnega sredstva prenesemo na naključno izbrano neaktivno. Sestava portfelja se spremeni, število aktivnih sredstev in vsota uteži pa ostaneta enaka.

V preostalih primerih spreminjamo uteži znotraj trenutnega nabora aktivnih sredstev. Če so aktivna vsaj tri sredstva, naključno izberemo tri in ustvarimo smer spremembe (d_1, d_2, d_3) z $d_1 + d_2 + d_3 = 0$, ki pred projekcijo ohranja vsoto uteži. Smer normaliziramo, velikost premika pa izberemo enakomerno na $[0, q']$, kjer zgornjo mejo q' narekujejo polmer iskanja q in dopustne meje posameznih uteži. Crama in Schyns [44] omejujeta sosedo na lupino krogle s fiksnim polmerom, pri nas pa ležijo v njeni notranjosti. Če aktivnih sredstev ni vsaj troje, uporabimo dvodelni premik: utež enega sredstva povečamo za naključen korak iz $U(-q, q)$, utež drugega pa zmanjšamo za enako vrednost.

Po vsakem premiku uteži projiciramo na dopustno množico. Pričakovanega donosa pri tem ne ohranjamo na vnaprej določeni ravni: pri Crami in Schynsu je enačbena omejitev, pri nas pa del ciljne funkcije (10).

Kakovost tako ustvarjene sosednje rešitve $\mathbf{w}'$ primerjamo s trenutno prek spremembe ciljne funkcije $\Delta = g(\mathbf{w}') - g(\mathbf{w})$. Verjetnostna funkcija oz. Metropolisovo pravilo [43] določa verjetnost, s katero sprejmemo sosednjo rešitev. Ker funkcijo g minimiziramo, kandidata pri $\Delta \leq 0$ vedno sprejmemo. Če je $\Delta > 0$, ga sprejmemo z verjetnostjo

$$\Pr(\text{sprejem}) = \exp\left(-\frac{\Delta}{T}\right), \quad (14)$$

kjer je T trenutna temperatura. Pri višji temperaturi je verjetnost sprejema poslabšanja večja, z ohlajanjem pa se zmanjšuje. V implementaciji odločitev izvedemo s slučajno spremenljivko $U \sim U(0, 1)$: slabšo rešitev sprejmemo, če velja $U < \exp(-\Delta/T)$.


Začetne temperature T_0 ne določimo neposredno. Najprej izvedemo začasno verigo L sosednjih premikov z večjim polmerom q_1 . V tej kalibracijski verigi vse ustvarjene premike sprejmemo in zabeležimo pozitivne vrednosti Δ . Njihovo povprečje označimo z $\bar{\Delta}^+$. Če je v_0 zelena začetna verjetnost sprejema značilnega poslabšanja, začetno temperaturo in nadaljnje ohlajanje določimo z

$$T_0 = \frac{\bar{\Delta}^+}{-\ln v_0}, \quad T_{\ell+1} = \alpha_{SO} T_\ell, \quad 0 < \alpha_{SO} < 1. \quad (15)$$

Če med kalibracijo ne zaznamo pozitivnega poslabšanja, za izračun temperature uporabimo privzeto vrednost $\bar{\Delta}^+ = 0,01$.

Pri vsaki temperaturni stopnji izvedemo L kandidatnih premikov, iskanje pa začne z večjim polmerom q_1 . Če je število v stopnji sprejetih kandidatov manjše od nastavljenega praga $A_{\min}$, polmer zmanjšamo na q_2 ; prehod je enosmeren, saj se algoritem na q_1 ne vrne. Poleg trenutne rešitve $\mathbf{w}$ ves čas hranimo najboljšo doslej obiskano rešitev $\mathbf{w}^*$, zato začasno poslabšanje trenutne rešitve ne izgubi že najdenega najboljšega portfelja. Iskanje končamo (angl. *stopping criterion*), ko S zaporednih temperaturnih stopenj ne sprejme nobenega kandidata ali ko dosežemo $G_{\max}$ stopenj. Slika 5 prikazuje, kako temperatura in polmer skupaj usmerjata iskanje po prostoru portfeljev.

V prvem panelu (visok T) algoritem z velikim polmerom q_1 naredi korak navzdol po pokrajini, ki ga Metropolisovo pravilo sprejme, saj se ciljna funkcija izboljša. V



Slika 5. Simulirano ohlajanje na poenostavljeni 1D pokrajini portfeljev ($x = \text{portfelj } \mathbf{w}$, $y = -\text{Sharpe}(\mathbf{w})$). Zelena polna puščica pomeni sprejet korak, rdeča prekinjena zavrženega; osenčeno področje je soseščina polmera q okoli trenutnega portfelja.

drugem panelu (srednji T) poskuša enako velik korak navzgor; ker je temperatura nižja, je Metropolisova verjetnost sprejema majhna in algoritem korak zavrne. V tretjem panelu (nizek T) je temperatura padla in polmer se je skrčil na $q_2 < q_1$; manjši koraki vodijo do finega iskanja ob globalnem optimumu $\mathbf{w}^*$.

Algoritem 2. Simulirano ohlajanje za KONP

```

1: Vhod: ocene donosov  $\hat{\mu}$ , kovariančna matrika  $\hat{\Sigma}$ , averzija do tveganja  $\lambda$ , kardinalnost  $K$ , dolžina stopnje  $L$ , začetna verjetnost sprejema  $v_0$ , faktor ohlajanja  $\alpha_{SO}$ , polmera  $q_1$  in  $q_2$ , prag sprejemov  $A_{\min}$ , prag mirovanja  $S$ , največ stopenj  $G_{\max}$ 
2: Izhod: uteži  $best\_weights$ 
3:  $weights, selected \leftarrow$  naključen dopusten portfelj
4:  $T \leftarrow$  kalibracija z  $L$  poskusnimi premiki pri  $v_0$ 
5:  $current\_value \leftarrow g(weights)$ 
6:  $best\_weights \leftarrow weights$ 
7:  $best\_value \leftarrow current\_value$ 
8:  $q \leftarrow q_1$ ,  $idle\_stages \leftarrow 0$ 
9: for  $\ell = 1, \dots, G_{\max}$  do
10:    $accepted \leftarrow 0$ 
11:   for  $j = 1, \dots, L$  do
12:      $candidate \leftarrow$  sosed rešitve  $weights$  pri polmeru  $q$ 
13:      $\Delta \leftarrow g(candidate) - current\_value$ 
14:      $r \leftarrow rand(0, 1)$ 
15:     if  $\Delta \leq 0$  ali  $e^{-\Delta/T} > r$  then
16:        $weights \leftarrow candidate$ 
17:        $current\_value \leftarrow current\_value + \Delta$ 
18:        $accepted \leftarrow accepted + 1$ 
19:       if  $current\_value < best\_value$  then
20:          $best\_value \leftarrow current\_value$ 
21:          $best\_weights \leftarrow weights$ 
22:   if  $accepted < A_{\min}$  then
23:      $q \leftarrow q_2$ 
24:    $T \leftarrow \alpha_{SO} \times T$ 
25:   if  $accepted = 0$  then
26:      $idle\_stages \leftarrow idle\_stages + 1$ 
27:   else
28:      $idle\_stages \leftarrow 0$ 
29:   if  $idle\_stages \geq S$  then
30:     break
31: return  $best\_weights$ 

```

Naše prilagoditve. Izvorni SA [43] določa le Metropolisovo pravilo sprejema in geometrijsko ohlajanje; funkcija sosednosti je prepuščena domeni in jo je treba zasnovati za vsak problem posebej. Poleg tega izvorni opis ne predpisuje, kako nastaviti začetno


temperaturo T_0 niti kdaj iskanje zaključiti. Po Crami in Schynsu [44] uvedemo naslednje prilagoditve:

- *Dvovrstna sosednost za KONP.* Soseščina vsebuje dve vrsti premikov: zamenjavo sredstev (z verjetnostjo 0,10; binarni selekcijski del se spremeni pri nespremenjeni vsoti uteži) in perturbacijo uteži znotraj trenutnega nabora aktivnih sredstev. Izvorni SA in Crama–Schyns ne predpišeta konkretnega razmerja med vrstama premikov; delež zamenjav je naša implementacijska odločitev.
- *Samodejna kalibracija T_0 .* Namesto ročnega nastavljanja začetno temperaturo izpeljemo iz želenega začetnega sprejema v_0 : krajša kalibracijska veriga izmeri tipično poslabšanje $\bar{\Delta}^+$, iz katerega sledi $T_0 = \bar{\Delta}^+ / (-\ln v_0)$. S tem se algoritem samodejno prilagodi obsegu ciljne funkcije.
- *Dvopolmerska shema.* Crama in Schyns [44] uporabljata en sam polmer. Mi dodamo prehod $q_1 \rightarrow q_2$, ki se sproži, ko je v stopnji sprejetih premikov manj kot $A_{\min}$; ta enosmerni prehod algoritmu omogoči fino iskanje v bližini optimuma po začetnem globalnem preiskovanju.
- *Ustavitveni pogoj po mirovanju.* Ko S zaporednih temperaturnih stopenj ne sprejme nobenega kandidata, iskanje zaključimo. Izvorni SA in Crama–Schyns tega ne predpisujeta; po naši izkušnji pogoj znatno skrajša čas na platojih brez izgube kakovosti, saj *best_weights* ves čas ohranja najboljšo doslej doseženo rešitev.

4. Implementacija in vrednotenje

V prejšnjih razdelkih smo ločeno predstavili napovedovanje pričakovanih donosov, ocenjevanje tveganja in reševanje KONP. V nadaljevanju te komponente povežemo v skupen eksperimentalni cevovod ter opišemo njegovo programsko izvedbo in postopek vrednotenja.

4.1. Programska zasnova cevovoda. Pripravo podatkov, učenje modelov, vodenje poskusov in vrednotenje rezultatov izvajamo v jeziku Python; transformerske modele v okolju PyTorch. Optimizacijski del je implementiran v C++17, oba dela pa komunicirata prek datotek JSON. Celoten tok je prikazan na Sliki 6.



Slika 6. Cevovod od tržnih podatkov do zunajvzorčnega vrednotenja portfelja. Rimske številke označujejo korake iz besedila.

4.2. Napovedni del cevovoda. V koraku I (Slika 6) iz tržnih podatkov, razpoložljivih do odločitvenega trenutka t , pripravimo donose in vhodne značilke. V koraku II napovedni model oceni $\hat{\mu}_t$; kot referenčni pristop brez nevronskega modela služi zgodovinsko povprečje. V koraku III vzorčno ocenimo $\hat{\Sigma}_t$ iz istih donosov; ker se $\hat{\Sigma}$ pri vseh pristopih ocenjuje enako, primerjava izolira vpliv $\hat{\mu}$. Učne in validacijske podatke vedno ločimo kronološko; spodaj so navedene le implementacijske odločitve, specifične za posamezni model.

Prilagoditve PatchTST so opisane v razdelku 2.1, TFT v razdelku 2.2 in MASTER v razdelku 2.3.

4.3. Optimizacijski del cevovoda. Prilagoditve RD so opisane v razdelku 3.1, SO v razdelku 3.2. Edina implementacijska posebnost, ki ni razvidna iz algoritmičnega opisa, je optimizacija izračuna variance: upoštevamo le aktivna sredstva, kar vrednosti ciljne funkcije ne spremeni, zahtevnost kvadratnega dela pa zmanjša z $O(N^2)$ na $O(K^2)$. Rezultat optimizacijskega dela je vektor $\mathbf{w}_t$, ki določa portfelj do naslednjega odločitvenega trenutka.

4.4. Postopno vrednotenje zunaj vzorca. V koraku V (Slika 6) portfelj $\mathbf{w}_t$ držimo od $t+1$ do $t+H$ in realizirani donos izračunamo iz dejanskih prihodnjih cen; korak VI skozi celotno testno obdobje zbere zunajvzorčne rezultate za mere iz razdelka 4.6. Ta postopek — postopno testiranje (angl. *walk-forward*) — zagotavlja, da v odločitvenem trenutku t učni postopek, ocenjevanje $(\hat{\mu}_t, \hat{\Sigma}_t)$ in optimizacija $\mathbf{w}_t$ uporabljajo samo informacije iz množice $\mathcal{D}_t$.

Za vsako kombinacijo napovednega vira, optimizatorja in parametra P določimo portfelj, ki ga držimo do naslednjega odločitvenega trenutka. Njegov donos nato izračunamo iz dejansko realiziranih kasnejših cen. Če eksperimentalni protokol zahteva ponovno učenje, model v predpisanih trenutkih naučimo znova samo na takrat razpoložljivih podatkih.

Takšen postopek preprečuje uhajanje prihodnjih informacij in omogoča primerjavo metod v razmerah, ki približujejo dejansko zaporedno sprejemanje naložbenih odločitev.

Napovedni in optimizacijski del poleg tega ovrednotimo tudi neodvisno. Kakovost samih napovedi preverimo na presečnem napovednem protokolu, optimizatorja pa na standardnih testnih primerih OR-Library [45], kjer dobljene rešitve primerjamo z referenčnimi rezultati po postopku Changa in sod. [2]. Rezultati obeh preverjanj so podani pred vrednotenjem celotnega cevovoda.

4.5. Nastavitve in ponovljivost. Vse nastavitve, uporabljene pri eksperimentih, so zbrane v Tabelah 1 in 2. V osnovnih konfiguracijah uporabljamo naključno seme 42 pri TFT in MASTER ter 2021 pri PatchTST; protokolno specifične izjeme in morebitna ponavljanja z več semeni so navedeni neposredno ob posameznem eksperimentu.

Tabela 1. Ključne nastavitve napovednih modelov in optimizacijskih algoritmov.

Sklop	Uporabljene nastavitve
RD	velikost roja 200; največ 1500 generacij; $\alpha_{RD} = 0,06$.
SO	$L = 2N$; $\alpha_{SO} = 0,95$; $v_0 = 0,8$; $q_1 = 0,005$; $q_2 = 0,001$; $S = 5$.
TFT	$k = 252$ v večini poskusov in $k = 45$ pri Leow All-Weather; skrita dimenzija 160; 1 glava pozornosti; osip 0,3; velikost učnega paketa 64; hitrost učenja 10^{-3} ; največ 100 epoh; potrpežljivost 10; omejitev norme gradienta 0,01.
MASTER	$D = 256$; $N_1 = 4$; $N_2 = 2$; $\beta = 5$; časovni in presečni osip 0,5; hitrost učenja 10^{-5} ; največ 100 epoh; potrpežljivost 10.
PatchTST	vhodno okno 336; dolžina časovnega odseka 16; korak 8; $D = 128$; $F = 256$; 3 kodirne plasti; 16 glav pozornosti; osip 0,2; velikost učnega paketa 32; hitrost učenja 10^{-4} ; največ 100 epoh; potrpežljivost 10; vključena RevIN in rezidualna pozornost.

Tabela 2. Osnovne nastavitve posameznih eksperimentalnih problemov.

Poskus	N	K	Uteži	Učenje	Test	Uravnoteževanje	H	Ponovno učenje	Optimizator	Stroški	P
Leow All-Weather	5	5	0,01–0,40	2018–2019	2020	tedensko	5	ob vsaki odločitvi	RD in SO	bruto	0,05–0,95 (11 točk)
Wang S&P 500	494	20	0,001–1,0	2018–2020	2021	mesečno	120	enkrat	RD	bruto	0,2
Dolgoročni vlagatelj	61	20	0,01–0,1	2005–2010	2011–2024	mesečno	21	letno	RD	10 b. t.	0,5

Napovedno obzorje H ni lastnost ene same arhitekture, temveč ga določa eksperimentalni protokol. Enako velja za univerzum sredstev, kardinalnost, omejitve uteži, pogostost uravnoteževanja, ponovno učenje in parameter P .

4.6. Mere vrednotenja. Ker želimo med različnimi eksperimenti ohraniti čim bolj enotno in hkrati pregledno vrednotenje, pri vseh portfeljskih benchmarkih uporabljamo iste tri skupne metrike: letni donos, letno volatilitnost in letni Sharpov količnik. Te metrike so v tabelah vedno navedene najprej in v istem vrstnem redu. Pri zunanjih primerjavah jim po potrebi dodamo le tiste protokolno specifične metrike, ki so potrebne za neposredno primerjavo z referenčnim člankom. Napovedni in optimizacijski del cevovoda vrednotimo ločeno z manjšim naborom mer, primernim za posamezni problem.

Napovedna kakovost. Naj bo $\mathcal{I}_t$ množica sredstev, za katera v času t primerjamo napovedani donos $\hat{\mu}_{i,t}$ z realiziranim donosom $r_{i,t}^{(H)}$ na napovednem obzorju H . Napovedno kakovost merimo z informacijskim koeficientom (IC) in rangovnim informacijskim koeficientom (RankIC), ki ju za posamezni časovni korak definiramo kot

$$IC_t = \text{corr}_P \left(\{\hat{\mu}_{i,t}\}_{i \in \mathcal{I}_t}, \{r_{i,t}^{(H)}\}_{i \in \mathcal{I}_t} \right), \quad \text{RankIC}_t = \text{corr}_S \left(\{\hat{\mu}_{i,t}\}_{i \in \mathcal{I}_t}, \{r_{i,t}^{(H)}\}_{i \in \mathcal{I}_t} \right). \quad (16)$$

kjer corr_P označuje Pearsonovo, corr_S pa Spearmanovo korelacijo. V rezultatih poročamo povprečje IC_t in RankIC_t skozi testno obdobje; višja pozitivna vrednost pomeni močnejšo povezanost med napovedanim in realiziranim donosom, pri čemer RankIC meri predvsem kakovost relativne razvrstitve sredstev.

Kakovost optimizacije. RD in SO neodvisno od napovednih modelov preverimo na standardnih problemih OR-Library [45]. Kardinalno omejeno efektivno fronto primerjamo z objavljeno neomejeno efektivno fronto (USEF) po postopku Changa in sod. [2]. Standardna odstotna napaka meri relativno oddaljenost najdene rešitve od referenčne fronte; manjša vrednost pomeni kakovostnejšo rešitev, nič pa sovpadanje z referenčno fronto. Ker za posamezno instanco preverimo več vrednosti parametra tveganja, poročamo povprečno in mediansko odstotno napako. Računski čas optimizatorjev poročamo kot spremljevalni podatek o računski zahtevnosti, ne kot mero kakovosti rešitve.

Skupne portfeljske metrike. Naj bo $\{r_t^p\}_{t=1}^T$ zaporedje realiziranih periodičnih donosov portfelja zunaj vzorca, $\bar{r}$ njihovo aritmetično povprečje, s standardni odklon in p število takih obdobj na leto. Kumulativno vrednost portfelja W_t , letni donos R_{letno} , letno volatilitnost σ_{letno} in letni Sharpov količnik SR definiramo kot

$$W_t = \prod_{j=1}^t (1 + r_j^p), \quad R_{\text{letno}} = p \bar{r}, \quad (17)$$

$$\sigma_{\text{letno}} = s \sqrt{p}, \quad \text{SR} = \frac{\bar{r}}{s} \sqrt{p}.$$

Pri dnevni donosih uporabimo $p = 252$, pri tedenskih $p = 52$ in pri mesečnih $p = 12$. Pri Sharpovem količniku predpostavimo ničelno oziroma zanemarljivo brezveganost donosnost [46]. Višji letni donos je ugodnejši, nižja volatilitnost pomeni manjše realizirano tveganje, višji Sharpov količnik pa ugodnejše razmerje med donosom in volatilitnostjo. Te tri metrike v vseh naših portfeljskih benchmarkih poročamo v vrstnem redu donos, volatilitnost in Sharpe.

Protokolno specifične metrike Wang in sod. Pri primerjavi z delom Wang in sod. [7] poleg skupnih metrik ohranimo še njihove objavljene portfeljske metrike donosa, tveganja in Sharpovega količnika, saj le tako omogočimo neposredno primerjavo z referenčnimi vrednostmi. Ker njihov način agregiranja rezultatov sledi lastnemu 120-dnevnomu investicijskemu protokolu, te vrednosti v tabeli označimo ločeno od skupnih metrik in jih ne uporabljamo kot nadomestilo za skupni letni donos, volatilitnost in Sharpov količnik.

Promet portfelja. Promet portfelja meri velikost spremembe uteži med zaporednima uravnoveženjema in ga za posamezno uravnoveženje izračunamo kot

$$\text{TO}_t = \sum_{i=1}^N |w_{i,t} - w_{i,t-1}|. \quad (18)$$

Višji promet pomeni izrazitejšo spremembo sestave portfelja in praviloma več trgovanja. To mero uporabljamo le kot dopolnilno analizo in ne kot glavno merilo uspešnosti benchmarkov.

5. Rezultati


Vrednotenje poteka v štirih korakih. Najprej preverimo, ali napovedni modeli sploh vsebujejo koristen signal, neodvisno od optimizatorja. Nato preverimo, ali optimizator pravilno rešuje kardinalni problem. Šele ko sta oba dela posamično preverjena, ju povežemo v celoten cevovod in ga vrednotimo na štirih zunanjih protokolih – primerjava z delom Leow in sod. [6], primerjava z delom Wang in sod. [7] ter dve primerjavi z delom Aprea in Sbaiz [47] na univerzumih DJIA in NASDAQ 100 – ter na praktičnem dolgoročnem scenariju vlagatelja. Pri vsakem portfeljskem benchmarku poročamo letni donos, letno volatilitnost in Sharpov količnik. Skupna ugotovitev, ki jo rezultati potrdijo v vseh petih benchmarkih, je vnaprej izpostavljena: v vsakem od njih vsaj en transformerski napovednik preseže svojo ujemačo zgodovinsko osnovno linijo, čeprav se model, ki to doseže, med benchmarki menja.

Vsi portfeljski benchmarki si delijo isti postopni protokol; razlikujejo se le po univerzumu, obdobju, pogostosti odločanja in pogostosti ponovnega učenja. Njegovo zgradbo zato predstavimo enkrat, splošno, na Sliki 7, konkretne vrednosti za posamezni benchmark pa zbira Tabela 3. Stolpec *val.* navaja število validacijskih opazovanj za zgodnje ustavljanje; *obnovitev* pove, kako pogosto se model in $\hat{\Sigma}$ znova naučita (zgodovinska povprečja se osvežijo ob vsaki odločitvi ne glede na to).

Pomen posameznih pasov je naslednji. *Učenje modela* obsega dneve, na katerih se uteži modela posodablja z gradientnim spustom; njegov zadnji del (šrafran) je validacijski del, izločen iz posodobitev uteži in namenjen zgodnjemu ustavljanju. *Vhod v model* (L dni) je zadnjih L trgovalnih dni pred odločitvenim trenutkom, torej natanko tisto okno, ki ga zamrznjeni model prebere ob sklepanju; L je določen z arhitekturo posameznega modela. Ključno je, da se *zgodovinsko povprečje* $\hat{\mu}$ izračuna iz istega L -dnevnega okna: vsak transformer ima tako svojo *ujemačo* zgodovinsko osnovno linijo, ki vidi natanko enako količino nedavne zgodovine, zato primerjava ne meri zgolj razlike v dolžini okna. Zgodovinska povprečja se osvežijo ob vsaki odločitvi.

Vzorčno kovarianco $\hat{\Sigma}$ ocenimo iz zadnjih $L_{\max}$ trgovalnih dni, kjer je $L_{\max}$ najdaljše pogojno okno med vsemi vključenimi modeli. Za razliko od $\hat{\mu}$ kovariance namenoma ne ujemamo po modelih: isto oceno $\hat{\Sigma}$ dobijo vsi viri napovedi, zato njena izbira vse enako prizadene in ne more nagniti neposredne primerjave. Kovarianca se osveži ob istih presečnih datumih kot model, kar je v Tabeli 3 navedeno v stolpcu *obnovitev*. Nazadnje *držanje portfelja* označuje obdobje H dni, v katerem portfelj, določen iz te napovedi, ostane nespremenjen do naslednje odločitve.

Vse ocenjevalne okna se končajo v odločitvenem trenutku ali pred njim, zato ob nobeni odločitvi ne uporabimo podatkov, ki takrat še ne bi bili na voljo.



Slika 7. Zgradba postopnega protokola za en odločitveni trenutek. Okna ne segajo v osenčeno prihodnost.

Tabela 3. Nastavitve postopnega protokola po benchmarkih (H = napovedno obzorje, K = kardinalnost).

Benchmark	Učenje	Preizkus	Obnovitev	H	K	Val.
Leow All-Weather	2018–2019	jan.–apr. 2020	ob vsaki odločitvi	5	5	63
Wang S&P 500	2018–2020	2021	enkratna	120	20	120
Aprea DJIA	2007–2015	2016–2020	letna	21	10	126
Aprea NASDAQ 100	2007–2015	2016–2020	letna	21	10	126
Dolgoročni vlagatelj	2005–2010	2011–2024	letna	21	20	126

5.1. Napovedna kakovost na standardnem protokolu. Preden vključimo optimizator, preverimo, ali modeli sploh vsebujejo koristni napovedni signal. Vprašanje je preprosto: ali napovedi transformerjev o prihodnjih donosih sploh korelirajo z dejansko realiziranimi donosi?

Testni scenarij: 494 delnic indeksa S&P 500, učenje 2018–2020, preizkus v letu 2021, napovedno obzorje pet dni. Vsak dan napovedujemo donose za vsa sredstva hkrati in primerjamo napovedi z realiziranimi vrednostmi. Ker nas zanima presečna kakovost (katere delnice model pravilno razvrsti glede na donos), merimo IC in RankIC, ki sta definirani v razdelku 4.6. Optimizator tu sploh ni vključen.

Tabela 4. Napovedna kakovost na presečnem protokolu (S&P 500, učenje 2018–2020, preizkus 2021, horizont pet dni).

Vir napovedi	IC	RankIC
Zgodovinski	−0,0284	−0,0213
MASTER	+0,0014	−0,0009
TFT	+0,0405	+0,0363
PatchTST	−0,0031	+0,0006

Rezultate povzema Tabela 4. Zgodovinski pristop v letu 2021 doseže negativni IC in RankIC: napovedi na podlagi preteklih povprečij ne korelirajo z realiziranimi donosi. Vsi trije transformerji presežejo to izhodišče. TFT je edini z izrazito pozitivnim IC (+0,04) in RankIC (+0,04), kar pomeni, da njegove napovedi merljivo korelirajo s kasnejšimi donosi. MASTER in PatchTST se gibljeta blizu nič – napovedi niso sistemsko napačne, a tudi ne zanesljivo pravilne.

Ta preizkus ne določi vrstnega reda modelov pri sestavi portfelja, saj dobra presečna napoved ni nujno enaka dobri portfeljski uspešnosti. Pokaže pa, da transformerji vsebujejo boljši signal od gole zgodovine. Naslednji eksperimenti preverijo, ali se ta prednost prenese v portfeljske donose.

5.2. Kakovost optimizatorjev na standardnih primerih. Preden vključimo napovedne modele, preverimo, ali optimizator pravilno rešuje kardinalno omejeni problem povprečja in variance. Vprašanje je: ali RD in SO najdeta portfelje blizu optimalne efektivne fronte?

Testni scenarij: pet standardnih primerov zbirke OR-Library [45]: Hang Seng (31 sredstev), DAX 100 (85), FTSE 100 (89), S&P 100 (98) in Nikkei (225). Za vsak primer izračunamo kardinalno omejeno efektivno fronto pri 50 vrednostih parametra tveganja ($K = 10$, $\varepsilon_i = 0,01$, $\delta_i = 1$) in jo primerjamo z objavljeno neomejeno fronto (USEF) po postopku Changa in sod. [2]. $\hat{\mu}$ in $\hat{\Sigma}$ vzamemo neposredno iz referenčnih podatkovnih datotek, da napovedni model ne vpliva na rezultat.

Tabela 5. Standardna odstotna napaka (%) kardinalno omejene fronte glede na USEF na primerih OR-Library.

Instanca (N)	RD		SO	
	povpr.	med.	povpr.	med.
Hang Seng (31)	1,28	1,26	1,12	1,22
DAX 100 (85)	2,93	2,66	3,45	2,61
FTSE 100 (89)	2,03	1,29	1,63	1,08
S&P 100 (98)	2,93	1,61	2,51	1,18
Nikkei (225)	1,96	1,33	0,61	0,60
Povprečje	2,23	1,63	1,86	1,34


**Slika 8.** Kardinalno omejena fronta na primeru S&P 100: RD in SO v primerjavi z neomejeno fronto (USEF); vsaka točka predstavlja eno vrednost parametra tveganja.

Tabela 5 kaže, da oba optimizatorja dosežata rešitve blizu objavljene neomejene fronte. Povprečna odstotna napaka je pri večini primerov pod 3 %, mediana pa je pri obeh algoritmihi v povprečju nižja od 2 %. SO ima nekoliko nižjo skupno povprečno in mediansko napako kot RD, vendar prednost ni enaka pri vseh instancah.

Slika 8 rezultat ponazori na primeru S&P 100, kjer se točke obeh kardinalno omejenih postopkov skozi večji del razpona tesno približajo neomejeni fronti. To zmanjšuje verjetnost, da bi bile razlike med napovednimi modeli v nadaljnjih poskusih predvsem posledica očitno neakovostnega optimizacijskega postopka.

Računska zahtevnost obeh optimizatorjev je pri teh problemih majhna: posamezno reševanje traja med 0,02 in 0,26 s, celoten pregled petih primerov s po 50 vrednostmi parametra tveganja pa se zaključi v manj kot minuti.

5.3. Zunanja primerjava z delom Leow in sod.. Leow in sod. [6] razširijo klasično optimizacijo portfelja z razpoloženjem, pridobljenim iz družbenih omrežij. Besedilne objave obdelajo z modelom BERT in iz njih izluščijo razpoloženski signal, ki ga vključijo v kriterij optimizacije skupaj z genetskim algoritmom. Njihova najboljša metoda (SAW) v kriznem obdobju COVID-19 doseže Sharpov količnik 2,14.

Testni scenarij. Preznamemo njihovo časovno delitev (januar–april 2020, 13 tedenskih odločitev). Namesto razpoloženskega signala v cevovod vstavimo naše napovedi $\hat{\mu}$, zato gre za primerjavo napovednega in optimizacijskega pristopa v sorodnem protokolu, ne za reprodukcijo njihovega signala. Testiramo njihov petsredstveni nabor All-Weather (VTI, TLT, IEF, GLD, DBC; kardinalnost $K=5$) – edini nabor, za katerega Leow in sod. poročajo številčne rezultate (njihovi tabeli 4 in 6). Sektorski nabor SPDR v njihovem delu nastopa le kot slika brez poročenih mer in ga zato ne uporabljamo za primerjavo. Vprašanje je, ali naš transformerski signal v krizi dosega primerljive rezultate z njihovim razpoloženskim pristopom.

Ker isti P pri različnih virih $\hat{\mu}$ pomeni različno realizirano tveganje, vsak model poročamo pri tistem P , pri katerem je njegova realizirana letna volatilitnost najbližja volatilitnosti ujemajoče zgodovinske osnovne linije; s tem so donos in Sharpov količnik primerjani pri enakem realiziranem tveganju. Vsak transformer je primerjan z lastno osnovno linijo: »Zgodovinski (L dni)« označuje vzorčno povprečje čez L trgovalnih dni, kjer L ustreza pogojnemu oknu tistega modela (PatchTST: $L=45$, TFT: $L=64$). Ta konvencija in oznaka veljata za vse portfeljske tabele v nadaljevanju. Stolpec »Čas učenja« je skupni čas učenja čez vse ponovitve in semena (65 učenj na model); zgodovinski pristop je označen z »–«.

Tabela 6. Portfeljska uspešnost v protokolu Leow in sod. [6] (jan.–apr. 2020, 13 tedenskih odločitev, nabor All-Weather, optimizator RD, bruto). Referenčne vrednosti iz njihove Tabele 6.

Nabor	Metoda	Donos	Volatilitnost	Sharpe	Čas učenja
All-Weather	Leow: SPY (pasivno)	−65,4 %	55,1 %	−1,65	–
All-Weather	Leow: CRB (pasivno)	−8,5 %	17,8 %	−0,41	–
All-Weather	Leow: MPT (Markowitz)	+13,6 %	18,0 %	+0,80	–
All-Weather	Leow: SAW (najboljši)	+53,9 %	21,2 %	+2,14	–
All-Weather	Zgodovinski (45 dni)	+29,6 %	20,9 %	+1,42	–
All-Weather	Zgodovinski (64 dni)	+11,2 %	24,4 %	+0,46	–
All-Weather	PatchTST	+14,6 %	22,7 %	+0,64	18,4 min
All-Weather	TFT	+28,6 %	22,2 %	+1,29	20,1 min


Rezultati – All-Weather. Ker vsak model bere svoje pogojno okno, ni ene same »zgodovinske« primerjalne vrednosti: vzorčno povprečje čez 45 dni doseže Sharpe +1,416 (letni donos +29,6 %), čez 64 dni pa le +0,458 (+11,2 %). Že ta razlika – devetnajst dodatnih dni zgodovine prepolovi Sharpov količnik – pokaže, da je dolžina okna v tem obdobju enako pomembna kot izbira napovednika. TFT doseže Sharpe +1,289 (+28,6 %) in tako za +0,831 jasno prekaša svojo ujemajočo osnovno linijo, medtem ko PatchTST s Sharpom +0,644 (+14,6 %) svoji osnovni liniji občutno podleže (−0,772). TFT s Sharpom +1,289 preseže tudi Leowov MPT z maksimizacijo Sharpovega količnika (+0,80) in se približa njihovem modelu z minimizacijo volatilitnosti (+1,51), ne doseže pa najvišje vrednosti Leow in sod. (+2,14, model SAW z maksimizacijo donosa); PatchTST s Sharpom +0,644 v tej ponovitvi ne doseže niti njihovega MPT.

Rezultate je treba brati previdno. Izhajajo iz le 13 tedenskih odločitev v izjemno kratkem kriznem obdobju, zato so občutljivi na posamezne realizirane donose in na podrobnosti učenja. Kako občutljivi, kaže naslednja primerjava z zgodnejšo ponovitvijo istega protokola: zgolj sprememba dolžine validacijskega okna za zgodnje ustavljanje (pri TFT skupaj s spremembo potrpežljivosti), torej učinkovitostna nastavitve, ki ne spremeni niti podatkov niti arhitekture, je Sharpov količnik TFT premaknila z +0,21 na +1,289, pri PatchTST pa v nasprotno smer, z +1,09 na +0,644. Velik del razpona med modeloma v tem obdobju je torej šum pri izbiri ustavitvene točke učenja in ne stabilna napovedna vsebina; primerjava je zato zgolj usmeritvena, vrstni red modelov pa se lahko z drugačno nastavitvijo zgodnjega ustavljanja ponovno obrne.

Razlike med modeloma v tem naboru niso skladne z njihovo napovedno kakovostjo – kar je samo po sebi pomembna ugotovitev. PatchTST doseže pozitiven presečni R^2

(+0,018; $R_{OS}^2 = +0,029$ proti svoji osnovni liniji pri $-0,012$), kar je edini pozitivni absolutni R^2 med vsemi štirimi viri v tem naboru – pa vendar je njegov portfeljski Sharpe najnižji med transformerji. TFT ostane pri negativnem absolutnem R^2 ($-0,009$), a rahlo prekaša svojo osnovno linijo ($R_{OS}^2 = +0,006$). Portfeljski izid se torej obrne glede na presečno napovedno kakovost: boljši R^2 (PatchTST) ne prinese boljšega Sharpovega količnika. To je skladno z ugotovitvijo razdelka 5.1, da dobra presečna korelacija ne zagotavlja dobre portfeljske uspešnosti; slednjo dodatno določata razporeditev uteži in odziv optimizatorja na velikost napovedanih donosov (razdelek 5.8). Ob 13 odločitvah gre za usmeritveno in ne statistično značilno ugotovitev.

Gibanje vrednosti posameznih portfeljev skozi to obdobje prikazuje Slika 9. Skupna ugotovitev je, da visok ali nizek rezultat posameznega napovednika v tem kratkem obdobju ne odraža splošne superiornosti modela. Obdobje obsega le 13 tedenskih odločitev znotraj enega samega zloma, zato rezultate beremo zgolj ekonomsko in usmeritveno, brez statistične značilnosti.



Slika 9. Gibanje vrednosti portfelja All-Weather med COVID-19 zlomom (protokol Leow in sod., brutto). Vsak model je prikazan pri ujemajočem P iz Tabele 6.

5.4. Zunanja primerjava z delom Wang in sod.. Wang in sod. [7] predlagajo enkratni nevronske reševalnik CardNN-GS za kardinalno omejeni portfeljski problem. Namesto ločenega napovednega in optimizacijskega koraka reševalnik oba združi v enoten model z diferenciablem plastjo optimalnega transporta, ki neposredno maksimizira Sharpov količnik. Kot primerjalno metodo vključijo tudi pristop »napovej, nato optimiziraj«: LSTM oceni pričakovane donose, Gurobi pa na podlagi teh ocen poišče optimalne uteži. Ta pristop je strukturno najbližji našemu cevovodu.

Testni scenarij. Prevmemo njihov podatkovni nabor: 494 sredstev iz indeksa S&P 500, leto 2021 kot testno obdobje, 120-dnevni horizont odločanja, kardinalnost $K=20$. Kovariančno matriko fiksiramo na učnem obdobju 2018–2020; to je odstopanje od njihovega protokola, kjer $\hat{\Sigma}$ ni fiksna, temveč jo za vsako odločitev izračunajo iz napovedanih prihodnjih donosov modela LSTM. Naš cevovod take napovedane $\hat{\Sigma}$ nima, zato uporabimo vzorčno oceno iz učnega obdobja, ki v testno obdobje ne pogleda. Ker Wang in sod. neposredno maksimizirajo Sharpov količnik, naša ciljna funkcija povprečje–varianca pri $P=0,5$ temu ni enakovredna – primerjava je smiselna na ravni Sharpa, ki tveganje že upošteva. Vprašanje je, ali metahevristična optimizacija s standardno ciljno funkcijo doseže primerljivo kakovost kot specializirani nevronske reševalci.

Dve opombi pred branjem Tabele 7: Wang in sod. Sharpov količnik računajo z netvegano mero 3 %, mi pa brez nje, zato so naše vrednosti v tem stolpcu za 0,15 ugodnejše. Poleg tega so standardni odkloni Sharpovih količnikov v tem protokolu večji od samih vrednosti (od 0,579 do 1,393), zato tabela dopušča le umestitev v razred, ne razvrstitve med posameznimi modeli.

Tabela 7. Primerjava z delom Wang in sod. [7] (S&P 500 2021, 120-dnevna okna, $K=20$, optimizator RD). Referenčne vrednosti iz njihove Tabele 3 in Slike 5.

Metoda	Donos	Tveganje	Sharpe	Čas učenja
Wang: zgodovinski (Gurobi)	0,139	0,162	0,673	–
Wang: napovej-nato (LSTM+Gurobi)	0,241	0,195	1,082	–
Zgodovinski (67 dni)	0,223	0,225	0,859	–
Zgodovinski (271 dni)	0,278	0,254	1,080	–
Zgodovinski (336 dni)	0,357	0,256	1,410	–
MASTER	0,296	0,231	1,123	33,7 min
PatchTST	0,363	0,227	1,641	1,8 min
TFT	0,402	0,246	1,794	1,04 h
Wang: napovej-in (CardNN-GS)	0,400	0,188	1,968	–

Rezultati. Naš cevovod se objavljenim metodam dobro primerja. TFT doseže Sharpe 1,794, tik pred njim PatchTST z 1,641; oba se uvrstita med Wangov pristop »napovej, nato optimiziraj« (LSTM+Gurobi, 1,08) in njihov enkratni nevronske reševalnik CardNN-GS (1,97), ki neposredno maksimizira Sharpov količnik. Komercialni Gurobi pri njih uporabljata prav primerjalni metodi (zgodovinska in »napovej, nato optimiziraj«), medtem ko ga CardNN-GS nadomesti. Pri tem je naš letni donos (0,402) skoraj enak CardNN-GS (0,400), a ob občutno višjem realiziranem tveganju (0,246 proti 0,188): del razlike v Sharpovem količniku torej ni posledica boljših napovedi, temveč večje izpostavljenosti.

Dva rezultata je treba navesti odkrito. Prvič, MASTER s Sharpom 1,123 ostaja najšibkejši od treh transformerjev v tem protokolu, čeprav svojo ujemačo osnovno linijo (0,859) prekaša le za +0,264; njegova prednost pred zgodovino je torej postranska in bistveno manjša kot pri TFT in PatchTST. Drugič, sama zgodovinska osnovna linija čez 336 dni doseže Sharpe 1,410 in s tem prekaša Wangov LSTM+Gurobi (1,08) – brez vsakršnega napovednega modela. Razpon osnovnih linij (0,859, 1,080, 1,410 pri 67, 271 in 336 dneh) je primerljiv z razponom med modeli, kar pomeni, da dolžina okna v tem protokolu opravi približno toliko dela kot izbira napovednika.

Skupna ugotovitev je zato zadržana: odprtokodna metahevrstična optimizacija s standardno ciljno funkcijo povprečje–varianca dosega kakovost v razredu specializiranih nevronske reševalcev brez potrebe po komercialni infrastrukturi, vendar protokol s sedmimi odločitvami in 83 % prekrivanjem obdobja držanja (kar ustreza približno dvema neodvisnima opazovanjema) ne dopušča razvrstitve med posameznimi napovedniki.

5.5. Zunanja primerjava z delom Aprea in Sbaiz: DJIA. Aprea in Sbaiz [47] predlagajo globoko naučen pristop k izbiri portfelja, ki namesto variance kot mere tveganja minimizira agregiran ΔCoVaR (sistemsko tveganje, ocenjeno z LSTM) ob dodatnih omejitvah ESG, prometa in minimalnega donosa. Nastali nekonveksni problem rešujejo z izboljšanim rojenjem delcev, pri katerem parametre roja (w, c_1, c_2) sproti prilagaja nevronska mreža, omejitve pa obravnavajo s projekcijo na proračunsko simpleks in kazensko funkcijo. Njihova ciljna funkcija in omejitve so torej bistveno drugačne od našega povprečje–variančnega kriterija, zato gre za primerjavo metod na skupnih naknadno izračunanih merah (Sharpov količnik, letni donos), ne za replikacijo; skupna pa je izbira rojenja delcev kot reševalnika.

Testni scenarij. Preznamemo njihov univerzum 28 delnic indeksa DJIA (poravnan z njihovim investicijskim naborom na presečni datum 31. 12. 2020, rekonstruiran iz javno dostopnih cen) in njihovo časovno shemo: učenje na obdobju 2007–2015, mesečno odločanje v obdobju 2016–2020 (60 razporeditev; njun $T_f=59$ šteje ponovna uravnoteženja po začetni razporeditvi) in $w_{\max}=0,2$ (zgornja meja uteži, skladna z eno od dveh mej Aprea in sod.). Kardinalnost $K=10$ je naš dodatek: njun model kardinalne omejitve ne vsebuje – njune omejitve so proračunska, intervalna ($x_i \in [l_i, u_i]$), ESG, prometna in minimalni donos, brez binarnih spremenljivk. Število pozicij pri njih ni nastavitve, temveč posledica intervalne meje: zadnja vrstica njunih tabel 7 in 8 poroča *povprečno* število sredstev z neničelno utežjo zunaj vzorca, in to je 10 pri $u_i=0,2$ ter 16 pri $u_i=0,06$, torej $\lfloor 1/u_i \rfloor$. Naš $K=10$ pri $w_{\max}=0,2$ tako eksplicitno predpiše prav tisto število pozicij, ki pri njiju nastane samo od sebe. Njihova omejitev prometa ($\leq 0,2$ na odločitev), omejitev ESG in kriterij minimalnega donosa v našem cevovodu niso implementirani, zato je neposredna primerjava s to referenco zgolj usmeritvena.

Tabela 8. Primerjava z delom Aprea in Sbaiz [47] na univerzumu DJIA (28 delnic, 2016–2020, 60 mesečnih odločitev, $K=10$, $P=0,5$, optimizator RD, bruto).

Metoda	Donos	Volatilitnost	Sharpe
Zgodovinski (67 dni)	14,1 %	15,3 %	0,75
Zgodovinski (271 dni)	12,4 %	15,5 %	0,64
Zgodovinski (336 dni)	14,8 %	15,5 %	0,80
MASTER	16,3 %	17,2 %	0,76
PatchTST	19,3 %	15,4 %	1,09
TFT	16,9 %	16,9 %	0,79
Aprea in Sbaiz: B^+ ($p=1\%$, $u_i=0,2$)	20,8 %	5,0 % ¹	1,21 ²

Rezultati. Na tem naboru vsi trije transformerji presežejo svojo ujemačo zgodovinsko osnovno linijo. PatchTST doseže najvišji Sharpe (1,09 proti 0,80 za osnovno linijo čez 336 dni) in edini preseže tudi Apreovo referenco (1,21 letno normalizirano), čeprav ob občutno višji volatilitnosti – njihov model eksplicitno minimizira tveganje (sistemsko, ne variančno), naš pa ga uravnateži z donosom pri $P=0,5$. TFT (0,79 proti 0,64) in MASTER (0,76 proti 0,75, komaj) prav tako presežeta svoji osnovni liniji, a z manjšo razliko; MASTER je tu na robu. Noben od treh ne doseže Apreove referenčne volatilitnosti niti pri sami metodologiji (ΔCoVaR proti varianci, brez omejitve prometa), zato branje

te tabele ostaja usmeritveno.

5.6. Zunanja primerjava z delom Aprea in Sbaiz: NASDAQ 100. Isti protokol Aprea in Sbaiz [47] ponovimo na njihovem večjem univerzumu 54 delnic indeksa NASDAQ 100 (poravnanem z njihovim polnozgodovinskim naborom), da preverimo, ali se ugotovitve iz razdelka 5.5 prenesejo na širši, bolj tehnološko nagnjen nabor sredstev. Nastavitve (obdobje, $K=10$, $w_{\max}=0,2$, 60 mesečnih odločitev) so sicer enake kot pri DJIA.

Tabela 9. Primerjava z delom Aprea in Sbaiz [47] na univerzumu NASDAQ 100 (54 delnic, 2016–2020, 60 mesečnih odločitev, $K=10$, $P=0,5$, optimizator RD, bruto).

Metoda	Donos	Volatilnost	Sharpe
Zgodovinski (67 dni)	28,0 %	21,7 %	1,03
Zgodovinski (271 dni)	28,3 %	23,3 %	0,94
Zgodovinski (336 dni)	30,6 %	23,9 %	1,00
MASTER	27,0 %	18,4 %	1,23
PatchTST	30,9 %	24,9 %	0,96
TFT	18,9 %	22,7 %	0,55
Aprea in Sbaiz: B^+ ($p=1$ %, $u_i=0,2$)	22,9 %	6,3 % ¹	1,08 ²

Rezultati. Rezultate zbira Tabela 9. Na tem večjem, bolj tehnološko nagnjenem naboru se vrstni red modelov obrne glede na DJIA. MASTER je tu edini, ki jasno preseže svojo osnovno linijo (1,23 proti 1,03 čez 67 dni) in edini preseže tudi Apreovo referenco (1,08 letno normalizirano). PatchTST ostane praktično na ravni svoje osnovne linije (0,96 proti 1,00, neznatno nižje). TFT je edini model, ki v tem naboru izrazito zaostane za svojo osnovno linijo (0,55 proti 0,94) – v nasprotju z njegovo vlogo v Leow All-Weather in dolgoročnem scenariju (razdelek 5.7), kjer osnovno linijo presega. Diagnostika kaže, da gre pri TFT deloma za arhitekturno omejitev pri tem večjem univerzumu: TFT za razliko od MASTER nima presečne (medsredstvene) pozornosti in torej svoje kapacitete ne prilagaja velikosti nabora, kar je pri 54 sredstvih izrazitejša ovira kot pri 28 (DJIA) ali petih (Leow). Rezultat je zato treba brati kot opozorilo, da uspešnost posameznega transformerja ni univerzalna lastnost modela, temveč je odvisna tudi od velikosti in narave univerzuma – kar je skladno s skupno ugotovitvijo tega dela, da noben posamezni napovednik ne dominira dosledno prek vseh benchmarkov, medtem ko je v vsakem benchmarku vsaj eden, ki svojo zgodovinsko osnovno linijo preseže (tu MASTER).

5.7. Praktični scenarij: dolgoročni vlagatelj. Predhodne primerjave preverijo cevovod v protokolih obstoječih študij. Kot zadnji korak izvedemo scenarij, ki ga sami oblikujemo za preverbo dolgoročnega vedenja: ali transformerski signal ostaja koristen prek daljšega obdobja z večimi tržnimi razmerami, ne le v kratkem kriznem oknu?

Testni scenarij. Testiramo na univerzumu velikih ameriških delnic v obdobju 2011–2024 z letnim preučevanjem (12 odločitev). Ker scenarij ni vezan na referenčno študijo, referenčna točka je naš lasten zgodovinski pristop in pasivni indeks S&P 500 (dodan kot ločena, nemodelirana referenca; ker nima prometa, velja bruto = neto). Opozorilo: univerzum vsebuje samo delnice, ki so preživele celotno obdobje (survivorship bias), zato so absolutni rezultati navzgor pristrani; primerjava med napovednimi pristopi je kljub temu neposredna, saj vsi delijo isti rekonstruirani univerzum. Tabela 10 poroča bruto in neto mere, kjer neto upošteva 10 bazičnih točk (b.t.) stroška na enoto letnega prometa (L1 uteži) – standardna groba ocena transakcijskih stroškov za likvidne ameriške delnice.

Tabela 10. Praktični scenarij dolgoročnega vlagatelja (2011–2024, $K=20$, $P=0,5$, optimizator RD). Bruto in neto mere pri 10 b.t. transakcijskih stroškov.


Strategija	Bruto		Neto (10 b.t.)		Promet/leto
	Donos	Sharpe	Donos	Sharpe	
Zgodovinski (67 dni)	14,0 %	1,01	12,9 %	0,93	11,5 %
Zgodovinski (271 dni)	13,6 %	0,99	13,0 %	0,94	6,2 %
Zgodovinski (336 dni)	14,7 %	1,10	14,2 %	1,06	5,8 %
MASTER (transformerski)	11,6 %	0,73	9,8 %	0,61	18,3 %
PatchTST (transformerski)	17,6 %	1,38	16,2 %	1,27	14,4 %
TFT (transformerski)	16,4 %	1,10	15,6 %	1,04	8,5 %
S&P 500 (indeks)	12,1 %	0,85	12,1 %	0,85	0,0 %

Rezultati. Tabela 10 zbira bruto in neto mere. PatchTST doseže najvišji Sharpe (1,38; 17,6 %) in tako jasno prekaša svojo ujemajočo osnovno linijo čez 336 dni (1,10; 14,7 %). TFT doseže Sharpe 1,10 (16,4 %) in prav tako preseže svojo (krajšo, šibkejšo) osnovno linijo čez 271 dni (0,99; 13,6 %). MASTER je edini transformer, ki v tem scenariju zaostane za svojo osnovno linijo: Sharpe 0,73 (11,6 %) proti 1,01 (14,0 %) čez 67 dni. Vse tri zgodovinske osnovne linije in TFT presežejo pasivni S&P 500 (0,85; 12,1 %);

PatchTST ga preseže z največjo razliko. PatchTST torej vzdržuje prednost pred svojo zgodovinsko osnovno linijo prek celotnega 14-letnega obdobja, ki zajema tako krizna (2020, 2022) kot mirnejša leta, TFT enako, medtem ko MASTER v tem dolgoročnem, velikem univerzumu (61 sredstev) zgodovini podleže.

Vpliv transakcijskih stroškov. Gibanje vrednosti portfeljev v bruto in neto različici prikazuje Slika 10. Pri 10 b.t. na enoto letnega prometa se vrstni red ohrani: PatchTST in TFT ostaneta jasno pred svojo ujemačo osnovno linijo in pred S&P 500 tudi neto, MASTER pa ostane edini transformer pod svojo osnovno linijo, tokrat še bolj izrazito. Stroški niso nevtralni glede na model – MASTER ima daleč najvišji letni promet (18,3 %), zato ga strošek prizadene najbolj (Sharpe 0,73 $\rightarrow$ 0,61, $-0,12$); TFT ima med transformerji najnižji promet (8,5 %, blizu ravni zgodovinskih osnovnih linij) in je zato do stroškov najbolj odporen (1,10 $\rightarrow$ 1,04, $-0,06$); PatchTST je vmes (14,4 % promet, 1,38 $\rightarrow$ 1,27, $-0,11$). Ugotovitev torej ostane robustna na realistične transakcijske stroške, promet portfelja pa je pomembna dodatna dimenzija pri izbiri modela za praktično uporabo (glej tudi razdelek 5.8).

Čez vse štiri scenarije transformerji pozitivno vplivajo na vrednost portfelja, čeprav ne vedno isti model in ne brezpogojno. TFT doseže najboljši Sharpov količnik pri Leow All-Weather (+1,289 proti +0,458 za ujemačo osnovno linijo) in preseže svojo osnovno linijo tudi v dolgoročnem scenariju (1,10 proti 0,99); PatchTST v dolgoročnem scenariju doseže najvišji absolutni Sharpe (1,38 proti 1,10 za svojo osnovno linijo), a v Leow All-Weather za svojo osnovno linijo zaostane. Pri Wangu sta TFT (1,794) in PatchTST (1,641) primerljiva in oba jasno presežeta svoji osnovni liniji ter se uvrstita med Wangov pristop »napovej, nato optimiziraj« (1,08) in nevronske reševalnik CardNN-GS (1,97). V vsakem od štirih zunanjih benchmarkov (Leow, Wang, DJIA, NASDAQ 100 – razdelka 5.5 in 5.6) in v praktičnem dolgoročnem scenariju torej vsaj en transformer preseže svojo ujemačo zgodovinsko osnovno linijo; kateri model to je, pa je odvisno od protokola in univerzuma, zato rezultatov ne posplošujemo na en sam »najboljši« model.



Slika 10. Gibanje vrednosti portfelja v dolgoročnem scenariju (2011–2024, $P=0,5$): bruto (levo) in neto pri 10 b.t. (desno). Prisoten je survivorship bias.

5.8. Stabilnost napovedi in promet portfelja. Rezultati prejšnjih eksperimentov kažejo, da sama presečna napovedna korelacija še ne pojasni v celoti končne portfeljske uspešnosti. Zato v Tabeli 11 kot dopolnilno analizo primerjamo letni promet portfelja; te mere ne obravnavamo kot glavno benchmark merilo.

Tabela 11. Letni promet portfelja za transformerske modele pri optimizatorju RD.

Nabor	TFT	MASTER	PatchTST
Leow: razpršeni ETF	2,6	13,5	14,4
Wang: S&P 500	0,5	23,3	16,1
Dolgoročni vlagatelj	10,2	17,8	13,1
Povprečje	4,4	18,2	14,5

TFT v povprečju doseže letni promet 4,4, MASTER 18,2 in PatchTST 14,5. Razlika med TFT in MASTER je posebej izrazita pri Wang S&P 500 (0,5 proti 23,3), kar neposredno pojasni razliko v neto Sharpovem količniku med modeloma.

Nižji promet je praktično pomemben, ker pomeni manj izrazite spremembe izbora in uteži med zaporednimi odločitvenimi trenutki ter praviloma manj trgovanja. Rezultate zato interpretiramo na ravni celotnega cevovoda: poleg napovedne kakovosti so pomembni tudi velikost napovedanih donosov, odziv optimizatorja na spremembe $\hat{\mu}$ in posledična stabilnost portfeljskih odločitev.

6. Sklep

V magistrskem delu smo zasnovali cevovod za sestavo kardinalno omejenega portfelja, ki napovedovanje pričakovanih donosov in optimizacijo uteži obravnava kot dva ločena,

vendar zaporedno povezana problema. Pričakovane donose $\hat{\mu}$ ocenjujemo s tremi arhitekturno različnimi transformerskimi modeli – MASTER [5], TFT [4] in PatchTST [3]. Pri tem je nevronska jedro vsakega modela čim tesneje povezano z uradno programsko izvedbo avtorjev, naše spremembe pa omejimo na podatkovni vmesnik, ameriški finančni univerzum in pretvorbo izhoda v oceno pričakovanega donosa. Za vse tri napovedne modele uporabljamo isto vzorčno kovariančno matriko zgodovinskih donosov, zato primerjava izolira predvsem vpliv napovednega signala.

Iskanje uteži ob striktni kardinalni omejitvi rešujeta dve stohastični metahevrstiki, rojenje delcev in simulirano ohlajanje. Obe rešujeta isti KONP in uporabljata isto ciljno funkcijo ter iste omejitve, razlikujeta pa se v strategiji preiskovanja prostora rešitev. Kakovost optimizacijskega dela preverjamo ločeno na standardnih problemih OR-Library, napovedni del pa na ločenem presečnem protokolu. Šele nato oba dela povežemo v postopno vrednotenje zunaj vzorca.

Pomemben metodološki vidik dela je sledljivost implementacij. PatchTST uporablja uradni `PatchTST_backbone`, TFT odprtokodno knjižnico `pytorch-forecasting`, MASTER pa izvirno arhitekturo avtorjev. Namestitvene skripte zabeležijo uporabljene revizije Git, zato je mogoče poleg nastavitev eksperimenta določiti tudi konkretno programsko različico posameznega modela. Pri metodah, ki jih zaradi drugačnega trga ali drugačne formulacije optimizacijskega problema ni mogoče dobesedno prenesti, prilagoditve eksplicitno opišemo.

Transformerski napovedni signal pozitivno vpliva na vrednost portfelja, a ne prek enega samega, dosledno najboljšega modela. TFT doseže najvišji Sharpor količnik v kriznem obdobju Leow All-Weather (+1,289 proti +0,458 za ujemačo osnovno linijo) in preseže svojo osnovno linijo tudi v dolgoročnem scenariju; PatchTST doseže najvišji absolutni Sharpe v dolgoročnem scenariju (1,38 proti 1,10 za svojo osnovno linijo) in na naboru Aprea DJIA (1,09 proti 0,80); MASTER pa je edini, ki jasno preseže svojo osnovno linijo na večjem naboru Aprea NASDAQ 100 (1,23 proti 1,03), kjer TFT nasprotno izrazito zaostane (0,55 proti 0,94). Pri Wangu sta TFT in PatchTST primerljiva (1,794 oziroma 1,641) in se oba uvrstita med Wangov pristop »napovej, nato optimiziraj« in nevronske reševalnik CardNN-GS, ki komercialni reševalnik nadomesti z naučeno plastjo. Ključna ugotovitev, ki drži v vseh petih benchmarkih (Leow, Wang, Aprea DJIA, Aprea NASDAQ 100, dolgoročni scenarij), je, da v vsakem od njih *vsaj en* transformer jasno preseže svojo ujemačo zgodovinsko osnovno linijo – kateri model to je, pa se sistematično menja z univerzumom in protokolom, kar kaže, da izbira napovednega modela ni univerzalna odločitev, temveč je odvisna od konteksta uporabe. Razlike med rojenjem delcev in simuliranim ohlajanjem so ob tem majhne in nekonsistentne prek scenarijev, kar kaže, da je kakovost napovednega signala $\hat{\mu}$ dominantni dejavnik portfeljske uspešnosti, ne izbira optimizatorja.

Delo ima več metodoloških omejitev. Zunanje študije uporabljajo različne univerzume, časovna obdobja, ciljne funkcije in merila uspešnosti, zato njihove rezultate obravnavamo kot referenčne primerjave in ne kot popolne reprodukcije: pri Aprea in Sbaiz je razlika največja, saj njun ΔCoVaR -kriterij ter omejitvi prometa in ESG niso implementirani, kardinalno omejitev $K=10$ pa dodamo mi, medtem ko pri njiju število pozicij ni omejeno, ampak je posledica intervalne meje uteži ($\lfloor 1/u_i \rfloor$). Nekateri javno rekonstruirani nabori vsebujejo pristranost zaradi preživetja, pri MASTER pa moramo kitajske tržne indekse nadomestiti z ameriškimi približki. Pri TFT in PatchTST se napovedno obzorje prilagaja posameznemu portfeljskemu protokolu, kar je potrebno za skupni cevovod, vendar pomeni odstopanje od posamezne referenčne eksperimentalne nastavitve. Rezultati Leow so poleg tega izrazito občutljivi na podrobnosti zgodnjega ustavljanja učenja (razdelek 5.3), kar zahteva previdnost pri posploševanju iz katerekoli posamezne ponovitve tega protokola.

V prihodnje bi lahko cevovod razširili z natančnejšim modeliranjem transakcijskih stroškov in davkov, z robustnejšimi ocenami kovariančne matrike, s samodejnim izborom napovednega modela glede na tržni režim ter z merami repnega tveganja. Druga smer je tesnejša sklopitev napovedovanja in optimizacije v enoten postopek, naučen skozi optimizacijo [7].

Literatura

1. Markowitz H (1952) Portfolio selection. *The Journal of Finance* 7(1):77–91.
2. Chang TJ, Meade N, Beasley JE, Sharaiha YM (2000) Heuristics for cardinality constrained portfolio optimisation. *Computers & Operations Research* 27(13):1271–1302.
3. Nie Y, Nguyen NH, Sinthong P, Kalagnanam J (2023) A time series is worth 64 words: Long-term forecasting with transformers in *Proceedings of the Eleventh International Conference on Learning Representations (ICLR)*. <https://doi.org/10.48550/arXiv.2211.14730>.
4. Lim B, Arik SÖ, Loeff N, Pfister T (2021) Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting* 37(4):1748–1764.
5. Li T et al. (2024) MASTER: Market-guided stock transformer for stock price forecasting in *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 38, pp. 162–170.
6. Leow EKW, Nguyen BP, Chua MCH (2021) Robo-advisor using genetic algorithm and BERT sentiments from tweets for hybrid portfolio optimisation. *Expert Systems with Applications* 179:115060.
7. Wang R et al. (2023) Towards one-shot neural combinatorial solvers: Theoretical and empirical notes on the cardinality-constrained case in *International Conference on Learning Representations (ICLR)*. Na voljo na: <https://openreview.net/forum?id=h21yJhdzbwz>. Dostopano: 18. 9. 2026.
8. Michaud RO (1989) The Markowitz optimization enigma: Is 'optimized' optimal? *Financial Analysts Journal* 45(1):31–42.

9. Black F, Litterman R (1992) Global portfolio optimization. *Financial Analysts Journal* 48(5):28–43.
10. He G, Litterman R (1999) The intuition behind Black-Litterman model portfolios, (Goldman Sachs Investment Management Research), Technical report. <https://doi.org/10.2139/ssrn.334304>.
11. DeMiguel V, Garlappi L, Uppal R (2009) Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies* 22(5):1915–1953.
12. Bessler W, Opfer H, Wolff D (2017) Multi-asset portfolio optimization and out-of-sample performance: An evaluation of Black-Litterman, mean-variance, and naive diversification approaches. *The European Journal of Finance* 23(1):1–30.
13. Tu J, Zhou G (2011) Markowitz meets talmud: A combination of sophisticated and naive diversification strategies. *Journal of Financial Economics* 99(1):204–215.
14. Bienstock D (1996) Computational study of a family of mixed-integer quadratic programming problems. *Mathematical Programming* 74(2):121–140.
15. Gao J, Li D (2013) Optimal cardinality constrained portfolio selection. *Operations Research* 61(3):745–761.
16. Brodie J, Daubechies I, De Mol C, Giannone D, Loris I (2009) Sparse and stable Markowitz portfolios. *Proceedings of the National Academy of Sciences of the United States of America* 106(30):12267–12272.
17. Kim MJ, Lee Y, Kim JH, Kim WC (2016) Sparse tangent portfolio selection via semi-definite relaxation. *Operations Research Letters* 44(4):540–543.
18. Akbay MA, Kalayci CB, Polat O (2020) A parallel variable neighborhood search algorithm with quadratic programming for cardinality constrained portfolio optimization. *Knowledge-Based Systems* 198:105944.
19. Jegadeesh N, Titman S (1993) Returns to buying winners and selling losers: Implications for stock market efficiency. *The Journal of Finance* 48(1):65–91.
20. Carhart MM (1997) On persistence in mutual fund performance. *The Journal of Finance* 52(1):57–82.
21. Gu S, Kelly B, Xiu D (2020) Empirical asset pricing via machine learning. *The Review of Financial Studies* 33(5):2223–2273.
22. Ke G et al. (2017) LightGBM: A highly efficient gradient boosting decision tree in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 3146–3154. Na vo ljo na: https://papers.neurips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html. Dostopano: 18. 9. 2026.
23. Selvin S, Vinayakumar R, Gopalakrishnan EA, Menon VK, So-man KP (2017) Stock price prediction using LSTM, RNN and CNN-sliding window model in 2017 *International Conference on Advances in Computing, Communications and Informatics (ICACCI)*. pp. 1643–1647.
24. Hochreiter S, Schmidhuber J (1997) Long short-term memory. *Neural Computation* 9(8):1735–1780.
25. Barua R, Sharma AK (2022) Dynamic Black Litterman portfolios with views derived via CNN-BiLSTM predictions. *Finance Research Letters* 49:103111.
26. Vaswani A et al. (2017) Attention is all you need in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 5998–6008.
27. Wang C, Chen Y, Zhang S, Zhang Q (2022) Stock market index prediction using deep Transformer model. *Expert Systems with Applications* 208:118128.
28. Zhang Q et al. (2022) Transformer-based attention network for stock movement prediction. *Expert Systems with Applications* 202:117239.
29. Wu H, Xu J, Wang J, Long M (2021) Autoformer: Decomposition transformers with Auto-Correlation for long-term series forecasting in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 34, pp. 22419–22430.
30. Das A, Kong W, Sen R, Zhou Y (2024) A decoder-only foundation model for time-series forecasting in *Proceedings of the 41st International Conference on Machine Learning (ICML)*. Vol. 235, pp. 10148–10167.
31. Ye J, Zhao J, Ye K, Xu C (2021) Multi-graph convolutional network for relationship-driven stock movement prediction in 2020 *25th International Conference on Pattern Recognition (ICPR)*. pp. 6702–6709.
32. Li W et al. (2020) Modeling the stock relation with graph network for overnight stock movement prediction in *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence*. pp. 4541–4547.
33. Sawhney R, Agarwal S, Wadhwa A, Shah RR (2020) Deep attentive learning for stock movement prediction from social media text and company correlations in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. (Association for Computational Linguistics), pp. 8415–8426.
34. Cheng D, Yang F, Xiang S, Liu J (2022) Financial time series forecasting with multi-modality graph neural network. *Pattern Recognition* 121:108218.
35. Fan J, Fan Y, Lv J (2008) High dimensional covariance matrix estimation using a factor model. *Journal of Econometrics* 147(1):186–197.
36. Engle R (2002) Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics* 20(3):339–350.
37. Chiriac R, Voev V (2011) Modelling and forecasting multivariate realized volatility. *Journal of Applied Econometrics* 26(6):922–947.
38. Lin H, Zhou D, Liu W, Bian J (2021) Deep risk model: A deep learning solution for mining latent risk factors to improve covariance matrix estimation in *Proceedings of the Second ACM International Conference on AI in Finance (ICAIF)*. <https://doi.org/10.1145/3490354.3494377>.
39. Yang L, Zhao S, Chai S (2026) Neural nonlinear shrinkage of covariance matrices for minimum variance portfolio optimization (arXiv preprint arXiv:2601.15597 [q-fin.PM]). <https://doi.org/10.48550/arXiv.2601.15597>.
40. Salinas D, Bohlke-Schneider M, Callot L, Medico R, Gasthaus J (2019) High-dimensional multivariate forecasting with low-rank Gaussian copula processes in *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 32, pp. 6824–6834.
41. Kennedy J, Eberhart R (1995) Particle swarm optimization in *Proceedings of the IEEE International Conference on Neural Networks*. Vol. 4, pp. 1942–1948.
42. Cura T (2009) Particle swarm optimization approach to portfolio optimization. *Nonlinear Analysis: Real World Applications* 10(4):2396–2406.
43. Kirkpatrick S, Gelatt CD, Vecchi MP (1983) Optimization by simulated annealing. *Science* 220(4598):671–680.
44. Crama Y, Schyns M (2003) Simulated annealing for complex portfolio selection problems. *European Journal of Operational Research* 150(3):546–571.
45. Beasley JE (1990) OR-Library: Distributing test problems by electronic mail. *Journal of the Operational Research Society* 41(11):1069–1072.
46. Sharpe WF (1994) The Sharpe ratio. *The Journal of Portfolio Management* 21(1):49–58.
47. Aprea IL, Sbaiz G (2026) A neural network-particle swarm solver for sustainable portfolio optimization problems. *Decisions in Economics and Finance* 49(1):25–64.